

Universidad del Norte

Trabajo de profundización

Desigualdades socioeconómicas, étnicas y territoriales en el bajo peso al nacer en Colombia: análisis multinivel y predictivo de las estadísticas vitales, 1998–2024

Autor:

Gregory Jesús Meléndez

Supervisor:

Lihki José Rubio Ortega

*Trabajo presentado en cumplimiento de los requisitos
para el grado de Maestría en Estadística Aplicada*

Facultad de Ciencias Básicas

Departamento de Matemáticas y Estadística

August 24, 2026

Resumen

El bajo peso al nacer (BPN) es uno de los indicadores más sensibles de la salud materno-infantil y un predictor robusto de mortalidad neonatal, rezago del desarrollo infantil y enfermedad crónica en la adultez. En Colombia, país de ingreso mediano con una desigualdad marcada, la investigación nacional se ha concentrado en factores biológicos y clínicos y ha aprovechado poco el potencial de los registros poblacionales para examinar de manera integral los determinantes sociales del problema. Este estudio analizó la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia entre 1998 y 2024, a partir de los microdatos de nacimientos de las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística. Se trata de un estudio observacional, analítico, de corte transversal repetido, con estructura jerárquica de tres niveles: nacimientos anidados en municipios y municipios anidados en departamentos. La desigualdad socioeconómica se cuantificó mediante el índice de concentración con corrección de Erreygers, el índice de desigualdad de la pendiente y el índice relativo de desigualdad, y se descompuso siguiendo el procedimiento de Wagstaff, van Doorslaer y Watanabe. Los efectos independientes de cada determinante se estimaron mediante una secuencia de modelos logísticos multinivel, y la variación contextual se expresó mediante la correlación intraclase, la razón de momios mediana y el cambio proporcional en la varianza. De forma complementaria se evaluó la capacidad de identificar un nacimiento en riesgo a partir únicamente de la posición social de la madre, comparando siete modelos de clasificación supervisada: regresión logística, regresión logística con penalización lasso y ridge, árbol de decisión, bosque aleatorio, *gradient boosting* y perceptrón multicapa, con ponderación nativa de clases y selección de hiperparámetros por validación cruzada estratificada. Los intervalos de confianza de los índices de desigualdad, de las contribuciones de la descomposición y de las métricas de desempeño se obtuvieron por bootstrap no paramétrico con 1.000 réplicas. [Completar con los resultados principales una vez ejecutado el análisis: prevalencia global y por período, valor del índice de concentración, determinantes con mayor contribución, correlación intraclase departamental y conclusión sustantiva.]

Palabras clave: bajo peso al nacer, determinantes sociales de la salud, desigualdad en salud, índice de concentración, modelos multinivel, aprendizaje automático, estadísticas vitales.

Abstract: Low birth weight (LBW) is one of the most sensitive indicators of maternal and child health and a robust predictor of neonatal mortality, impaired child development, and chronic disease in adulthood. In Colombia, a middle-income country with marked inequality, national research has focused on biological and clinical factors and has made limited use of population registers to examine the social determinants of the problem in an integrated way. This study analysed the association between the social determinants of health and low birth weight in Colombia between 1998 and 2024, using birth microdata from the Vital Statistics (EEVV) of the National Administrative Department of Statistics. This is an observational, analytical, repeated cross-sectional study with a three-level hierarchical structure: births nested within municipalities and municipalities nested within departments. Socioeconomic inequality was quantified using the concentration index with Erreygers correction, the slope index of inequality and the relative index of inequality, and was decomposed following the Wagstaff, van Doorslaer and Watanabe procedure. The independent effects of each determinant were estimated through a sequence of multilevel logistic models, and contextual variation was expressed through the intraclass correlation, the median odds ratio and the proportional change in variance. Confidence intervals for the inequality indices and for the decomposition contributions were obtained through nonparametric bootstrap with 1,000 replicates. [Complete with main results.]

Keywords: low birth weight, social determinants of health, health inequality, concentration index, multilevel models, machine learning, vital statistics.

Dedicatoria

A cada niño que llega al mundo con menos de lo que merece: que esta investigación aporte, aunque sea una cifra, a la causa de una vida más justa desde el primer día.

A las familias colombianas cuyos nacimientos son mucho más que un dato en un registro: son la razón y el sentido de este trabajo.

A quienes creen que el conocimiento puede reducir las desigualdades y transformar la salud de los que menos tienen.

A la investigación, labor callada que rara vez recibe aplausos, pero sobre cuyos hombros se ha construido cada avance de la humanidad.

Y a los investigadores: a los que trabajan de noche cuando el mundo duerme, a los que insisten donde otros abandonan, a los que dedican una vida entera para que una sola verdad quede en pie.

Este esfuerzo se suma, con humildad, a esa larga cadena de manos anónimas que empujan la historia hacia adelante.

Agradecimientos

A Dios, por otorgarme la fortaleza, la sabiduría y la perseverancia necesarias para culminar con éxito este camino de formación académica.

A mi esposa, Grace Kelly, por su apoyo constante y por ser el sostén sereno que me acompañó en cada momento de este proceso.

A mis hijos, por ser el motor de amor, comprensión y apoyo incondicional en mis horas de esfuerzo, y la razón más profunda de mi superación constante. A mi familia, por su paciencia infinita, confianza y por brindarme un aliento inquebrantable en cada paso del camino.

A mis compañeros de trabajo, y a mis profesores y compañeros de maestría, por su respaldo y comprensión, y por cada conversación y aporte del que me llevo algo que dejó mejor no solo al proyecto, sino a la persona que lo escribió.

Asimismo, extendiendo mi sincero reconocimiento a todas las personas e instituciones que, de manera directa o indirecta, brindaron su colaboración y apoyo para la feliz realización de este estudio.

Contents

Resumen	i
Dedicatoria	iii
Agradecimientos	iv
Abreviaturas y siglas	xii
1 Introducción	1
1.1 Planteamiento del problema	3
1.1.1 Delimitación del objeto de estudio	4
1.1.2 La oportunidad de las Estadísticas Vitales	4
1.1.3 Pregunta general de investigación	5
1.1.4 Preguntas específicas	5
1.2 Justificación	6
1.2.1 Relevancia sanitaria	6
1.2.2 Relevancia distributiva	7
1.2.3 Relevancia metodológica	7
1.2.4 Relevancia para la política pública	7
1.2.5 Resultados esperados	8
2 Objetivos	9
2.1 Objetivo general	9
2.2 Objetivos específicos	9

3	Marco teórico	11
3.1	Determinantes sociales de la salud: marco conceptual	11
3.2	El bajo peso al nacer: definición, mecanismos y delimitación	13
3.2.1	Los dos mecanismos	13
3.2.2	Delimitación del desenlace en este estudio	14
3.2.3	El bajo peso al nacer como indicador social	14
3.3	Medidas de asociación en epidemiología	15
3.4	Análisis bivariado y colinealidad	15
3.5	Medición de la desigualdad socioeconómica en salud	16
3.6	Descomposición de la desigualdad	16
3.7	Modelos de regresión multinivel	17
3.8	Modelos de clasificación supervisada	18
3.8.1	Notación	18
3.8.2	Regresión logística	18
3.8.3	Regresión logística penalizada: Lasso	19
3.8.4	Regresión logística penalizada: Ridge	20
3.8.5	Árboles de decisión	20
3.8.6	Random Forest	21
3.8.7	Gradient boosting	22
3.8.8	Redes neuronales artificiales	23
3.8.9	Contraste jerárquico entre el modelo multinivel y el ensamble	24
3.9	Estrategia de validación y métricas de evaluación	25
3.9.1	Partición estratificada y validación cruzada	25
3.9.2	Manejo del desbalance de clases	25
3.9.3	Métricas de evaluación	26
3.10	Confusión, mediación y estrategia de modelos anidados	26
3.10.1	Confusor y mediador	27
3.10.2	Efecto total y efecto directo	28
3.10.3	Consecuencia para la estrategia de modelos anidados	28
3.11	Tratamiento de datos faltantes	29

3.11.1	Mecanismos de ausencia	29
3.11.2	Relevancia en esta fuente	29
3.11.3	Imputación múltiple por ecuaciones encadenadas	30
3.12	Estimación de intervalos de confianza por bootstrap	31
4	Metodología	32
4.1	Enfoque y diseño	32
4.2	Descripción de los datos	33
4.2.1	Fuente y período	33
4.2.2	Población y muestra	33
4.2.3	Variables del estudio	34
4.3	Preparación y depuración de los datos	36
4.3.1	Armonización de la serie 1998–2024	36
4.3.2	Consistencia y recodificación	40
4.3.3	Codificación territorial	40
4.3.4	Tratamiento de los valores faltantes	40
4.4	Análisis estadístico	41
4.4.1	Fase 1. Análisis descriptivo y de tendencia	41
4.4.2	Fase 2. Medición de la desigualdad socioeconómica	41
4.4.3	Fase 3. Modelos de regresión logística multinivel	41
4.4.4	Fase 4. Descomposición de la desigualdad	42
4.4.5	Fase 5. Análisis de sensibilidad	43
4.4.6	Fase 6. Comparación de modelos de clasificación	43
4.5	Software y reproducibilidad	47
4.6	Consideraciones éticas	47
5	Resultados	48
5.1	Análisis descriptivo	48
5.1.1	Conformación de la muestra y completitud	48
5.1.2	Distribución de la variable respuesta	48
5.1.3	Caracterización sociodemográfica de las madres	49

5.1.4	Tendencia temporal de la prevalencia, 1998–2024	49
5.1.5	Distribución territorial	50
5.2	Desigualdad socioeconómica	50
5.2.1	Prevalencia según posición socioeconómica	50
5.2.2	Índice y curva de concentración	50
5.2.3	Índice de desigualdad de la pendiente e índice relativo	50
5.2.4	Evolución de la desigualdad en el período	50
5.3	Modelos multinivel	50
5.3.1	Modelo vacío: variación municipal y departamental	50
5.3.2	Modelo 1: efecto social total	51
5.3.3	Modelo 2: efecto directo tras el ajuste por mediadores	51
5.3.4	Modelo 3: privación municipal como predictor contextual	51
5.3.5	Comparación de ajuste y cambio proporcional en la varianza	51
5.4	Descomposición de la desigualdad	51
5.4.1	Contribución de cada determinante	51
5.4.2	Elasticidades y distribución de los determinantes	51
5.5	Comparación de modelos de clasificación	51
5.5.1	Desempeño en validación cruzada	52
5.5.2	Desempeño en el conjunto de prueba	52
5.5.3	Brecha entre entrenamiento y prueba	52
5.5.4	Desempeño bajo partición temporal	52
5.5.5	Curvas ROC y precisión-sensibilidad	53
5.5.6	Importancia de variables por modelo	53
5.5.7	Matrices de confusión	53
5.5.8	Intervalos bootstrap y modelo seleccionado	53
5.5.9	Contraste jerárquico entre el ensamble y el modelo multinivel	53
5.6	Análisis de sensibilidad	53
6	Conclusiones	54
6.1	Síntesis de hallazgos	54
6.2	Respuesta a la pregunta de investigación	54

6.3	Limitaciones del estudio	54
7	Recomendaciones	56
7.1	Recomendaciones para autoridades sanitarias e instituciones	56
7.2	Recomendaciones metodológicas para los sistemas de información	56
7.3	Líneas de investigación futura	56
A	Código fuente y reproducibilidad	57
A.1	Repositorio	57
A.2	Contenido del repositorio	58
A.3	Condiciones de reproducibilidad	58
B	Diccionario consolidado de variables, 1998–2024	59
	Bibliografía	64

List of Figures

3.1	Grafo acíclico dirigido con la estructura causal supuesta. La flecha discontinua representa el efecto contextual del territorio, que los modelos multinivel de la Sección 3.7 estiman como varianza de nivel superior.	27
4.1	Evolución del número de variables del archivo de nacimientos de las Estadísticas Vitales, 1998–2024. Elaboración propia a partir de los diccionarios de datos publicados por el DANE para cada catálogo (Departamento Administrativo Nacional de Estadística, 2025).	38
5.1	Prevalencia anual de bajo peso al nacer en Colombia, 1998–2024. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025). . . .	49

List of Tables

3.1	Correspondencia entre el modelo de determinantes sociales de la salud (Solar and Irwin, 2010) y las variables del certificado de nacido vivo.	12
4.1	Conformación de la muestra analítica. Nacidos vivos registrados en las Estadísticas Vitales del DANE, 1998–2024. Los porcentajes se calculan sobre la base original.	34
4.2	Variables de exposición y su operacionalización en los microdatos de nacimientos de las EEVV.	35
4.3	Catálogos de microdatos de nacimientos publicados por el DANE y número de variables del archivo correspondiente. Elaboración propia a partir de los diccionarios de datos publicados en el portal de microdatos (Departamento Administrativo Nacional de Estadística, 2025).	37
4.4	Variables incorporadas al certificado de nacido vivo con posterioridad a 1998.	39
4.5	Variables presentes en algunos períodos y ausentes en otros.	39
5.1	Desempeño en entrenamiento y en prueba de los siete modelos de clasificación. Una brecha reducida entre ambas columnas indica ausencia de sobreajuste.	52
B.1	Equivalencia de nombres de variable por período, archivos de nacimientos de las Estadísticas Vitales del DANE.	60

Abreviaturas y siglas

AUC	Área bajo la curva ROC (<i>area under the ROC curve</i>).
BPN	Bajo peso al nacer.
CART	Árboles de clasificación y regresión (<i>classification and regression trees</i>).
CIE	Clasificación Internacional de Enfermedades.
CPV	Cambio proporcional en la varianza.
CCI	Correlación intraclase (<i>intraclass correlation coefficient</i>).
DANE	Departamento Administrativo Nacional de Estadística.
DIVIPOLA	División Político-Administrativa de Colombia.
EEVV	Estadísticas Vitales.
EPS	Entidad Promotora de Salud.
GBM	Máquina de potenciación del gradiente (<i>gradient boosting machine</i>).
F_1	Puntuación F_1 , media armónica entre precisión y sensibilidad.
IC	Índice de concentración.
IC95 %	Intervalo de confianza al 95 %.
IDP	Índice de desigualdad de la pendiente.
IRD	Índice relativo de desigualdad.
MICE	Imputación múltiple por ecuaciones encadenadas (<i>multivariate imputation by chained equations</i>).
MLP	Perceptrón multicapa (<i>multilayer perceptron</i>).

MOR	Razón de momios mediana (<i>median odds ratio</i>).
OMS	Organización Mundial de la Salud.
OR	Razón de momios (<i>odds ratio</i>).
RCIU	Restricción del crecimiento intrauterino.
RF	Bosque aleatorio (<i>random forest</i>).
ROC	Característica operativa del receptor (<i>receiver operating characteristic</i>).
RP	Razón de prevalencias.
RUAF-ND	Registro Único de Afiliados, módulo de nacimientos y defunciones.
SGSSS	Sistema General de Seguridad Social en Salud.
SIVIGILA	Sistema Nacional de Vigilancia en Salud Pública.
XGBoost	<i>Extreme gradient boosting</i> .

Chapter 1

Introducción

El bajo peso al nacer (BPN), definido por la Organización Mundial de la Salud como un peso inferior a 2.500 gramos con independencia de la edad gestacional, es uno de los indicadores más sensibles de la salud materno-infantil y un predictor robusto de mortalidad neonatal, rezago del desarrollo infantil y enfermedad crónica en la vida adulta (Okwaraji et al., 2024; Organización Mundial de la Salud, 2014). En 2020 nacieron en el mundo 19,8 millones de neonatos con BPN, el 14,7 % de los nacidos vivos, una proporción que apenas ha cedido frente al 16,6 % del año 2000 (Okwaraji et al., 2024). Ese estancamiento, documentado a partir de más de 2.000 fuentes de datos de 158 países, revela un progreso insuficiente frente a las metas mundiales de nutrición (Okwaraji et al., 2024; Blencowe et al., 2019; Organización Mundial de la Salud, 2014).

Un peso inferior a 2.500 gramos puede originarse por dos vías: el nacimiento antes de las 37 semanas de gestación y la restricción del crecimiento intrauterino (Velásquez et al., 2004; Pérez Martínez et al., 2018). Todos los factores de riesgo descritos en la literatura actúan a través de alguno de estos dos mecanismos, lo que explica la heterogeneidad etiológica del fenómeno. Entre ellos figuran las edades extremas de la vida reproductiva y los antecedentes obstétricos adversos (Pérez Martínez et al., 2018; Heredia-Olivera and Munares-García, 2016); la patología del embarazo, que aporta los riesgos de mayor magnitud, con razones de momios entre 2,85 y 4,37 para la enfermedad hipertensiva, la hemorragia del tercer trimestre y la rotura prematura de membranas (Ticona Rendón et al., 2012); la anemia gestacional, asociada a una reducción media de 420 gramos en el peso al nacer (Urdaneta Machado et al., 2015); y el tabaquismo, que resta entre 200 y 300 gramos (Pérez Martínez et al., 2018). La ganancia insuficiente de peso durante la gestación se comporta también como predictor, aunque con una precisión diagnóstica modesta en cohortes latinoamericanas (Santos-Antonio et al., 2020).

Lejos de distribuirse de manera homogénea, el BPN se concentra en los países de ingresos bajos y medianos, que aportan cerca del 91 % de los casos mundiales (Blencowe et al., 2019). Esa concentración no obedece únicamente a factores clínicos, sino en buena medida a los determinantes sociales de la salud, esto es, las condiciones en que las personas nacen, crecen, viven y trabajan (Solar and Irwin, 2010). La pertenencia étnica, la residencia rural, la escolaridad insuficiente y el bajo nivel socioeconómico operan como marcadores de riesgo perinatal (Amjad et al., 2019). Entre ellos la educación materna ocupa un lugar central: un metaanálisis en países de ingresos bajos y medianos estimó que una mayor escolaridad reduce el riesgo de BPN (OR combinado = 0,67; IC95 % [0,61; 0,74]) (Godah et al., 2021). El acceso a la atención prenatal adecuada lo disminuye igualmente (Engdaw et al., 2023), y en un análisis de 360 ciudades latinoamericanas los contextos de mayor privación social mostraron mayor prevalencia aun después de ajustar por características individuales (Rodríguez López et al., 2021).

Las consecuencias justifican la atención que recibe el indicador. En el corto plazo, la mortalidad durante el primer año de vida es catorce veces mayor en los niños con bajo peso que en los nacidos con peso normal a término (Ticona Rendón et al., 2012), y la morbilidad se acentúa en los subgrupos de muy bajo y extremo bajo peso (Castro-Delgado et al., 2016; Heredia-Olivera and Munares-García, 2016). En el largo plazo, la hipótesis del origen fetal de las enfermedades sostiene que las alteraciones nutricionales de la vida intrauterina inducen adaptaciones permanentes que se traducen en hipertensión, diabetes tipo 2 y enfermedad coronaria en la adultez (Jiménez García et al., 2017), tesis respaldada por un metaanálisis de 135 estudios con más de 7,6 millones de participantes (Knop et al., 2018) y por la cohorte del UK Biobank, donde el bajo peso al nacer se asoció con razones de riesgo de 1,23 para enfermedad cardiovascular incidente y 1,52 para accidente cerebrovascular (Huang et al., 2022). A estos desenlaces clínicos se añaden los socioeconómicos: las personas nacidas con muy bajo peso alcanzan en la adultez peores resultados en logro educativo, empleo e ingresos (Zhou et al., 2025). El BPN no es solo producto de la desigualdad social, sino que contribuye a reproducirla (Zhou et al., 2025; Pérez Martínez et al., 2018), y esas brechas perinatales se han mantenido notablemente estables a lo largo de las décadas pese a las mejoras generales en salud (Cozzani, 2023; Núñez Rivas and Morice Trejos, 1999).

En Colombia, país de ingreso mediano con alta inequidad, las prevalencias de BPN superan el promedio regional. Un análisis de más de cinco millones de nacimientos ocurridos entre 2008 y 2018 halló gradientes socioeconómicos persistentes, medidos a través de la educación materna y del régimen de afiliación al sistema de salud (Guarnizo-Herreño et al., 2021). Ese trabajo confirma que el registro censal de nacimientos es una fuente idónea

para el estudio de las inequidades perinatales, pero se concentró en el eje socioeconómico individual dentro de una ventana de once años, sin descomponer la variación geográfica del riesgo ni situar la pertenencia étnica y el área de residencia como ejes autónomos de inequidad.

Ahí se sitúa el vacío que este trabajo aborda. Las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística constituyen un registro continuo y de cobertura nacional de los nacimientos del país, con microdatos públicos disponibles de forma ininterrumpida entre 1998 y 2024 (Departamento Administrativo Nacional de Estadística, 2025). Cada registro consigna el peso al nacer junto con el nivel educativo de la madre y del padre, el régimen de afiliación al Sistema General de Seguridad Social en Salud, la pertenencia étnica, el área y el territorio de residencia, y variables asistenciales como el número de consultas prenatales. Pese a su cobertura censal, a su continuidad de más de dos décadas y a su estructura naturalmente jerárquica, con los nacimientos anidados en municipios y departamentos, estas variables rara vez se han explotado de forma conjunta y multinivel. Las herramientas para hacerlo están disponibles y probadas: los modelos multinivel separan el aporte individual del contextual (Kassie et al., 2025) y las técnicas de descomposición cuantifican qué proporción de la brecha corresponde a cada determinante (Zhang et al., 2025).

En consecuencia, esta investigación tiene como objetivo analizar la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia entre 1998 y 2024, mediante modelos multinivel aplicados a los microdatos de nacimientos del DANE, con el fin de estimar la magnitud de las desigualdades socioeconómicas, étnicas y territoriales, cuantificar la proporción de la variación atribuible al nivel departamental, describir su evolución a lo largo del período e identificar los grupos poblacionales en mayor riesgo.

1.1 Planteamiento del problema

El bajo peso al nacer es uno de los problemas de salud pública más persistentes y, al mismo tiempo, uno de los que mejor reflejan las condiciones de vida de una población. En 2020, el 14,7 % de los nacidos vivos en el mundo pesó menos de 2.500 gramos, una cifra que apenas ha cedido frente al 16,6 % del año 2000 (Okwaraji et al., 2024). Su relevancia no es menor: el BPN predice de forma robusta la mortalidad neonatal, el rezago en el desarrollo infantil y la enfermedad crónica en la adultez, con efectos que pueden prolongarse durante décadas (Okwaraji et al., 2024; Zhou et al., 2025).

El problema, sin embargo, no golpea a todos por igual. Cerca del 91 % de los casos

se concentra en países de ingresos bajos y medianos (Blencowe et al., 2019), y dentro de cada país el riesgo se distribuye siguiendo líneas sociales: la educación de la madre, su posición socioeconómica, el acceso a los servicios de salud y el entorno donde vive (Amjad et al., 2019). La evidencia es consistente. Una mayor escolaridad materna reduce el riesgo de BPN ($OR = 0,67$) (Godah et al., 2021); un control prenatal adecuado también lo disminuye (Engdaw et al., 2023); y los entornos urbanos más desfavorecidos de América Latina muestran mayores prevalencias, incluso tras ajustar por características individuales (Rodríguez López et al., 2021). Esas brechas, además, son estables en el tiempo y tienden a transmitirse entre generaciones (Zhou et al., 2025; Cozzani, 2023).

Colombia no escapa a este patrón. Es un país de ingreso mediano con una desigualdad marcada y prevalencias de BPN que superan el promedio regional. Un análisis de más de cinco millones de nacimientos ocurridos entre 2008 y 2018 evidenció desigualdades claras según la educación materna y el régimen de afiliación al sistema de salud (Guarnizo-Herreño et al., 2021). Pese a ello, buena parte de la investigación nacional se ha concentrado en factores biológicos o clínicos y ha aprovechado poco el potencial de los sistemas de información para examinar, de manera integral, los determinantes sociales del problema.

1.1.1 Delimitación del objeto de estudio

Conviene precisar el alcance del fenómeno que se estudia. El BPN resulta de dos mecanismos distintos: el nacimiento antes de las 37 semanas de gestación y la restricción del crecimiento intrauterino. Ambos comparten el desenlace (un peso inferior a 2.500 gramos) pero responden a cadenas causales diferentes, y los determinantes sociales operan sobre cada una con intensidad desigual.

El certificado de nacido vivo del DANE registra simultáneamente el peso al nacer en gramos y el tiempo de gestación en semanas, lo que permite separar analíticamente ambas vías en lugar de tratarlas como un bloque indiferenciado. Esta capacidad es una ventaja sustantiva del diseño: el desenlace principal se define como el bajo peso al nacer en el conjunto de nacidos vivos, y se estratifica en bajo peso al nacer a término (gestaciones de 37 o más semanas, atribuible a restricción del crecimiento intrauterino) y bajo peso al nacer asociado a prematuridad. La vía del crecimiento fetal es precisamente donde los determinantes sociales (nutrición materna, carga de trabajo, pobreza, acceso a control prenatal) ejercen su influencia de manera más directa, de modo que el contraste entre ambos estratos constituye en sí mismo un resultado sobre el mecanismo por el cual la posición social se inscribe en el cuerpo del recién nacido.

1.1.2 La oportunidad de las Estadísticas Vitales

Las Estadísticas Vitales del DANE presentan tres propiedades que las hacen particularmente adecuadas para esta investigación.

La primera es la cobertura censal. A diferencia de un sistema de vigilancia, que notifica casos y exige un denominador externo, las EEVV registran la totalidad de los nacidos vivos del país. Numerador y denominador provienen del mismo instrumento, lo que hace directamente estimables las prevalencias departamentales, los índices de concentración y las curvas de concentración sin necesidad de enlazar fuentes heterogéneas ni armonizar categorías entre instrumentos distintos.

La segunda es la continuidad. La serie de microdatos de nacimientos está disponible de forma ininterrumpida entre 1998 y 2024 (Departamento Administrativo Nacional de Estadística, 2025), lo que permite examinar no solo la magnitud de las desigualdades sino su evolución a lo largo de más de dos décadas, período que abarca la consolidación del Sistema General de Seguridad Social en Salud, la expansión del régimen subsidiado y transformaciones demográficas de gran alcance.

La tercera es la riqueza social del certificado de nacido vivo. Cada registro incorpora un perfil de la madre que rara vez se analiza de manera conjunta: el nivel educativo de la madre y del padre, la edad materna, el estado conyugal, el régimen de afiliación al Sistema General de Seguridad Social en Salud (contributivo, subsidiado, especial, de excepción o no asegurado), el área de residencia habitual diferenciada en cabecera municipal, centro poblado y rural disperso, la pertenencia étnica en las categorías del DANE, y el territorio de residencia a escala departamental y municipal. A ello se suman variables asistenciales que operan como indicadores directos de acceso efectivo: el número de consultas prenatales, el sitio de atención del parto, el tipo de parto y la persona que lo atendió.

Analizar estas variables de forma conjunta (y no aislada) permite dimensionar cuánto de la carga de BPN en Colombia se explica por la posición social y no solo por factores individuales, e identificar con precisión los grupos que concentran el mayor riesgo. Herramientas como los modelos multinivel y las técnicas de descomposición de la desigualdad, ya aplicadas en otros contextos (Kassie et al., 2025; Zhang et al., 2025), hacen viable ese análisis con datos poblacionales de gran escala. No hacerlo perpetúa una brecha de conocimiento con consecuencias prácticas: sin evidencia local sobre qué determinantes sociales pesan más y sobre quiénes recae la desigualdad, las políticas de salud materno-perinatal difícilmente podrán focalizarse donde más se necesitan.

1.1.3 Pregunta general de investigación

¿Cuál es la asociación entre los determinantes sociales de la salud (edad materna, nivel educativo de la madre y del padre, régimen de afiliación, estado conyugal, área de residencia, pertenencia étnica y territorio) y el bajo peso al nacer en Colombia, a partir de los microdatos de nacimientos de las Estadísticas Vitales del DANE durante el período 1998–2024?

1.1.4 Preguntas específicas

Las cinco preguntas escalan en complejidad analítica: describen, miden la desigualdad, la modelan, la descomponen y la sitúan en el territorio.

1. ¿Cuál es la magnitud y la tendencia de la prevalencia del bajo peso al nacer en Colombia entre 1998 y 2024, y cómo varía esa prevalencia entre departamentos y municipios?
2. ¿Cómo se distribuye el bajo peso al nacer según la posición socioeconómica de la madre (nivel educativo y régimen de afiliación) y qué magnitud alcanza esa desigualdad al cuantificarla mediante índices y curvas de concentración?
3. ¿Qué determinantes sociales se asocian de forma independiente con el bajo peso al nacer, una vez ajustado el modelo por edad materna, paridad y multiplicidad del embarazo?
4. ¿Qué proporción de la brecha socioeconómica observada es atribuible a cada determinante social, según la descomposición del índice de concentración?
5. ¿Qué proporción de la variación del bajo peso al nacer corresponde al nivel municipal y departamental, y persiste esa variación contextual después de ajustar por la composición socioeconómica individual de las madres?

1.2 Justificación

El bajo peso al nacer reúne tres condiciones que rara vez coinciden en un mismo indicador: es frecuente, tiene consecuencias graves y prolongadas, y una parte sustancial de su distribución responde a causas socialmente modificables. Esa combinación es la que justifica destinarle un trabajo de investigación. A continuación se exponen las cuatro razones que sostienen la pertinencia del estudio y los productos concretos que se espera obtener.

1.2.1 Relevancia sanitaria

El BPN es el principal predictor de la mortalidad infantil: el riesgo de morir durante el primer año de vida es catorce veces mayor en un recién nacido de bajo peso que en uno de peso normal a término (Ticona Rendón et al., 2012). Su efecto no se agota en la infancia. La evidencia acumulada sobre la programación fetal muestra que las carencias nutricionales de la vida intrauterina dejan una huella permanente que se expresa décadas después en hipertensión, diabetes tipo 2 y enfermedad coronaria (Jiménez García et al., 2017; Knop et al., 2018; Huang et al., 2022). Cada nacimiento con bajo peso representa, por tanto, un riesgo inmediato de muerte y una carga diferida de enfermedad crónica sobre el sistema de salud. Reducir su prevalencia produce beneficios sanitarios que se extienden a lo largo de toda la vida de la persona.

1.2.2 Relevancia distributiva

El segundo argumento es de equidad. El BPN no se distribuye al azar: se concentra en los hogares de menor escolaridad, menor aseguramiento y peor acceso a los servicios de salud (Amjad et al., 2019; Godah et al., 2021; Guarnizo-Herreño et al., 2021). Y la relación opera en ambos sentidos. Quienes nacen con bajo peso alcanzan en la adultez peores resultados en logro educativo, empleo e ingresos (Zhou et al., 2025), de modo que la desventaja social que produjo el bajo peso vuelve a producirse en la generación siguiente. El indicador señala así un punto donde la desigualdad se transmite entre generaciones, y la comparación de cohortes británicas muestra que esas brechas perinatales permanecen prácticamente inalteradas a lo largo de las décadas pese a las mejoras generales en salud (Cozzani, 2023). Intervenir sobre el bajo peso al nacer no es solo una acción sanitaria: es una intervención sobre el mecanismo que reproduce la desigualdad.

1.2.3 Relevancia metodológica

Colombia dispone de un registro censal de nacimientos con veintisiete años de continuidad, acceso público y un conjunto de variables sociales que pocos sistemas de información reúnen en un mismo instrumento (Departamento Administrativo Nacional de Estadística, 2025). Ese activo está infrautilizado. La investigación nacional sobre bajo peso al nacer se ha apoyado mayoritariamente en series hospitalarias y en diseños de casos y controles, cuyo alcance es local y cuyo poder para estimar desigualdades poblacionales es limitado. El antecedente nacional más próximo (Guarnizo-Herreño et al., 2021) demostró el valor de la fuente, pero abarcó once años y no descompuso la variación territorial.

Este trabajo aporta tres elementos metodológicos. Primero, extiende la serie a 1998–2024, lo que permite examinar no solo la magnitud de la desigualdad sino su evolución a lo largo de un período que abarca la consolidación del Sistema General de Seguridad Social en Salud y la expansión del régimen subsidiado. Segundo, adopta una especificación multinivel que separa el aporte individual del contextual, en lugar de tratar el territorio como una covariable más. Y tercero, entrega una consolidación documentada de los trece diccionarios de datos del período, que constituye por sí sola un insumo reutilizable por otros investigadores.

1.2.4 Relevancia para la política pública

Saber que existe desigualdad no basta para actuar sobre ella. Una política de focalización necesita respuestas a tres preguntas operativas: cuánta desigualdad hay, sobre quiénes recae y qué proporción de esa brecha aporta cada determinante. El índice de concentración responde a la primera, la estratificación por grupos a la segunda y la descomposición de Wagstaff a la tercera (Wagstaff et al., 2003). Los resultados se traducen directamente en criterios de priorización: qué departamentos concentran el exceso de riesgo, qué grupos poblacionales requieren atención diferencial y sobre qué determinante conviene intervenir primero para obtener la mayor reducción de la brecha.

La medición de la variación territorial tiene además una implicación práctica inmediata. Si la desigualdad entre departamentos persiste después de ajustar por la composición social de sus habitantes, el problema no reside únicamente en quién vive allí sino en las características del territorio, y la respuesta debe dirigirse a la oferta institucional y no solo a los individuos.

1.2.5 Resultados esperados

Al término del estudio se espera disponer de:

1. Una serie continua y armonizada de la prevalencia de bajo peso al nacer en Colombia entre 1998 y 2024, desagregada por departamento y municipio.
2. Una estimación de la magnitud de la desigualdad socioeconómica mediante el índice de concentración y su evolución en el período.
3. La cuantificación de la contribución de cada determinante social a esa desigualdad.

4. La proporción de la variación del bajo peso al nacer atribuible al nivel departamental y municipal, con la identificación de los territorios que concentran el exceso de riesgo.
5. La identificación de los grupos poblacionales en mayor riesgo, como insumo para la focalización de programas materno-perinatales.
6. Un conjunto de rutinas de procesamiento y análisis documentadas y reproducibles, junto con la consolidación de los diccionarios de datos de la serie.

Chapter 2

Objetivos

2.1 Objetivo general

Analizar la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia durante el período 1998–2024, mediante modelos multinivel aplicados a los microdatos de nacimientos de las Estadísticas Vitales del Departamento Administrativo Nacional de Estadística, con el fin de estimar la magnitud de las desigualdades socioeconómicas, étnicas y territoriales e identificar los grupos poblacionales en mayor riesgo.

2.2 Objetivos específicos

1. Estimar la magnitud y la tendencia de la prevalencia del bajo peso al nacer en Colombia entre 1998 y 2024, y describir su variación entre departamentos y municipios.
2. Cuantificar la desigualdad socioeconómica en el bajo peso al nacer mediante el índice de concentración, el índice de desigualdad de la pendiente y el índice relativo de desigualdad, empleando el nivel educativo materno y el régimen de afiliación como ejes de ordenamiento social.
3. Estimar el efecto independiente de cada determinante social sobre el bajo peso al nacer mediante modelos de regresión logística multinivel, ajustados por edad materna, paridad y multiplicidad del embarazo.
4. Descomponer el índice de concentración en las contribuciones de cada determinante social, con el fin de establecer qué proporción de la brecha socioeconómica es atribuible

a cada uno.

5. Determinar la proporción de la variación del bajo peso al nacer atribuible a los niveles municipal y departamental, y evaluar si esa variación contextual persiste después de ajustar por la composición socioeconómica individual de las madres.

Chapter 3

Marco teórico

Este capítulo desarrolla los fundamentos conceptuales y estadísticos sobre los que se apoya la estrategia analítica descrita en el Capítulo 4. Cada sección sostiene una fase concreta del análisis: no hay apartado sin uso ni fase sin fundamento.

3.1 Determinantes sociales de la salud: marco conceptual

El marco conceptual que ordena este trabajo es el propuesto por la Comisión sobre Determinantes Sociales de la Salud de la Organización Mundial de la Salud (Comisión sobre Determinantes Sociales de la Salud, 2008), en la formulación operativa de Solar e Irwin (Solar and Irwin, 2010). Su tesis central es que la distribución desigual de la enfermedad no es un accidente ni el agregado de decisiones individuales, sino el resultado previsible de la forma en que una sociedad organiza el acceso al poder, al dinero y a los recursos.

El modelo distingue dos niveles de determinación. Los *determinantes estructurales* son los mecanismos que generan estratificación social y asignan a cada persona una posición dentro de la jerarquía: el contexto socioeconómico y político, y los ejes que definen esa posición, esto es, la educación, la ocupación, el ingreso, el género y la adscripción étnica. Los *determinantes intermedios* son las condiciones concretas a través de las cuales esa posición se traduce en salud o enfermedad: las circunstancias materiales de la vivienda y el entorno, los factores conductuales y biológicos, los factores psicosociales y el acceso al sistema de salud (Solar and Irwin, 2010).

La distinción no es una taxonomía descriptiva sino una hipótesis causal, y de ella se

derivan tres consecuencias que atraviesan el diseño de este estudio.

La primera es que los determinantes estructurales anteceden causalmente a los intermedios. La educación de la madre no compite con su estado nutricional por explicar el bajo peso al nacer: lo antecede y opera a través de él. Esta jerarquía es la que justifica que las variables del embarazo se traten como mediadores y no como factores de confusión, argumento que se desarrolla en la Sección 3.10.

La segunda es que la posición socioeconómica no es una variable sino un constructo, y ninguna variable observada la mide por completo. En el certificado de nacido vivo, el nivel educativo de la madre y del padre y el régimen de afiliación al Sistema General de Seguridad Social en Salud operan como indicadores parciales de esa posición: el primero capta el componente de capital cultural y credencial, y el segundo, el de inserción laboral formal, dado que la afiliación al régimen contributivo está condicionada por el empleo remunerado. Ninguno mide el ingreso, que no se registra en la fuente.

La tercera es que el territorio no es un simple contenedor. La residencia en un municipio rural disperso no es solo un atributo individual: implica una oferta institucional, una distancia efectiva a los servicios y una composición social del entorno que actúan sobre todos sus habitantes con independencia de sus características personales. Esta doble naturaleza, individual y contextual, es la que exige la estructura jerárquica de los modelos de la Sección 3.7.

El Cuadro 3.1 traduce el modelo a las variables efectivamente disponibles en la fuente.

Table 3.1: Correspondencia entre el modelo de determinantes sociales de la salud (Solar and Irwin, 2010) y las variables del certificado de nacido vivo.

Nivel	Dimensión del modelo	Variable disponible
Determinantes estructurales	Educación	Nivel educativo de la madre y del padre
	Inserción laboral e ingreso	Régimen de afiliación al SGSSS (indicador parcial)
	Adscripción étnica	Pertenencia étnica del nacido vivo
	Territorio y contexto	Departamento, municipio y área de residencia
Determinantes intermedios	Acceso a servicios de salud	Número de consultas prenatales, sitio y tipo de parto, persona que atendió el parto
	Factores biológicos	Edad materna, paridad, multiplicidad del embarazo
Desenlace	Equidad en salud	Bajo peso al nacer

Conviene señalar de forma explícita qué queda fuera. El modelo contempla las circunstancias materiales de la vivienda, los factores psicosociales, la cohesión social y las

conductas relacionadas con la salud, ninguno de los cuales se registra en el certificado de nacido vivo. Tampoco se recogen el ingreso del hogar ni el estado nutricional materno. El estudio no puede, por tanto, verificar la cadena causal completa: estima la asociación entre la posición social y el desenlace, y observa cuánto de esa asociación transcurre por las dos vías intermedias que sí resultan observables, el acceso a la atención prenatal y los factores biológicos del embarazo.

3.2 El bajo peso al nacer: definición, mecanismos y delimitación

La Organización Mundial de la Salud define el bajo peso al nacer como un peso inferior a 2.500 gramos medido dentro de la primera hora de vida, con independencia de la edad gestacional (Organización Mundial de la Salud, 2014). El umbral no corresponde a un punto de inflexión biológico sino a un consenso epidemiológico: por debajo de esa cifra el riesgo de mortalidad neonatal y de morbilidad se eleva de manera apreciable, y su estabilidad a lo largo del tiempo y entre países es lo que permite la comparación internacional.

La definición admite dos gradaciones de severidad de uso corriente: el muy bajo peso al nacer, inferior a 1.500 gramos, y el extremo bajo peso, inferior a 1.000 gramos, subgrupos en los que la morbilidad y la mortalidad se acentúan de forma marcada (Castro-Delgado et al., 2016).

3.2.1 Los dos mecanismos

Un peso inferior a 2.500 gramos puede originarse por dos vías distintas, que pueden presentarse de forma aislada o combinada (Velásquez et al., 2004; Pérez Martínez et al., 2018).

La primera es el **parto pretérmino**: el nacimiento ocurre antes de las 37 semanas completas de gestación y el recién nacido pesa poco porque ha dispuesto de menos tiempo para crecer. Su peso puede ser enteramente adecuado para su edad gestacional. Los factores que anteceden a esta vía son predominantemente clínicos y obstétricos: rotura prematura de membranas, infección, enfermedad hipertensiva del embarazo, gestación múltiple y antecedente de prematuridad.

La segunda es la **restricción del crecimiento intrauterino**: la gestación alcanza el término, pero el feto no logra el peso esperado para su edad gestacional. Aquí el peso insuficiente refleja un déficit acumulado de aporte de nutrientes y oxígeno a lo largo del

embarazo, cuyos antecedentes son en buena medida nutricionales y ambientales: desnutrición materna, anemia, carga física de trabajo, tabaquismo, y una atención prenatal tardía o insuficiente que impide detectar y corregir el problema a tiempo.

La distinción importa porque los determinantes sociales no operan con igual intensidad sobre ambas vías. La pobreza, la escolaridad insuficiente y la falta de acceso oportuno a los servicios de salud actúan sobre el crecimiento fetal de forma directa y sostenida, a través de la alimentación, del esfuerzo físico y del control del embarazo. Sobre la prematuridad su influencia es más indirecta, mediada por cuadros clínicos cuya aparición depende también de factores que la posición social no determina. Cabe esperar, por tanto, que el gradiente social sea más pronunciado en el bajo peso al nacer a término que en el asociado a prematuridad, y ese contraste constituye en sí mismo una hipótesis verificable sobre el mecanismo.

3.2.2 Delimitación del desenlace en este estudio

El certificado de nacido vivo registra simultáneamente el peso y el tiempo de gestación, lo que permite separar analíticamente ambas vías en lugar de tratarlas como un bloque indiferenciado. El desenlace principal se define sobre el conjunto de nacidos vivos y se estratifica después por edad gestacional, de modo que el contraste entre los dos estratos se convierte en un resultado y no en un supuesto.

Esta estratificación está condicionada por la forma en que la fuente registra el tiempo de gestación, cuestión que se aborda en la Sección 4.3.1. Conviene anticipar aquí que las categorías publicadas no permiten situar el corte exactamente en las 37 semanas, lo que obliga a adoptar un umbral operativo y a declararlo como limitación.

3.2.3 El bajo peso al nacer como indicador social

Más allá de su significado clínico, el bajo peso al nacer se emplea como indicador sintético de las condiciones de vida de una población y de la capacidad de respuesta de su sistema de salud (Núñez Rivas and Morice Trejos, 1999). Tres propiedades lo hacen particularmente útil para ese fin. Se registra de forma universal y con un instrumento estandarizado, lo que permite comparaciones consistentes entre territorios y a lo largo del tiempo. Su medición es objetiva y no depende del juicio del observador. Y condensa, en una sola cifra disponible en el momento del nacimiento, la historia acumulada de nueve meses de exposición material y social de la madre.

3.3 Medidas de asociación en epidemiología

La razón de momios (*odds ratio*) es la medida de asociación que arrojan de forma natural los modelos logísticos. Cuando el desenlace no es raro, la razón de momios sobrestima sistemáticamente la razón de prevalencias, por lo que su interpretación exige cautela y, cuando corresponde, la estimación complementaria de razones de prevalencia (Barros and Hirakata, 2003).

El intervalo de confianza de la razón de momios se obtiene por el método de Woolf, a partir del error estándar del logaritmo del momio. Para una tabla de contingencia 2×2 con celdas a , b , c y d :

$$SE[\ln(OR)] = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}} \quad (3.1)$$

$$IC_{95\%} = \exp[\ln(OR) \pm 1,96 \cdot SE(\ln(OR))] \quad (3.2)$$

Ante frecuencias nulas en alguna celda (situación previsible en municipios de baja población y en categorías étnicas de frecuencia reducida) se aplica la corrección de Haldane-Anscombe, que consiste en sumar 0,5 a cada celda antes del cálculo.

3.4 Análisis bivariado y colinealidad

La independencia entre cada determinante y el desenlace se evalúa mediante la prueba χ^2 de Pearson. Dado que el estadístico χ^2 crece con el tamaño de muestra y resulta significativo de forma trivial en bases de gran escala, la fuerza de la asociación se cuantifica mediante el coeficiente V de Cramér, que normaliza el estadístico entre 0 y 1:

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r - 1, c - 1)}} \quad (3.3)$$

donde n es el número de observaciones y r y c son el número de filas y columnas de la tabla de contingencia.

La matriz de V de Cramér entre determinantes cumple aquí una función de diagnóstico de colinealidad, no de redundancia predictiva. El régimen de afiliación, el nivel educativo y el área de residencia están conceptual y empíricamente correlacionados entre sí, de modo que conviene complementar V con el factor de inflación de la varianza generalizado,

apropiado para variables categóricas de más de dos niveles. La decisión de excluir un determinante no debe ser estadística sino conceptual: si dos variables miden la misma dimensión social, se elige la de mejor completitud y se declara explícitamente.

3.5 Medición de la desigualdad socioeconómica en salud

El índice de concentración resume la asociación entre un desenlace de salud y la posición socioeconómica ordenada de la población. Se define como el doble de la covarianza entre el desenlace y el rango fraccional socioeconómico, dividida por la media del desenlace (Kakwani et al., 1997):

$$IC = \frac{2}{\mu} \text{cov}(y, R) \quad (3.4)$$

donde y es el desenlace, R el rango fraccional de la posición socioeconómica y μ la media del desenlace. El índice toma valores en $[-1, 1]$: valores negativos indican concentración del desenlace entre los grupos de menor posición social.

Cuando el desenlace es binario, los límites del índice dependen de la media y dejan de ser ± 1 , lo que impide comparar poblaciones con prevalencias distintas (Wagstaff, 2005). Se emplean dos correcciones. La normalización de Wagstaff divide el índice por $(1 - \mu)$ (Wagstaff, 2005). La de Erreygers lo multiplica por cuatro veces la media, restableciendo las propiedades de invariancia del indicador (Erreygers, 2009):

$$E(y) = 4\mu \cdot IC \quad (3.5)$$

Se incorporan además dos medidas basadas en regresión sobre el rango fraccional: el índice de desigualdad de la pendiente, que expresa la diferencia absoluta de prevalencia entre los extremos de la jerarquía social, y el índice relativo de desigualdad, que expresa esa misma diferencia como razón. La curva de concentración acompaña gráficamente a los tres indicadores.

3.6 Descomposición de la desigualdad

La descomposición propuesta por Wagstaff, van Doorslaer y Watanabe aprovecha la linealidad del índice de concentración para expresarlo como la suma de las contribuciones

de cada determinante, más un residuo no explicado (Wagstaff et al., 2003):

$$IC = \sum_k \left(\frac{\beta_k \bar{x}_k}{\mu} \right) IC_k + \frac{GC_\varepsilon}{\mu} \quad (3.6)$$

donde el término entre paréntesis es la elasticidad del desenlace respecto del determinante k , IC_k es el índice de concentración de ese determinante y GC_ε es el índice de concentración generalizado del residuo.

El punto conceptual decisivo es que la contribución de un determinante depende de dos factores simultáneos: su elasticidad, es decir cuánto aumenta el riesgo, y su propia distribución desigual entre grupos socioeconómicos (Wagstaff et al., 2003). Un factor de riesgo potente que se distribuya de forma homogénea en la población no genera inequidad. El procedimiento ha sido aplicado al bajo peso al nacer en estudios recientes (Alam et al., 2022; Sathi et al., 2022; Zhang et al., 2025).

3.7 Modelos de regresión multinivel

Los datos de nacimientos presentan una estructura jerárquica: cada nacimiento ocurre en un municipio y cada municipio pertenece a un departamento. Ignorar esa estructura viola el supuesto de independencia de las observaciones y subestima los errores estándar. Los modelos de efectos aleatorios incorporan la jerarquía de forma explícita y permiten descomponer la varianza total del desenlace entre los distintos niveles.

Tres medidas traducen la varianza de nivel superior a cantidades interpretables (Merlo et al., 2006). La correlación intraclase expresa la proporción de la varianza total atribuible al nivel territorial; en el modelo logístico, donde la varianza de nivel individual se fija en $\pi^2/3$:

$$CCI = \frac{\sigma_u^2}{\sigma_u^2 + \pi^2/3} \quad (3.7)$$

La razón de momios mediana traduce la heterogeneidad contextual a la escala de los momios, lo que la hace directamente comparable con los coeficientes de las variables individuales:

$$MOR = \exp\left(\sqrt{2\sigma_u^2} \cdot 0,6745\right) \quad (3.8)$$

El cambio proporcional en la varianza indica qué proporción de la varianza territorial

queda explicada al añadir covariables individuales, es decir, cuánto de la diferencia entre municipios se debe a su composición social y no a un efecto contextual propio:

$$\text{CPV} = \frac{\sigma_{u(\text{vacío})}^2 - \sigma_{u(\text{ajustado})}^2}{\sigma_{u(\text{vacío})}^2} \times 100 \quad (3.9)$$

La estimación se realiza por máxima verosimilitud con aproximación de Laplace, y la comparación entre modelos anidados se apoya en el criterio de información de Akaike y el criterio bayesiano de Schwarz. El procedimiento ha sido aplicado al bajo peso al nacer tanto en encuestas nacionales (Kassie et al., 2025) como en contextos urbanos latinoamericanos (Rodríguez López et al., 2021).

3.8 Modelos de clasificación supervisada

El aprendizaje supervisado consiste en aprender una función que asocia un vector de características $\mathbf{x} = (x_1, x_2, \dots, x_p)$ con una variable respuesta Y , a partir de un conjunto de pares $(\mathbf{x}_i, y_i)$ etiquetados (Hastie et al., 2009). En este estudio Y es binaria (presencia o ausencia de bajo peso al nacer) y los predictores son los determinantes sociales de la madre registrados en el certificado de nacido vivo.

Este componente del análisis persigue un objetivo distinto del de los modelos multinivel de la Sección 3.7. Allí el propósito es explicativo: estimar la magnitud del efecto social y descomponer la desigualdad. Aquí es predictivo: establecer con qué anticipación puede identificarse un nacimiento en riesgo a partir únicamente de la posición social de la madre, y determinar si la introducción de no linealidades e interacciones aporta capacidad predictiva real o si la regresión logística captura ya la mayor parte de la señal. Los siete algoritmos se describen a continuación, ordenados por complejidad creciente.

3.8.1 Notación

En lo que sigue, $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ denota el vector de determinantes sociales del nacimiento i ; $y_i \in \{0, 1\}$ indica la presencia de bajo peso al nacer; $\hat{p}_i$ es la probabilidad estimada de que $y_i = 1$; N es el número de observaciones y p el de predictores. Todos los modelos se ajustan sobre el conjunto de entrenamiento y se evalúan sobre el de prueba, según el procedimiento de la Sección 3.9.

3.8.2 Regresión logística

La regresión logística modela la probabilidad de pertenencia a la clase positiva mediante la función sigmoide aplicada a un predictor lineal (Hosmer et al., 2013):

$$P(y_i = 1 \mid \mathbf{x}_i) = \hat{p}_i = \frac{1}{1 + e^{-(\beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta})}} \quad (3.10)$$

donde β_0 es el intercepto y $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$ el vector de coeficientes. Estos se estiman por máxima verosimilitud, lo que equivale a minimizar la entropía cruzada binaria, también llamada pérdida logarítmica:

$$\min_{\beta_0, \boldsymbol{\beta}} -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (3.11)$$

El modelo asume una relación lineal entre los predictores y el logaritmo de la razón de momios, e independencia de las observaciones. Su principal ventaja es la interpretabilidad: cada coeficiente es el cambio en el *log-odds* asociado a la presencia del factor, y $\exp(\beta_j)$ es la razón de momios del predictor x_j , que es la medida de asociación descrita en la Sección 3.3.

Se utiliza como modelo de referencia por tres razones. Por su uso establecido en epidemiología, donde la razón de momios es la métrica estándar de asociación. Porque es el modelo que sostiene la descomposición del índice de concentración de la Sección 3.6, de modo que su ajuste es necesario con independencia del ejercicio predictivo. Y porque el contraste con modelos más flexibles permite evaluar si la estructura social del riesgo es esencialmente aditiva.

3.8.3 Regresión logística penalizada: Lasso

Cuando los predictores son numerosos o están correlacionados entre sí, la estimación por máxima verosimilitud produce coeficientes inestables y de varianza elevada. La regularización añade a la función objetivo un término que penaliza la magnitud de los coeficientes.

La penalización *lasso* (*least absolute shrinkage and selection operator*), propuesta por Tibshirani (Tibshirani, 1996), emplea la norma L_1 . Partiendo de la misma función de probabilidad (3.10), el problema de optimización es

$$\min_{\beta_0, \boldsymbol{\beta}} \left[-\frac{1}{N} \sum_{i=1}^N \left(y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right) + \lambda \sum_{j=1}^p |\beta_j| \right] \quad (3.12)$$

donde $\lambda \geq 0$ regula la intensidad de la penalización y se selecciona por validación cruzada. Con $\lambda = 0$ se recupera la regresión logística sin penalizar; a medida que λ crece, los coeficientes se contraen hacia cero.

La propiedad distintiva de la norma L_1 es que su punto no diferenciable en el origen lleva algunos coeficientes *exactamente* a cero, de modo que el lasso realiza selección de variables de forma automática. Esto resulta pertinente aquí porque el conjunto de determinantes sociales incluye variables conceptualmente solapadas, como el régimen de afiliación, el nivel educativo y el área de residencia, cuya colinealidad se diagnostica en la Sección 3.4.

3.8.4 Regresión logística penalizada: Ridge

La regresión *ridge*, introducida por Hoerl y Kennard (Hoerl and Kennard, 1970), penaliza la norma L_2 , es decir, la suma de los cuadrados de los coeficientes:

$$\min_{\beta_0, \beta} \left[-\frac{1}{N} \sum_{i=1}^N \left(y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right) + \lambda \sum_{j=1}^p \beta_j^2 \right] \quad (3.13)$$

A diferencia del lasso, la penalización cuadrática es diferenciable en todo el dominio y contrae los coeficientes hacia cero sin anularlos, por lo que conserva todas las variables en el modelo. En ambos casos la penalización se aplica a β pero no al intercepto β_0 , y exige estandarizar previamente los predictores, ya que su magnitud depende de la escala.

Ridge es preferible cuando se asume que muchos predictores contribuyen de forma pequeña pero real, situación verosímil en el estudio de determinantes sociales, donde la desventaja se acumula a través de múltiples dimensiones simultáneas en lugar de concentrarse en una sola. El contraste entre ambas penalizaciones es, por tanto, informativo en sí mismo: si el lasso anula gran parte de los determinantes sin pérdida de desempeño, la desigualdad se concentra en pocos ejes; si ridge resulta superior, la desventaja es difusa y acumulativa.

3.8.5 Árboles de decisión

Un árbol de decisión particiona recursivamente el espacio de predictores en M regiones disjuntas $R_1, \dots, R_M$ y asigna a cada una un valor constante (Breiman et al., 1984). La función de predicción es, por tanto, una función escalonada:

$$\hat{f}(\mathbf{x}) = \sum_{m=1}^M c_m I(\mathbf{x} \in R_m) \quad (3.14)$$

donde c_m es el valor asignado a la región R_m e $I(\cdot)$ es la función indicadora. En clasificación, c_m es la clase mayoritaria de la región o, si se requiere una probabilidad, la proporción de casos positivos que contiene.

La construcción del árbol procede de forma voraz: en cada nodo se elige la variable y el punto de corte que producen la mayor reducción de impureza. Los criterios habituales son el índice de Gini y la entropía. Para un nodo con K clases y proporciones p_k :

$$G = 1 - \sum_{k=1}^K p_k^2 \quad (3.15)$$

$$H = - \sum_{k=1}^K p_k \log_2(p_k) \quad (3.16)$$

Ambos alcanzan su máximo cuando las clases están equilibradas en el nodo y valen cero cuando el nodo es puro. Sus resultados suelen ser muy similares; en este trabajo se emplea el índice de Gini, que es computacionalmente más económico al no requerir el cálculo de logaritmos. Para completar la exposición cabe señalar que, en problemas de regresión, el criterio equivalente es el error cuadrático medio dentro de cada región,

$$\text{MSE} = \frac{1}{N_m} \sum_{i \in R_m} (y_i - \hat{y}_{R_m})^2 \quad (3.17)$$

aunque no se utiliza aquí, dado que el desenlace de este estudio es binario.

El árbol de decisión captura interacciones entre predictores sin necesidad de especificarlas y genera reglas legibles, lo que facilita la comunicación de los resultados a audiencias no técnicas. Su limitación es la inestabilidad: pequeñas variaciones en los datos pueden producir estructuras muy distintas, y un árbol sin restricciones sobreajusta con facilidad. Por ello se controlan la profundidad máxima y el número mínimo de observaciones por hoja.

3.8.6 Random Forest

Random Forest es un método de ensamble basado en *bagging* (*bootstrap aggregating*), propuesto por Breiman (Breiman, 2001). El algoritmo construye B árboles $T_1, \dots, T_B$, cada uno entrenado sobre una muestra bootstrap distinta del conjunto de entrenamiento. La segunda fuente de aleatoriedad es decisiva: en cada división de un nodo se considera únicamente un subconjunto aleatorio de $m < p$ variables predictoras, lo que descorrelaciona los árboles entre sí y reduce la varianza del ensamble más de lo que lograría el

remuestreo por sí solo.

En clasificación, la predicción se obtiene por voto de mayoría:

$$\hat{C}_{\text{rf}}^B(\mathbf{x}) = \text{Moda} \{T_b(\mathbf{x})\}_{b=1}^B \quad (3.18)$$

y en regresión, por promedio de las predicciones individuales:

$$\hat{f}_{\text{rf}}^B(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (3.19)$$

En este estudio se emplea la formulación de clasificación (3.18). La expresión (3.19) se aplica de forma análoga cuando el ensamble se utiliza para promediar las probabilidades estimadas por cada árbol, procedimiento preferible al voto de mayoría cuando interesa una probabilidad calibrada y no solo una etiqueta.

Random Forest captura interacciones no lineales sin necesidad de especificarlas, es robusto frente a variables irrelevantes y proporciona una medida nativa de importancia de variables mediante la reducción promedio de impureza de Gini (3.15) acumulada en los nodos de todos los árboles. Su desempeño es competitivo en una amplia variedad de problemas con datos tabulares.

3.8.7 Gradient boosting

El *gradient boosting* es, como Random Forest, un método de ensamble de árboles, pero los construye de forma secuencial y no independiente (Chen and Guestrin, 2016). Cada árbol nuevo se entrena para corregir los errores residuales del ensamble acumulado hasta ese punto, de modo que el modelo reduce el sesgo por adición sucesiva en lugar de reducir la varianza por promediado.

En la iteración t , el algoritmo minimiza una función objetivo que combina una pérdida diferenciable con un término de regularización sobre la complejidad del árbol añadido:

$$\mathcal{L}^{(t)} = \sum_{i=1}^N \ell(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t) \quad (3.20)$$

donde $\hat{y}_i^{(t-1)}$ es la predicción acumulada tras $t - 1$ iteraciones, f_t es el árbol añadido en la iteración t y $\Omega(f_t)$ penaliza el número de hojas y la magnitud de los pesos mediante normas L_1 y L_2 . Para el desenlace binario de este estudio, ℓ es la entropía cruzada de la Ecuación (3.11). La tasa de aprendizaje controla la contribución de cada árbol al ensamble

y actúa como mecanismo adicional de regularización.

Su inclusión responde a una razón concreta: en problemas de clasificación sobre datos tabulares, el *gradient boosting* es hoy el punto de referencia frente al cual se juzga cualquier comparación de modelos, y su ausencia dejaría incompleto el contraste entre la regresión logística y las alternativas no lineales. A diferencia del bosque aleatorio, que promedia árboles profundos e independientes, el *boosting* combina árboles poco profundos y dependientes entre sí, lo que suele traducirse en mejor desempeño sobre datos tabulares a costa de una mayor sensibilidad a los hiperparámetros y de un riesgo de sobreajuste que exige control explícito.

3.8.8 Redes neuronales artificiales

El perceptrón multicapa es una red de propagación hacia adelante compuesta por una capa de entrada, una o más capas ocultas y una capa de salida (Goodfellow et al., 2016). Cada neurona j de la capa l calcula una combinación lineal de las activaciones de la capa anterior y le aplica una función de activación no lineal $g(\cdot)$:

$$a_j^{(l)} = g(z_j^{(l)}) = g\left(\sum_i w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)}\right) \quad (3.21)$$

donde $w_{ji}^{(l)}$ es el peso que conecta la neurona i de la capa $l-1$ con la neurona j de la capa l , y $b_j^{(l)}$ es su sesgo. En notación matricial, la red completa de L capas se expresa como la composición

$$\hat{\mathbf{y}} = g_{\text{out}}\left(\mathbf{W}^{(L)} g_{L-1}\left(\cdots g_1\left(\mathbf{W}^{(1)} \mathbf{x} + \mathbf{b}^{(1)}\right) \cdots\right) + \mathbf{b}^{(L)}\right) \quad (3.22)$$

con $\mathbf{a}^{(0)} = \mathbf{x}$. La función de activación de las capas ocultas es la unidad lineal rectificada, $g(z) = \max(0, z)$, y la de salida es la sigmoide $g_{\text{out}}(z) = (1 + e^{-z})^{-1}$, que devuelve una probabilidad. Los parámetros $\mathbf{W}$ y $\mathbf{b}$ se estiman minimizando la entropía cruzada binaria

$$\mathcal{L}(\mathbf{W}, \mathbf{b}) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \quad (3.23)$$

mediante descenso de gradiente estocástico, calculando las derivadas parciales por retro-propagación del error.

Conviene notar que una red sin capas ocultas y con activación sigmoide en la salida es exactamente la regresión logística (3.10), y que su función de pérdida (3.23) coincide con

(3.11). Las capas ocultas son, por tanto, lo único que añade capacidad de representación no lineal: la comparación entre ambos modelos aísla el aporte de esa flexibilidad.

La red neuronal representa el extremo de mayor flexibilidad del conjunto comparado. Puede aproximar relaciones de forma arbitraria, pero a costa de la interpretabilidad y de una mayor sensibilidad a la escala de los predictores, al tamaño de la muestra y a la elección de hiperparámetros. Su inclusión permite establecer un techo empírico de capacidad predictiva: si un modelo de esta flexibilidad no supera a la regresión logística, puede concluirse que la relación entre posición social y bajo peso al nacer es esencialmente aditiva y que la complejidad algorítmica no aporta información adicional.

3.8.9 Contraste jerárquico entre el modelo multinivel y el ensamble

Los modelos de clasificación descritos hasta aquí tratan cada nacimiento como una observación independiente, supuesto que la Sección 3.7 rechaza de forma explícita para el componente explicativo. Esta asimetría no es inocua: si la dependencia territorial es sustantiva, un modelo predictivo que la ignore está desaprovechando estructura que el propio marco teórico ya justificó.

Para ponerlos en relación se ajusta el modelo de *gradient boosting* incorporando el departamento de residencia como variable categórica codificada, y se comparan las medidas de agrupamiento territorial que produce frente a las del modelo logístico multinivel clásico. El contraste se articula en tres cantidades.

- **Varianza territorial capturada.** A partir de las probabilidades predichas por el ensamble se calcula la varianza entre departamentos y, con ella, una correlación intraclase análoga a la de la Ecuación (3.7). La comparación con la CCI del modelo multinivel indica si el ensamble recupera por vía puramente predictiva la misma estructura que el modelo de efectos aleatorios estima por verosimilitud.
- **Razón de momios mediana empírica.** Se calcula el equivalente empírico de la MOR (3.8) sobre las predicciones del ensamble, lo que permite expresar la heterogeneidad contextual capturada por el modelo predictivo en la misma escala que la del modelo explicativo.
- **Contracción.** El modelo multinivel aplica contracción a los departamentos con pocos nacimientos, acercando su estimación a la media nacional; el ensamble, en cambio, no contrae. El contraste entre ambas estimaciones departamentales cuantifica el efecto de

la contracción jerárquica y resulta particularmente informativo en los departamentos de menor población, donde las estimaciones no contraídas son más inestables.

La comparación tiene un propósito sustantivo y no meramente ilustrativo. Si el ensamble reproduce la magnitud de la variación territorial estimada por el modelo multinivel, ambos enfoques convergen y el hallazgo gana robustez. Si el ensamble la sobreestima sistemáticamente en los departamentos pequeños, el resultado ilustra empíricamente el valor de la contracción jerárquica sobre datos reales, que es precisamente el argumento que justifica emplear modelos de efectos aleatorios y no efectos fijos por territorio.

3.9 Estrategia de validación y métricas de evaluación

3.9.1 Partición estratificada y validación cruzada

El conjunto de datos se divide en entrenamiento y prueba mediante una partición estratificada que preserva la proporción de la clase positiva en ambos subconjuntos. La estratificación es necesaria porque la prevalencia del bajo peso al nacer es baja y una partición aleatoria simple podría generar subconjuntos con proporciones distintas.

Sobre el conjunto de entrenamiento se aplica **validación cruzada anidada**: un bucle interno selecciona los hiperparámetros y un bucle externo, sobre datos que ese bucle interno nunca vio, estima el desempeño. El bucle interno es una validación cruzada estratificada de k pliegues: los datos se dividen en k subconjuntos, se entrena el modelo k veces dejando cada vez un pliegue como validación, y las métricas se promedian sobre los k ajustes. Este procedimiento proporciona una estimación menos variable del desempeño y es el mecanismo mediante el cual se selecciona el parámetro de regularización λ de las Ecuaciones (3.12) y (3.13).

3.9.2 Manejo del desbalance de clases

La clase positiva es minoritaria. Un clasificador que prediga siempre la clase mayoritaria alcanzaría una exactitud elevada sin identificar un solo caso, de modo que el desbalance debe abordarse de forma explícita. Se emplea ponderación nativa de clases, que asigna a cada observación un peso inversamente proporcional a la frecuencia de su clase en la función de pérdida. Frente al remuestreo sintético (Chawla et al., 2002), la ponderación tiene la ventaja de no alterar la distribución empírica de los datos, lo que resulta relevante en un estudio cuyo objetivo paralelo es estimar la prevalencia real del desenlace.

3.9.3 Métricas de evaluación

A partir de la matriz de confusión, con VP verdaderos positivos, FP falsos positivos y FN falsos negativos, se definen la precisión y la sensibilidad:

$$\text{Precisión} = \frac{VP}{VP + FP}, \quad \text{Sensibilidad} = \frac{VP}{VP + FN} \quad (3.24)$$

La puntuación F_1 es la media armónica de ambas y constituye el criterio principal de comparación:

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad (3.25)$$

Se adopta F_1 y no la exactitud porque esta última es engañosa ante clases desbalanceadas. La elección entre precisión y sensibilidad no es neutral: en salud pública, un falso negativo (no identificar un nacimiento en riesgo) tiene un costo mayor que un falso positivo (destinar seguimiento a un caso que no lo requería), de modo que la sensibilidad se reporta de forma destacada junto al F_1 .

Se reporta además la especificidad, definida como la proporción de verdaderos negativos entre los casos sin el desenlace. Se acompañan la curva ROC, con su área bajo la curva como medida de discriminación independiente del umbral, y la curva de precisión-sensibilidad, más informativa que la ROC cuando la clase positiva es minoritaria. La incertidumbre de todas las métricas se cuantifica por remuestreo bootstrap según el procedimiento de la Sección 3.12, y la comparación entre modelos se resuelve mediante el criterio de solapamiento de los intervalos de confianza.

3.10 Confusión, mediación y estrategia de modelos anidados

Las secciones anteriores describen cómo se estima la asociación entre un determinante y el desenlace. Esta describe qué variables deben entrar en el modelo y cuáles no, que es una decisión previa y de consecuencias mayores: un modelo correctamente estimado sobre una especificación equivocada produce un número preciso y sin sentido.

3.10.1 Confusor y mediador

Un **factor de confusión** es una variable que influye a la vez sobre la exposición y sobre el desenlace, sin situarse en la cadena causal que los une. Genera una asociación espuria entre ambos, y no ajustar por ella sesga la estimación. La edad materna cumple ese papel en este estudio: incide sobre el nivel educativo alcanzado, puesto que las madres muy jóvenes han tenido menos oportunidad de completar su formación, y de manera independiente sobre el riesgo de bajo peso al nacer.

Un **mediador** es una variable que se sitúa *dentro* de la cadena causal: la exposición actúa sobre ella y ella sobre el desenlace. El número de consultas prenatales cumple ese papel: la posición socioeconómica condiciona el acceso oportuno al control prenatal, y ese control incide sobre el crecimiento fetal. Lo mismo ocurre con el estado nutricional materno y con la patología del embarazo.

La diferencia entre ambos no es estadística sino causal, y no puede resolverse mirando los datos: dos variables con idéntica correlación con la exposición y el desenlace exigen tratamientos opuestos según su posición en el orden temporal y causal (Hernán and Robins, 2020). Por eso la especificación del modelo debe apoyarse en un supuesto explícito sobre esa estructura, que es lo que representa el grafo de la Figura 3.1.




Figure 3.1: Grafo acíclico dirigido con la estructura causal supuesta. La flecha discontinua representa el efecto contextual del territorio, que los modelos multinivel de la Sección 3.7 estiman como varianza de nivel superior.

3.10.2 Efecto total y efecto directo

De la distinción se sigue una regla operativa. Ajustar por un confusor corrige un sesgo y acerca la estimación al efecto real. Ajustar por un mediador no corrige nada: bloquea una parte del efecto que se pretende estimar y devuelve una cantidad distinta de la buscada. Este fenómeno se conoce como *sobreaajuste* y es una fuente frecuente de subestimación en epidemiología social (VanderWeele, 2015).

Formalmente, el modelo que ajusta únicamente por confusores estima el **efecto total** de la posición socioeconómica: todo el efecto, transcurra por la vía que transcurra. El modelo que añade además los mediadores estima el **efecto directo controlado**: la parte del efecto que no pasa por las vías bloqueadas (VanderWeele, 2015).

Ninguno de los dos es el correcto en abstracto; responden a preguntas distintas. Para una política pública dirigida a reducir la inequidad perinatal, la cantidad relevante es el efecto total, porque una intervención sobre la educación materna actúa simultáneamente por todas las vías. El efecto directo interesa para otra pregunta: si la atención prenatal fuera igual para todas las madres, ¿cuánta desigualdad persistiría?

3.10.3 Consecuencia para la estrategia de modelos anidados

De aquí se deriva la lectura de la secuencia de modelos descrita en la Sección 4.4.6. El Modelo 1, que incorpora los determinantes sociales ajustados solo por confusores demográficos, se reporta como estimación principal del **efecto total**. El Modelo 2, que añade las variables del embarazo, se reporta como estimación del **efecto directo**.

El coeficiente social se atenuará al pasar del Modelo 1 al Modelo 2. Esa atenuación no es un defecto del modelo ni evidencia de que el efecto social fuera espurio: es la medida de cuánto del efecto transcurre por la vía bloqueada, y por tanto un resultado sustantivo sobre el mecanismo. Se reporta de forma explícita como porcentaje de atenuación de cada coeficiente, y no se interpreta como corrección de un sesgo.

Conviene señalar la limitación del procedimiento. La descomposición en efecto total y directo mediante modelos anidados es válida bajo el supuesto de que no existen confusores no medidos de la relación entre el mediador y el desenlace (VanderWeele, 2015). Ese supuesto no es verificable con los datos disponibles, de modo que las cantidades estimadas deben interpretarse como aproximaciones y no como efectos causales identificados.

3.11 Tratamiento de datos faltantes

Ninguna variable del certificado de nacido vivo está completa. Descartar los registros incompletos es la salida más simple, pero solo es inocua bajo un supuesto muy restrictivo sobre el origen de la ausencia. Esta sección expone ese supuesto y el procedimiento que se adopta cuando no se sostiene.

3.11.1 Mecanismos de ausencia

Rubin (Rubin, 1976) distingue tres mecanismos, cuyas implicaciones para la validez del análisis son muy distintas.

- **Ausencia completamente al azar (MCAR).** La probabilidad de que un dato falte no depende de ningún valor, observado o no. El subconjunto completo es entonces una muestra aleatoria del total y el análisis de casos completos es insesgado, aunque pierde precisión. Es un supuesto fuerte y rara vez plausible en registros administrativos.
- **Ausencia al azar (MAR).** La probabilidad de que un dato falte depende de variables observadas, pero no del valor ausente en sí. Si la pertenencia étnica se diligencia peor en los municipios rurales dispersos, pero dentro de cada municipio la ausencia no guarda relación con la etnia real de la madre, el mecanismo es MAR. Bajo este supuesto la información de las variables observadas permite recuperar la distribución del dato ausente, y la imputación múltiple produce estimaciones válidas.
- **Ausencia no al azar (MNAR).** La probabilidad de que un dato falte depende del propio valor ausente. Si las madres sin ninguna escolaridad son sistemáticamente menos propensas a que ese dato quede registrado, ninguna técnica basada en los datos observados corrige el sesgo, porque la información necesaria no está en la base.

La distinción entre MAR y MNAR no es verificable empíricamente: ambos mecanismos producen patrones idénticos en los datos observados. Es un supuesto que se declara y cuya plausibilidad se argumenta, no una hipótesis que se contrasta.

3.11.2 Relevancia en esta fuente

Tres variables concentran el problema. La pertenencia étnica y el nivel educativo de la madre presentan diligenciamiento incompleto, y el número de consultas prenatales depende de que el dato haya sido trasladado desde la historia clínica al certificado. En los tres

casos hay razones para sospechar que la ausencia no se distribuye al azar respecto del territorio: la calidad del diligenciamiento depende de la carga asistencial y de la capacidad institucional de quien certifica, que son menores precisamente donde la población es más vulnerable.

Esto tiene una consecuencia direccional que debe declararse. Si los registros incompletos se concentran entre las madres de menor posición social, el análisis de casos completos las excluye de forma desproporcionada y la desigualdad estimada resulta *menor* que la real. El sesgo, en otras palabras, opera en contra de la hipótesis del estudio: los resultados obtenidos con casos completos constituyen una cota inferior de la inequidad.

Una precisión operativa: en las Estadísticas Vitales la ausencia no aparece como celda vacía sino codificada con valores convencionales, habitualmente 9 o 99 según la longitud del campo. Un análisis que no los recodifique previamente tratará “Sin información” como una categoría sustantiva más y producirá coeficientes carentes de interpretación.

3.11.3 Imputación múltiple por ecuaciones encadenadas

Bajo el supuesto MAR se aplica imputación múltiple por ecuaciones encadenadas (van Buuren and Groothuis-Oudshoorn, 2011). El procedimiento ajusta un modelo condicional para cada variable incompleta en función de las demás y genera m conjuntos de datos completos, cada uno con valores imputados distintos que reflejan la incertidumbre sobre el dato ausente. El análisis se repite en cada conjunto y las m estimaciones se combinan mediante las reglas de Rubin: el estimador puntual es el promedio de los m estimadores,

$$\bar{\theta} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}_j \quad (3.26)$$

y su varianza total suma la variabilidad dentro de cada conjunto y la variabilidad entre conjuntos,

$$T = \bar{U} + \left(1 + \frac{1}{m}\right) B, \quad \bar{U} = \frac{1}{m} \sum_{j=1}^m \hat{U}_j, \quad B = \frac{1}{m-1} \sum_{j=1}^m (\hat{\theta}_j - \bar{\theta})^2 \quad (3.27)$$

donde $\hat{U}_j$ es la varianza estimada en el conjunto j . El término B es lo que distingue a la imputación múltiple de la sustitución por un valor único: incorpora al error estándar la incertidumbre propia del procedimiento de imputación, que la sustitución simple ignora y que la lleva a subestimar la varianza.

El modelo de imputación incluye todas las variables del modelo de análisis, incluido el desenlace, y las variables auxiliares que ayudan a predecir la ausencia, en particular el territorio y el año. El análisis restringido a casos completos se conserva como análisis de sensibilidad, y la comparación entre ambos resultados informa sobre la robustez de las conclusiones frente al supuesto adoptado.

3.12 Estimación de intervalos de confianza por bootstrap

Ni el índice de concentración corregido, ni el índice relativo de desigualdad, ni las contribuciones de la descomposición tienen expresión analítica cerrada para su varianza. Sus intervalos de confianza se obtienen por remuestreo bootstrap (Efron, 1979): se extraen B muestras con reemplazo del mismo tamaño que la original, se recalcula el estadístico en cada réplica y se construye el intervalo por el método del percentil, tomando los cuantiles 2,5 y 97,5 de la distribución empírica. Se emplean $B = 1.000$ réplicas. El criterio de solapamiento de intervalos se conserva como regla conservadora de comparación entre estimaciones.

Chapter 4

Metodología

Este capítulo describe las decisiones operativas del estudio: el diseño, la fuente de datos, la conformación de la muestra, la definición y operacionalización de las variables, y la estrategia de análisis estadístico. Los fundamentos conceptuales de los determinantes sociales de la salud y de las técnicas de medición de la desigualdad se desarrollaron en el Capítulo 3.

4.1 Enfoque y diseño

El estudio es cuantitativo, observacional, analítico y de carácter aplicado. Se basa en datos secundarios de un registro administrativo de cobertura nacional, lo que define un diseño de corte transversal repetido con componente multinivel, sobre el período 1998–2024. A diferencia de los diseños predictivos, cuyo objetivo es maximizar la capacidad de clasificación, aquí el propósito es explicativo: estimar la magnitud de la asociación entre la posición socioeconómica de la madre y el bajo peso al nacer, cuantificar la desigualdad social resultante y descomponerla en las contribuciones de cada determinante.

La unidad de análisis primaria es el nacimiento. Las unidades de agregación contextual son el municipio y el departamento de residencia habitual de la madre, lo que configura una estructura jerárquica de tres niveles: nacimientos anidados en municipios y municipios anidados en departamentos. Esta estructura no es un artificio estadístico, sino el reflejo de que la exposición social opera simultáneamente en el plano individual y en el territorial.

4.2 Descripción de los datos

4.2.1 Fuente y período

Se utilizaron los microdatos de nacimientos de las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística, correspondientes al período 1998–2024 (Departamento Administrativo Nacional de Estadística, 2025). Las EEVV se producen a partir de los certificados de nacido vivo diligenciados por el personal de salud autorizado y consolidados por el DANE, y constituyen el registro oficial de los nacimientos del país.

Tres propiedades de esta fuente condicionan el diseño y deben explicitarse.

La primera es la cobertura censal. Las EEVV no notifican casos seleccionados sino la totalidad de los nacidos vivos registrados, de modo que numerador y denominador provienen del mismo instrumento. Esto hace directamente estimables las prevalencias, los índices de concentración y las curvas de concentración, sin necesidad de enlazar el archivo con una fuente externa de denominadores.

La segunda es la disponibilidad del peso al nacer en gramos y del tiempo de gestación en semanas dentro del mismo registro, lo que permite construir el desenlace en sus formas continua, dicotómica y estratificada por edad gestacional.

La tercera es la discontinuidad instrumental de la serie. El certificado de nacido vivo fue objeto de una actualización sustantiva hacia 2008, en el marco de la implementación de la certificación en línea a través del Registro Único de Afiliados. Los archivos de nacimientos de 1998–2007 contienen 33 variables, frente a 39 en los años recientes. La armonización de la serie y la verificación del año a partir del cual está disponible cada variable social son requisitos previos al análisis, y se documentan en la Sección 4.3.1.

4.2.2 Población y muestra

La población de estudio la constituyen todos los nacidos vivos registrados en las Estadísticas Vitales del DANE en Colombia durante el período 1998–2024. No se aplica muestreo probabilístico: se trabaja con el universo de nacimientos registrados, por lo que las estimaciones no requieren factores de expansión y los intervalos de confianza se interpretan como medida de la variabilidad del proceso de registro y no del muestreo.

La conformación de la muestra analítica se realiza en cuatro etapas secuenciales de depuración, resumidas en el Cuadro 4.1.

Table 4.1: Conformación de la muestra analítica. Nacidos vivos registrados en las Estadísticas Vitales del DANE, 1998–2024. Los porcentajes se calculan sobre la base original.

Etapas	Criterio	Registros	%
Base original	Nacidos vivos registrados, EEVV–DANE, 1998–2024	18.008.809	100,00
Exclusión 1	Registros sin peso al nacer informado	–332.369	–1,85
Exclusión 2	Registros sin tiempo de gestación informado	–207.990	–1,15
Exclusión 3	Registros sin departamento y municipio de residencia identificables en Colombia, incluidas las madres con residencia habitual en el exterior	–64.487	–0,36
<i>Total excluido</i>		<i>–604.846</i>	<i>–3,36</i>
Muestra analítica	Nacimientos incluidos en el análisis	17.403.963	96,64

Las tres exclusiones retiran en conjunto 604.846 registros, el 3,36 % de la base, de modo que la muestra analítica conserva 17.403.963 nacimientos, el 96,64 % de los nacidos vivos del período. Ninguna de ellas es discrecional: las dos primeras responden a la ausencia del desenlace o de la variable que permite clasificarlo, y la tercera a la imposibilidad de asignar el nacimiento a una unidad territorial, que es el requisito mínimo de la estructura jerárquica descrita en la Sección 3.7.

La completitud mejora de forma sostenida a lo largo del período. La ausencia de peso al nacer pasa del 6,03 % en 1998 al 0,29 % en 2016, y la de tiempo de gestación, del 2,79 % al 0,12 % en el mismo lapso, lo que refleja la consolidación del certificado electrónico. En sentido contrario, la exclusión por territorio no identificable, marginal hasta 2017, se multiplica a partir de 2018 y alcanza 11.571 registros en 2019. La verificación de esos casos muestra que corresponden de manera casi exclusiva a madres con residencia habitual en Venezuela: en 2019, 11.434 de los 11.592 registros sin departamento asignable declaran ese país de residencia. El fenómeno documenta el efecto del flujo migratorio sobre el registro de nacimientos y debe tenerse presente al interpretar las series departamentales de los años recientes.

4.2.3 Variables del estudio

Variable respuesta. El bajo peso al nacer, definido como un peso inferior a 2.500 gramos (PESO_NAC). Se opera en tres formas complementarias:

- **Dicotómica.** Presencia o ausencia de bajo peso al nacer sobre el total de nacidos vivos. Es el desenlace principal de los modelos multinivel y de los índices de desigualdad.

- **Estratificada por edad gestacional.** Bajo peso al nacer a término (≥ 37 semanas, atribuible a restricción del crecimiento intrauterino) frente a bajo peso asociado a prematuridad (< 37 semanas), a partir de T_GES. El contraste entre ambos estratos informa sobre el mecanismo.
- **Continua.** El peso en gramos, empleado en análisis complementarios de gradiente de severidad.

Variables de exposición. Los determinantes sociales registrados en el certificado de nacido vivo, referidos a la madre salvo indicación contraria. Se agrupan en tres dimensiones conceptuales, siguiendo el modelo adoptado en la Sección 3.1. El Cuadro 4.2 resume su operacionalización.

Table 4.2: Variables de exposición y su operacionalización en los microdatos de nacimientos de las EEVV.

Dimensión	Variable	Nombre en la base	Categorías analíticas
Posición socioeconómica	Nivel educativo de la madre	NIV_EDUM	Ninguno · Primaria · Secundaria · Técnico o superior (ref.)
	Nivel educativo del padre	NIV_EDUP	Mismas categorías
Acceso y aseguramiento	Régimen de afiliación	SEG_SOCIAL	Contributivo (ref.) · Subsidiado · Especial o excepción · No asegurado
	Consultas prenatales	NUMCONSUL	Ninguna · 1 a 3 · 4 a 6 · 7 o más (ref.)
Adscripción social y territorial	Pertenencia étnica	IDPERTET	Indígena · Rom · Raizal · Palenquero · Negro o afrocolombiano · Ninguna (ref.)
	Área de residencia	AREA_RES	Cabecera (ref.) · Centro poblado · Rural disperso
	Estado conyugal	EST_CIVM	Casada o unión libre (ref.) · Soltera · Separada o viuda

Variables de ajuste. La edad materna (EDAD_MADRE), categorizada en menor de 15 años, 15 a 19, 20 a 34 (referencia), 35 a 39 y 40 o más; la paridad (N_HIJOSV, N_EMB); la multiplicidad del embarazo (MUL_PARTO); el sexo del recién nacido (SEXO); y el año de ocurrencia (ANO) para captar la tendencia temporal.

Variables de nivel contextual. El municipio y el departamento de residencia habitual de la madre (CODMUNRE, CODPTORE) definen los niveles superiores de la estructura

jerárquica. Se emplea la residencia y no la ocurrencia del nacimiento, porque la exposición social opera en el lugar donde vive la madre y no donde es atendida. Cuando estén disponibles, se incorporan indicadores agregados de privación municipal (índice de pobreza multidimensional o porcentaje de necesidades básicas insatisfechas del DANE) como predictores de nivel 2.

4.3 Preparación y depuración de los datos

4.3.1 Armonización de la serie 1998–2024

Los microdatos no se publican en un archivo único sino en trece catálogos distintos, cada uno con su propio diccionario de datos. El Cuadro 4.3 los relaciona. Entre ellos, ni los nombres de los archivos ni los de las variables son idénticos, de modo que la construcción de una serie continua exige una etapa previa de armonización que constituye, en sí misma, un resultado metodológico del trabajo.

El procedimiento adoptado corresponde a la **armonización mediante esquema canónico y tabla de correspondencias versionada**, conocida en la literatura anglosajona como *crosswalk* y enmarcada en el enfoque de *modelo de datos común*. Es la estrategia empleada de forma estándar en la armonización de encuestas longitudinales y en los modelos de datos clínicos estandarizados, y su adopción explícita permite que el procedimiento sea auditable y reutilizable por terceros. Comprende cuatro elementos.

Esquema canónico. Una lista maestra de conceptos, no de nombres de columna, que representa las variables de interés a lo largo de todo el período. En este trabajo lo constituyen los 44 conceptos del Apéndice B. La distinción entre concepto y nombre de campo es lo que permite seguir una misma variable aunque el instrumento la renombre.

Tabla de correspondencias con tres estados. Para cada concepto y cada versión del instrumento, la celda toma uno de tres valores, y no un simple presente o ausente:

- **Presente.** La variable existe y es comparable entre versiones.
- **Ausente por diseño** (*structural missing*). El concepto no existía en ese catálogo, como ocurre con la pertenencia étnica antes de 2008.
- **Renombrada.** El mismo concepto aparece bajo otro nombre de campo, como IDPERTET frente a IDPUEBLOIN en 2012 y 2013.

Separación entre ausencia estructural y ausencia por ítem. Esta distinción es decisiva y precede a cualquier imputación. La imputación múltiple descrita en la Sección 3.11 supone que el dato falta al azar a nivel de observación, pero una variable que no existía en el instrumento durante un tramo completo de años no falta al azar: no era observable por construcción. Imputar a través de ese quiebre estructural introduciría sesgo. En consecuencia, la ausencia estructural se trata restringiendo el período de análisis a los años en que la variable sí se capturó, tal como se hace con la pertenencia étnica y el régimen de afiliación, limitados a 2008–2024; y la imputación múltiple se reserva exclusivamente para la ausencia por ítem que ocurre dentro de un mismo régimen de captura.

Versión del instrumento como covariable auxiliar. El modelo de imputación incorpora, además del territorio y del año, una variable indicadora del catálogo o versión del certificado de nacido vivo, dado que versiones distintas pueden presentar patrones de captura distintos incluso dentro de un mismo año.

La tabla de correspondencias no se conserva únicamente como cuadro estático en el Apéndice B: se versiona además como archivo de texto plano (`datos/crosswalk.yaml`) dentro del repositorio descrito en el Apéndice A, de modo que cualquier persona pueda auditar cómo se mapeó cada variable entre versiones del instrumento.

Table 4.3: Catálogos de microdatos de nacimientos publicados por el DANE y número de variables del archivo correspondiente. Elaboración propia a partir de los diccionarios de datos publicados en el portal de microdatos (Departamento Administrativo Nacional de Estadística, 2025).

Catálogo	Años	Archivo(s) de nacimientos	N.º vars.
366	1998-2007	Nacimientos_1998 ... Nacimientos_2007	33
375	2008-2011	nac2008 ... nac2011	38
377	2012-2013	Nac_2012, Nac_2013	41
420	2014	nac2014	38
475	2015	nac2015	38
519	2016	nac2016	38
652	2017-2018	nac2017, nac2018	38
696	2019	nac2019	38
732	2020	nac2020	37
775	2021	nac2021	39
807	2022	nac2022	39
876	2023	nac2023	39
878	2024-2025	BD-EEVV-Nacimientos-2024	40

El número de variables del archivo de nacimientos no es constante a lo largo del período. La Figura 4.1 resume su trayectoria y señala los puntos de ruptura del instrumento.




Figure 4.1: Evolución del número de variables del archivo de nacimientos de las Estadísticas Vitales, 1998–2024. Elaboración propia a partir de los diccionarios de datos publicados por el DANE para cada catálogo (Departamento Administrativo Nacional de Estadística, 2025).

La lectura de la figura ordena el período en seis tramos. Entre 1998 y 2007 el archivo contiene 33 variables, con los nombres en minúscula, el grupo sanguíneo y el factor RH registrados en un solo campo y sin información sobre pertenencia étnica ni sobre el último grado aprobado. En 2008, con la implementación de la certificación en línea, el archivo salta a 38 variables: los nombres pasan a mayúscula, se separan IDHEMOCLAS e IDFACTORRH, y se incorporan la pertenencia étnica, el último grado aprobado por cada progenitor y la entidad administradora en salud. Los años 2012 y 2013 marcan el pico histórico de 41 variables, con cuatro campos transitorios sobre la institución de salud y la persona que atendió el parto. Entre 2014 y 2019 el archivo regresa a 38 variables al retirarse esos campos. En 2020 desciende a 37 por la pérdida de T_GES_AGRU_CIE. Y entre 2021 y 2024 asciende de nuevo hasta las 40 variables actuales.

Los Cuadros 4.4 y 4.5 detallan qué variables entran y cuáles desaparecen. El Apéndice B recoge la tabla completa de equivalencias, concepto por concepto, para los 44 conceptos que componen el certificado a lo largo de toda la serie.

De esta consolidación se desprenden tres consecuencias para el diseño, que deben declararse de forma explícita.

La primera afecta al alcance temporal de los ejes de inequidad. La pertenencia étnica y

Table 4.4: Variables incorporadas al certificado de nacido vivo con posterioridad a 1998.

Variable	Etiqueta	Aparece desde	Nota
OTRO_SIT	Otro sitio, ¿cuál?	Desde 2008	No existía en 1998-2007
T_GES_AGRU_CIE	Tiempo de gestación ajustado a agrupación CIE	Desde 2008 (con huecos)	Ausente en 1998-2007; ausente en el diccionario de 2012-2013; ausente en 2020; presente 2008-2019, 2021-2024
IDFACTORRH	Hemoclasificación: Factor RH	Desde 2008	Antes (1998-2007) iba unido con el grupo sanguíneo en una sola variable (gru_san)
IDPERTET IDPUEBLOIN	/ Reconocimiento étnico del nacido vivo	Desde 2008	No existía en 1998-2007; en 2012-2013 el DANE la llamó IDPUEBLOIN en vez de IDPERTET
ULTCURMAD	Último año o grado aprobado por la madre	Desde 2008	No existía en 1998-2007
ULTCURPAD	Último año o grado aprobado por el padre	Desde 2008	No existía en 1998-2007
IDCLASADMI	Entidad Administradora en Salud de la madre	Desde 2008	No existía en 1998-2007
OTRPARATX	El parto fue atendido por otra persona, ¿cuál?	Solo 2012-2013	Variable exclusiva de ese diccionario; no aparece antes ni después
NOMCLASAD	Nombre de la Administradora en Salud de la madre	Solo 2012-2013	Variable exclusiva de ese diccionario; no aparece antes ni después
TIPOFORMULARIO	Fuente del Certificado	Desde 2021	No existía antes de 2021
CODPAISNACMAD	País de nacimiento de la madre	Solo 2024	No existía en ningún periodo anterior

Table 4.5: Variables presentes en algunos períodos y ausentes en otros.

Variable	Etiqueta	Presente en	Nota
NOM_INST	Nombre de la institución de salud	1998-2007 y 2012-2013	Ausente en 2008-2011, 2014-2024 (excepto que reaparece puntualmente en el diccionario 2012-2013)
COD_INST	Código de la institución de salud	1998-2007 y 2012-2013	Misma situación que NOM_INST
T_GES_AGRU_CIE	Tiempo de gestación ajustado a agrupación CIE	Se retira en el diccionario de 2012-2013 y en 2020	Vuelve a aparecer en 2021-2024

la entidad administradora en salud no existen antes de 2008. En consecuencia, el análisis de esos ejes se restringe a 2008–2024, mientras que la serie completa 1998–2024 se reserva para los ejes de educación materna, área de residencia y territorio, presentes en todo el período.

La segunda es un cambio de nombre que resulta fácil pasar por alto. El campo de reconocimiento étnico se denomina IDPERTET en la mayoría de los catálogos, pero en los archivos de 2012 y 2013 aparece como IDPUEBLOIN. Una rutina que busque únicamente el primer nombre perderá dos años completos de información sin emitir ningún aviso.

La tercera es que tres conceptos no se comportan como una serie continua. Las variables NOM_INST y COD_INST solo están presentes en 1998–2007 y en 2012–2013, y T_GES_AGRU_CIE se retira en 2012–2013, reaparece de forma intermitente hasta 2019, se pierde en 2020 y vuelve en 2021. Ninguna de las tres puede emplearse como covariable en modelos que abarquen el período completo.

4.3.2 Consistencia y recodificación

Se verifica la consistencia interna de cada registro contra los rangos biológicamente admisibles: peso al nacer entre 300 y 7.000 gramos, talla entre 20 y 60 centímetros, edad gestacional entre 20 y 45 semanas, y coherencia entre peso y edad gestacional mediante curvas de referencia. Los valores fuera de rango se recodifican como faltantes y no se imputan por sustitución simple. Las categorías administrativas de *sin información* se tratan como datos faltantes y no como categorías sustantivas, decisión que se documenta explícitamente por su efecto sobre las estimaciones.

4.3.3 Codificación territorial

La codificación de departamentos y municipios se unifica según la División Político-Administrativa (DIVIPOLA) del DANE en su versión más reciente, considerando las creaciones, supresiones y recodificaciones municipales ocurridas dentro del período de estudio. Los casos sin correspondencia directa se documentan en un anexo de equivalencias.

4.3.4 Tratamiento de los valores faltantes

Se reporta la proporción de valores faltantes por variable y por año, con atención particular a la pertenencia étnica, el nivel educativo y el número de consultas prenatales. Se examina si la ausencia se distribuye de manera aleatoria o si guarda relación con el

territorio, el año o el tipo de institución que certifica. Bajo el supuesto de datos faltantes al azar condicionalmente, se aplica imputación múltiple por ecuaciones encadenadas, con veinte conjuntos imputados y combinación de estimaciones mediante las reglas de Rubin (van Buuren and Groothuis-Oudshoorn, 2011). El análisis restringido a casos completos se conserva como análisis de sensibilidad.

4.4 Análisis estadístico

La estrategia analítica se organiza en cinco fases, en correspondencia directa con las cinco preguntas específicas formuladas en la Sección 1.1.

4.4.1 Fase 1. Análisis descriptivo y de tendencia

Las variables categóricas se describen mediante frecuencias absolutas y relativas; las continuas, mediante media y desviación estándar o mediana y rango intercuartílico, según su distribución. La prevalencia de bajo peso al nacer se calcula por cada cien nacidos vivos, con intervalos de confianza del 95 % por el método de Wilson. La tendencia temporal se modela mediante regresión de Poisson con varianza robusta, estimando el cambio porcentual anual; cuando la serie sugiere puntos de inflexión, se recurre a regresión de puntos de unión. La distribución territorial se representa mediante mapas de coropletas por departamento y municipio.

4.4.2 Fase 2. Medición de la desigualdad socioeconómica

La desigualdad se cuantifica mediante el índice de concentración definido en la Ecuación (3.4). La variable de ordenamiento principal es el nivel educativo materno y, de manera alternativa, el régimen de afiliación. Dado que el desenlace es binario y acotado, el índice se corrige mediante la normalización de Erreygers (3.5). Se acompaña de la curva de concentración y de dos medidas complementarias basadas en regresión: el índice de desigualdad de la pendiente y el índice relativo de desigualdad. Los intervalos de confianza se estiman por remuestreo bootstrap con mil réplicas. El procedimiento se repite por año, lo que permite examinar si la desigualdad se ha ampliado o reducido a lo largo del período.

4.4.3 Fase 3. Modelos de regresión logística multinivel

Para estimar el efecto independiente de cada determinante social se ajustan modelos de regresión logística multinivel de tres niveles, con nacimientos anidados en municipios y municipios anidados en departamentos. La estimación se realiza por máxima verosimilitud con aproximación de Laplace. Se ajusta una secuencia de cuatro modelos anidados:

- **Modelo 0.** Modelo vacío, sin covariables. Permite estimar la varianza atribuible a cada nivel territorial, la correlación intraclase (3.7) y la razón de momios mediana (3.8).
- **Modelo 1.** Incorpora las variables de posición socioeconómica y adscripción social de la madre. Estima el efecto social bruto ajustado por la estructura jerárquica.
- **Modelo 2.** Añade las variables demográficas y del embarazo: edad materna, paridad, multiplicidad y sexo del recién nacido.
- **Modelo 3.** Incorpora los indicadores agregados de privación municipal como predictores de nivel 2, para examinar si el contexto conserva efecto una vez controlada la composición individual.

El ajuste comparativo entre modelos se evalúa mediante el criterio de información de Akaike, el criterio bayesiano de Schwarz y el cambio proporcional en la varianza (3.9). Los resultados se presentan como razones de momios con intervalos de confianza del 95 %.

Advertencia sobre la interpretación de los modelos anidados. Las variables del embarazo se sitúan en la vía causal entre la posición socioeconómica y el bajo peso al nacer: son mediadores, no factores de confusión. Su incorporación en el Modelo 2 atenúa deliberadamente el coeficiente social, y esa atenuación se interpreta como evidencia sobre el mecanismo y no como corrección de un sesgo. Por esta razón el Modelo 1 se reporta como estimación principal del efecto social total, y el Modelo 2 como estimación del efecto directo.

Medida de asociación. Dado que la prevalencia del desenlace no es baja, la razón de momios sobrestima la razón de prevalencias (Barros and Hirakata, 2003). Como análisis complementario se estiman razones de prevalencia mediante regresión de Poisson multinivel con varianza robusta, y se contrastan ambas estimaciones.

4.4.4 Fase 4. Descomposición de la desigualdad

La cuarta pregunta se responde mediante la descomposición del índice de concentración (3.6) propuesta por Wagstaff, van Doorslaer y Watanabe (Wagstaff et al., 2003). Las contribuciones de cada determinante se expresan en términos absolutos y como porcentaje del índice total, y sus intervalos de confianza se obtienen por bootstrap.

4.4.5 Fase 5. Análisis de sensibilidad

Se ejecutan cinco análisis de sensibilidad para evaluar la robustez de los hallazgos:

- **Casos completos.** Repetición de los modelos principales sin imputación, para verificar que las conclusiones no dependen del procedimiento de imputación.
- **Restricción temporal.** Análisis limitado a 2008–2024, período con el instrumento de captura homogéneo, contrastado con la serie completa.
- **Especificación alternativa.** Ordenamiento socioeconómico basado en el régimen de afiliación en lugar del nivel educativo, y viceversa, para evaluar la estabilidad del índice de concentración.
- **Definición del desenlace.** Comparación de los resultados con el desenlace restringido a nacimientos a término frente al conjunto de nacidos vivos.
- **Estructura jerárquica.** Comparación del modelo de tres niveles frente a uno de dos niveles con errores estándar agrupados por departamento.

4.4.6 Fase 6. Comparación de modelos de clasificación

Las cinco fases anteriores responden a un objetivo explicativo. Esta sexta fase aborda el componente predictivo: establecer con qué capacidad puede identificarse un nacimiento en riesgo a partir únicamente de la posición social de la madre, y determinar si la complejidad algorítmica añade información sobre la regresión logística. Se comparan los siete modelos descritos en la Sección 3.8: regresión logística, regresión logística con penalización lasso, regresión logística con penalización ridge, árbol de decisión, bosque aleatorio, *gradient boosting* y perceptrón multicapa.

Naturaleza predictiva de esta fase. A diferencia de las Fases 3 y 4, orientadas a la estimación de efectos, la Fase 6 tiene un objetivo estrictamente predictivo. En consecuencia, no hereda la restricción de excluir mediadores que impone el marco causal de la Sección 3.10: variables como el número de consultas prenatales se incorporan aquí como predictores legítimos, porque el propósito es maximizar la capacidad de clasificación y no estimar un efecto causal. Esta diferencia de objetivo explica que una misma variable reciba tratamientos distintos en fases distintas, sin que ello constituya una inconsistencia interna del trabajo.

Estrategia de partición

El estudio emplea dos esquemas de partición que responden a preguntas distintas y se reportan por separado.

El **esquema principal** es una partición aleatoria estratificada por la clase del desenlace, con 70 % de entrenamiento y 30 % de prueba. La estratificación preserva la prevalencia del bajo peso al nacer en ambos subconjuntos, condición necesaria dado que la clase positiva es minoritaria. Este esquema mide la capacidad de discriminación de cada modelo y es el que sustenta la comparación entre los siete algoritmos.

El **esquema complementario** es una partición temporal: los modelos se entrenan con los nacimientos de 1998 a 2018 y se evalúan sobre los de 2019 a 2024, que el modelo no vio durante el entrenamiento. Este segundo esquema no compite con el primero, sino que responde a una pregunta diferente: si el modelo generaliza hacia el futuro. La pregunta es pertinente porque la prevalencia del desenlace no es estable en el período, sino que asciende del 7,67 % en 1998 al 11,24 % en 2024, lo que indica una deriva temporal real del fenómeno. Un modelo que discrimine bien sobre una mezcla aleatoria de años puede degradarse al aplicarse a un período posterior.

Ambos resultados se reportan en el Capítulo 5, indicando de forma explícita qué partición corresponde a cada cifra. La partición temporal se interpreta como análisis de robustez y no sustituye al esquema principal.

Procedimiento

1. **Partición.** Según los dos esquemas descritos, con semilla fija.
2. **Preprocesamiento.** Codificación disyuntiva completa de las variables categóricas y estandarización de las continuas. La estandarización es indispensable para las penalizaciones L_1 y L_2 de las Ecuaciones (3.12) y (3.13), cuya magnitud depende de la escala

de los coeficientes, y para el perceptrón multicapa.

3. **Imputación.** Los valores faltantes se imputan según el procedimiento de la Sección 3.11, con una restricción que se detalla más abajo: el imputador se ajusta exclusivamente sobre el conjunto de entrenamiento.
4. **Ajuste de hiperparámetros.** Validación cruzada anidada: el bucle interno, de cinco pliegues estratificados sobre el conjunto de entrenamiento, selecciona los hiperparámetros; el bucle externo, sobre el conjunto de prueba reservado, estima el desempeño. Se optimizan el parámetro de regularización λ en lasso y ridge; la profundidad máxima y el número mínimo de observaciones por hoja en el árbol; el número de árboles, el número de variables por división y el tamaño mínimo de hoja en el bosque aleatorio; la tasa de aprendizaje, la profundidad, el número de estimadores y los términos de regularización en el *gradient boosting*; y la arquitectura de capas ocultas, la tasa de aprendizaje y los parámetros de regularización en la red neuronal.
5. **Manejo del desbalance.** Ponderación nativa de clases en los siete modelos, con pesos inversamente proporcionales a la frecuencia de cada clase.
6. **Evaluación.** Cálculo de la puntuación F_1 (3.25), la precisión y la sensibilidad (3.24), la especificidad, el área bajo la curva ROC y el área bajo la curva de precisión-sensibilidad. Todas las métricas se calculan sobre el conjunto de entrenamiento *y* sobre el de prueba, de modo que la brecha entre ambos documente la ausencia de sobreajuste. Los intervalos de confianza se obtienen por bootstrap con mil réplicas y la comparación entre modelos se resuelve por solapamiento de intervalos.

Control de la fuga de información

La validez del componente predictivo depende de que ninguna información del conjunto de prueba intervenga en el ajuste. Se adoptan cuatro medidas.

Imputación ajustada solo sobre entrenamiento. El imputador se ajusta únicamente con los datos de entrenamiento y se aplica al conjunto de prueba mediante la transformación ya aprendida, sin reajustarlo. Dentro de la validación cruzada, el imputador se ajusta de forma independiente en cada pliegue. Ajustarlo sobre la base completa antes de particionar permitiría que el modelo de imputación aprendiera patrones del propio conjunto de prueba e inflaría artificialmente el desempeño reportado. Se aplica el mismo criterio ya adoptado para la estandarización de variables.

Predictores sin vínculo mecánico con el desenlace. El conjunto de predictores se restringe a los determinantes sociales y a las variables asistenciales de la madre. Se excluyen deliberadamente las variables clínicas del recién nacido ligadas por construcción al desenlace, como la talla al nacer y la puntuación APGAR, cuya inclusión constituiría una fuga directa de la etiqueta hacia los predictores.

Independencia del índice de privación municipal. El índice de privación empleado como predictor de nivel 2 en el Modelo 3 se calcula de forma independiente del desenlace estudiado, a partir de fuentes externas del DANE, evitando así cualquier circularidad entre el predictor y la variable de respuesta.

Corte temporal de la historia obstétrica. Las variables de historia obstétrica previa (fecha de nacimiento del hijo anterior, número de hijos nacidos vivos y número de embarazos) se construyen utilizando exclusivamente información anterior al parto índice, por lo que no introducen fuga temporal.

Limitación no resoluble. El certificado de nacido vivo no incluye un identificador único de la madre, de modo que no es posible agrupar los registros correspondientes a una misma mujer ni aplicar estrategias de partición agrupada. Sus implicaciones se declaran en la Sección 6.3.

Regularización del perceptrón multicapa

El perceptrón multicapa es, de los siete modelos, el más propenso a memorizar patrones del conjunto de entrenamiento. Se aplican tres mecanismos de control: detención temprana (*early stopping*) sobre un conjunto interno de validación equivalente al 10 % del entrenamiento, con paciencia de diez épocas sin mejora; decaimiento de pesos (*weight decay*), cuyo coeficiente se incluye en la búsqueda de hiperparámetros junto con la arquitectura y la tasa de aprendizaje; y un número máximo de épocas fijado de antemano. Los valores finalmente seleccionados se reportan en el Capítulo 5.

Importancia de variables

La importancia se reporta mediante los coeficientes estandarizados en los tres modelos lineales, la reducción media de impureza de Gini (3.15) en el árbol, el bosque y el *gradient boosting*, y la importancia por permutación en todos los modelos, que es el único

procedimiento comparable entre familias.

Relación con el componente explicativo. Esta fase no sustituye a los modelos multinivel ni a la descomposición de la desigualdad. Un modelo con alta capacidad predictiva no identifica causas, y un determinante socialmente decisivo puede aportar poco al desempeño predictivo si su distribución es homogénea. Ambos componentes responden a preguntas distintas y se reportan por separado, salvo en el contraste jerárquico descrito en la Sección 3.8.9, que los pone deliberadamente en relación.

4.5 Software y reproducibilidad

El procesamiento y el análisis se realizan en Python, versión 3.9, sobre un entorno virtual aislado que fija las versiones de todas las dependencias. La manipulación de los microdatos se apoya en `pandas` y `numpy`; la lectura de los archivos originales en formato SPSS, en `pyreadstat`. Los modelos de clasificación descritos en la Sección 3.8 se implementan con `scikit-learn` (Pedregosa et al., 2011), que provee la regresión logística con penalización L_1 y L_2 , los árboles de decisión, el bosque aleatorio y el perceptrón multicapa, además de las rutinas de partición estratificada, validación cruzada y cálculo de métricas. El tratamiento del desbalance de clases se apoya en `imbalanced-learn`. La imputación múltiple se realiza con `IterativeImputer` de `scikit-learn`; los modelos multinivel, con `statsmodels`; y la cartografía, con `geopandas` y `matplotlib`. El índice de concentración, su descomposición y los intervalos por remuestreo se implementan mediante rutinas propias documentadas, verificadas sobre un subconjunto de prueba contra los resultados del comando `conindex` de Stata.

Todo el flujo de trabajo se organiza en un proyecto con control de versiones y semilla aleatoria fija, de modo que los resultados sean íntegramente reproducibles. El archivo `requirements.txt` registra las versiones exactas de cada biblioteca. Los scripts de depuración, análisis y generación de figuras se incluyen en el Apéndice A.

4.6 Consideraciones éticas

El estudio utiliza datos secundarios, anonimizados y de acceso público, provenientes de un registro estadístico oficial. De acuerdo con la Resolución 8430 de 1993 del Ministerio de Salud, que establece las normas científicas, técnicas y administrativas para la investigación en salud en Colombia, una investigación documental retrospectiva que no interviene sobre

variables biológicas, fisiológicas, psicológicas o sociales de los participantes se clasifica como investigación sin riesgo. No obstante, el protocolo se somete a la revisión y aval del comité de ética institucional antes de su ejecución.

El tratamiento de la información observa lo dispuesto en la Ley 1581 de 2012 sobre protección de datos personales. Los microdatos publicados por el DANE no contienen variables de identificación directa. Los resultados se presentan únicamente en forma agregada, y se aplica supresión de celdas con frecuencias reducidas para impedir la reidentificación de casos en municipios de baja población.

Chapter 5

Resultados

[Capítulo por redactar tras la ejecución del análisis. La estructura sigue el orden de las seis fases descritas en la Sección 4.4.6 y en las que la preceden, de modo que cada apartado responde a una pregunta específica del Capítulo 2. Las notas en rojo indican qué debe contener cada sección.]

5.1 Análisis descriptivo

[Responde a la pregunta específica 1.]

5.1.1 Conformación de la muestra y completitud

La conformación de la muestra se presenta en el Cuadro 4.1: de los 18.008.809 nacidos vivos registrados entre 1998 y 2024, la muestra analítica retiene 17.403.963, esto es, el 96,64 %.

[Añadir el diagrama de flujo de las exclusiones y el cuadro de completitud por variable y por año.]

5.1.2 Distribución de la variable respuesta

[Prevalencia global de bajo peso al nacer con intervalo de Wilson, y distribución por categorías de peso y por edad gestacional.]

5.1.3 Caracterización sociodemográfica de las madres

[Cuadro descriptivo de los determinantes sociales para el total y estratificado por presencia del desenlace.]

5.1.4 Tendencia temporal de la prevalencia, 1998–2024

La prevalencia de bajo peso al nacer en el conjunto de la muestra analítica es del 8,82 % (1.534.819 casos sobre 17.403.963 nacimientos). Lejos de mantenerse estable, la serie muestra un ascenso sostenido a lo largo de todo el período, que la Figura 5.1 resume.




Figure 5.1: Prevalencia anual de bajo peso al nacer en Colombia, 1998–2024. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

La prevalencia pasa del 7,67 % en 1998 al 11,24 % en 2024, un incremento relativo del 46,5 %. El ascenso no es uniforme: entre 1998 y 2011 la serie sube de forma gradual hasta estabilizarse en torno al 9 % durante la década siguiente, y a partir de 2021 se acelera de nuevo hasta los valores más altos de todo el registro.

[Estimar el cambio porcentual anual mediante regresión de Poisson con varianza robusta y aplicar regresión de puntos de unión para localizar formalmente los puntos de inflexión. Discutir en qué medida el ascenso reciente refleja un deterioro real y en qué medida responde a la caída del número de nacimientos registrados, que pasa de 656.704 en 2017 a 453.901 en 2024.]

5.1.5 Distribución territorial

[Mapas de coropletas por departamento y municipio, y ordenamiento de los departamentos por prevalencia.]

5.2 Desigualdad socioeconómica

[Responde a la pregunta específica 2.]

5.2.1 Prevalencia según posición socioeconómica

[Prevalencia por nivel educativo materno y por régimen de afiliación, con intervalos de confianza.]

5.2.2 Índice y curva de concentración

[Valor del índice con corrección de Erreygers e intervalo bootstrap, y curva de concentración frente a la diagonal de igualdad.]

5.2.3 Índice de desigualdad de la pendiente e índice relativo

[Diferencia absoluta y razón entre los extremos de la jerarquía social.]

5.2.4 Evolución de la desigualdad en el período

[Serie anual del índice de concentración: ¿la brecha se amplía o se reduce?]

5.3 Modelos multinivel

[Responde a las preguntas específicas 3 y 5.]

5.3.1 Modelo vacío: variación municipal y departamental

[Varianza de cada nivel, correlación intraclase y razón de momios mediana.]

5.3.2 Modelo 1: efecto social total

[Razones de momios de los determinantes sociales ajustadas solo por confusores.]

5.3.3 Modelo 2: efecto directo tras el ajuste por mediadores

[Mismos coeficientes con las variables del embarazo, y porcentaje de atenuación de cada uno respecto del Modelo 1.]

5.3.4 Modelo 3: privación municipal como predictor contextual

[Efecto de los indicadores agregados de nivel 2.]

5.3.5 Comparación de ajuste y cambio proporcional en la varianza

[AIC, BIC y CPV entre los cuatro modelos.]

5.4 Descomposición de la desigualdad

[Responde a la pregunta específica 4.]

5.4.1 Contribución de cada determinante

[Contribución absoluta y porcentual al índice total, con intervalos bootstrap.]

5.4.2 Elasticidades y distribución de los determinantes

[Los dos componentes de cada contribución por separado, para distinguir un determinante potente pero homogéneo de otro moderado pero muy desigual.]

5.5 Comparación de modelos de clasificación

[Responde al componente predictivo de la Fase 6.]

5.5.1 Desempeño en validación cruzada

[Métricas promedio de los cinco pliegues para los siete modelos.]

5.5.2 Desempeño en el conjunto de prueba

[F_1 , precisión, sensibilidad, especificidad y AUC de los siete modelos, con intervalos bootstrap.]

5.5.3 Brecha entre entrenamiento y prueba

[Cuadro con una fila por modelo y columnas separadas para cada métrica en entrenamiento y en prueba (F_1 , sensibilidad, especificidad y AUC), según el formato del Cuadro 5.1. Interpretar modelo por modelo: una brecha amplia indica sobreajuste; una brecha estrecha, buena generalización. Prestar atención particular al perceptrón multicapa y al bosque aleatorio, que son los más propensos a separar casi perfectamente el conjunto de entrenamiento.]

Table 5.1: Desempeño en entrenamiento y en prueba de los siete modelos de clasificación. Una brecha reducida entre ambas columnas indica ausencia de sobreajuste.

Modelo	F_1		Sensibilidad		Especificidad		AUC	
	Entr.	Prueba	Entr.	Prueba	Entr.	Prueba	Entr.	Prueba
Regresión logística								
Lasso								
Ridge								
Árbol de decisión								
Random Forest								
Gradient boosting								
Perceptrón multicapa								

5.5.4 Desempeño bajo partición temporal

[Resultados del esquema complementario: entrenamiento 1998–2018, prueba 2019–2024. Contrastar con la partición aleatoria y discutir si el modelo generaliza hacia el futuro, dado que la prevalencia asciende a lo largo del período.]

5.5.5 Curvas ROC y precisión-sensibilidad

[Curvas del modelo seleccionado y umbral óptimo.]

5.5.6 Importancia de variables por modelo

[Coeficientes estandarizados, impureza de Gini e importancia por permutación.]

5.5.7 Matrices de confusión

[Las siete matrices sobre el conjunto de prueba.]

5.5.8 Intervalos bootstrap y modelo seleccionado

[Solapamiento de intervalos y justificación del modelo elegido.]

5.5.9 Contraste jerárquico entre el ensamble y el modelo multinivel

[Comparar la correlación intraclase y la razón de momios mediana obtenidas del *gradient boosting* con el departamento codificado frente a las del modelo logístico multinivel de la Sección 5.3. Reportar además la diferencia entre las estimaciones departamentales de ambos enfoques, con atención a los departamentos de menor población, donde se espera que la contracción jerárquica tenga mayor efecto.]

5.6 Análisis de sensibilidad

[Los cinco análisis de la Fase 5: casos completos, restricción temporal, especificación alternativa del ordenamiento social, definición del desenlace y estructura jerárquica.]

Chapter 6

Conclusiones

[Capítulo por redactar tras los resultados.]

6.1 Síntesis de hallazgos

6.2 Respuesta a la pregunta de investigación

6.3 Limitaciones del estudio

Seis limitaciones deben declararse de forma explícita.

Discontinuidad instrumental de la serie. El certificado de nacido vivo se actualizó hacia 2008, de modo que la pertenencia étnica y el régimen de afiliación no están disponibles antes de esa fecha. El análisis de esos dos ejes se restringe a 2008–2024, mientras que la serie completa se reserva para los ejes presentes en todo el período.

Ausencia de medidas directas de posición socioeconómica. El certificado no capta estrato, ingreso del hogar ni ocupación materna. La posición social se aproxima mediante el nivel educativo y el régimen de afiliación, que son indicadores parciales del constructo descrito en la Sección 3.1.

Subregistro de nacimientos. El registro es plausiblemente menos completo en zonas rurales dispersas y en territorios de baja densidad institucional. Si el subregistro se concentra en la población más desfavorecida, la desigualdad estimada constituye una cota

inferior de la real.

Ausencia de variables clínicas del embarazo. No se registran el estado nutricional materno, la anemia, la enfermedad hipertensiva ni las infecciones, lo que impide verificar directamente los mecanismos biológicos discutidos en la Sección 3.2.

Imposibilidad de agrupar por madre. Los certificados de nacido vivo no incluyen un identificador materno único, de modo que no fue posible identificar partos sucesivos de una misma mujer ni aplicar estrategias de partición agrupada en el componente predictivo. En consecuencia, registros correspondientes a una misma madre pueden haber quedado distribuidos entre los conjuntos de entrenamiento y prueba, lo que podría implicar una leve sobreestimación del desempeño predictivo reportado en la Sección 4.4.6. La limitación no es resoluble con los datos disponibles y afecta únicamente al componente predictivo, no a las estimaciones de efecto ni a los índices de desigualdad.

Diseño observacional y transversal. La naturaleza de los datos impide establecer relaciones causales. Las asociaciones estimadas se interpretan bajo los supuestos declarados en la Sección 3.10, que no son verificables con la información disponible.

Chapter 7

Recomendaciones

[Capítulo por redactar a partir de los hallazgos y limitaciones del Capítulo 6.]

7.1 Recomendaciones para autoridades sanitarias e instituciones

7.2 Recomendaciones metodológicas para los sistemas de información

7.3 Líneas de investigación futura

Appendix A

Código fuente y reproducibilidad

Todo el procesamiento y el análisis de este trabajo se desarrollaron en Python 3.9 sobre un entorno virtual aislado. Con el fin de garantizar la reproducibilidad íntegra de los resultados, el código no se reproduce en este documento sino que se publica en un repositorio de acceso abierto.

A.1 Repositorio

Repositorio del proyecto

[Insertar aquí el enlace al repositorio de GitHub]

[Indicar si el repositorio es público desde ya o si se hará público en el momento de la sustentación.]

Ejemplo del formato final:

`https://github.com/usuario/nombre-del-repositorio`

El repositorio se publica bajo licencia abierta y queda archivado con un identificador persistente en el momento de la entrega, de modo que la versión consultada corresponda exactamente a la empleada para producir los resultados reportados en el Capítulo 5.

A.2 Contenido del repositorio

datos/	Instrucciones de descarga de los microdatos desde el portal del DANE. Los archivos originales no se incluyen por su tamaño; el repositorio documenta el catálogo y la versión de cada uno. Incluye <code>crosswalk.yaml</code> , la tabla de correspondencias versionada descrita en la Sección 4.3.1, con los 44 conceptos del esquema canónico y el estado de cada uno en cada versión del instrumento.
scripts/	Rutinas de lectura, armonización de la serie 1998–2024, depuración, recodificación de valores de no informado y construcción de las variables analíticas.
analisis/	Cálculo del índice de concentración y su descomposición, ajuste de los modelos multinivel, entrenamiento y evaluación de los seis modelos de clasificación, y procedimientos de remuestreo.
figuras/	Código de generación de todas las figuras y mapas del documento.
salidas/	Cuadros y resultados en formato reproducible.
requirements.txt	Versiones exactas de todas las bibliotecas empleadas.
README.md	Instrucciones de instalación y orden de ejecución de los scripts.

A.3 Condiciones de reproducibilidad

La semilla aleatoria se fija en todos los procedimientos que involucran aleatoriedad: la partición estratificada, la validación cruzada, el remuestreo bootstrap, la imputación múltiple y el entrenamiento de los modelos de ensamble y de la red neuronal. El archivo `requirements.txt` registra las versiones de cada biblioteca, dado que los resultados de algunos algoritmos pueden variar entre versiones. Con esos dos elementos, la ejecución del repositorio sobre los mismos archivos de entrada reproduce los resultados reportados.

Appendix B

Diccionario consolidado de variables, 1998–2024

Este apéndice consolida los nombres que recibe cada concepto del certificado de nacido vivo en los distintos diccionarios de datos publicados por el DANE entre 1998 y 2024. No modifica los diccionarios originales: los reorganiza en una sola vista para que cada fila permita seguir un mismo concepto a lo largo de toda la serie. La celda con guion indica que el concepto no está presente en ese período. Es la tabla de equivalencias que sostiene la rutina de armonización descrita en la Sección 4.3.1.

Table B.1: Equivalencia de nombres de variable por período, archivos de nacimientos de las Estadísticas Vitales del DANE.

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Departamento de ocurrencia del nacimiento	cod_dpto	COD_DPTO	COD_DPTO	COD_DPTO	COD_DPTO	COD_DPTO	Sin cambios de fondo
Municipio de ocurrencia del nacimiento	cod_munic	COD_MUNIC	COD_MUNIC	COD_MUNIC	COD_MUNIC	COD_MUNIC	Sin cambios de fondo
Área del nacimiento (urbana/rural)	areanac	AREANAC	AREANAC	AREANAC	AREANAC	AREANAC	Sin cambios
Sitio del parto	sit_parto	SIT_PARTO	SIT_PARTO	SIT_PARTO	SIT_PARTO	SIT_PARTO	Sin cambios
Otro sitio del parto, ¿cuál?	–	OTRO_SIT	OTRO_SIT	OTRO_SIT	OTRO_SIT	OTRO_SIT	NUEVA desde 2008; no existía en 1998-2007
Nombre de la institución de salud	nom_inst	–	NOM_INST	–	–	–	Solo en 1998-2007 y 2012-2013
Código de la institución de salud	cod_inst	–	COD_INST	–	–	–	Solo en 1998-2007 y 2012-2013
Sexo del nacido vivo	sexo	SEXO	SEXO	SEXO	SEXO	SEXO	Sin cambios
Peso al nacer	peso_nac	PESO_NAC	PESO_NAC	PESO_NAC	PESO_NAC	PESO_NAC	Sin cambios
Talla al nacer	talla_nac	TALLA_NAC	TALLA_NAC	TALLA_NAC	TALLA_NAC	TALLA_NAC	Sin cambios
Año de ocurrencia	ano	ANO	ANO	ANO	ANO	ANO	Sin cambios
Mes de ocurrencia	mes	MES	MES	MES	MES	MES	Sin cambios
Quién atendió el parto	aten_par	ATEN_PAR	ATEN_PAR	ATEN_PAR	ATEN_PAR	ATEN_PAR	Sin cambios
Atendido por otra persona, ¿cuál?	–	–	OTRPARATX	–	–	–	NUEVA y EXCLUSIVA de 2012-2013
Tiempo de gestación	t_ges	T_GES	T_GES	T_GES	T_GES	T_GES	Sin cambios

continúa en la página siguiente

Cuadro B.1 (continuación)

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Tiempo de gestación – agrupado (CIE)		T_GES_AGRU_CIE –	–	–	T_GES_AGRU_CIE	T_GES_AGRU_CIE	NUEVA desde 2008; ausente en 2012-2013 y en 2020
N° de consultas prena- tales	numconsul	NUMCONSUL	NUMCONSUL	NUMCONSUL	NUMCONSUL	NUMCONSUL	Sin cambios
Tipo de parto	tipo_parto	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	Sin cambios
Multiplicidad del em- barazo	mul_parto	MUL_PARTO	MUL_PARTO	MUL_PARTO	MUL_PARTO	MUL_PARTO	Sin cambios
APGAR al minuto	apgar1	APGAR1	APGAR1	APGAR1	APGAR1	APGAR1	Sin cambios
APGAR a los 5 minu- tos	apgar2	APGAR2	APGAR2	APGAR2	APGAR2	APGAR2	Sin cambios
Grupo sanguíneo del nacido vivo	gru_san	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	1998-2007 unía grupo+factor en 1 variable; desde 2008 se separó en 2
Factor RH del nacido (incluido en vivo	gru_san)	IDFACTORRH	IDFACTORRH	IDFACTORRH	IDFACTORRH	IDFACTORRH	NUEVA como variable independiente desde 2008 (antes iba dentro de gru_san)
Reconocimiento étnico – del nacido vivo		IDPERTET	IDPUEBLOIN	IDPERTET	IDPERTET	IDPERTET	NUEVA desde 2008; renombrada en 2012- 2013 (IDPUEBLOIN)
País de nacimiento de – la madre		–	–	–	–	CODPAISNACMAD	NUEVA y EXCLUSIVA de 2024

continúa en la página siguiente

Cuadro B.1 (continuación)

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Edad de la madre	edad_madre	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	Sin cambios
Estado civil/conyugal de la madre	est_civm	EST_CIVM	EST_CIVM	EST_CIVM	EST_CIVM	EST_CIVM	Categorías ampliadas desde 2008 (ver hoja Categorías)
Nivel educativo de la madre	niv_edum	NIV_EDUM	NIV_EDUM	NIV_EDUM	NIV_EDUM	NIV_EDUM	Categorías ampliadas de 9 a 14 desde 2008 (ver hoja Categorías)
Último año/grado – aprobado por la madre		ULTCURMAD	ULTCURMAD	ULTCURMAD	ULTCURMAD	ULTCURMAD	NUEVA desde 2008; no existía en 1998-2007
País de residencia de la madre (extranjero)	codpres	CODPRES	CODPRES	CODPRES	CODPRES	CODPRES	Sin cambios
Departamento de residencia de la madre	codptore	CODPTORE	CODPTORE	CODPTORE	CODPTORE	CODPTORE	Sin cambios
Municipio de residencia de la madre	codmunre	CODMUNRE	CODMUNRE	CODMUNRE	CODMUNRE	CODMUNRE	Sin cambios
Área de residencia de la madre	area_res	AREA_RES	AREA_RES	AREA_RES	AREA_RES	AREA_RES	Sin cambios
N° de hijos nacidos vivos	n_hijosv	N_HIJOSV	N_HIJOSV	N_HIJOSV	N_HIJOSV	N_HIJOSV	Sin cambios
Fecha de nacimiento del hijo anterior	fecha_nacm	FECHA_NACM	FECHA_NACM	FECHA_NACM	FECHA_NACM	FECHA_NACM	Sin cambios
N° de embarazos	n_emb	N_EMB	N_EMB	N_EMB	N_EMB	N_EMB	Sin cambios

continúa en la página siguiente

Cuadro B.1 (continuación)

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Régimen de seguridad social de la madre	seg_social	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	Categorías cambiaron con la Ley 100/reformas de salud (ver hoja Categorías)
Entidad administradora en salud de la madre	–	IDCLASADMI	IDCLASADMI	IDCLASADMI	IDCLASADMI	IDCLASADMI	NUEVA desde 2008; no existía en 1998-2007
Nombre de la entidad administradora	–	–	NOMCLASAD	–	–	–	NUEVA y EXCLUSIVA de 2012-2013
Edad del padre	edad_padre	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	Sin cambios
Nivel educativo del padre	niv_edup	NIV_EDUP	NIV_EDUP	NIV_EDUP	NIV_EDUP	NIV_EDUP	Mismo patrón de ampliación que NIV_EDUM
Último año/grado aprobado por el padre	–	ULTCURPAD	ULTCURPAD	ULTCURPAD	ULTCURPAD	ULTCURPAD	NUEVA desde 2008; no existía en 1998-2007
Profesión de quien certifica el nacimiento	profesion	PROFESION	PROFESION	PROFESION	PROFESION	PROFESION	Sin cambios
Fuente del certificado (tipo de formulario)	–	–	–	–	TIPOFORMULARIO	TIPOFORMULARIO	NUEVA desde 2021

Bibliography

- Alam, M. J., Islam, M. M., Maniruzzaman, M., Ahmed, N. A. M. F., Tawabunnahar, M., Rahman, M. J., et al. (2022). Socioeconomic inequality in the prevalence of low birth weight and its associated determinants in Bangladesh. *PLoS ONE*, 17(10):e0276718.
- Amjad, S., MacDonald, I., Chambers, T., Osornio-Vargas, A., Chandra, S., Voaklander, D., et al. (2019). Social determinants of health and adverse maternal and birth outcomes in adolescent pregnancies: a systematic review and meta-analysis. *Paediatric and Perinatal Epidemiology*, 33(1):88–99.
- Barros, A. J. D. and Hiraakata, V. N. (2003). Alternatives for logistic regression in cross-sectional studies: an empirical comparison of models that directly estimate the prevalence ratio. *BMC Medical Research Methodology*, 3:21.
- Blencowe, H., Krusevec, J., de Onis, M., Black, R. E., An, X., Stevens, G. A., et al. (2019). National, regional, and worldwide estimates of low birthweight in 2015, with trends from 2000: a systematic analysis. *The Lancet Global Health*, 7(7):e849–e860.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth & Brooks/Cole, Monterey, CA.
- Castro-Delgado, Ó. E., Salas-Delgado, Í., Acosta-Argoty, F. A., Delgado-Noguera, M., and Calvache, J. A. (2016). Muy bajo y extremo bajo peso al nacer. *Pediatría*, 49(1):23–30.
- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Chen, T. and Guestrin, C. (2016). XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.

- Comisión sobre Determinantes Sociales de la Salud (2008). Subsanan las desigualdades en una generación: alcanzar la equidad sanitaria actuando sobre los determinantes sociales de la salud. Technical report, Organización Mundial de la Salud, Ginebra.
- Cozzani, M. (2023). Inequalities at birth: stable socioeconomic differences in birth outcomes in three British cohorts. *Genus*, 79:18.
- Departamento Administrativo Nacional de Estadística (2025). Estadísticas Vitales — EEVV: microdatos de nacimientos, 1998–2024. Base de datos en internet. Bogotá: DANE.
- Efron, B. (1979). Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, 7(1):1–26.
- Engdaw, G. T., Tesfaye, A. H., Feleke, M., Negash, A., Yeshiwas, A., Addis, W., et al. (2023). Effect of antenatal care on low birth weight: a systematic review and meta-analysis in africa, 2022. *Frontiers in Public Health*, 11:1158809.
- Erreygers, G. (2009). Correcting the concentration index. *Journal of Health Economics*, 28(2):504–515.
- Godah, M. W., Beydoun, Z., Abdul-Khalek, R. A., Safieddine, B., Khamis, A. M., and Abdulrahim, S. (2021). Maternal education and low birth weight in low- and middle-income countries: systematic review and meta-analysis. *Maternal and Child Health Journal*, 25(8):1305–1315.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge, MA.
- Guarnizo-Herreño, C. C., Torres, G., and Buitrago, G. (2021). Socioeconomic inequalities in birth outcomes: an 11-year analysis in Colombia. *PLoS ONE*, 16(7):e0255150.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition.
- Heredia-Olivera, K. and Munares-García, O. (2016). Factores maternos asociados al bajo peso al nacer. *Revista Médica del Instituto Mexicano del Seguro Social*, 54(5):562–567.
- Hernán, M. A. and Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC, Boca Raton, FL.

- Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.
- Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons, Hoboken, NJ, 3 edition.
- Huang, X., Liu, J., Qi, L., Adachi, J. D., Wu, J., Li, Z., Meng, Q., Li, G., and Lip, G. Y. H. (2022). Birth weight and the risk of cardiovascular outcomes: a report from the large population-based UK Biobank cohort study. *Frontiers in Cardiovascular Medicine*, 9:827491.
- Jiménez García, R., Alfonso Novo, L., Peñalver, R., and Santana Porbén, S. (2017). El bajo peso al nacer y la programación temprana de la vida, un problema de actualidad y del futuro. *Revista Cubana de Pediatría*, 89(2):241–251.
- Kakwani, N., Wagstaff, A., and van Doorslaer, E. (1997). Socioeconomic inequalities in health: measurement, computation, and statistical inference. *Journal of Econometrics*, 77(1):87–103.
- Kassie, G. A., Gebrekidan, A. Y., Adella, G. A., Woldegeorgis, B. Z., Haile, K. E., Workineh, A., and Asgedom, Y. S. (2025). Socioeconomic inequality and determinants of low birth weight in Kenya: a multilevel analysis using 2022 demographic and health survey. *Italian Journal of Pediatrics*, 51(1):222.
- Knop, M. R., Geng, T.-T., Gorny, A. W., Ding, R., Li, C., Ley, S. H., and Huang, T. (2018). Birth weight and risk of type 2 diabetes mellitus, cardiovascular disease, and hypertension in adults: a meta-analysis of 7 646 267 participants from 135 studies. *Journal of the American Heart Association*, 7(23):e008870.
- Merlo, J., Chaix, B., Ohlsson, H., Beckman, A., Johnell, K., Hjerpe, P., et al. (2006). A brief conceptual tutorial of multilevel analysis in social epidemiology: using measures of clustering in multilevel logistic regression to investigate contextual phenomena. *Journal of Epidemiology and Community Health*, 60(4):290–297.
- Núñez Rivas, H. P. and Morice Trejos, A. C. (1999). Bajo peso al nacer: un indicador de riesgo biológico y social. Technical Report Serie de documentos técnicos del Inciensa 3, Instituto Costarricense de Investigación y Enseñanza en Nutrición y Salud, Tres Ríos, Costa Rica.

- Okwaraji, Y. B., Krasevec, J., Bradley, E., Conkle, J., Stevens, G. A., Gatica-Domínguez, G., et al. (2024). National, regional, and global estimates of low birthweight in 2020, with trends from 2000: a systematic analysis. *The Lancet*, 403(10431):1071–1080.
- Organización Mundial de la Salud (2014). Metas mundiales de nutrición 2025: documento normativo sobre bajo peso al nacer. Technical Report WHO/NMH/NHD/14.5, Organización Mundial de la Salud, Ginebra.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Pérez Martínez, M., Basain Valdés, J. M., and Calderón Chappotin, G. C. (2018). Factores de riesgo del bajo peso al nacer. *Acta Médica del Centro*, 12(3):369–382.
- Rodríguez López, S., Tumas, N., Ortigoza, A., de Lima Friche, A. A., and Diez-Roux, A. V. (2021). Urban social environment and low birth weight in 360 Latin American cities. *BMC Public Health*, 21(1):795.
- Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3):581–592.
- Santos-Antonio, G., Alvis-Chirinos, K., Aguilar-Esenarro, L., Bautista-Olórtegui, W., Velarde-Delgado, P., and Aramburu, A. (2020). Ganancia de peso gestacional como predictor de macrosomía y bajo peso al nacer: revisión sistemática. *Revista Peruana de Medicina Experimental y Salud Pública*, 37(3):403–411.
- Sathi, N. J., Ahammed, B., Alam, K., Hashmi, R., Lee, K.-Y., and Keramat, S. A. (2022). Socioeconomic inequalities in low birth weight in South Asia: a comparative analysis using Demographic and Health Surveys. *SSM — Population Health*, 20:101248.
- Solar, O. and Irwin, A. (2010). A conceptual framework for action on the social determinants of health. Technical Report Social Determinants of Health Discussion Paper 2, Organización Mundial de la Salud, Ginebra.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288.
- Ticona Rendón, M., Huanco Apaza, D., and Ticona Vildoso, M. (2012). Incidencia y factores de riesgo de bajo peso al nacer en población atendida en hospitales del Ministerio de Salud del Perú. *Ginecología y Obstetricia de México*, 80(2):51–60.

- Urdaneta Machado, J. R., Lozada Reyes, M., Cepeda de Villalobos, M., García, J., Villalobos, N., Contreras Benítez, A., et al. (2015). Anemia materna y peso al nacer en productos de embarazo a término. *Revista Chilena de Obstetricia y Ginecología*, 80(4):297–305.
- van Buuren, S. and Groothuis-Oudshoorn, K. (2011). mice: multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3):1–67.
- VanderWeele, T. J. (2015). *Explanation in Causal Inference: Methods for Mediation and Interaction*. Oxford University Press, New York.
- Velásquez, N., Masud, J., and Ávila, R. (2004). Recién nacidos con bajo peso; causas, problemas y perspectivas a futuro. *Boletín Médico del Hospital Infantil de México*, 61(1):73–86.
- Wagstaff, A. (2005). The bounds of the concentration index when the variable of interest is binary, with an application to immunization inequality. *Health Economics*, 14(4):429–432.
- Wagstaff, A., van Doorslaer, E., and Watanabe, N. (2003). On decomposing the causes of health sector inequalities with an application to malnutrition inequalities in Vietnam. *Journal of Econometrics*, 112(1):207–223.
- Zhang, X., Shah, A. A., and Han, L. (2025). Exploring socio-economic inequalities in low birth weight: a statistical decomposition approach. *American Journal of Human Biology*, 37(12):e70173.
- Zhou, Y., Mendonça, M., Tsalacopoulos, N., Bartmann, P., Darlow, B. A., Harris, S. L., et al. (2025). Socioeconomic outcomes in very preterm/very low birth weight adults: individual participant data meta-analysis. *Pediatric Research*, 98:2401–2413.