

Universidad del Norte

Trabajo de profundización

Desigualdades socioeconómicas, étnicas y territoriales en el bajo peso al nacer en Colombia: análisis multinivel y predictivo de las estadísticas vitales, 1998–2024

Autor:

Gregory Jesús Meléndez

Supervisor:

Lihki José Rubio Ortega

*Trabajo presentado en cumplimiento de los requisitos
para el grado de Maestría en Estadística Aplicada*

Facultad de Ciencias Básicas

Departamento de Matemáticas y Estadística

19 de septiembre de 2026

Resumen

El bajo peso al nacer (BPN) es uno de los indicadores más sensibles de la salud materno-infantil y un predictor robusto de mortalidad neonatal, rezago del desarrollo infantil y enfermedad crónica en la adultez. En Colombia, país de ingreso mediano con una desigualdad marcada, la investigación nacional se ha concentrado en factores biológicos y clínicos y ha aprovechado poco el potencial de los registros poblacionales para examinar de manera integral los determinantes sociales del problema. Este estudio analizó la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia entre 1998 y 2024, a partir de los microdatos de nacimientos de las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística. Se trata de un estudio observacional, analítico, de corte transversal repetido, con estructura jerárquica de tres niveles: nacimientos anidados en municipios y municipios anidados en departamentos. Las variables candidatas se sometieron previamente a un cribado por información mutua, contrastada frente a una distribución nula obtenida por permutación, para documentar tanto su asociación con el desenlace como su redundancia entre sí. La desigualdad socioeconómica se cuantificó mediante el índice de concentración con corrección de Erreygers, el índice de desigualdad de la pendiente y el índice relativo de desigualdad, y se descompuso siguiendo el procedimiento de Wagstaff, van Doorslaer y Watanabe. Los efectos independientes de cada determinante se estimaron mediante una secuencia de modelos logísticos multinivel, y la variación contextual se expresó mediante la correlación intraclase, la razón de momios mediana y el cambio proporcional en la varianza. De forma complementaria se evaluó la capacidad de identificar un nacimiento en riesgo a partir de la información disponible en el certificado de nacido vivo, y en qué medida los determinantes sociales contribuyen a esa identificación por encima de la información clínica, comparando siete modelos de clasificación supervisada: regresión logística, regresión logística con penalización lasso y ridge, árbol de decisión, bosque aleatorio, *gradient boosting* y perceptrón multicapa, con hiperparámetros fijados en valores convencionales. El desbalance del desenlace se compensó mediante ponderación de clases en los seis modelos que la admiten y mediante el umbral de decisión en el perceptrón multicapa, que no la implementa. Los intervalos de confianza

de los índices de desigualdad, de las contribuciones de la descomposición y de las métricas de desempeño se obtuvieron por remuestreo bootstrap. En los índices de desigualdad y en la descomposición se empleó un bootstrap paramétrico sobre los datos agrupados, que es el procedimiento adecuado para un desenlace binario agregado en celdas y el único viable sobre diecisiete millones de registros; en la comparación de modelos de clasificación, un bootstrap no paramétrico sobre el conjunto de prueba. De los 18,008,809 nacidos vivos registrados en el período, la muestra analítica retuvo 17,376,860 (96,49 %). La prevalencia global de bajo peso al nacer fue del 8,78 % (IC 95 %: 8,77–8,79) y ascendió del 7,64 % en 1998 al 11,15 % en 2024, con un cambio porcentual anual del +1,18 % (IC 95 %: +0,98 a +1,38). Una regresión segmentada identificó tres puntos de unión (2010, 2014 y 2020) y un último tramo que crece al +4,97 % anual, coincidente con el período de mayor deterioro de la cobertura del registro.

El índice de concentración según el nivel educativo materno fue de +0,0174 (Erreygers +0,0061) y el índice de desigualdad de la pendiente de +1,17 puntos porcentuales. El signo positivo indica concentración del desenlace hacia el extremo más educado de la distribución, patrón contrario al gradiente social clásico y ya presente en la descripción: la prevalencia por nivel educativo no desciende de forma monótona al ascender por la escala (9,40, 8,16, 8,80 y 9,20 %). Las cotas calculadas sin supuesto alguno sobre el mecanismo de ausencia de datos situaron el índice entre +0,0132 y +0,0191.

La descomposición atribuyó el mayor aporte a la paridad (+0,01529; 84,1 % del índice), seguida del régimen de afiliación (+0,00696) y del área de residencia (+0,00410); el nivel educativo contribuyó en sentido contrario (−0,00343). El contraste entre la multiplicidad del embarazo (razón de momios de 19,96 y contribución del 4,9 %) y la paridad ilustra que un factor de riesgo que no está socialmente distribuido genera morbilidad pero no desigualdad.

La variación territorial resultó modesta: la correlación intraclase fue del 1,79 % en el nivel municipal y del 0,86 % en el departamental, con una razón de momios mediana entre municipios de 1,197, inferior a la razón de momios de la soltería materna (1,257). El ajuste por edad materna, paridad y multiplicidad *ordenó* el gradiente educativo en lugar de atenuarlo (de 0,857/0,858/0,874 a 0,854/0,834/0,808), comportamiento propio de covariables de confusión y no de mediadores. La pertenencia étnica no aportó información por encima del municipio de residencia.

El resultado central del trabajo es que el gradiente educativo **se invirtió entre 2018 y 2019**: el índice de concentración pasó de +0,00123 en 1998 a −0,00651 en 2024. La descomposición por subperíodos mostró que la inversión procede de que la contribución

propia de la educación se cuadruplica mientras el contrapeso de la paridad se debilita, y el cambio de signo se observó también dentro de cada régimen de codificación del formulario, lo que descarta un artefacto del instrumento. El gradiente por régimen de afiliación, en cambio, se mantuvo positivo los veintisiete años. Se documenta además una ruptura de codificación en 2008 cuya omisión invalidaría cualquier comparación de la serie. [ME FALTA UN PÁRRAFO con el resultado de la Fase 7, cuando la corra. Va aquí, antes de las palabras clave: AUC-PR del mejor modelo frente a la línea base de 0,0878, si los ensambles superan a la logística, y qué aporta el bloque social por encima del clínico.]

Palabras clave: bajo peso al nacer, determinantes sociales de la salud, desigualdad en salud, índice de concentración, modelos multinivel, aprendizaje automático, estadísticas vitales.

Abstract: Low birth weight (LBW) is one of the most sensitive indicators of maternal and child health and a robust predictor of neonatal mortality, impaired child development, and chronic disease in adulthood. In Colombia, a middle-income country with marked inequality, national research has focused on biological and clinical factors and has made limited use of population registers to examine the social determinants of the problem in an integrated way. This study analysed the association between the social determinants of health and low birth weight in Colombia between 1998 and 2024, using birth microdata from the Vital Statistics (EEVV) of the National Administrative Department of Statistics. This is an observational, analytical, repeated cross-sectional study with a three-level hierarchical structure: births nested within municipalities and municipalities nested within departments. Candidate variables were first screened by mutual information, contrasted against a permutation-based null distribution, to document both their association with the outcome and their redundancy with one another. Socioeconomic inequality was quantified using the concentration index with Erreygers correction, the slope index of inequality and the relative index of inequality, and was decomposed following the Wagstaff, van Doorslaer and Watanabe procedure. The independent effects of each determinant were estimated through a sequence of multilevel logistic models, and contextual variation was expressed through the intraclass correlation, the median odds ratio and the proportional change in variance. Confidence intervals for the inequality indices and for the decomposition contributions were obtained through a parametric bootstrap on the aggregated data, the appropriate procedure for a binary outcome aggregated into cells and the only one feasible over seventeen million records; model comparison used a nonparametric bootstrap on the test set.

Of the 18,008,809 live births recorded over the period, the analytic sample retained 17,376,860 (96.49 %). The overall prevalence of low birth weight was 8.78 % (95 % CI: 8.77–8.79), rising from 7.64 % in 1998 to 11.15 % in 2024, with an annual percent change of +1.18 % (95 % CI: +0.98 to +1.38). Segmented regression identified three joinpoints (2010, 2014 and 2020) and a final segment rising at +4.97 % per year, coinciding with the period of greatest deterioration in registration coverage.

The concentration index by maternal education was +0.0174 (Erreygers +0.0061) and the slope index of inequality was +1.17 percentage points. The positive sign indicates that the outcome concentrates towards the more educated end of the distribution, a pattern contrary to the classic social gradient and already present in the descriptive data: prevalence by educational level does not decrease monotonically along the scale (9.40, 8.16, 8.80 and 9.20 %). Bounds computed without any assumption about the missing data mechanism placed the index between +0.0132 and +0.0191.

The decomposition attributed the largest share to parity (+0.01529; 84.1 % of the index), followed by health insurance scheme and area of residence; maternal education contributed in the opposite direction (−0.00343). Territorial variation was modest: the intraclass correlation was 1.79 % at the municipal level and 0.86 % at the departmental level, with a median odds ratio between municipalities of 1.197, lower than the odds ratio for unmarried motherhood (1.257). Adjustment for maternal age, parity and plurality *ordered* the educational gradient rather than attenuating it, a behaviour consistent with confounding covariates rather than mediators. Ethnic identification added no information beyond municipality of residence.

The central finding is that the educational gradient **reversed between 2018 and 2019**: the concentration index moved from +0.00123 in 1998 to −0.00651 in 2024. The decomposition by subperiod showed that the reversal arises because education's own contribution quadruples while parity's counterweight weakens, and the sign change was also observed within each coding regime of the certificate, which rules out an instrument artefact. The gradient by health insurance scheme, by contrast, remained positive throughout the twenty-seven years. A 2008 coding discontinuity is further documented, the omission of which would invalidate any comparison across the series.

Keywords: low birth weight, social determinants of health, health inequality, concentration index, multilevel models, machine learning, vital statistics.

Dedicatoria

A cada niño que llega al mundo con menos de lo que merece: que esta investigación aporte, aunque sea una cifra, a la causa de una vida más justa desde el primer día.

A las familias colombianas cuyos nacimientos son mucho más que un dato en un registro: son la razón y el sentido de este trabajo.

A quienes creen que el conocimiento puede reducir las desigualdades y transformar la salud de los que menos tienen.

A la investigación, labor callada que rara vez recibe aplausos, pero sobre cuyos hombros se ha construido cada avance de la humanidad.

Y a los investigadores: a los que trabajan de noche cuando el mundo duerme, a los que insisten donde otros abandonan, a los que dedican una vida entera para que una sola verdad quede en pie.

Este esfuerzo se suma, con humildad, a esa larga cadena de manos anónimas que empujan la historia hacia adelante.

Agradecimientos

A Dios, por otorgarme la fortaleza, la sabiduría y la perseverancia necesarias para culminar con éxito este camino de formación académica.

A mi esposa, Grace Kelly, por su apoyo constante y por ser el sostén sereno que me acompañó en cada momento de este proceso.

A mis hijos, por ser el motor de amor, comprensión y apoyo incondicional en mis horas de esfuerzo, y la razón más profunda de mi superación constante. A mi familia, por su paciencia infinita, confianza y por brindarme un aliento inquebrantable en cada paso del camino.

A mis compañeros de trabajo, y a mis profesores y compañeros de maestría, por su respaldo y comprensión, y por cada conversación y aporte del que me llevo algo que dejó mejor no solo al proyecto, sino a la persona que lo escribió.

Asimismo, extendiendo mi sincero reconocimiento a todas las personas e instituciones que, de manera directa o indirecta, brindaron su colaboración y apoyo para la feliz realización de este estudio.

Índice general

Resumen	I
Dedicatoria	V
Agradecimientos	VI
Abreviaturas y siglas	XIX
1. Introducción	1
1.1. Planteamiento del problema	3
1.1.1. Delimitación del objeto de estudio	4
1.1.2. La oportunidad de las Estadísticas Vitales	5
1.1.3. Pregunta general de investigación	6
1.1.4. Preguntas específicas	6
1.2. Justificación	7
1.2.1. Relevancia sanitaria	7
1.2.2. Relevancia distributiva	7
1.2.3. Relevancia metodológica	8
1.2.4. Relevancia para la política pública	8
1.2.5. Resultados esperados	9
2. Objetivos	10
2.1. Objetivo general	10
2.2. Objetivos específicos	10

3. Marco teórico	12
3.1. Determinantes sociales de la salud: marco conceptual	12
3.2. El bajo peso al nacer: definición, mecanismos y delimitación	14
3.2.1. Los dos mecanismos	14
3.2.2. Delimitación del desenlace en este estudio	15
3.2.3. El bajo peso al nacer como indicador social	15
3.3. Medidas de asociación en epidemiología	16
3.4. Análisis bivariado y colinealidad	16
3.4.1. Prueba χ^2 y coeficiente V de Cramér	16
3.4.2. Información mutua	17
3.5. Medición de la desigualdad socioeconómica en salud	21
3.6. Descomposición de la desigualdad	22
3.7. Modelos de regresión multinivel	22
3.8. Modelos de clasificación supervisada	23
3.8.1. Notación	24
3.8.2. Regresión logística	24
3.8.3. Regresión logística penalizada: Lasso	25
3.8.4. Regresión logística penalizada: Ridge	25
3.8.5. Árboles de decisión	26
3.8.6. Random Forest	27
3.8.7. Gradient boosting	27
3.8.8. Redes neuronales artificiales	28
3.8.9. Contraste jerárquico entre el modelo multinivel y el ensamble	29
3.9. Estrategia de validación y métricas de evaluación	30
3.9.1. Partición estratificada y validación cruzada	30
3.9.2. Manejo del desbalance de clases	31
3.9.3. Métricas de evaluación	31
3.10. Confusión, mediación y estrategia de modelos anidados	32
3.10.1. Confusor y mediador	32
3.10.2. Efecto total y efecto directo	32

3.10.3. Consecuencia para la estrategia de modelos anidados	33
3.11. Tratamiento de datos faltantes	34
3.11.1. Mecanismos de ausencia	34
3.11.2. Relevancia en esta fuente	35
3.11.3. Imputación múltiple por ecuaciones encadenadas	35
3.12. Estimación de intervalos de confianza por bootstrap	36
4. Metodología	38
4.1. Enfoque y diseño	38
4.2. Descripción de los datos	39
4.2.1. Fuente y período	39
4.2.2. Población y muestra	39
4.2.3. Variables del estudio	42
4.3. Preparación y depuración de los datos	44
4.3.1. Armonización de la serie 1998–2024	44
4.3.2. Consistencia y validación	50
4.3.3. Codificación territorial	52
4.3.4. Tratamiento de los valores faltantes	52
4.3.5. Infraestructura de datos	56
4.3.6. Construcción de la matriz analítica	57
4.3.7. Trazabilidad y reproducibilidad del procesamiento	64
4.4. Análisis estadístico	65
4.4.1. Fase 1. Análisis descriptivo y de tendencia	65
4.4.2. Fase 2. Cribado de variables por información mutua	65
4.4.3. Fase 3. Medición de la desigualdad socioeconómica	68
4.4.4. Fase 4. Modelos de regresión logística multinivel	69
4.4.5. Fase 5. Descomposición de la desigualdad	72
4.4.6. Fase 6. Análisis de sensibilidad	72
4.4.7. Fase 7. Comparación de modelos de clasificación	73
4.5. Software y reproducibilidad	79
4.6. Consideraciones éticas	79

5. Resultados	81
5.1. Análisis descriptivo	81
5.1.1. Conformación de la muestra y completitud	81
5.1.2. Distribución de la variable respuesta	82
5.1.3. Caracterización sociodemográfica de las madres	83
5.1.4. Tendencia temporal de la prevalencia, 1998–2024	84
5.1.5. Distribución territorial	87
5.2. Cribado de variables por información mutua	89
5.2.1. Cribado por información mutua	91
5.3. Desigualdad socioeconómica	92
5.3.1. Prevalencia según posición socioeconómica	93
5.3.2. Índice y curva de concentración	93
5.3.3. Índice de desigualdad de la pendiente e índice relativo	95
5.3.4. Evolución de la desigualdad en el período	96
5.4. Modelos multinivel	98
5.4.1. Modelo 0. Variación municipal y departamental	99
5.4.2. Modelo 1. Efecto total de la posición social	100
5.4.3. Modelo 2. Efecto independiente tras el ajuste obstétrico	101
5.4.4. Modelo 3. Efecto social descontada la composición étnica	104
5.4.5. Modelo 4. Efecto directo tras el ajuste por atención prenatal	105
5.4.6. Comparación de ajuste y cambio proporcional en la varianza	106
5.4.7. Contraste con la desigualdad territorial observada	108
5.5. Descomposición de la desigualdad	108
5.5.1. Contribución de cada determinante	109
5.5.2. Elasticidades y distribución de los determinantes	111
5.5.3. Reparto por subperíodo	111
5.6. Comparación de modelos de clasificación	113
5.6.1. Desempeño en validación cruzada	113
5.6.2. Desempeño en el conjunto de prueba	114
5.6.3. Brecha entre entrenamiento y prueba	114

5.6.4.	Desempeño bajo partición temporal	114
5.6.5.	Curvas ROC y precisión-sensibilidad	114
5.6.6.	Importancia de variables por modelo	115
5.6.7.	Matrices de confusión	115
5.6.8.	Contraste de la especificación categórica	115
5.6.9.	Intervalos bootstrap y modelo seleccionado	115
5.6.10.	Contraste jerárquico entre el ensamble y el modelo multinivel	115
5.7.	Análisis de sensibilidad	115
5.7.1.	Especificación alternativa de la variable de ordenamiento	115
6.	Conclusiones	120
6.1.	Magnitud y evolución del bajo peso al nacer	120
6.2.	Magnitud de la desigualdad socioeconómica	121
6.3.	Efectos independientes de los determinantes sociales	122
6.4.	Reparto de la desigualdad entre determinantes	123
6.5.	La dimensión territorial	123
6.6.	La dimensión étnica	124
6.7.	Capacidad predictiva	125
6.8.	Contribuciones del trabajo	125
6.9.	Limitaciones del estudio	126
6.10.	Alcance de las conclusiones	129
7.	Recomendaciones	130
7.1.	Recomendaciones metodológicas para los sistemas de información	130
7.2.	Recomendaciones para autoridades sanitarias e instituciones	131
7.3.	Líneas de investigación futura	132
A.	Código fuente y reproducibilidad	134
A.1.	Repositorio	134
A.2.	Contenido del repositorio	134
A.3.	Atlas interactivo del bajo peso al nacer	135
A.4.	Condiciones de reproducibilidad	137

B. Validación del estimador multinivel	138
B.1. Limitaciones de las implementaciones disponibles	138
B.2. Estrategia de estimación	139
B.3. Verificación de la agregación binomial	140
B.4. Validación mediante simulación	141
B.5. Contraste de la aproximación de Laplace	142
B.6. Síntesis	143
C. Resultados completos generados por el código	144
C.1. Modelos multinivel	144
C.2. Descomposición de la desigualdad	147
C.3. Desigualdad territorial	148
D. Diccionario consolidado de variables, 1998–2024	149
Bibliografía	152
Mis pendientes	159

Índice de figuras

3.1. Grafo acíclico dirigido con la estructura causal supuesta. La flecha discontinua representa el efecto contextual del territorio, que los modelos multinivel de la Sección 3.7 estiman como varianza de nivel superior.	33
4.1. Evolución del número de variables del archivo de nacimientos de las Estadísticas Vitales, 1998–2024. Elaboración propia a partir de los diccionarios de datos publicados por el DANE para cada catálogo (Departamento Administrativo Nacional de Estadística, 2025).	47
4.2. Efecto de la armonización sobre el nivel educativo materno	49
4.3. Efecto de la armonización sobre el estado conyugal	50
4.4. Efecto de la armonización sobre el régimen de afiliación	50
4.5. Completitud de las variables por año, 1998–2024	53
4.6. Nivel educativo materno por código original, 1998–2024	60
4.7. Régimen de afiliación por código original, 1998–2024	62
4.8. Estado conyugal por código original, 1998–2024	62
4.9. Área de residencia por código original, 1998–2024	63
5.1. Prevalencia anual de bajo peso al nacer, 1998–2024	84
5.2. Volumen de nacimientos registrados y prevalencia observada	85
5.3. Regresión de puntos de unión sobre la prevalencia anual	86
5.4. Prevalencia municipal de bajo peso al nacer, 1998 y 2024	87
5.5. Prevalencia departamental de bajo peso al nacer, 1998 y 2024	88
5.6. Matriz de asociación entre variables	90
5.7. Matriz de interacción entre pares de variables	91
5.8. Curva de concentración del bajo peso al nacer según nivel educativo	94

5.9. Índice de desigualdad de la pendiente según nivel educativo	95
5.10. Evolución anual de la desigualdad educativa y de la prevalencia, 1998–2024	97
5.11. Contribución de cada determinante al índice de concentración	109
5.12. Reparto de la desigualdad educativa por subperíodo	112
5.13. Desigualdad según la variable de ordenamiento socioeconómico	116

Índice de cuadros

3.1. Correspondencia entre el modelo de determinantes sociales de la salud (Solar and Irwin, 2010) y las variables del certificado de nacido vivo. Elaboración propia.	13
4.1. Conformación de la muestra analítica. Nacidos vivos registrados en las Estadísticas Vitales del DANE, 1998–2024. Los porcentajes se calculan sobre la base original. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	40
4.2. Variables de exposición y su operacionalización en los microdatos de nacimientos de las EEVV. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	43
4.3. Catálogos de microdatos de nacimientos publicados por el DANE y número de variables del archivo correspondiente. Elaboración propia a partir de los diccionarios de datos publicados en el portal de microdatos (Departamento Administrativo Nacional de Estadística, 2025).	47
4.4. Variables incorporadas al certificado de nacido vivo con posterioridad a 1998. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	48
4.5. Variables presentes en algunos períodos y ausentes en otros. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	49

4.6. Categorías de la variable PESO_NAC en los microdatos de las EEVV. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	51
4.7. Descomposición de los valores faltantes según su origen. La pertenencia étnica presenta 40,1 % de nulos sobre la serie completa y <i>ninguna</i> no respuesta. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	55
4.8. Composición de la matriz. La capa base preserva los datos publicados; la capa analítica es la que alimenta los modelos. Elaboración propia.	57
4.9. Variables con ruptura semántica en 2008. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	58
4.10. Regímenes de codificación identificados y volumen de registros. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	59
4.11. Efecto de la recodificación de las categorías de no informado sobre las variables de interés analítico. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	60
4.12. Significado de los códigos de NIV_EDUM antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	61
4.13. Significado de los códigos de SEG_SOCIAL antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	61
4.14. Significado de los códigos de EST_CIVM antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	63
5.1. Completitud de las variables del análisis en años seleccionados, en porcentaje de registros informados. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	82

5.2. Distribución de la población y prevalencia de bajo peso al nacer según los determinantes sociales, 1998–2024. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	83
5.3. Cambio porcentual anual por tramo y estabilidad de cada punto de unión en 500 réplicas. Elaboración propia.	86
5.4. Cribado por información mutua. La incertidumbre simétrica normaliza la información mutua por las entropías marginales; la razón frente al nulo compara el valor observado con el percentil 95 de la distribución obtenida por permutación. Elaboración propia.	92
5.5. Índices de desigualdad según el nivel educativo materno, con intervalos bootstrap del 95 %. Elaboración propia.	94
5.6. Componentes de varianza del modelo vacío. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	99
5.7. Razones de momios del Modelo 2, ajustadas por edad materna, paridad y multiplicidad. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	101
5.8. Razones de momios de la pertenencia étnica en el Modelo 3, referidas a la categoría indígena. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	104
5.9. Gradiente educativo antes y después del ajuste por atención prenatal. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	105
5.10. Criterios de información de los cinco ajustes y de los tres modelos auxiliares. Elaboración propia.	107
5.11. Cambio proporcional en la varianza entre modelos ajustados sobre la misma submuestra. Elaboración propia.	107
5.12. Contribución de cada determinante al índice de concentración, por subperíodo. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	112

5.13. Desempeño en entrenamiento y en prueba de los siete modelos de clasificación. Una brecha reducida entre ambas columnas indica ausencia de sobreajuste. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).	114
5.14. Análisis de sensibilidad del índice de concentración educativa. La columna de cambio expresa la variación de la corrección de Erreygers respecto del análisis base. Elaboración propia.	118
5.15. Índice de concentración estimado dentro de cada régimen de codificación del formulario. Elaboración propia.	119
B.1. Escalamiento de <code>BinomialBayesMixedGLM</code> con el número de conglomerados. Elaboración propia a partir de datos simulados.	139
B.2. Coeficientes estimados sobre datos individuales y sobre celdas binomiales. Elaboración propia a partir de datos simulados.	141
B.3. Sesgo medio del estimador sobre cinco réplicas simuladas. Elaboración propia a partir de datos simulados.	141
B.4. Estimaciones según el número de nodos de cuadratura. Elaboración propia a partir de datos simulados.	142
C.1. Componentes de varianza del modelo vacío, salida completa	145
C.2. Modelo 1, salida completa	145
C.3. Modelo 2, salida completa	146
C.4. Efecto del ajuste obstétrico, salida completa	146
C.5. Contribución por determinante, salida completa	147
C.6. Elasticidades y concentración de cada determinante, salida completa	147
C.7. Índice por subperíodo, salida completa	147
C.8. Reparto por subperíodo, salida completa	148
C.9. Cambio de posición de los departamentos, salida completa	148
D.1. Equivalencia de nombres de variable por período, archivos de nacimientos de las Estadísticas Vitales del DANE.	149

Abreviaturas y siglas

AUC	Área bajo la curva ROC (<i>area under the ROC curve</i>).
BPN	Bajo peso al nacer.
CART	Árboles de clasificación y regresión (<i>classification and regression trees</i>).
CIE	Clasificación Internacional de Enfermedades.
CPV	Cambio proporcional en la varianza.
CCI	Correlación intraclase (<i>intraclass correlation coefficient</i>).
DANE	Departamento Administrativo Nacional de Estadística.
DIVIPOLA	División Político-Administrativa de Colombia.
EEVV	Estadísticas Vitales.
EPS	Entidad Promotora de Salud.
GBM	Máquina de potenciación del gradiente (<i>gradient boosting machine</i>).
F_1	Puntuación F_1 , media armónica entre precisión y sensibilidad.
IC	Índice de concentración.
IC95 %	Intervalo de confianza al 95 %.
IDP	Índice de desigualdad de la pendiente.
IRD	Índice relativo de desigualdad.
MICE	Imputación múltiple por ecuaciones encadenadas (<i>multivariate imputation by chained equations</i>).
MLP	Perceptrón multicapa (<i>multilayer perceptron</i>).

MOR	Razón de momios mediana (<i>median odds ratio</i>).
OMS	Organización Mundial de la Salud.
OR	Razón de momios (<i>odds ratio</i>).
RCIU	Restricción del crecimiento intrauterino.
RF	Bosque aleatorio (<i>random forest</i>).
ROC	Característica operativa del receptor (<i>receiver operating characteristic</i>).
RP	Razón de prevalencias.
RUAF-ND	Registro Único de Afiliados, módulo de nacimientos y defunciones.
SGSSS	Sistema General de Seguridad Social en Salud.
SIVIGILA	Sistema Nacional de Vigilancia en Salud Pública.
XGBoost	<i>Extreme gradient boosting</i> .

Capítulo 1

Introducción

El bajo peso al nacer (BPN), definido por la Organización Mundial de la Salud como un peso inferior a 2.500 gramos con independencia de la edad gestacional, es uno de los indicadores más sensibles de la salud materno-infantil y un predictor robusto de mortalidad neonatal, rezago del desarrollo infantil y enfermedad crónica en la vida adulta (Okwaraji et al., 2024; Organización Mundial de la Salud, 2014). En 2020 nacieron en el mundo 19,8 millones de neonatos con BPN, el 14,7 % de los nacidos vivos, una proporción que apenas ha cedido frente al 16,6 % del año 2000 (Okwaraji et al., 2024). Ese estancamiento, documentado a partir de más de 2.000 fuentes de datos de 158 países, revela un progreso insuficiente frente a las metas mundiales de nutrición (Okwaraji et al., 2024; Blencowe et al., 2019; Organización Mundial de la Salud, 2014).

Un peso inferior a 2.500 gramos puede originarse por dos vías: el nacimiento antes de las 37 semanas de gestación y la restricción del crecimiento intrauterino (Velásquez et al., 2004; Pérez Martínez et al., 2018). Todos los factores de riesgo descritos en la literatura actúan a través de alguno de estos dos mecanismos, lo que explica la heterogeneidad etiológica del fenómeno. Entre ellos figuran las edades extremas de la vida reproductiva y los antecedentes obstétricos adversos (Pérez Martínez et al., 2018; Heredia-Olivera and Munares-García, 2016); la patología del embarazo, que aporta los riesgos de mayor magnitud, con razones de momios entre 2,85 y 4,37 para la enfermedad hipertensiva, la hemorragia del tercer trimestre y la rotura prematura de membranas (Ticona Rendón et al., 2012); la anemia gestacional, asociada a una reducción media de 420 gramos en el peso al nacer (Urdaneta Machado et al., 2015); y el tabaquismo, que resta entre 200 y 300 gramos (Pérez Martínez et al., 2018). La ganancia insuficiente de peso durante la gestación se comporta también como predictor, aunque con una precisión diagnóstica modesta en cohortes latinoamericanas (Santos-Antonio et al., 2020).

Lejos de distribuirse de manera homogénea, el BPN se concentra en los países de ingresos bajos y medianos, que aportan cerca del 91 % de los casos mundiales (Blencowe et al., 2019). Esa concentración no obedece únicamente a factores clínicos, sino en buena medida a los determinantes sociales de la salud, esto es, las condiciones en que las personas nacen, crecen, viven y trabajan (Solar and Irwin, 2010). La pertenencia étnica, la residencia rural, la escolaridad insuficiente y el bajo nivel socioeconómico operan como marcadores de riesgo perinatal (Amjad et al., 2019). Entre ellos la educación materna ocupa un lugar central: un metaanálisis en países de ingresos bajos y medianos estimó que una mayor escolaridad reduce el riesgo de BPN (OR combinado = 0,67; IC95 % [0,61; 0,74]) (Godah et al., 2021). El acceso a la atención prenatal adecuada lo disminuye igualmente (Engdaw et al., 2023), y en un análisis de 360 ciudades latinoamericanas los contextos de mayor privación social mostraron mayor prevalencia aun después de ajustar por características individuales (Rodríguez López et al., 2021).

Las consecuencias justifican la atención que recibe el indicador. En el corto plazo, la mortalidad durante el primer año de vida es catorce veces mayor en los niños con bajo peso que en los nacidos con peso normal a término (Ticona Rendón et al., 2012), y la morbilidad se acentúa en los subgrupos de muy bajo y extremo bajo peso (Castro-Delgado et al., 2016; Heredia-Olivera and Munares-García, 2016). En el largo plazo, la hipótesis del origen fetal de las enfermedades sostiene que las alteraciones nutricionales de la vida intrauterina inducen adaptaciones permanentes que se traducen en hipertensión, diabetes tipo 2 y enfermedad coronaria en la adultez (Jiménez García et al., 2017), tesis respaldada por un metaanálisis de 135 estudios con más de 7,6 millones de participantes (Knop et al., 2018) y por la cohorte del UK Biobank, donde el bajo peso al nacer se asoció con razones de riesgo de 1,23 para enfermedad cardiovascular incidente y 1,52 para accidente cerebrovascular (Huang et al., 2022). A estos desenlaces clínicos se añaden los socioeconómicos: las personas nacidas con muy bajo peso alcanzan en la adultez peores resultados en logro educativo, empleo e ingresos (Zhou et al., 2025). El BPN no es solo producto de la desigualdad social, sino que contribuye a reproducirla (Zhou et al., 2025; Pérez Martínez et al., 2018), y esas brechas perinatales se han mantenido notablemente estables a lo largo de las décadas pese a las mejoras generales en salud (Cozzani, 2023; Núñez Rivas and Morice Trejos, 1999).

En Colombia, país de ingreso mediano con alta inequidad, las prevalencias de BPN superan el promedio regional. Un análisis de más de cinco millones de nacimientos ocurridos entre 2008 y 2018 halló gradientes socioeconómicos persistentes, medidos a través de la educación materna y del régimen de afiliación al sistema de salud (Guarnizo-Herreño et al., 2021). Ese trabajo confirma que el registro censal de nacimientos es una fuente idónea pa-

ra el estudio de las inequidades perinatales, pero se concentró en el eje socioeconómico individual dentro de una ventana de once años, sin descomponer la variación geográfica del riesgo ni situar la pertenencia étnica y el área de residencia como ejes autónomos de inequidad.

Ahí se sitúa el vacío que este trabajo aborda. Las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística constituyen un registro continuo y de cobertura nacional de los nacimientos del país, con microdatos públicos disponibles de forma ininterrumpida entre 1998 y 2024 (Departamento Administrativo Nacional de Estadística, 2025). Cada registro consigna el peso al nacer junto con el nivel educativo de la madre y del padre, el régimen de afiliación al Sistema General de Seguridad Social en Salud, la pertenencia étnica, el área y el territorio de residencia, y variables asistenciales como el número de consultas prenatales. Pese a su cobertura censal, a su continuidad de más de dos décadas y a su estructura naturalmente jerárquica, con los nacimientos anidados en municipios y departamentos, estas variables rara vez se han explotado de forma conjunta y multinivel. Las herramientas para hacerlo están disponibles y probadas: los modelos multinivel separan el aporte individual del contextual (Kassie et al., 2025) y las técnicas de descomposición cuantifican qué proporción de la brecha corresponde a cada determinante (Zhang et al., 2025).

En consecuencia, esta investigación tiene como objetivo analizar la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia entre 1998 y 2024, mediante modelos multinivel aplicados a los microdatos de nacimientos del DANE, con el fin de estimar la magnitud de las desigualdades socioeconómicas, étnicas y territoriales, cuantificar la proporción de la variación atribuible al nivel departamental, describir su evolución a lo largo del período e identificar los grupos poblacionales en mayor riesgo.

1.1. Planteamiento del problema

El bajo peso al nacer es uno de los problemas de salud pública más persistentes y, al mismo tiempo, uno de los que mejor reflejan las condiciones de vida de una población. En 2020, el 14,7 % de los nacidos vivos en el mundo pesó menos de 2.500 gramos, una cifra que apenas ha cedido frente al 16,6 % del año 2000 (Okwaraji et al., 2024). Su relevancia no es menor: el BPN predice de forma robusta la mortalidad neonatal, el rezago en el desarrollo infantil y la enfermedad crónica en la adultez, con efectos que pueden prolongarse durante décadas (Okwaraji et al., 2024; Zhou et al., 2025).

El problema, sin embargo, no golpea a todos por igual. Cerca del 91 % de los casos

se concentra en países de ingresos bajos y medianos (Blencowe et al., 2019), y dentro de cada país el riesgo se distribuye siguiendo líneas sociales: la educación de la madre, su posición socioeconómica, el acceso a los servicios de salud y el entorno donde vive (Amjad et al., 2019). La evidencia es consistente. Una mayor escolaridad materna reduce el riesgo de BPN ($OR = 0,67$) (Godah et al., 2021); un control prenatal adecuado también lo disminuye (Engdaw et al., 2023); y los entornos urbanos más desfavorecidos de América Latina muestran mayores prevalencias, incluso tras ajustar por características individuales (Rodríguez López et al., 2021). Esas brechas, además, son estables en el tiempo y tienden a transmitirse entre generaciones (Zhou et al., 2025; Cozzani, 2023).

Colombia no escapa a este patrón. Es un país de ingreso mediano con una desigualdad marcada y prevalencias de BPN que superan el promedio regional. Un análisis de más de cinco millones de nacimientos ocurridos entre 2008 y 2018 evidenció desigualdades claras según la educación materna y el régimen de afiliación al sistema de salud (Guarnizo-Herreño et al., 2021). Pese a ello, buena parte de la investigación nacional se ha concentrado en factores biológicos o clínicos y ha aprovechado poco el potencial de los sistemas de información para examinar, de manera integral, los determinantes sociales del problema.

1.1.1. Delimitación del objeto de estudio

Conviene precisar el alcance del fenómeno que se estudia. El BPN resulta de dos mecanismos distintos: el nacimiento antes de las 37 semanas de gestación y la restricción del crecimiento intrauterino. Ambos comparten el desenlace (un peso inferior a 2.500 gramos) pero responden a cadenas causales diferentes, y los determinantes sociales operan sobre cada una con intensidad desigual.

El certificado de nacido vivo del DANE registra simultáneamente el peso al nacer en gramos y el tiempo de gestación en semanas, lo que permite separar analíticamente ambas vías en lugar de tratarlas como un bloque indiferenciado. Esta capacidad es una ventaja sustantiva del diseño: el desenlace principal se define como el bajo peso al nacer en el conjunto de nacidos vivos, y se estratifica en bajo peso al nacer a término (gestaciones de 37 o más semanas, atribuible a restricción del crecimiento intrauterino) y bajo peso al nacer asociado a prematuridad. La vía del crecimiento fetal es precisamente donde los determinantes sociales (nutrición materna, carga de trabajo, pobreza, acceso a control prenatal) ejercen su influencia de manera más directa, de modo que el contraste entre ambos estratos constituye en sí mismo un resultado sobre el mecanismo por el cual la posición social se inscribe en el cuerpo del recién nacido.

1.1.2. La oportunidad de las Estadísticas Vitales

Las Estadísticas Vitales del DANE presentan tres propiedades que las hacen particularmente adecuadas para esta investigación.

La primera es la cobertura censal. A diferencia de un sistema de vigilancia, que notifica casos y exige un denominador externo, las EEVV registran la totalidad de los nacidos vivos del país. Numerador y denominador provienen del mismo instrumento, lo que hace directamente estimables las prevalencias departamentales, los índices de concentración y las curvas de concentración sin necesidad de enlazar fuentes heterogéneas ni armonizar categorías entre instrumentos distintos.

La segunda es la continuidad. La serie de microdatos de nacimientos está disponible de forma ininterrumpida entre 1998 y 2024 (Departamento Administrativo Nacional de Estadística, 2025), lo que permite examinar no solo la magnitud de las desigualdades sino su evolución a lo largo de más de dos décadas, período que abarca la consolidación del Sistema General de Seguridad Social en Salud, la expansión del régimen subsidiado y transformaciones demográficas de gran alcance.

La tercera es la riqueza social del certificado de nacido vivo. Cada registro incorpora un perfil de la madre que rara vez se analiza de manera conjunta: el nivel educativo de la madre y del padre, la edad materna, el estado conyugal, el régimen de afiliación al Sistema General de Seguridad Social en Salud (contributivo, subsidiado, especial, de excepción o no asegurado), el área de residencia habitual diferenciada en cabecera municipal, centro poblado y rural disperso, la pertenencia étnica en las categorías del DANE, y el territorio de residencia a escala departamental y municipal. A ello se suman variables asistenciales que operan como indicadores directos de acceso efectivo: el número de consultas prenatales, el sitio de atención del parto, el tipo de parto y la persona que lo atendió.

Analizar estas variables de forma conjunta (y no aislada) permite dimensionar cuánto de la carga de BPN en Colombia se explica por la posición social y no solo por factores individuales, e identificar con precisión los grupos que concentran el mayor riesgo. Herramientas como los modelos multinivel y las técnicas de descomposición de la desigualdad, ya aplicadas en otros contextos (Kassie et al., 2025; Zhang et al., 2025), hacen viable ese análisis con datos poblacionales de gran escala. No hacerlo perpetúa una brecha de conocimiento con consecuencias prácticas: sin evidencia local sobre qué determinantes sociales pesan más y sobre quiénes recae la desigualdad, las políticas de salud materno-perinatal difícilmente podrán focalizarse donde más se necesitan.

1.1.3. Pregunta general de investigación

¿Cuál es la asociación entre los determinantes sociales de la salud (nivel educativo materno, régimen de afiliación, estado conyugal, área de residencia, pertenencia étnica y territorio) y el bajo peso al nacer en Colombia, a partir de los microdatos de nacimientos de las Estadísticas Vitales del DANE durante el período 1998–2024?

El certificado de nacido vivo registra además el nivel educativo del padre, que se describe y se somete al cribado de variables pero no entra en los modelos explicativos: es la única variable del bloque social con ausencia por no respuesta sustancial, un 12,38 % frente al 3,2 % de la educación materna, de modo que incorporarla reduciría la muestra analítica sin añadir un eje de ordenamiento que el nivel educativo de la madre no capte ya. La edad materna, por su parte, se trata como covariable de ajuste y no como eje de desigualdad, por las razones que expone la Sección 3.10.

1.1.4. Preguntas específicas

Las siete preguntas escalan en complejidad analítica: describen, miden la desigualdad, la modelan, la descomponen, la sitúan en el territorio, someten a prueba el eje étnico y examinan hasta dónde llega la identificación del riesgo con la información disponible.

1. ¿Cuál es la magnitud y la tendencia de la prevalencia del bajo peso al nacer en Colombia entre 1998 y 2024, y cómo varía esa prevalencia entre departamentos y municipios?
2. ¿Cómo se distribuye el bajo peso al nacer según la posición socioeconómica de la madre (nivel educativo y régimen de afiliación) y qué magnitud alcanza esa desigualdad al cuantificarla mediante índices y curvas de concentración?
3. ¿Qué determinantes sociales se asocian de forma independiente con el bajo peso al nacer, una vez ajustado el modelo por edad materna, paridad y multiplicidad del embarazo?
4. ¿Qué proporción de la brecha socioeconómica observada es atribuible a cada determinante social, según la descomposición del índice de concentración?
5. ¿Qué proporción de la variación del bajo peso al nacer corresponde al nivel municipal y departamental, y persiste esa variación contextual después de ajustar por la composición socioeconómica individual de las madres?
6. ¿Se asocia la pertenencia étnica de la madre con el bajo peso al nacer por encima de los demás determinantes sociales y del municipio de residencia, y qué permite concluir

esa respuesta sobre la desigualdad étnica cuando etnia y territorio no son separables en esta fuente?

7. ¿En qué medida permite la información del certificado de nacido vivo identificar un nacimiento en riesgo de bajo peso, y cuánto añaden los determinantes sociales a esa identificación por encima de la información obstétrica?

1.2. Justificación

El bajo peso al nacer reúne tres condiciones que rara vez coinciden en un mismo indicador: es frecuente, tiene consecuencias graves y prolongadas, y una parte sustancial de su distribución responde a causas socialmente modificables. Esa combinación es la que justifica destinarle un trabajo de investigación. A continuación se exponen las cuatro razones que sostienen la pertinencia del estudio y los productos concretos que se espera obtener.

1.2.1. Relevancia sanitaria

El BPN es el principal predictor de la mortalidad infantil: el riesgo de morir durante el primer año de vida es catorce veces mayor en un recién nacido de bajo peso que en uno de peso normal a término (Ticona Rendón et al., 2012). Su efecto no se agota en la infancia. La evidencia acumulada sobre la programación fetal muestra que las carencias nutricionales de la vida intrauterina dejan una huella permanente que se expresa décadas después en hipertensión, diabetes tipo 2 y enfermedad coronaria (Jiménez García et al., 2017; Knop et al., 2018; Huang et al., 2022). Cada nacimiento con bajo peso representa, por tanto, un riesgo inmediato de muerte y una carga diferida de enfermedad crónica sobre el sistema de salud. Reducir su prevalencia produce beneficios sanitarios que se extienden a lo largo de toda la vida de la persona.

1.2.2. Relevancia distributiva

El segundo argumento es de equidad. El BPN no se distribuye al azar: se concentra en los hogares de menor escolaridad, menor aseguramiento y peor acceso a los servicios de salud (Amjad et al., 2019; Godah et al., 2021; Guarnizo-Herreño et al., 2021). Y la relación opera en ambos sentidos. Quienes nacen con bajo peso alcanzan en la adultez peores resultados en logro educativo, empleo e ingresos (Zhou et al., 2025), de modo que la desventaja social que produjo el bajo peso vuelve a producirse en la generación siguiente.

El indicador señala así un punto donde la desigualdad se transmite entre generaciones, y la comparación de cohortes británicas muestra que esas brechas perinatales permanecen prácticamente inalteradas a lo largo de las décadas pese a las mejoras generales en salud (Cozzani, 2023). Intervenir sobre el bajo peso al nacer no es solo una acción sanitaria: es una intervención sobre el mecanismo que reproduce la desigualdad.

1.2.3. Relevancia metodológica

Colombia dispone de un registro censal de nacimientos con veintisiete años de continuidad, acceso público y un conjunto de variables sociales que pocos sistemas de información reúnen en un mismo instrumento (Departamento Administrativo Nacional de Estadística, 2025). Ese activo está infrautilizado. La investigación nacional sobre bajo peso al nacer se ha apoyado mayoritariamente en series hospitalarias y en diseños de casos y controles, cuyo alcance es local y cuyo poder para estimar desigualdades poblacionales es limitado. El antecedente nacional más próximo (Guarnizo-Herreño et al., 2021) demostró el valor de la fuente, pero abarcó once años y no descompuso la variación territorial.

Este trabajo aporta tres elementos metodológicos. Primero, extiende la serie a 1998–2024, lo que permite examinar no solo la magnitud de la desigualdad sino su evolución a lo largo de un período que abarca la consolidación del Sistema General de Seguridad Social en Salud y la expansión del régimen subsidiado. Segundo, adopta una especificación multinivel que separa el aporte individual del contextual, en lugar de tratar el territorio como una covariable más. Y tercero, entrega una consolidación documentada de los trece diccionarios de datos del período, que constituye por sí sola un insumo reutilizable por otros investigadores.

1.2.4. Relevancia para la política pública

Saber que existe desigualdad no basta para actuar sobre ella. Una política de focalización necesita respuestas a tres preguntas operativas: cuánta desigualdad hay, sobre quiénes recae y qué proporción de esa brecha aporta cada determinante. El índice de concentración responde a la primera, la estratificación por grupos a la segunda y la descomposición de Wagstaff a la tercera (Wagstaff et al., 2003). Los resultados se traducen directamente en criterios de priorización: qué departamentos concentran el exceso de riesgo, qué grupos poblacionales requieren atención diferencial y sobre qué determinante conviene intervenir primero para obtener la mayor reducción de la brecha.

La medición de la variación territorial tiene además una implicación práctica inmediata.

Si la desigualdad entre departamentos persiste después de ajustar por la composición social de sus habitantes, el problema no reside únicamente en quién vive allí sino en las características del territorio, y la respuesta debe dirigirse a la oferta institucional y no solo a los individuos.

1.2.5. Resultados esperados

Al término del estudio se espera disponer de:

1. Una serie continua y armonizada de la prevalencia de bajo peso al nacer en Colombia entre 1998 y 2024, desagregada por departamento y municipio.
2. Una estimación de la magnitud de la desigualdad socioeconómica mediante el índice de concentración y su evolución en el período.
3. La cuantificación de la contribución de cada determinante social a esa desigualdad.
4. La proporción de la variación del bajo peso al nacer atribuible al nivel departamental y municipal, con la identificación de los territorios que concentran el exceso de riesgo.
5. La identificación de los grupos poblacionales en mayor riesgo, como insumo para la focalización de programas materno-perinatales.
6. Un conjunto de rutinas de procesamiento y análisis documentadas y reproducibles, junto con la consolidación de los diccionarios de datos de la serie.

Capítulo 2

Objetivos

2.1. Objetivo general

Analizar la asociación entre los determinantes sociales de la salud y el bajo peso al nacer en Colombia durante el período 1998–2024, mediante modelos multinivel aplicados a los microdatos de nacimientos de las Estadísticas Vitales del Departamento Administrativo Nacional de Estadística, con el fin de estimar la magnitud de las desigualdades socioeconómicas, étnicas y territoriales e identificar los grupos poblacionales en mayor riesgo.

2.2. Objetivos específicos

1. Estimar la magnitud y la tendencia de la prevalencia del bajo peso al nacer en Colombia entre 1998 y 2024, y describir su variación entre departamentos y municipios.
2. Cuantificar la desigualdad socioeconómica en el bajo peso al nacer mediante el índice de concentración, el índice de desigualdad de la pendiente y el índice relativo de desigualdad, empleando el nivel educativo materno y el régimen de afiliación como ejes de ordenamiento social.
3. Estimar el efecto independiente de cada determinante social sobre el bajo peso al nacer mediante modelos de regresión logística multinivel, ajustados por edad materna, paridad y multiplicidad del embarazo.
4. Descomponer el índice de concentración en las contribuciones de cada determinante social, con el fin de establecer qué proporción de la brecha socioeconómica es atribuible

a cada uno.

5. Determinar la proporción de la variación del bajo peso al nacer atribuible a los niveles municipal y departamental, y evaluar si esa variación contextual persiste después de ajustar por la composición socioeconómica individual de las madres.
6. Establecer si la pertenencia étnica de la madre se asocia con el bajo peso al nacer por encima de los determinantes sociales y del municipio de residencia, y delimitar qué puede y qué no puede concluirse sobre desigualdad étnica a partir de una fuente en la que etnia y territorio están fuertemente asociados.
7. Evaluar en qué medida la información contenida en el certificado de nacido vivo permite identificar un nacimiento en riesgo de bajo peso, y cuánto aportan los determinantes sociales a esa identificación por encima de la información obstétrica, comparando el desempeño de siete modelos de clasificación supervisada.

Capítulo 3

Marco teórico

Este capítulo desarrolla los fundamentos conceptuales y estadísticos sobre los que se apoya la estrategia analítica descrita en el Capítulo 4. Cada sección sostiene una fase concreta del análisis: no hay apartado sin uso ni fase sin fundamento.

3.1. Determinantes sociales de la salud: marco conceptual

El marco conceptual que ordena este trabajo es el propuesto por la Comisión sobre Determinantes Sociales de la Salud de la Organización Mundial de la Salud (Comisión sobre Determinantes Sociales de la Salud, 2008), en la formulación operativa de Solar e Irwin (Solar and Irwin, 2010). Su tesis central es que la distribución desigual de la enfermedad no es un accidente ni el agregado de decisiones individuales, sino el resultado previsible de la forma en que una sociedad organiza el acceso al poder, al dinero y a los recursos.

El modelo distingue dos niveles de determinación. Los *determinantes estructurales* son los mecanismos que generan estratificación social y asignan a cada persona una posición dentro de la jerarquía: el contexto socioeconómico y político, y los ejes que definen esa posición, esto es, la educación, la ocupación, el ingreso, el género y la adscripción étnica. Los *determinantes intermedios* son las condiciones concretas a través de las cuales esa posición se traduce en salud o enfermedad: las circunstancias materiales de la vivienda y el entorno, los factores conductuales y biológicos, los factores psicosociales y el acceso al sistema de salud (Solar and Irwin, 2010).

La distinción no es una taxonomía descriptiva sino una hipótesis causal, y de ella se

derivan tres consecuencias que atraviesan el diseño de este estudio.

La primera es que los determinantes estructurales anteceden causalmente a los intermedios. La educación de la madre no compite con su estado nutricional por explicar el bajo peso al nacer: lo antecede y opera a través de él. Esta jerarquía es la que justifica que las variables del embarazo se traten como mediadores y no como factores de confusión, argumento que se desarrolla en la Sección 3.10.

La segunda es que la posición socioeconómica no es una variable sino un constructo, y ninguna variable observada la mide por completo. En el certificado de nacido vivo, el nivel educativo de la madre y del padre y el régimen de afiliación al Sistema General de Seguridad Social en Salud operan como indicadores parciales de esa posición: el primero capta el componente de capital cultural y credencial, y el segundo, el de inserción laboral formal, dado que la afiliación al régimen contributivo está condicionada por el empleo remunerado. Ninguno mide el ingreso, que no se registra en la fuente.

La tercera es que el territorio no es un simple contenedor. La residencia en un municipio rural disperso no es solo un atributo individual: implica una oferta institucional, una distancia efectiva a los servicios y una composición social del entorno que actúan sobre todos sus habitantes con independencia de sus características personales. Esta doble naturaleza, individual y contextual, es la que exige la estructura jerárquica de los modelos de la Sección 3.7.

El Cuadro 3.1 traduce el modelo a las variables efectivamente disponibles en la fuente.

Cuadro 3.1: Correspondencia entre el modelo de determinantes sociales de la salud (Solar and Irwin, 2010) y las variables del certificado de nacido vivo. Elaboración propia.

Nivel	Dimensión del modelo	Variable disponible
Determinantes estructurales	Educación	Nivel educativo de la madre y del padre
	Inserción laboral e ingreso	Régimen de afiliación al SGSSS (indicador parcial)
	Adscripción étnica	Pertenencia étnica del nacido vivo
	Territorio y contexto	Departamento, municipio y área de residencia
Determinantes intermedios	Acceso a servicios de salud	Número de consultas prenatales, sitio y tipo de parto, persona que atendió el parto
	Factores biológicos	Edad materna, paridad, multiplicidad del embarazo
Desenlace	Equidad en salud	Bajo peso al nacer

Conviene señalar de forma explícita qué queda fuera. El modelo contempla las circunstancias materiales de la vivienda, los factores psicosociales, la cohesión social y las

conductas relacionadas con la salud, ninguno de los cuales se registra en el certificado de nacido vivo. Tampoco se recogen el ingreso del hogar ni el estado nutricional materno. El estudio no puede, por tanto, verificar la cadena causal completa: estima la asociación entre la posición social y el desenlace, y observa cuánto de esa asociación transcurre por las dos vías intermedias que sí resultan observables, el acceso a la atención prenatal y los factores biológicos del embarazo.

3.2. El bajo peso al nacer: definición, mecanismos y delimitación

La Organización Mundial de la Salud define el bajo peso al nacer como un peso inferior a 2.500 gramos medido dentro de la primera hora de vida, con independencia de la edad gestacional (Organización Mundial de la Salud, 2014). El umbral no corresponde a un punto de inflexión biológico sino a un consenso epidemiológico: por debajo de esa cifra el riesgo de mortalidad neonatal y de morbilidad se eleva de manera apreciable, y su estabilidad a lo largo del tiempo y entre países es lo que permite la comparación internacional.

La definición admite dos gradaciones de severidad de uso corriente: el muy bajo peso al nacer, inferior a 1.500 gramos, y el extremo bajo peso, inferior a 1.000 gramos, subgrupos en los que la morbilidad y la mortalidad se acentúan de forma marcada (Castro-Delgado et al., 2016).

3.2.1. Los dos mecanismos

Un peso inferior a 2.500 gramos puede originarse por dos vías distintas, que pueden presentarse de forma aislada o combinada (Velásquez et al., 2004; Pérez Martínez et al., 2018).

La primera es el **parto pretérmino**: el nacimiento ocurre antes de las 37 semanas completas de gestación y el recién nacido pesa poco porque ha dispuesto de menos tiempo para crecer. Su peso puede ser enteramente adecuado para su edad gestacional. Los factores que anteceden a esta vía son predominantemente clínicos y obstétricos: rotura prematura de membranas, infección, enfermedad hipertensiva del embarazo, gestación múltiple y antecedente de prematuridad.

La segunda es la **restricción del crecimiento intrauterino**: la gestación alcanza el término, pero el feto no logra el peso esperado para su edad gestacional. Aquí el peso insuficiente refleja un déficit acumulado de aporte de nutrientes y oxígeno a lo largo del

embarazo, cuyos antecedentes son en buena medida nutricionales y ambientales: desnutrición materna, anemia, carga física de trabajo, tabaquismo, y una atención prenatal tardía o insuficiente que impide detectar y corregir el problema a tiempo.

La distinción importa porque los determinantes sociales no operan con igual intensidad sobre ambas vías. La pobreza, la escolaridad insuficiente y la falta de acceso oportuno a los servicios de salud actúan sobre el crecimiento fetal de forma directa y sostenida, a través de la alimentación, del esfuerzo físico y del control del embarazo. Sobre la prematuridad su influencia es más indirecta, mediada por cuadros clínicos cuya aparición depende también de factores que la posición social no determina. Cabe esperar, por tanto, que el gradiente social sea más pronunciado en el bajo peso al nacer a término que en el asociado a prematuridad, y ese contraste constituye en sí mismo una hipótesis verificable sobre el mecanismo.

3.2.2. Delimitación del desenlace en este estudio

El certificado de nacido vivo registra simultáneamente el peso y el tiempo de gestación, lo que permite separar analíticamente ambas vías en lugar de tratarlas como un bloque indiferenciado. El desenlace principal se define sobre el conjunto de nacidos vivos y se estratifica después por edad gestacional, de modo que el contraste entre los dos estratos se convierte en un resultado y no en un supuesto.

Esta estratificación está condicionada por la forma en que la fuente registra el tiempo de gestación, cuestión que se aborda en la Sección 4.3.1. Conviene anticipar aquí que las categorías publicadas no permiten situar el corte exactamente en las 37 semanas, lo que obliga a adoptar un umbral operativo y a declararlo como limitación.

3.2.3. El bajo peso al nacer como indicador social

Más allá de su significado clínico, el bajo peso al nacer se emplea como indicador sintético de las condiciones de vida de una población y de la capacidad de respuesta de su sistema de salud (Núñez Rivas and Morice Trejos, 1999). Tres propiedades lo hacen particularmente útil para ese fin. Se registra de forma universal y con un instrumento estandarizado, lo que permite comparaciones consistentes entre territorios y a lo largo del tiempo. Su medición es objetiva y no depende del juicio del observador. Y condensa, en una sola cifra disponible en el momento del nacimiento, la historia acumulada de nueve meses de exposición material y social de la madre.

3.3. Medidas de asociación en epidemiología

La razón de momios (*odds ratio*) es la medida de asociación que arrojan de forma natural los modelos logísticos. Cuando el desenlace no es raro, la razón de momios sobrestima sistemáticamente la razón de prevalencias, por lo que su interpretación exige cautela y, cuando corresponde, la estimación complementaria de razones de prevalencia (Barros and Hirakata, 2003).

El intervalo de confianza de la razón de momios se obtiene por el método de Woolf, a partir del error estándar del logaritmo del momio. Para una tabla de contingencia 2×2 con celdas a , b , c y d :

$$SE[\ln(OR)] = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}} \quad (3.1)$$

$$IC_{95\%} = \exp[\ln(OR) \pm 1,96 \cdot SE(\ln(OR))] \quad (3.2)$$

Ante frecuencias nulas en alguna celda (situación previsible en municipios de baja población y en categorías étnicas de frecuencia reducida) se aplica la corrección de Haldane-Anscombe, que consiste en sumar 0,5 a cada celda antes del cálculo.

3.4. Análisis bivariado y colinealidad

3.4.1. Prueba χ^2 y coeficiente V de Cramér

La independencia entre cada determinante y el desenlace se evalúa mediante la prueba χ^2 de Pearson. Dado que el estadístico χ^2 crece con el tamaño de muestra y resulta significativo de forma trivial en bases de gran escala, la fuerza de la asociación se cuantifica mediante el coeficiente V de Cramér, que normaliza el estadístico entre 0 y 1:

$$V = \sqrt{\frac{\chi^2}{n \cdot \min(r - 1, c - 1)}} \quad (3.3)$$

donde n es el número de observaciones y r y c son el número de filas y columnas de la tabla de contingencia.

La matriz de V de Cramér entre determinantes cumple aquí una función de diagnóstico de colinealidad, no de redundancia predictiva. El régimen de afiliación, el nivel educativo

y el área de residencia están conceptual y empíricamente correlacionados entre sí, de modo que conviene complementar V con el factor de inflación de la varianza generalizado, apropiado para variables categóricas de más de dos niveles. La decisión de excluir un determinante no debe ser estadística sino conceptual: si dos variables miden la misma dimensión social, se elige la de mejor completitud y se declara explícitamente.

3.4.2. Información mutua

El coeficiente V de Cramér detecta asociación en tablas de contingencia, pero deriva de un estadístico construido bajo la hipótesis de independencia y penaliza únicamente las desviaciones respecto de las frecuencias esperadas. La información mutua ofrece una alternativa de naturaleza distinta: cuantifica, en unidades de información, cuánto disminuye la incertidumbre sobre el desenlace al conocer el valor de un determinante, sin suponer forma funcional alguna ni linealidad en la relación (Cover and Thomas, 2006).

Sea Y el indicador binario de bajo peso al nacer y X un determinante con soporte discreto. La entropía de Shannon de Y mide su incertidumbre (Shannon, 1948):

$$H(Y) = - \sum_y p(y) \log_2 p(y) \quad (3.4)$$

La entropía condicional $H(Y | X)$ es la incertidumbre que permanece sobre Y una vez observado X , y la información mutua es la diferencia entre ambas:

$$I(X; Y) = H(Y) - H(Y | X) = \sum_x \sum_y p(x, y) \log_2 \left(\frac{p(x, y)}{p(x)p(y)} \right) \quad (3.5)$$

La expresión de la derecha es la divergencia de Kullback y Leibler entre la distribución conjunta y el producto de las marginales. De ahí se siguen tres propiedades relevantes para este trabajo. Primera, $I(X; Y) \geq 0$, con igualdad si y solo si X e Y son independientes; a diferencia de la correlación, un valor nulo implica independencia completa y no solo ausencia de relación lineal. Segunda, $I(X; Y) = I(Y; X)$, de modo que la medida es simétrica. Tercera, la información mutua es invariante ante transformaciones biyectivas de las variables, lo que la hace insensible a la codificación numérica arbitraria de las categorías: recodificar el régimen de afiliación de $\{1, 2, 3\}$ a $\{7, 2, 9\}$ no altera $I(X; Y)$, mientras que sí alteraría cualquier medida basada en momentos.

Normalización e incertidumbre simétrica

La información mutua no está acotada superiormente: su límite es $\min\{H(X), H(Y)\}$, que depende de la entropía de las variables y, por tanto, del número de categorías de X . Una variable con mil niveles puede alcanzar valores de I superiores a los de una variable dicotómica sin que ello indique mayor relevancia sustantiva. La comparación entre determinantes de cardinalidad distinta exige normalizar. Se emplea la incertidumbre simétrica, que divide la información mutua por la media de las entropías marginales y queda acotada en el intervalo unitario:

$$U(X; Y) = \frac{2 I(X; Y)}{H(X) + H(Y)} \quad (3.6)$$

Sesgo de estimación por cardinalidad

La normalización de la Ecuación (3.6) corrige la escala pero no el sesgo del estimador. La información mutua estimada por conteo de frecuencias en una muestra finita es sistemáticamente positiva incluso bajo independencia, y el sesgo crece con el número de celdas de la tabla conjunta (Steuer et al., 2002). En una base con aproximadamente mil cien municipios, la información mutua muestral entre municipio y desenlace sería apreciable aunque el municipio no aportara información alguna, sencillamente porque cada celda contiene pocas observaciones.

El procedimiento de corrección adoptado consiste en construir una distribución nula específica para cada variable mediante permutación aleatoria del desenlace, que preserva la cardinalidad y las frecuencias marginales de X pero destruye toda asociación con Y . La información mutua observada se contrasta contra esa distribución, de modo que el umbral de decisión no es un valor fijado por convención sino el nivel esperable por azar dada la estructura de la variable.

Estimación con variables continuas

Para los determinantes de soporte continuo o de recuento amplio, la estimación por conteo de frecuencias exige discretizar, y el resultado depende del número y la anchura de los intervalos. Se recurre al estimador basado en vecinos más próximos de Kraskov, Stögbauer y Grassberger (2004), en la adaptación de Ross (2014) para el caso mixto de un predictor continuo y un desenlace discreto, que es el implementado en la biblioteca empleada (Pedregosa et al., 2011).

Información mutua condicional

La información mutua de la Ecuación (3.5) es *marginal*: evalúa cada determinante frente al desenlace en aislamiento, sin considerar los demás. Esa propiedad, que la hace cómoda de calcular, la vuelve ciega a una situación epidemiológica frecuente: la de un determinante que informa poco por sí solo y mucho en combinación con otro.

La información mutua condicional resuelve esa limitación. Dado un tercer conjunto de variables Z , mide cuánto reduce X la incertidumbre sobre Y *una vez que Z ya se conoce*:

$$I(X; Y | Z) = \sum_z p(z) \sum_x \sum_y p(x, y | z) \log_2 \left(\frac{p(x, y | z)}{p(x | z) p(y | z)} \right) \quad (3.7)$$

Es la información mutua calculada dentro de cada estrato definido por Z y promediada según el tamaño de los estratos. Cuando Z es vacío, la Ecuación (3.7) se reduce a la Ecuación (3.5): la marginal es el caso particular de la condicional sin condicionamiento.

La diferencia entre ambas no es marginal en magnitud. En una simulación de doscientos mil casos con dos determinantes binarios cuyo efecto sobre el riesgo depende exclusivamente de que coincidan, el segundo presenta $I(X; Y) = 0,000001$ bits, valor inferior al percentil 95 de su propia distribución nula por permutación, mientras que $I(X; Y | Z) = 0,018642$ bits. Un cribado basado solo en la información mutua marginal habría descartado esa variable, y con ella la interacción que el componente predictivo se propone detectar.

Información de interacción

La comparación entre la información mutua conjunta de dos determinantes y la suma de sus informaciones mutuas individuales cuantifica si su aporte conjunto excede la suma de las partes:

$$II(X, Z; Y) = I(X, Z; Y) - I(X; Y) - I(Z; Y) \quad (3.8)$$

El signo admite lectura directa. Un valor positivo indica *sinergia*: los dos determinantes informan conjuntamente más de lo que informan por separado, situación característica de una interacción estadística. Un valor negativo indica *redundancia*: ambos capturan en parte la misma información, de modo que uno de los dos resulta prescindible. Un valor próximo a cero indica aportes independientes.

De las tres medidas, la información de interacción es la única cuyo signo tiene interpretación sustantiva, y por esa razón se reporta como resultado y no únicamente como

control interno del procedimiento.

Selección secuencial

La aplicación de la Ecuación (3.7) a la selección de variables sigue un procedimiento hacia adelante que se remonta a Battiti (1994) y que la revisión de Vergara y Estévez (2013) sistematiza. Entra en primer lugar el determinante de mayor información mutua marginal; en cada paso posterior, las candidatas restantes se evalúan por su información mutua condicional al conjunto ya seleccionado, no por su marginal. El procedimiento se detiene cuando ninguna candidata supera el percentil 95 de su distribución nula.

Este esquema tiene un límite intrínseco que conviene declarar. La estimación no paramétrica de $I(X; Y \mid Z)$ requiere estratificar por las combinaciones de las variables ya seleccionadas, y el número de estratos crece de forma multiplicativa con el tamaño del conjunto condicionante. A partir de un número reducido de variables, los estratos contienen pocas observaciones, la estimación se degrada y la distribución nula por permutación alcanza a la señal. El procedimiento se detiene entonces por agotamiento de la estimación y no porque las variables restantes carezcan de información, distinción que debe explicitarse al interpretar los resultados.

Redundancia entre determinantes

La selección secuencial descrita arriba controla la redundancia de forma implícita, puesto que una candidata redundante con las ya seleccionadas presenta información mutua condicional próxima a cero. Conviene no obstante cuantificarla de manera explícita: la información mutua marginal mide relevancia pero no redundancia. Dos determinantes fuertemente asociados entre sí pueden presentar información mutua elevada con el desenlace y aportar, conjuntamente, poco más que uno de ellos por separado. El criterio de máxima relevancia y mínima redundancia de Peng, Long y Ding (2005) penaliza explícitamente la información mutua entre predictores, y es el que se aplica cuando el cribado marginal retiene variables que la matriz de V de Cramér señala como colineales.

Ámbito legítimo de aplicación

Conviene delimitar con precisión para qué sirve y para qué no sirve esta medida en el presente trabajo. La información mutua ordena variables por su asociación con el desenlace, y esa ordenación es un criterio razonable para reducir la dimensionalidad de un problema predictivo. No lo es para decidir qué covariables entran en un modelo con pro-

pósito inferencial. Un confusor puede presentar información mutua marginal baja con el desenlace y seguir siendo indispensable para estimar sin sesgo el efecto de otro determinante; a la inversa, un mediador puede presentar información mutua alta y no deber ser ajustado, por las razones expuestas en la Sección 3.10. Seleccionar covariables mediante criterios guiados por los datos sesga las estimaciones puntuales e invalida la cobertura nominal de los intervalos de confianza, porque el proceso de selección no se incorpora a la varianza (Heinze et al., 2018).

En consecuencia, la información mutua cumple aquí dos funciones y solo dos: es una medida descriptiva de asociación que complementa a V de Cramér en la fase exploratoria, y es un filtro de variables dentro del componente predictivo. La especificación de los modelos multinivel permanece determinada por el marco de determinantes sociales y por la distinción entre confusor y mediador, no por la ordenación empírica de la información mutua.

3.5. Medición de la desigualdad socioeconómica en salud

El índice de concentración resume la asociación entre un desenlace de salud y la posición socioeconómica ordenada de la población. Se define como el doble de la covarianza entre el desenlace y el rango fraccional socioeconómico, dividida por la media del desenlace (Kakwani et al., 1997):

$$IC = \frac{2}{\mu} \text{cov}(y, R) \quad (3.9)$$

donde y es el desenlace, R el rango fraccional de la posición socioeconómica y μ la media del desenlace. El índice toma valores en $[-1, 1]$: valores negativos indican concentración del desenlace entre los grupos de menor posición social.

Cuando el desenlace es binario, los límites del índice dependen de la media y dejan de ser ± 1 , lo que impide comparar poblaciones con prevalencias distintas (Wagstaff, 2005). Se emplean dos correcciones. La normalización de Wagstaff divide el índice por $(1 - \mu)$ (Wagstaff, 2005). La de Erreygers lo multiplica por cuatro veces la media, restableciendo las propiedades de invariancia del indicador (Erreygers, 2009):

$$E(y) = 4\mu \cdot IC \quad (3.10)$$

Se incorporan además dos medidas basadas en regresión sobre el rango fraccional: el índice de desigualdad de la pendiente, que expresa la diferencia absoluta de prevalencia entre los extremos de la jerarquía social, y el índice relativo de desigualdad, que expresa esa misma diferencia como razón. La curva de concentración acompaña gráficamente a los tres indicadores.

3.6. Descomposición de la desigualdad

La descomposición propuesta por Wagstaff, van Doorslaer y Watanabe aprovecha la linealidad del índice de concentración para expresarlo como la suma de las contribuciones de cada determinante, más un residuo no explicado (Wagstaff et al., 2003):

$$IC = \sum_k \left(\frac{\beta_k \bar{x}_k}{\mu} \right) IC_k + \frac{GC_\varepsilon}{\mu} \quad (3.11)$$

donde el término entre paréntesis es la elasticidad del desenlace respecto del determinante k , IC_k es el índice de concentración de ese determinante y GC_ε es el índice de concentración generalizado del residuo.

El punto conceptual decisivo es que la contribución de un determinante depende de dos factores simultáneos: su elasticidad, es decir cuánto aumenta el riesgo, y su propia distribución desigual entre grupos socioeconómicos (Wagstaff et al., 2003). Un factor de riesgo potente que se distribuya de forma homogénea en la población no genera inequidad. El procedimiento ha sido aplicado al bajo peso al nacer en estudios recientes (Alam et al., 2022; Sathi et al., 2022; Zhang et al., 2025).

3.7. Modelos de regresión multinivel

Los datos de nacimientos presentan una estructura jerárquica: cada nacimiento ocurre en un municipio y cada municipio pertenece a un departamento. Ignorar esa estructura viola el supuesto de independencia de las observaciones y subestima los errores estándar. Los modelos de efectos aleatorios incorporan la jerarquía de forma explícita y permiten descomponer la varianza total del desenlace entre los distintos niveles.

Tres medidas traducen la varianza de nivel superior a cantidades interpretables (Merlo et al., 2006). La correlación intraclase expresa la proporción de la varianza total atribuible al nivel territorial; en el modelo logístico, donde la varianza de nivel individual se fija en $\pi^2/3$:

$$\text{CCI} = \frac{\sigma_u^2}{\sigma_u^2 + \pi^2/3} \quad (3.12)$$

La razón de momios mediana traduce la heterogeneidad contextual a la escala de los momios, lo que la hace directamente comparable con los coeficientes de las variables individuales:

$$\text{MOR} = \exp\left(\sqrt{2\sigma_u^2} \cdot 0,6745\right) \quad (3.13)$$

El cambio proporcional en la varianza indica qué proporción de la varianza territorial queda explicada al añadir covariables individuales, es decir, cuánto de la diferencia entre municipios se debe a su composición social y no a un efecto contextual propio:

$$\text{CPV} = \frac{\sigma_{u(\text{vacío})}^2 - \sigma_{u(\text{ajustado})}^2}{\sigma_{u(\text{vacío})}^2} \times 100 \quad (3.14)$$

La estimación se realiza por máxima verosimilitud con aproximación de Laplace, y la comparación entre modelos anidados se apoya en el criterio de información de Akaike y el criterio bayesiano de Schwarz. El procedimiento ha sido aplicado al bajo peso al nacer tanto en encuestas nacionales (Kassie et al., 2025) como en contextos urbanos latinoamericanos (Rodríguez López et al., 2021).

3.8. Modelos de clasificación supervisada

El aprendizaje supervisado consiste en aprender una función que asocia un vector de características $\mathbf{x} = (x_1, x_2, \dots, x_p)$ con una variable respuesta Y , a partir de un conjunto de pares $(\mathbf{x}_i, y_i)$ etiquetados (Hastie et al., 2009). En este estudio Y es binaria (presencia o ausencia de bajo peso al nacer) y los predictores son los determinantes sociales de la madre registrados en el certificado de nacido vivo.

Este componente del análisis persigue un objetivo distinto del de los modelos multinivel de la Sección 3.7. Allí el propósito es explicativo: estimar la magnitud del efecto social y descomponer la desigualdad. Aquí es predictivo: establecer con qué anticipación puede identificarse un nacimiento en riesgo a partir únicamente de la posición social de la madre, y determinar si la introducción de no linealidades e interacciones aporta capacidad predictiva real o si la regresión logística captura ya la mayor parte de la señal. Los siete algoritmos se describen a continuación, ordenados por complejidad creciente.

3.8.1. Notación

En lo que sigue, $\mathbf{x}_i = (x_{i1}, \dots, x_{ip})^\top$ denota el vector de determinantes sociales del nacimiento i ; $y_i \in \{0, 1\}$ indica la presencia de bajo peso al nacer; $\hat{p}_i$ es la probabilidad estimada de que $y_i = 1$; N es el número de observaciones y p el de predictores. Todos los modelos se ajustan sobre el conjunto de entrenamiento y se evalúan sobre el de prueba, según el procedimiento de la Sección 3.9.

3.8.2. Regresión logística

La regresión logística modela la probabilidad de pertenencia a la clase positiva mediante la función sigmoide aplicada a un predictor lineal (Hosmer et al., 2013):

$$P(y_i = 1 \mid \mathbf{x}_i) = \hat{p}_i = \frac{1}{1 + e^{-(\beta_0 + \mathbf{x}_i^\top \boldsymbol{\beta})}} \quad (3.15)$$

donde β_0 es el intercepto y $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top$ el vector de coeficientes. Estos se estiman por máxima verosimilitud, lo que equivale a minimizar la entropía cruzada binaria, también llamada pérdida logarítmica:

$$\min_{\beta_0, \boldsymbol{\beta}} -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right] \quad (3.16)$$

El modelo asume una relación lineal entre los predictores y el logaritmo de la razón de momios, e independencia de las observaciones. Su principal ventaja es la interpretabilidad: cada coeficiente es el cambio en el *log-odds* asociado a la presencia del factor, y $\exp(\beta_j)$ es la razón de momios del predictor x_j , que es la medida de asociación descrita en la Sección 3.3.

Se utiliza como modelo de referencia por tres razones. Por su uso establecido en epidemiología, donde la razón de momios es la métrica estándar de asociación. Porque es el modelo que sostiene la descomposición del índice de concentración de la Sección 3.6, de modo que su ajuste es necesario con independencia del ejercicio predictivo. Y porque el contraste con modelos más flexibles permite evaluar si la estructura social del riesgo es esencialmente aditiva.

3.8.3. Regresión logística penalizada: Lasso

Cuando los predictores son numerosos o están correlacionados entre sí, la estimación por máxima verosimilitud produce coeficientes inestables y de varianza elevada. La regularización añade a la función objetivo un término que penaliza la magnitud de los coeficientes.

La penalización *lasso* (*least absolute shrinkage and selection operator*), propuesta por Tibshirani (Tibshirani, 1996), emplea la norma L_1 . Partiendo de la misma función de probabilidad (3.15), el problema de optimización es

$$\min_{\beta_0, \beta} \left[-\frac{1}{N} \sum_{i=1}^N \left(y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right) + \lambda \sum_{j=1}^p |\beta_j| \right] \quad (3.17)$$

donde $\lambda \geq 0$ regula la intensidad de la penalización y se selecciona por validación cruzada. Con $\lambda = 0$ se recupera la regresión logística sin penalizar; a medida que λ crece, los coeficientes se contraen hacia cero.

La propiedad distintiva de la norma L_1 es que su punto no diferenciable en el origen lleva algunos coeficientes *exactamente* a cero, de modo que el lasso realiza selección de variables de forma automática. Esto resulta pertinente aquí porque el conjunto de determinantes sociales incluye variables conceptualmente solapadas, como el régimen de afiliación, el nivel educativo y el área de residencia, cuya colinealidad se diagnostica en la Sección 3.4.

3.8.4. Regresión logística penalizada: Ridge

La regresión *ridge*, introducida por Hoerl y Kennard (Hoerl and Kennard, 1970), penaliza la norma L_2 , es decir, la suma de los cuadrados de los coeficientes:

$$\min_{\beta_0, \beta} \left[-\frac{1}{N} \sum_{i=1}^N \left(y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i) \right) + \lambda \sum_{j=1}^p \beta_j^2 \right] \quad (3.18)$$

A diferencia del lasso, la penalización cuadrática es diferenciable en todo el dominio y contrae los coeficientes hacia cero sin anularlos, por lo que conserva todas las variables en el modelo. En ambos casos la penalización se aplica a β pero no al intercepto β_0 , y exige estandarizar previamente los predictores, ya que su magnitud depende de la escala.

Ridge es preferible cuando se asume que muchos predictores contribuyen de forma pequeña pero real, situación verosímil en el estudio de determinantes sociales, donde la desventaja se acumula a través de múltiples dimensiones simultáneas en lugar de concentrarse en una sola. El contraste entre ambas penalizaciones es, por tanto, informativo en

sí mismo: si el lasso anula gran parte de los determinantes sin pérdida de desempeño, la desigualdad se concentra en pocos ejes; si ridge resulta superior, la desventaja es difusa y acumulativa.

3.8.5. Árboles de decisión

Un árbol de decisión particiona recursivamente el espacio de predictores en M regiones disjuntas $R_1, \dots, R_M$ y asigna a cada una un valor constante (Breiman et al., 1984). La función de predicción es, por tanto, una función escalonada:

$$\hat{f}(\mathbf{x}) = \sum_{m=1}^M c_m I(\mathbf{x} \in R_m) \quad (3.19)$$

donde c_m es el valor asignado a la región R_m e $I(\cdot)$ es la función indicadora. En clasificación, c_m es la clase mayoritaria de la región o, si se requiere una probabilidad, la proporción de casos positivos que contiene.

La construcción del árbol procede de forma voraz: en cada nodo se elige la variable y el punto de corte que producen la mayor reducción de impureza. Los criterios habituales son el índice de Gini y la entropía. Para un nodo con K clases y proporciones p_k :

$$G = 1 - \sum_{k=1}^K p_k^2 \quad (3.20)$$

$$H = - \sum_{k=1}^K p_k \log_2(p_k) \quad (3.21)$$

Ambos alcanzan su máximo cuando las clases están equilibradas en el nodo y valen cero cuando el nodo es puro. Sus resultados suelen ser muy similares; en este trabajo se emplea el índice de Gini, que es computacionalmente más económico al no requerir el cálculo de logaritmos. Para completar la exposición cabe señalar que, en problemas de regresión, el criterio equivalente es el error cuadrático medio dentro de cada región,

$$\text{MSE} = \frac{1}{N_m} \sum_{i \in R_m} (y_i - \hat{y}_{R_m})^2 \quad (3.22)$$

aunque no se utiliza aquí, dado que el desenlace de este estudio es binario.

El árbol de decisión captura interacciones entre predictores sin necesidad de especificarlas y genera reglas legibles, lo que facilita la comunicación de los resultados a audiencias

no técnicas. Su limitación es la inestabilidad: pequeñas variaciones en los datos pueden producir estructuras muy distintas, y un árbol sin restricciones sobreajusta con facilidad. Por ello se controlan la profundidad máxima y el número mínimo de observaciones por hoja.

3.8.6. Random Forest

Random Forest es un método de ensamble basado en *bagging* (*bootstrap aggregating*), propuesto por Breiman (Breiman, 2001). El algoritmo construye B árboles $T_1, \dots, T_B$, cada uno entrenado sobre una muestra bootstrap distinta del conjunto de entrenamiento. La segunda fuente de aleatoriedad es decisiva: en cada división de un nodo se considera únicamente un subconjunto aleatorio de $m < p$ variables predictoras, lo que descorrelaciona los árboles entre sí y reduce la varianza del ensamble más de lo que lograría el remuestreo por sí solo.

En clasificación, la predicción se obtiene por voto de mayoría:

$$\hat{C}_{\text{rf}}^B(\mathbf{x}) = \text{Moda} \{T_b(\mathbf{x})\}_{b=1}^B \quad (3.23)$$

y en regresión, por promedio de las predicciones individuales:

$$\hat{f}_{\text{rf}}^B(\mathbf{x}) = \frac{1}{B} \sum_{b=1}^B T_b(\mathbf{x}) \quad (3.24)$$

En este estudio se emplea la formulación de clasificación (3.23). La expresión (3.24) se aplica de forma análoga cuando el ensamble se utiliza para promediar las probabilidades estimadas por cada árbol, procedimiento preferible al voto de mayoría cuando interesa una probabilidad calibrada y no solo una etiqueta.

Random Forest captura interacciones no lineales sin necesidad de especificarlas, es robusto frente a variables irrelevantes y proporciona una medida nativa de importancia de variables mediante la reducción promedio de impureza de Gini (3.20) acumulada en los nodos de todos los árboles. Su desempeño es competitivo en una amplia variedad de problemas con datos tabulares.

3.8.7. Gradient boosting

El *gradient boosting* es, como Random Forest, un método de ensamble de árboles, pero los construye de forma secuencial y no independiente (Chen and Guestrin, 2016). Cada

árbol nuevo se entrena para corregir los errores residuales del ensamble acumulado hasta ese punto, de modo que el modelo reduce el sesgo por adición sucesiva en lugar de reducir la varianza por promediado.

En la iteración t , el algoritmo minimiza una función objetivo que combina una pérdida diferenciable con un término de regularización sobre la complejidad del árbol añadido:

$$\mathcal{L}^{(t)} = \sum_{i=1}^N \ell(y_i, \hat{y}_i^{(t-1)} + f_t(\mathbf{x}_i)) + \Omega(f_t) \quad (3.25)$$

donde $\hat{y}_i^{(t-1)}$ es la predicción acumulada tras $t - 1$ iteraciones, f_t es el árbol añadido en la iteración t y $\Omega(f_t)$ penaliza el número de hojas y la magnitud de los pesos mediante normas L_1 y L_2 . Para el desenlace binario de este estudio, ℓ es la entropía cruzada de la Ecuación (3.16). La tasa de aprendizaje controla la contribución de cada árbol al ensamble y actúa como mecanismo adicional de regularización.

Su inclusión responde a una razón concreta: en problemas de clasificación sobre datos tabulares, el *gradient boosting* es hoy el punto de referencia frente al cual se juzga cualquier comparación de modelos, y su ausencia dejaría incompleto el contraste entre la regresión logística y las alternativas no lineales. A diferencia del bosque aleatorio, que promedia árboles profundos e independientes, el *boosting* combina árboles poco profundos y dependientes entre sí, lo que suele traducirse en mejor desempeño sobre datos tabulares a costa de una mayor sensibilidad a los hiperparámetros y de un riesgo de sobreajuste que exige control explícito.

3.8.8. Redes neuronales artificiales

El perceptrón multicapa es una red de propagación hacia adelante compuesta por una capa de entrada, una o más capas ocultas y una capa de salida (Goodfellow et al., 2016). Cada neurona j de la capa l calcula una combinación lineal de las activaciones de la capa anterior y le aplica una función de activación no lineal $g(\cdot)$:

$$a_j^{(l)} = g(z_j^{(l)}) = g\left(\sum_i w_{ji}^{(l)} a_i^{(l-1)} + b_j^{(l)}\right) \quad (3.26)$$

donde $w_{ji}^{(l)}$ es el peso que conecta la neurona i de la capa $l - 1$ con la neurona j de la capa l , y $b_j^{(l)}$ es su sesgo. En notación matricial, la red completa de L capas se expresa como la composición

$$\hat{y} = g_{\text{out}}\left(\mathbf{W}^{(L)} g_{L-1}\left(\cdots g_1\left(\mathbf{W}^{(1)}\mathbf{x} + \mathbf{b}^{(1)}\right) \cdots\right) + \mathbf{b}^{(L)}\right) \quad (3.27)$$

con $\mathbf{a}^{(0)} = \mathbf{x}$. La función de activación de las capas ocultas es la unidad lineal rectificada, $g(z) = \max(0, z)$, y la de salida es la sigmoide $g_{\text{out}}(z) = (1 + e^{-z})^{-1}$, que devuelve una probabilidad. Los parámetros $\mathbf{W}$ y $\mathbf{b}$ se estiman minimizando la entropía cruzada binaria

$$\mathcal{L}(\mathbf{W}, \mathbf{b}) = -\frac{1}{N} \sum_{i=1}^N \left[y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i) \right] \quad (3.28)$$

mediante descenso de gradiente estocástico, calculando las derivadas parciales por retropropagación del error.

Conviene notar que una red sin capas ocultas y con activación sigmoide en la salida es exactamente la regresión logística (3.15), y que su función de pérdida (3.28) coincide con (3.16). Las capas ocultas son, por tanto, lo único que añade capacidad de representación no lineal: la comparación entre ambos modelos aísla el aporte de esa flexibilidad.

La red neuronal representa el extremo de mayor flexibilidad del conjunto comparado. Puede aproximar relaciones de forma arbitraria, pero a costa de la interpretabilidad y de una mayor sensibilidad a la escala de los predictores, al tamaño de la muestra y a la elección de hiperparámetros. Su inclusión permite establecer un techo empírico de capacidad predictiva: si un modelo de esta flexibilidad no supera a la regresión logística, puede concluirse que la relación entre posición social y bajo peso al nacer es esencialmente aditiva y que la complejidad algorítmica no aporta información adicional.

3.8.9. Contraste jerárquico entre el modelo multinivel y el ensemble

Los modelos de clasificación descritos hasta aquí tratan cada nacimiento como una observación independiente, supuesto que la Sección 3.7 rechaza de forma explícita para el componente explicativo. Esta asimetría no es inocua: si la dependencia territorial es sustantiva, un modelo predictivo que la ignore está desaprovechando estructura que el propio marco teórico ya justificó.

Para ponerlos en relación se ajusta el modelo de *gradient boosting* incorporando el departamento de residencia como variable categórica codificada, y se comparan las medidas de agrupamiento territorial que produce frente a las del modelo logístico multinivel clásico. El contraste se articula en tres cantidades.

- **Varianza territorial capturada.** A partir de las probabilidades predichas por el ensamble se calcula la varianza entre departamentos y, con ella, una correlación intraclass análoga a la de la Ecuación (3.12). La comparación con la CCI del modelo multinivel indica si el ensamble recupera por vía puramente predictiva la misma estructura que el modelo de efectos aleatorios estima por verosimilitud.
- **Razón de momios mediana empírica.** Se calcula el equivalente empírico de la MOR (3.13) sobre las predicciones del ensamble, lo que permite expresar la heterogeneidad contextual capturada por el modelo predictivo en la misma escala que la del modelo explicativo.
- **Contracción.** El modelo multinivel aplica contracción a los departamentos con pocos nacimientos, acercando su estimación a la media nacional; el ensamble, en cambio, no contrae. El contraste entre ambas estimaciones departamentales cuantifica el efecto de la contracción jerárquica y resulta particularmente informativo en los departamentos de menor población, donde las estimaciones no contraídas son más inestables.

La comparación tiene un propósito sustantivo y no meramente ilustrativo. Si el ensamble reproduce la magnitud de la variación territorial estimada por el modelo multinivel, ambos enfoques convergen y el hallazgo gana robustez. Si el ensamble la sobreestima sistemáticamente en los departamentos pequeños, el resultado ilustra empíricamente el valor de la contracción jerárquica sobre datos reales, que es precisamente el argumento que justifica emplear modelos de efectos aleatorios y no efectos fijos por territorio.

3.9. Estrategia de validación y métricas de evaluación

3.9.1. Partición estratificada y validación cruzada

El conjunto de datos se divide en entrenamiento y prueba mediante una partición estratificada que preserva la proporción de la clase positiva en ambos subconjuntos. La estratificación es necesaria porque la prevalencia del bajo peso al nacer es baja y una partición aleatoria simple podría generar subconjuntos con proporciones distintas.

Sobre el conjunto de entrenamiento se aplica **validación cruzada anidada**: un bucle interno selecciona los hiperparámetros y un bucle externo, sobre datos que ese bucle interno nunca vio, estima el desempeño. El bucle interno es una validación cruzada estratificada de k pliegues: los datos se dividen en k subconjuntos, se entrena el modelo k veces dejando cada vez un pliegue como validación, y las métricas se promedian sobre los

k ajustes. Este procedimiento proporciona una estimación menos variable del desempeño y es el mecanismo mediante el cual se selecciona el parámetro de regularización λ de las Ecuaciones (3.17) y (3.18).

3.9.2. Manejo del desbalance de clases

La clase positiva es minoritaria. Un clasificador que prediga siempre la clase mayoritaria alcanzaría una exactitud elevada sin identificar un solo caso, de modo que el desbalance debe abordarse de forma explícita. Se emplea ponderación nativa de clases, que asigna a cada observación un peso inversamente proporcional a la frecuencia de su clase en la función de pérdida. Frente al remuestreo sintético (Chawla et al., 2002), la ponderación tiene la ventaja de no alterar la distribución empírica de los datos, lo que resulta relevante en un estudio cuyo objetivo paralelo es estimar la prevalencia real del desenlace.

3.9.3. Métricas de evaluación

A partir de la matriz de confusión, con VP verdaderos positivos, FP falsos positivos y FN falsos negativos, se definen la precisión y la sensibilidad:

$$\text{Precisión} = \frac{VP}{VP + FP}, \quad \text{Sensibilidad} = \frac{VP}{VP + FN} \quad (3.29)$$

La puntuación F_1 es la media armónica de ambas y constituye el criterio principal de comparación:

$$F_1 = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \quad (3.30)$$

Se adopta F_1 y no la exactitud porque esta última es engañosa ante clases desbalanceadas. La elección entre precisión y sensibilidad no es neutral: en salud pública, un falso negativo (no identificar un nacimiento en riesgo) tiene un costo mayor que un falso positivo (destinar seguimiento a un caso que no lo requería), de modo que la sensibilidad se reporta de forma destacada junto al F_1 .

Se reporta además la especificidad, definida como la proporción de verdaderos negativos entre los casos sin el desenlace. Se acompañan la curva ROC, con su área bajo la curva como medida de discriminación independiente del umbral, y la curva de precisión-sensibilidad, más informativa que la ROC cuando la clase positiva es minoritaria. La incertidumbre de todas las métricas se cuantifica por remuestreo bootstrap según el procedimiento de la Sec-

ción 3.12, y la comparación entre modelos se resuelve mediante el criterio de solapamiento de los intervalos de confianza.

3.10. Confusión, mediación y estrategia de modelos anidados

Las secciones anteriores describen cómo se estima la asociación entre un determinante y el desenlace. Esta describe qué variables deben entrar en el modelo y cuáles no, que es una decisión previa y de consecuencias mayores: un modelo correctamente estimado sobre una especificación equivocada produce un número preciso y sin sentido.

3.10.1. Confusor y mediador

Un **factor de confusión** es una variable que influye a la vez sobre la exposición y sobre el desenlace, sin situarse en la cadena causal que los une. Genera una asociación espuria entre ambos, y no ajustar por ella sesga la estimación. La edad materna cumple ese papel en este estudio: incide sobre el nivel educativo alcanzado, puesto que las madres muy jóvenes han tenido menos oportunidad de completar su formación, y de manera independiente sobre el riesgo de bajo peso al nacer.

Un **mediador** es una variable que se sitúa *dentro* de la cadena causal: la exposición actúa sobre ella y ella sobre el desenlace. El número de consultas prenatales cumple ese papel: la posición socioeconómica condiciona el acceso oportuno al control prenatal, y ese control incide sobre el crecimiento fetal. Lo mismo ocurre con el estado nutricional materno y con la patología del embarazo.

La diferencia entre ambos no es estadística sino causal, y no puede resolverse mirando los datos: dos variables con idéntica correlación con la exposición y el desenlace exigen tratamientos opuestos según su posición en el orden temporal y causal (Hernán and Robins, 2020). Por eso la especificación del modelo debe apoyarse en un supuesto explícito sobre esa estructura, que es lo que representa el grafo de la Figura 3.1.

3.10.2. Efecto total y efecto directo

De la distinción se sigue una regla operativa. Ajustar por un confusor corrige un sesgo y acerca la estimación al efecto real. Ajustar por un mediador no corrige nada: bloquea una parte del efecto que se pretende estimar y devuelve una cantidad distinta de la buscada.




Figura 3.1: Grafo acíclico dirigido con la estructura causal supuesta. La flecha discontinua representa el efecto contextual del territorio, que los modelos multinivel de la Sección 3.7 estiman como varianza de nivel superior.

Este fenómeno se conoce como *sobreajuste* y es una fuente frecuente de subestimación en epidemiología social (VanderWeele, 2015).

Formalmente, el modelo que ajusta únicamente por confusores estima el **efecto total** de la posición socioeconómica: todo el efecto, transcurra por la vía que transcurra. El modelo que añade además los mediadores estima el **efecto directo controlado**: la parte del efecto que no pasa por las vías bloqueadas (VanderWeele, 2015).

Ninguno de los dos es el correcto en abstracto; responden a preguntas distintas. Para una política pública dirigida a reducir la inequidad perinatal, la cantidad relevante es el efecto total, porque una intervención sobre la educación materna actúa simultáneamente por todas las vías. El efecto directo interesa para otra pregunta: si la atención prenatal fuera igual para todas las madres, ¿cuánta desigualdad persistiría?

3.10.3. Consecuencia para la estrategia de modelos anidados

De aquí se deriva la lectura de la secuencia de modelos descrita en la Sección 4.4.7. El Modelo 1, que incorpora los determinantes sociales ajustados solo por confusores demográficos, se reporta como estimación principal del **efecto total**. El Modelo 2, que añade las variables del embarazo, se reporta como estimación del **efecto directo**.

El coeficiente social se atenuará al pasar del Modelo 1 al Modelo 2. Esa atenuación no es un defecto del modelo ni evidencia de que el efecto social fuera espurio: es la medida de cuánto del efecto transcorre por la vía bloqueada, y por tanto un resultado sustantivo

sobre el mecanismo. Se reporta de forma explícita como porcentaje de atenuación de cada coeficiente, y no se interpreta como corrección de un sesgo.

Conviene señalar la limitación del procedimiento. La descomposición en efecto total y directo mediante modelos anidados es válida bajo el supuesto de que no existen confusores no medidos de la relación entre el mediador y el desenlace (VanderWeele, 2015). Ese supuesto no es verificable con los datos disponibles, de modo que las cantidades estimadas deben interpretarse como aproximaciones y no como efectos causales identificados.

3.11. Tratamiento de datos faltantes

Ninguna variable del certificado de nacido vivo está completa. Descartar los registros incompletos es la salida más simple, pero solo es inocua bajo un supuesto muy restrictivo sobre el origen de la ausencia. Esta sección expone ese supuesto y el procedimiento que se adopta cuando no se sostiene.

3.11.1. Mecanismos de ausencia

Rubin (Rubin, 1976) distingue tres mecanismos, cuyas implicaciones para la validez del análisis son muy distintas.

- **Ausencia completamente al azar (MCAR).** La probabilidad de que un dato falte no depende de ningún valor, observado o no. El subconjunto completo es entonces una muestra aleatoria del total y el análisis de casos completos es insesgado, aunque pierde precisión. Es un supuesto fuerte y rara vez plausible en registros administrativos.
- **Ausencia al azar (MAR).** La probabilidad de que un dato falte depende de variables observadas, pero no del valor ausente en sí. Si la pertenencia étnica se diligencia peor en los municipios rurales dispersos, pero dentro de cada municipio la ausencia no guarda relación con la etnia real de la madre, el mecanismo es MAR. Bajo este supuesto la información de las variables observadas permite recuperar la distribución del dato ausente, y la imputación múltiple produce estimaciones válidas.
- **Ausencia no al azar (MNAR).** La probabilidad de que un dato falte depende del propio valor ausente. Si las madres sin ninguna escolaridad son sistemáticamente menos propensas a que ese dato quede registrado, ninguna técnica basada en los datos observados corrige el sesgo, porque la información necesaria no está en la base.

La distinción entre MAR y MNAR no es verificable empíricamente: ambos mecanismos producen patrones idénticos en los datos observados. Es un supuesto que se declara y cuya plausibilidad se argumenta, no una hipótesis que se contrasta.

3.11.2. Relevancia en esta fuente

Tres variables concentran el problema. La pertenencia étnica y el nivel educativo de la madre presentan diligenciamiento incompleto, y el número de consultas prenatales depende de que el dato haya sido trasladado desde la historia clínica al certificado. En los tres casos hay razones para sospechar que la ausencia no se distribuye al azar respecto del territorio: la calidad del diligenciamiento depende de la carga asistencial y de la capacidad institucional de quien certifica, que son menores precisamente donde la población es más vulnerable.

Esto tiene una consecuencia direccional que debe declararse. Si los registros incompletos se concentran entre las madres de menor posición social, el análisis de casos completos las excluye de forma desproporcionada y la desigualdad estimada resulta *menor* que la real. El sesgo, en otras palabras, opera en contra de la hipótesis del estudio: los resultados obtenidos con casos completos constituyen una cota inferior de la inequidad.

Una precisión operativa: en las Estadísticas Vitales la ausencia no aparece como celda vacía sino codificada con valores convencionales, habitualmente 9 o 99 según la longitud del campo. Un análisis que no los recodifique previamente tratará “Sin información” como una categoría sustantiva más y producirá coeficientes carentes de interpretación.

3.11.3. Imputación múltiple por ecuaciones encadenadas

El procedimiento habitual bajo el supuesto MAR es la imputación múltiple por ecuaciones encadenadas (van Buuren and Groothuis-Oudshoorn, 2011). Se expone aquí porque es la referencia frente a la cual se justifica el tratamiento que este trabajo finalmente adopta (casos completos con cotas por ausencia, según se argumenta en la Sección 4.3.4) y porque comprender qué supone es lo que permite ver por qué no resulta apropiado cuando el supuesto MAR es precisamente lo que se desea no dar por bueno. El procedimiento ajusta un modelo condicional para cada variable incompleta en función de las demás y genera m conjuntos de datos completos, cada uno con valores imputados distintos que reflejan la incertidumbre sobre el dato ausente. El análisis se repite en cada conjunto y las m estimaciones se combinan mediante las reglas de Rubin: el estimador puntual es el promedio de los m estimadores,

$$\bar{\theta} = \frac{1}{m} \sum_{j=1}^m \hat{\theta}_j \quad (3.31)$$

y su varianza total suma la variabilidad dentro de cada conjunto y la variabilidad entre conjuntos,

$$T = \bar{U} + \left(1 + \frac{1}{m}\right) B, \quad \bar{U} = \frac{1}{m} \sum_{j=1}^m \hat{U}_j, \quad B = \frac{1}{m-1} \sum_{j=1}^m (\hat{\theta}_j - \bar{\theta})^2 \quad (3.32)$$

donde $\hat{U}_j$ es la varianza estimada en el conjunto j . El término B es lo que distingue a la imputación múltiple de la sustitución por un valor único: incorpora al error estándar la incertidumbre propia del procedimiento de imputación, que la sustitución simple ignora y que la lleva a subestimar la varianza.

Un modelo de imputación adecuado incluiría todas las variables del modelo de análisis, incluido el desenlace, y las variables auxiliares que ayudan a predecir la ausencia, en particular el territorio y el año.

La limitación del procedimiento es la que determina su papel en este trabajo: toda su validez descansa en el supuesto MAR, que en registros administrativos no es contrastable con la información disponible. Cuando ese supuesto es justamente lo que se pone en duda (como ocurre aquí, según se argumentó más arriba a propósito de la ausencia diferencial por posición social), la imputación múltiple no puede resolver la duda, porque la presupone resuelta. Por esa razón el análisis principal de este trabajo se realiza sobre casos completos y se acompaña de cotas que no exigen supuesto alguno sobre el mecanismo de ausencia, según se expone en la Sección 4.4.6.

3.12. Estimación de intervalos de confianza por bootstrap

Ni el índice de concentración corregido, ni el índice relativo de desigualdad, ni las contribuciones de la descomposición tienen expresión analítica cerrada para su varianza. Sus intervalos de confianza se obtienen por remuestreo bootstrap (Efron, 1979): se extraen B muestras con reemplazo del mismo tamaño que la original, se recalcula el estadístico en cada réplica y se construye el intervalo por el método del percentil, tomando los cuantiles 2,5 y 97,5 de la distribución empírica. Se emplean $B = 1,000$ réplicas. El criterio de

solapamiento de intervalos se conserva como regla conservadora de comparación entre estimaciones.

Capítulo 4

Metodología

Este capítulo describe las decisiones operativas del estudio: el diseño, la fuente de datos, la conformación de la muestra, la definición y operacionalización de las variables, y la estrategia de análisis estadístico. Los fundamentos conceptuales de los determinantes sociales de la salud y de las técnicas de medición de la desigualdad se desarrollaron en el Capítulo 3.

4.1. Enfoque y diseño

El estudio es cuantitativo, observacional, analítico y de carácter aplicado. Se basa en datos secundarios de un registro administrativo de cobertura nacional, lo que define un diseño de corte transversal repetido con componente multinivel, sobre el período 1998–2024. A diferencia de los diseños predictivos, cuyo objetivo es maximizar la capacidad de clasificación, aquí el propósito es explicativo: estimar la magnitud de la asociación entre la posición socioeconómica de la madre y el bajo peso al nacer, cuantificar la desigualdad social resultante y descomponerla en las contribuciones de cada determinante.

La unidad de análisis primaria es el nacimiento. Las unidades de agregación contextual son el municipio y el departamento de residencia habitual de la madre, lo que configura una estructura jerárquica de tres niveles: nacimientos anidados en municipios y municipios anidados en departamentos. Esta estructura no es un artificio estadístico, sino el reflejo de que la exposición social opera simultáneamente en el plano individual y en el territorial.

4.2. Descripción de los datos

4.2.1. Fuente y período

Se utilizaron los microdatos de nacimientos de las Estadísticas Vitales (EEVV) del Departamento Administrativo Nacional de Estadística, correspondientes al período 1998–2024 (Departamento Administrativo Nacional de Estadística, 2025). Las EEVV se producen a partir de los certificados de nacido vivo diligenciados por el personal de salud autorizado y consolidados por el DANE, y constituyen el registro oficial de los nacimientos del país.

Tres propiedades de esta fuente condicionan el diseño y deben explicitarse.

La primera es la cobertura censal. Las EEVV no notifican casos seleccionados sino la totalidad de los nacidos vivos registrados, de modo que numerador y denominador provienen del mismo instrumento. Esto hace directamente estimables las prevalencias, los índices de concentración y las curvas de concentración, sin necesidad de enlazar el archivo con una fuente externa de denominadores.

La segunda es que el peso al nacer y el tiempo de gestación constan en el mismo registro individual, con cobertura nacional y para los veintisiete años de la serie. Ambos se consignan en bandas y no en valores exactos, según se documenta en la Sección 4.3.2, de modo que lo que esta fuente aporta no es precisión de medida sino cobertura poblacional completa y continuidad temporal, que es precisamente lo que exige un análisis de desigualdad.

La tercera es la discontinuidad instrumental de la serie. El certificado de nacido vivo fue objeto de una actualización sustantiva hacia 2008, en el marco de la implementación de la certificación en línea a través del Registro Único de Afiliados. Los archivos de nacimientos de 1998–2007 contienen 33 variables, frente a 39 en los años recientes. La armonización de la serie y la verificación del año a partir del cual está disponible cada variable social son requisitos previos al análisis, y se documentan en la Sección 4.3.1.

4.2.2. Población y muestra

La población de estudio la constituyen todos los nacidos vivos registrados en las Estadísticas Vitales del DANE en Colombia durante el período 1998–2024. No se aplica muestreo probabilístico: se trabaja con el universo de nacimientos registrados, por lo que las estimaciones no requieren factores de expansión y los intervalos de confianza se interpretan como medida de la variabilidad del proceso de registro y no del muestreo.

La conformación de la muestra analítica se realiza en cuatro etapas secuenciales de depuración, resumidas en el Cuadro 4.1.

Cuadro 4.1: Conformación de la muestra analítica. Nacidos vivos registrados en las Estadísticas Vitales del DANE, 1998–2024. Los porcentajes se calculan sobre la base original. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Etapas	Criterio	Registros	%
Base original	Nacidos vivos registrados, EEVV–DANE, 1998–2024	18.008.809	100,00
Exclusión 1	Registros sin peso al nacer informado	–332.369	–1,85
Exclusión 2	Registros sin tiempo de gestación informado	–207.982	–1,16
Exclusión 3	Registros sin departamento y municipio de residencia habitual de la madre identificables en Colombia, incluidas las madres con residencia en el exterior	–64.431	–0,36
Exclusión 4	Duplicados exactos e incidencias de formato detectadas en la construcción de la matriz	–27.167	–0,15
<i>Total excluido</i>		<i>–631.949</i>	<i>–3,51</i>
Muestra analítica	Nacimientos incluidos en el análisis	17.376.860	96,49

Las cuatro exclusiones retiran en conjunto 631.949 registros, el 3,51 % de la base, de modo que la muestra analítica conserva 17.376.860 nacimientos, el 96,49 % de los nacidos vivos del período. Ninguna de ellas es discrecional: las dos primeras responden a la ausencia del desenlace o de la variable que permite clasificarlo; la tercera, a la imposibilidad de asignar el nacimiento a una unidad territorial, que es el requisito mínimo de la estructura jerárquica descrita en la Sección 3.7; y la cuarta, a registros que la construcción de la matriz identificó como no válidos.

Territorio de residencia, no de ocurrencia. La Exclusión 3 opera sobre el departamento y el municipio de *residencia habitual de la madre*, no sobre el lugar donde ocurrió el parto. La distinción es sustantiva y no meramente técnica: una mujer residente en un municipio rural que da a luz en un hospital de referencia de la capital pertenece analíticamente a su municipio de residencia. Asignarla al de ocurrencia concentraría artificialmente los nacimientos en las ciudades con oferta hospitalaria de alta complejidad, y el mapa resultante mediría la distribución de esa oferta en lugar de la desigualdad territorial que este trabajo se propone estimar.

Operacionalización de la Exclusión 3. La ausencia del territorio de residencia no se manifiesta de forma homogénea a lo largo de la serie, y reconocerlo es condición para aplicar el criterio de manera uniforme. Entre 2008 y 2024 el campo llega vacío. Entre 1998 y 2013, en cambio, nunca está vacío: la ausencia viene codificada mediante dos valores convencionales que no corresponden a ninguna entidad de la división político-administrativa. El primero, `CODPTORE = 1`, identifica el departamento de residencia como ignorado y aparece siempre acompañado de `CODMUNRE = 999`; reúne 16.328 registros. El segundo, `CODPTORE = 75`, corresponde a madres con residencia habitual en el exterior, y en esos casos el campo de municipio no contiene un municipio sino el código del país de residencia; reúne 2.170 registros. Un criterio que retirase únicamente los campos vacíos dejaría ambos conjuntos dentro de la muestra, y los dos códigos aparecerían en los mapas y en los ordenamientos departamentales como si designaran territorios reales. La Exclusión 3 contempla, por tanto, las dos formas de la ausencia.

Sobre las cifras de esta tabla. Los valores proceden de la ejecución del guion `01_edat.ipynb` sobre la matriz analítica versionada, y son reproducibles desde el repositorio. La Exclusión 3 coincide exactamente con la calculada en la versión preliminar de este cuadro en veinticuatro de los veintisiete años; la diferencia se concentra en 2004, 2005 y 2006, y suma 56 registros. La Exclusión 4 recoge duplicados exactos e incidencias de formato que la construcción de la matriz identificó con posterioridad a aquella versión. En conjunto la muestra difiere en 27.103 registros, el 0,16 %, y la prevalencia global pasa del 8,82 al 8,78 %: ninguna conclusión del trabajo se ve afectada.

La completitud mejora de forma sostenida a lo largo del período. La ausencia de peso al nacer pasa del 6,03 % en 1998 al 0,29 % en 2016, y la de tiempo de gestación, del 2,79 % al 0,12 % en el mismo lapso, lo que refleja la consolidación del certificado electrónico. En sentido contrario, la exclusión por territorio no identificable, marginal hasta 2017, se multiplica a partir de 2018 y alcanza 11.571 registros en 2019. La verificación de esos casos muestra que corresponden de manera casi exclusiva a madres con residencia habitual en Venezuela: en 2019, 11.434 de los 11.592 registros sin departamento asignable declaran ese país de residencia. El fenómeno documenta el efecto del flujo migratorio sobre el registro de nacimientos y debe tenerse presente al interpretar las series departamentales de los años recientes.

4.2.3. Variables del estudio

Variable respuesta. El bajo peso al nacer, definido como un peso inferior a 2.500 gramos (PESO_NAC). Se opera en forma **dicotómica**: presencia o ausencia de bajo peso al nacer sobre el total de nacidos vivos. Es el desenlace de los índices de desigualdad, de los modelos multinivel y de los modelos de clasificación, y es la única forma que se emplea en el trabajo.

Conviene precisar qué otras operacionalizaciones no se utilizan y por qué, porque son las que la literatura suele reportar y su ausencia podría atribuirse a un descuido en lugar de a una restricción de la fuente.

No existe una forma continua del desenlace. El certificado no registra el peso en gramos sino en ocho bandas de 500 g, de modo que no son calculables medias, desviaciones típicas ni modelos de regresión lineal sobre el peso. Esta restricción se documenta en la Sección 4.3.2.

No es posible el estrato por edad gestacional en los términos que fija la definición internacional. Separar el bajo peso a término, atribuible a restricción del crecimiento intrauterino, del asociado a prematuridad exige un corte en las 37 semanas, y T_GES se consigna en cinco bandas cuyos límites son *menos de 22, de 22 a 27, de 28 a 37, de 38 a 41 y de 42 y más*. El corte de las 37 semanas cae *dentro* de la tercera banda, que agrupa por tanto nacimientos pretérmino y nacimientos a término. El único corte que la fuente admite es el de las 38 semanas, que no es el de la definición, y por esa razón el contraste entre los dos mecanismos no se aborda. Queda recogido entre las limitaciones de la Sección 6.9.

La forma politómica ordinal sobre las ocho bandas de PESO_NAC sí es construible, y permitiría examinar el gradiente de severidad en lugar de un umbral único. No se desarrolla en este trabajo, cuyo objeto es la desigualdad en la ocurrencia del desenlace y no en su intensidad. Se recoge como línea de investigación futura en el Capítulo 7.

Variables de exposición. Los determinantes sociales registrados en el certificado de nacido vivo, referidos a la madre salvo indicación contraria. Se agrupan en tres dimensiones conceptuales, siguiendo el modelo adoptado en la Sección 3.1. El Cuadro 4.2 resume su operacionalización.

Variables de ajuste. La edad materna (EDAD_MADRE), categorizada en menor de 15 años, 15 a 19, 20 a 34 (referencia), 35 a 39 y 40 o más; la paridad (N_HIJOSV, N_EMB); la multiplicidad del embarazo (MUL_PARTO); el sexo del recién nacido (SEXO); y el año de ocurrencia (ANO) para captar la tendencia temporal.

Cuadro 4.2: Variables de exposición y su operacionalización en los microdatos de nacimientos de las EEVV. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Dimensión	Variable	Nombre en la base	Categorías analíticas
Posición socioeconómica	Nivel educativo de la madre	NIV_EDUM	Ninguno · Primaria · Secundaria · Técnico o superior (ref.)
	Nivel educativo del padre	NIV_EDUP	Mismas categorías
Acceso y aseguramiento	Régimen de afiliación	SEG_SOCIAL	Contributivo (ref.) · Subsidiado · Especial o excepción · No asegurado
	Consultas prenatales	NUMCONSUL	Ninguna · 1 a 3 · 4 a 6 · 7 o más (ref.)
Adscripción social y territorial	Pertenencia étnica	IDPERTET	Indígena · Rom · Raizal · Palenquero · Negro o afrocolombiano · Ninguna (ref.)
	Área de residencia	AREA_RES	Cabecera (ref.) · Centro poblado · Rural disperso
	Estado conyugal	EST_CIVM	Casada o unión libre (ref.) · Soltera · Separada o viuda

Variables de nivel contextual. El municipio y el departamento de residencia habitual de la madre (CODMUNRE, CODPTORE) definen los niveles superiores de la estructura jerárquica. Se emplea la residencia y no la ocurrencia del nacimiento, porque la exposición social opera en el lugar donde vive la madre y no donde es atendida.

Ausencia de covariables agregadas de privación municipal. El trabajo no incorpora indicadores municipales de privación (índice de pobreza multidimensional Departamento Administrativo Nacional de Estadística, 2023 o porcentaje de necesidades básicas insatisfechas) como predictores de nivel 2, y conviene justificar esa ausencia porque constituye una opción deliberada y no una omisión. La razón es de comparabilidad temporal: el análisis abarca 1998–2024, mientras que los indicadores municipales de privación solo se publican para los años censales, de manera que un único valor tendría que sostener la caracterización de un municipio a lo largo de más de dos décadas. Un indicador medido en un año censal y aplicado a toda la serie introduciría error de medición creciente con la distancia a ese año, precisamente en el período donde se concentra el hallazgo sobre la evolución de la desigualdad.

La consecuencia es que la variación territorial se modela mediante interceptos aleatorios y no mediante covariables contextuales observadas. Los interceptos capturan la heterogeneidad entre municipios sin exigir que se declare a qué se debe; lo que no permiten es atribuirle a la privación material en lugar de a la oferta de servicios, la composición de

mográfica o cualquier otro factor. Esta limitación no compromete la quinta pregunta de investigación, que indaga *qué proporción* de la variación es territorial y si persiste tras ajustar por la composición individual (ambas cantidades estimables con interceptos aleatorios), pero sí impide avanzar sobre *por qué* unos municipios presentan mayor riesgo que otros. Así se recoge entre las limitaciones del trabajo.

4.3. Preparación y depuración de los datos

4.3.1. Armonización de la serie 1998–2024

Los microdatos no se publican en un archivo único sino en trece catálogos distintos, cada uno con su propio diccionario de datos. El Cuadro 4.3 los relaciona. Entre ellos, ni los nombres de los archivos ni los de las variables son idénticos, de modo que la construcción de una serie continua exige una etapa previa de armonización que constituye, en sí misma, un resultado metodológico del trabajo.

El procedimiento adoptado corresponde a la **armonización mediante esquema canónico y tabla de correspondencias versionada**, conocida en la literatura anglosajona como *crosswalk* y enmarcada en el enfoque de *modelo de datos común*. Es la estrategia empleada de forma estándar en la armonización de censos y encuestas longitudinales, como en el proyecto IPUMS (Ruggles et al., 2003), y en los modelos de datos clínicos estandarizados, como el modelo OMOP de la iniciativa OHDSI (Hripcsak et al., 2015). Su adopción explícita permite que el procedimiento sea auditable y reutilizable por terceros. Comprende cuatro elementos.

Esquema canónico. Una lista maestra de conceptos, no de nombres de columna, que representa las variables de interés a lo largo de todo el período. En este trabajo lo constituyen los 44 conceptos del Apéndice D. La distinción entre concepto y nombre de campo es lo que permite seguir una misma variable aunque el instrumento la renombre.

Tabla de correspondencias con tres estados. Para cada concepto y cada versión del instrumento, la celda toma uno de tres valores, y no un simple presente o ausente:

- **Presente.** La variable existe y es comparable entre versiones.
- **Ausente por diseño** (*structural missing*). El concepto no existía en ese catálogo, como ocurre con la pertenencia étnica antes de 2008.

- **Renombrada.** El mismo concepto aparece bajo otro nombre de campo, como IDPERTET frente a IDPUEBLOIN en 2012 y 2013.

Separación entre ausencia estructural y ausencia por ítem. Esta distinción es decisiva, y lo es con independencia de cómo se traten después los valores que faltan. Una variable que no existía en el instrumento durante un tramo completo de años no falta al azar: no era observable por construcción. Tratarla como dato perdido, e intentar reconstruirla a través de ese quiebre estructural, introduciría sesgo. En consecuencia, la ausencia estructural se afronta restringiendo el período de análisis a los años en que la variable sí se capturó, tal como se hace con la pertenencia étnica y el régimen de afiliación, limitados a 2008–2024. La ausencia por ítem dentro de un mismo régimen de captura es la única que admite el tratamiento descrito en la Sección 4.3.4: análisis de casos completos acompañado de cotas que no exigen supuesto alguno sobre el mecanismo de ausencia.

Versión del instrumento como variable auxiliar. El catálogo o versión del certificado de nacido vivo se conserva como variable del análisis, junto al territorio y al año, dado que versiones distintas pueden presentar patrones de captura distintos incluso dentro de un mismo año. Sobre ella se apoya el contraste por régimen de codificación del Capítulo 5, que estima el índice de concentración dentro de cada versión del formulario y constituye la prueba que descarta que el resultado principal proceda del instrumento y no del fenómeno.

La tabla de correspondencias no se conserva únicamente como cuadro estático en el Apéndice D: se versiona además como archivo de texto plano (`datos/crosswalk.yaml`) dentro del repositorio descrito en el Apéndice A, de modo que cualquier persona pueda auditar cómo se mapeó cada variable entre versiones del instrumento.

Verificación empírica del esquema canónico

La aplicación del *crosswalk* sobre los veintisiete archivos permitió verificar empíricamente el número de conceptos. El conteo por archivo confirma los puntos de ruptura documentados: 33 variables entre 1998 y 2007; 38 entre 2008 y 2011 y de nuevo entre 2014 y 2019; 41 en 2012 y 2013, el máximo histórico; 37 en 2020; 39 entre 2021 y 2023; y 40 en 2024.

De ahí se sigue una distinción contraintuitiva que condiciona el diseño de la matriz. El máximo observado en un año cualquiera es 41, pero **la unión de todas las variables del período asciende a 45**, y ningún archivo anual las contiene simultáneamente. La diferencia se explica porque distintos conjuntos de variables aparecen en años que no

coinciden: los archivos de 2012 y 2013 aportan cuatro campos transitorios (NOM_INST, COD_INST, OTRPARATX y NOMCLASAD) que no existen en ningún otro año; GRU_SAN solo existe entre 1998 y 2007; TIPOFORMULARIO aparece desde 2021; y CODPAISNACMAD únicamente en 2024. Los 45 nombres de campo corresponden a los 44 conceptos del Apéndice D una vez resuelta la equivalencia IDPUEBLOIN $\rightarrow$ IDPERTET.

Construir la matriz con 41 columnas habría exigido descartar cuatro variables efectivamente observadas.

Incidencias de formato no documentadas

El procesamiento reveló tres incidencias que ningún diccionario recoge y que habrían impedido la lectura automática de la serie:

1. **Separadores heterogéneos.** Los archivos de 1998–2007 y 2012–2013 emplean punto y coma; el resto, coma.
2. **Codificaciones heterogéneas.** Doce archivos están en `latin-1` y quince en `UTF-8` con marca de orden de bytes.
3. **Delimitadores incrustados.** El archivo de 1998 contiene un punto y coma dentro de un campo de texto entrecomillado, en la línea 524.722, que invalida la autodetección del delimitador; y el de 2013 presenta un punto y coma sobrante al final del encabezado, que genera una columna adicional sin nombre.

La rutina de lectura detecta separador y codificación por inspección de la primera línea y del BOM, fija explícitamente el carácter de entrecomillado y descarta las columnas sin nombre.

El número de variables del archivo de nacimientos no es constante a lo largo del período. La Figura 4.1 resume su trayectoria y señala los puntos de ruptura del instrumento.

La lectura de la figura ordena el período en seis tramos. Entre 1998 y 2007 el archivo contiene 33 variables, con los nombres en minúscula, el grupo sanguíneo y el factor RH registrados en un solo campo y sin información sobre pertenencia étnica ni sobre el último grado aprobado. En 2008, con la implementación de la certificación en línea, el archivo salta a 38 variables: los nombres pasan a mayúscula, se separan IDHEMOCLAS e IDFACTORRH, y se incorporan la pertenencia étnica, el último grado aprobado por cada progenitor y la entidad administradora en salud. Los años 2012 y 2013 marcan el pico histórico de 41 variables, con cuatro campos transitorios sobre la institución de salud y la persona que

Cuadro 4.3: Catálogos de microdatos de nacimientos publicados por el DANE y número de variables del archivo correspondiente. Elaboración propia a partir de los diccionarios de datos publicados en el portal de microdatos (Departamento Administrativo Nacional de Estadística, 2025).

Catálogo	Años	Archivo(s) de nacimientos	N.º vars.
366	1998-2007	Nacimientos_1998 ... Nacimientos_2007	33
375	2008-2011	nac2008 ... nac2011	38
377	2012-2013	Nac_2012, Nac_2013	41
420	2014	nac2014	38
475	2015	nac2015	38
519	2016	nac2016	38
652	2017-2018	nac2017, nac2018	38
696	2019	nac2019	38
732	2020	nac2020	37
775	2021	nac2021	39
807	2022	nac2022	39
876	2023	nac2023	39
878	2024-2025	BD-EEVV-Nacimientos-2024	40




Figura 4.1: Evolución del número de variables del archivo de nacimientos de las Estadísticas Vitales, 1998–2024. Elaboración propia a partir de los diccionarios de datos publicados por el DANE para cada catálogo (Departamento Administrativo Nacional de Estadística, 2025).

atendió el parto. Entre 2014 y 2019 el archivo regresa a 38 variables al retirarse esos campos. En 2020 desciende a 37 por la pérdida de T_GES_AGRU_CIE. Y entre 2021 y 2024 asciende de nuevo hasta las 40 variables actuales.

Los Cuadros 4.4 y 4.5 detallan qué variables entran y cuáles desaparecen. El Apéndice D recoge la tabla completa de equivalencias, concepto por concepto, para los 44 conceptos que componen el certificado a lo largo de toda la serie.

Cuadro 4.4: Variables incorporadas al certificado de nacido vivo con posterioridad a 1998. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	Etiqueta	Aparece desde	Nota
OTRO_SIT	Otro sitio, ¿cuál?	Desde 2008	No existía en 1998-2007
T_GES_AGRU_CIE	Tiempo de gestación ajustado a agrupación CIE	Desde 2008 (con huecos)	Ausente en 1998-2007; ausente en el diccionario de 2012-2013; ausente en 2020; presente 2008-2019, 2021-2024
IDFACTORRH	Hemoclasificación: Factor RH	Desde 2008	Antes (1998-2007) iba unido con el grupo sanguíneo en una sola variable (gru_san)
IDPERTET IDPUEBLOIN	/ Reconocimiento étnico del nacido vivo	Desde 2008	No existía en 1998-2007; en 2012-2013 el DANE la llamó IDPUEBLOIN en vez de IDPERTET
ULTCURMAD	Último año o grado aprobado por la madre	Desde 2008	No existía en 1998-2007
ULTCURPAD	Último año o grado aprobado por el padre	Desde 2008	No existía en 1998-2007
IDCLASADMI	Entidad Administradora en Salud de la madre	Desde 2008	No existía en 1998-2007
OTRPARATX	El parto fue atendido por otra persona, ¿cuál?	Solo 2012-2013	Variable exclusiva de ese diccionario; no aparece antes ni después
NOMCLASAD	Nombre de la Administradora en Salud de la madre	Solo 2012-2013	Variable exclusiva de ese diccionario; no aparece antes ni después
TIPOFORMULARIO	Fuente del Certificado	Desde 2021	No existía antes de 2021
CODPAISNACMAD	País de nacimiento de la madre	Solo 2024	No existía en ningún periodo anterior

De esta consolidación se desprenden tres consecuencias para el diseño, que deben declararse de forma explícita.

La primera afecta al alcance temporal de los ejes de inequidad. La pertenencia étnica y la entidad administradora en salud no existen antes de 2008. En consecuencia, el análisis de esos ejes se restringe a 2008–2024, mientras que la serie completa 1998–2024 se reserva

Cuadro 4.5: Variables presentes en algunos períodos y ausentes en otros. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	Etiqueta	Presente en	Nota
NOM_INST	Nombre de la institución de salud	1998-2007 y 2012-2013	Ausente en 2008-2011, 2014-2024 (excepto que reaparece puntualmente en el diccionario 2012-2013)
COD_INST	Código de la institución de salud	1998-2007 y 2012-2013	Misma situación que NOM_INST
T_GES_AGRU_CIE	Tiempo de gestación ajustado a agrupación CIE	Se retira en el diccionario de 2012-2013 y en 2020	Vuelve a aparecer en 2021-2024

para los ejes de educación materna, área de residencia y territorio, presentes en todo el período.

La segunda es un cambio de nombre que resulta fácil pasar por alto. El campo de reconocimiento étnico se denomina IDPERTET en la mayoría de los catálogos, pero en los archivos de 2012 y 2013 aparece como IDPUEBLOIN. Una rutina que busque únicamente el primer nombre perderá dos años completos de información sin emitir ningún aviso.

La tercera es que tres conceptos no se comportan como una serie continua. Las variables NOM_INST y COD_INST solo están presentes en 1998–2007 y en 2012–2013, y T_GES_AGRU_CIE se retira en 2012–2013, reaparece de forma intermitente hasta 2019, se pierde en 2020 y vuelve en 2021. Ninguna de las tres puede emplearse como covariable en modelos que abarquen el período completo.




Figura 4.2: Distribución anual del nivel educativo materno antes y después de la recodificación a la escala común de cuatro niveles. La discontinuidad de 2008 en la serie original desaparece en la serie armonizada. Elaboración propia.




Figura 4.3: Distribución anual del estado conyugal de la madre antes y después de la recodificación a la escala común. Elaboración propia.




Figura 4.4: Distribución anual del régimen de afiliación de la madre antes y después de la recodificación a la escala común. Elaboración propia.

4.3.2. Consistencia y validación

Naturaleza categórica del desenlace

El certificado de nacido vivo **no registra el peso al nacer en gramos**. La variable PESO_NAC es categórica en los veintisiete años de la serie, con nueve categorías de intervalo:

Esta característica tiene tres consecuencias que deben declararse.

El desenlace dicotómico es construible sin pérdida de precisión. El umbral de la Organización Mundial de la Salud coincide exactamente con el límite superior de la categoría 4:

Cuadro 4.6: Categorías de la variable PESO_NAC en los microdatos de las EEVV. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Código	Intervalo	Código	Intervalo
1	menos de 1.000 g	6	3.000–3.499 g
2	1.000–1.499 g	7	3.500–3.999 g
3	1.500–1.999 g	8	4.000 g y más
4	2.000–2.499 g	9	sin información
5	2.500–2.999 g		

$$\text{BPN} = \begin{cases} 1 & \text{si PESO_NAC} \in \{1, 2, 3, 4\} \\ 0 & \text{si PESO_NAC} \in \{5, 6, 7, 8\} \\ \text{indefinido} & \text{si PESO_NAC} = 9 \end{cases} \quad (4.1)$$

La coincidencia entre el corte del DANE y el umbral de la OMS es fortuita pero afortunada: ninguna observación queda mal clasificada por efecto de la agrupación.

No existe una forma continua del desenlace. No es posible calcular medias de peso, desviaciones estándar ni modelos de regresión lineal sobre el peso al nacer, ni aplicar filtros de rango en gramos.

Las variables antropométricas y gestacionales comparten la limitación. TALLA_NAC se registra en seis categorías de intervalo y T_GES en cinco bandas de semanas, más los códigos de ignorado y de sin información. No es posible verificar la coherencia entre peso y edad gestacional mediante curvas percentilares, ni construir el indicador de pequeño para la edad gestacional con la precisión que exigen los estándares INTERGROWTH-21st o Fenton. Tampoco es posible aplicar el corte de las 37 semanas que separa el nacimiento pretérmino del nacimiento a término: la banda *de 28 a 37* lo contiene, de modo que los dos grupos quedan mezclados dentro de una misma categoría.

Validación de pertenencia al diccionario

En sustitución de una verificación de rangos continuos, que esta fuente no admite, se aplicó una **validación de pertenencia al diccionario**: para cada variable categórica se comprobó que todos los valores observados correspondieran a códigos documentados en el diccionario del período. El procedimiento identificó 167 registros (0,0009 % del total) con

desplazamiento de columnas, concentrados en dos patrones:

- **2004–2006 (67 registros).** Un separador sobrante desplaza los campos una posición. El desplazamiento es identificable porque NIV_EDUM toma el valor 170 —el código de país de CODPRES— y TALLA_NAC toma el valor del año.
- **2013 (100 registros).** Un punto y coma sin entrecomillar dentro del nombre de una institución fragmenta el campo y desplaza todos los siguientes. El daño se agrava porque COD_INST había sido corrompido previamente a notación científica, presumiblemente por apertura del archivo en una hoja de cálculo antes de su publicación.

En estos registros ninguna columna es fiable, por lo que se marcan mediante la variable indicadora FILA_CORRIDA y se excluyen del análisis. Las variables PESO_NAC e IDPERTET resultaron libres de códigos no documentados en los veintisiete años. Se detectaron asimismo códigos administrativos imposibles en SEG_SOCIAL entre 2004 y 2006 (valores 20, 22, 25, 32 y 40), tratados como faltantes.

Tratamiento de las categorías de no informado

Las categorías administrativas de *sin información* se tratan como datos faltantes y no como categorías sustantivas. La operación, sin embargo, **no puede aplicarse mediante una regla global**, porque el código que denota ausencia cambia entre períodos. Este punto se desarrolla en la Sección 4.3.6.

4.3.3. Codificación territorial

La codificación de departamentos y municipios se unifica según la División Político-Administrativa (DIVIPOLA) del DANE en su versión más reciente, considerando las creaciones, supresiones y recodificaciones municipales ocurridas dentro del período de estudio. Los casos sin correspondencia directa se documentan en un anexo de equivalencias.

4.3.4. Tratamiento de los valores faltantes

Se reporta la proporción de valores faltantes por variable y por año, con atención particular a la pertenencia étnica, el nivel educativo y el número de consultas prenatales, y se examina si la ausencia se distribuye de manera aleatoria o guarda relación con el territorio, el año o el tipo de institución que certifica.




Figura 4.5: Porcentaje de registros con valor observado en cada variable y año. Las franjas vacías anteriores a 2008 corresponden a variables que el certificado de nacido vivo no recogía en esa versión del instrumento. Elaboración propia.

El procedimiento adoptado, y por qué no es el previsto. El diseño inicial contemplaba imputación múltiple por ecuaciones encadenadas bajo el supuesto de datos faltantes al azar condicionalmente, con las reglas de combinación de las Ecuaciones (3.31) y (3.32) (van Buuren and Groothuis-Oudshoorn, 2011). Medida la completitud efectiva de las variables, ese procedimiento se descartó en favor de un **análisis de casos completos acompañado de cotas por ausencia**. Las razones son tres, y la última es la decisiva.

La primera es de magnitud. La variable que define el ordenamiento socioeconómico, el nivel educativo materno, está informada en el 96,80 % de los registros. Imputar el 3,2 % restante no puede desplazar un índice de forma apreciable, de modo que el procedimiento añadiría complejidad sin alterar la conclusión.

La segunda es de naturaleza. La variable con más ausencia, la pertenencia étnica, presenta un 40,1 % de nulos de los cuales *ninguno* es no respuesta: son ausencia estructural, porque el instrumento no recogía la pregunta antes de 2008, según se detalla en el Cuadro 4.7. Imputarla no recuperaría un dato perdido sino que fabricaría uno que nunca se recogió. La única variable con ausencia por ítem sustancial es el nivel educativo del padre, que no interviene en los modelos principales.

La tercera es de lógica del argumento. La imputación múltiple es válida bajo el supuesto de ausencia al azar condicional, que es precisamente el supuesto que el Capítulo 3 declara dudoso para esta fuente y que el trabajo se propone no dar por bueno. Un procedimiento

cuya validez descansa en el supuesto que se quiere someter a prueba no puede servir para someterlo a prueba.

El análisis de cotas, en cambio, no supone nada sobre el mecanismo de ausencia: asigna a la totalidad de los registros incompletos primero la categoría que minimiza la desigualdad estimada y después la que la maximiza, de modo que el intervalo resultante contiene el valor verdadero cualquiera que sea ese mecanismo, incluida la ausencia no aleatoria. El procedimiento se detalla en la Fase 6 y sus resultados en la Sección 5.7.1.

Qué se pierde y qué se gana con el cambio. Se pierde precisión: el análisis de casos completos descarta 556,762 registros sin ordenamiento educativo, y las cotas producen un intervalo más ancho que el que arrojaría la imputación. Se gana que la conclusión no dependa de un supuesto incontrastable. Dado que el resultado principal del trabajo es un cambio de *signo*, y que ambas cotas conservan ese signo, el procedimiento más conservador resulta también el suficiente.

Operacionalización de la ausencia estructural

La distinción entre ausencia estructural y ausencia por ítem exige un instrumento que permita aplicarla de forma sistemática. Dado que la matriz apilada asigna valor nulo a toda variable no presente en un año, un registro de 1998 contiene doce columnas íntegramente nulas que **no corresponden a no respuesta de la madre sino a preguntas inexistentes en el instrumento de esa época.**

Colapsar ambos tipos de ausencia tendría consecuencias directas sobre los tres tipos de modelo previstos: la imputación múltiple estimaría valores para variables no observables por construcción; los modelos multinivel excluirían por listas incompletas a cohortes enteras; y los algoritmos de clasificación interpretarían la ausencia de la pregunta como característica del individuo.

La solución mantiene la matriz sin marcas internas y traslada la distinción a dos productos auxiliares. La **tabla de disponibilidad** registra, para cada una de las 45 variables y cada uno de los 27 años, su presencia en el instrumento y su patrón temporal: 30 variables estables en todos los años, 12 presentes en un tramo continuo y 3 intermitentes, estas últimas inservibles para modelos de período completo. El **reporte de valores faltantes** clasifica cada nulo como estructural o como no respuesta. La magnitud de la diferencia justifica el procedimiento:

La pertenencia étnica presenta un 40,1 % de valores nulos, cifra que una rutina automática interpretaría como no respuesta masiva y que conduciría a descartar la variable

Cuadro 4.7: Descomposición de los valores faltantes según su origen. La pertenencia étnica presenta 40,1 % de nulos sobre la serie completa y *ninguna* no respuesta. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	Faltantes totales	Por no respuesta
IDPERTET (pertenencia étnica)	40,1 %	0,0 %
ULTCURMAD	40,1 %	0,0 %
T_GES_AGRU_CIE	51,0 %	0,0 %
TIPOFORMULARIO	88,0 %	0,0 %
FECHA_NACM	36,3 %	36,3 %

o a imputarla. La descomposición muestra que **la no respuesta es nula**: ese 40,1 % corresponde íntegramente a los diez años anteriores a 2008. De las variables examinadas, únicamente **FECHA_NACM** presenta no respuesta genuina.

En consecuencia, la ausencia estructural no se trata como dato perdido sino restringiendo el período, y la no respuesta genuina, que entre las variables examinadas solo afecta a **FECHA_NACM**, queda cubierta por el análisis de casos completos con cotas de la Sección 4.3.4.

Duplicados exactos

La serie contiene 34.551 registros (0,192 %) que duplican exactamente a otro en las 45 variables del certificado. En ausencia de identificador individual, la distinción entre error de captura y coincidencia legítima no es resoluble de forma determinista. Tres elementos de evidencia orientan la decisión:

1. Se observan grupos de hasta 28 registros idénticos, magnitud incompatible con cualquier parto múltiple.
2. En los grupos de seis o más registros de 2019, el 96,8 % declara parto simple, lo que excluye la interpretación de hermanos.
3. En los grupos de tres o más, la fecha de nacimiento de la madre está ausente en el 100 % de los casos.

Ese tercer elemento revela el mecanismo: al faltar la fecha, el registro queda descrito únicamente por categorías gruesas —grupo de edad, municipio, nivel educativo— y dos madres distintas coinciden en todos los campos por azar. La mayoría de los duplicados no son, por tanto, registros repetidos sino **colisiones por insuficiencia de granularidad**.

Su eliminación descartaría preferentemente a las mujeres con registro incompleto, que no constituyen un subconjunto aleatorio y que previsiblemente se concentran en los estratos de menor posición socioeconómica, es decir, en el objeto mismo de esta investigación. El análisis de sensibilidad muestra que la decisión no altera los resultados: la diferencia máxima en la prevalencia anual entre incluir y excluir los duplicados es de 0,046 puntos porcentuales. Se opta por **conservarlos**, marcándolos mediante la variable `ES_DUPLICADO_EXACTO`.

4.3.5. Infraestructura de datos

El volumen de la serie —18.008.809 registros y 45 variables— impide su tratamiento mediante hojas de cálculo, cuyo límite es de 1.048.576 filas, y hace inviable la carga íntegra en memoria: la representación de la matriz como texto requeriría del orden de 47 GB de memoria de acceso aleatorio. Se adoptó por ello una arquitectura de dos componentes.

Almacenamiento columnar particionado

La matriz se almacena en formato **Apache Parquet**, particionado por año y comprimido. La elección responde a tres propiedades del formato:

1. **Organización columnar.** Una consulta que requiera tres de las cincuenta columnas lee únicamente esas tres, no el registro completo. Dado que los análisis previstos —índice de concentración, descomposición, modelos multinivel— emplean subconjuntos reducidos de variables, la ganancia es sustancial.
2. **Codificación por diccionario.** Las variables del certificado son códigos de cardinalidad baja: `PESO_NAC` admite nueve valores distintos en 18 millones de registros. Parquet almacena el catálogo una sola vez y sustituye cada ocurrencia por un índice entero. Los 2,3 GB de los archivos originales se reducen a 173 MB.
3. **Preservación de tipos.** A diferencia del texto delimitado, Parquet conserva el tipo declarado de cada columna y evita la inferencia en cada lectura. Esta propiedad resulta crítica aquí por las razones que se exponen en la Sección 4.3.6.

Capa de consulta

Sobre los archivos Parquet se define una base de datos analítica **DuckDB** que expone cinco vistas: la matriz completa, la tabla de disponibilidad de variables, el reporte de

valores faltantes, el resumen anual y la serie de prevalencia. Las vistas no duplican los datos: el motor lee del disco únicamente las columnas y particiones que cada consulta requiere.

La elección obedece a que los datos son estáticos y de consulta analítica intensiva. Un gestor cliente-servidor introduciría una dependencia de infraestructura sin beneficio, dado que no hay concurrencia ni escritura. Un motor orientado a filas resulta ineficiente en agregaciones sobre millones de registros. Y el texto delimitado carece de tipos e índices, obligando a la lectura íntegra en cada operación.

Esta infraestructura constituye, junto con la tabla de correspondencias, un producto metodológico reutilizable del trabajo.

4.3.6. Construcción de la matriz analítica

Arquitectura en dos capas

La matriz se construye en dos capas sucesivas. La **capa base** contiene los códigos originales del DANE sin transformación alguna: sin imputación, sin recodificación, sin eliminación de registros y sin recorte de atípicos. Su propósito es la auditabilidad: cualquier resultado puede rastrearse hasta el valor tal como fue publicado. La **capa analítica** se deriva de la anterior aplicando el tratamiento de las categorías de no informado y añadiendo las variables derivadas.

Cuadro 4.8: Composición de la matriz. La capa base preserva los datos publicados; la capa analítica es la que alimenta los modelos. Elaboración propia.

Bloque	Columnas	Contenido
Variables del certificado	45	Unión del período, según la Sección 4.3.1
Variables de trazabilidad	5	ANIO, ARCHIVO_ORIGEN, CATALOGO_DANE, ESQUEMA_CODIGOS, N_VARS_ORIGEN
Capa base	50	Códigos crudos, sin transformar
Variables derivadas	3	BPN, FILA_CORRIDA, ES_DUPLICADO_EXACTO
Capa analítica	53	Con las categorías de no informado convertidas a nulo

Las variables de trazabilidad no proceden del certificado: se añaden al apilar para conservar, en cada registro, la información sobre su origen.

El problema: nombre estable, significado variable

La construcción de una serie continua sobre trece diccionarios enfrenta una dificultad que un *crosswalk* basado únicamente en nombres de campo **no detecta**: variables que conservan el mismo nombre durante todo el período pero modifican su esquema de categorías. Apilarlas produce una serie que aparenta continuidad sin poseerla, y que no emite ninguna señal de error.

El caso más severo es **EST_CIVM**. Entre 1998 y 2007 el código 1 designa *soltera*; desde 2008 designa *no está casada y lleva dos o más años viviendo con su pareja*. La verificación sobre los microdatos muestra el efecto: en 2005 el código 1 representa el 15,1 % de los registros y en 2019 el 50,8 %. Un análisis que tratase la serie como continua concluiría que la soltería materna se triplicó, cuando lo único que cambió fue la numeración.

Los ejes socioeconómicos centrales de esta investigación se ven afectados:

Cuadro 4.9: Variables con ruptura semántica en 2008. Elaboración propia a partir de los diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	Naturaleza de la ruptura
NIV_EDUM, NIV_EDUP	De 9 categorías a 14. El código 9 pasa de <i>sin información</i> a <i>profesional</i>
SEG_SOCIAL	El código 3 pasa de <i>vinculado</i> a <i>excepción</i> ; el 4, de <i>particular</i> a <i>especial</i> ; el 5, de <i>otro</i> a <i>no asegurado</i>
EST_CIVM	Renumeración completa de las categorías
APGAR1, APGAR2	De tres categorías agrupadas a puntaje bruto de 01 a 10
PROFESION	Los códigos 3 y 4 cambian de referente; el 5 se incorpora

La Figura 4.6 hace visible el mecanismo en el caso del nivel educativo materno, y las Figuras 4.7 a 4.9 lo repiten para los demás ejes. Cada panel izquierdo muestra la composición de la población por categoría a lo largo del período y cada panel derecho la prevalencia del desenlace en cada categoría; el recuadro lateral recoge el significado que el diccionario del DANE asigna a cada código antes y después de 2008. La discontinuidad de 2008 se manifiesta como un corte abrupto en las bandas de composición, sin que el instrumento emita señal alguna de error.

A la variación semántica se superpone una variación de formato de escritura. Se identificaron **tres convenciones** para el mismo conjunto de categorías: códigos de 1 a 9 con no informado en 9 (1998–2007); códigos de 1 a 13 sin relleno y no informado en 99 (2012–2013); y códigos de 01 a 13 con relleno (resto del período).

La convención de 2012–2013 es la más peligrosa: emplea el esquema posterior a 2008 pero omite el cero de relleno, de modo que el valor 9 designa *profesional*. Una regla de

recodificación que tratase el código 9 como faltante de forma uniforme habría eliminado **127.880 registros de madres con formación profesional** en esos dos años, sesgando a la baja el extremo superior del gradiente educativo justo en el período central de la serie.

La solución: el régimen de codificación como atributo

La estrategia adoptada consiste en **no recodificar** los valores en la capa base y adjuntar a cada registro el identificador de su régimen, en la variable `ESQUEMA_CODIGOS`:

Cuadro 4.10: Regímenes de codificación identificados y volumen de registros. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Régimen	Años	Registros
1998–2007	1998–2007	7.222.258
2008–2011/2014–2019	2008–2011 y 2014–2019	6.661.490
2012–2013	2012–2013	1.335.670
2020	2020	629.402
2021–2023	2021–2023	1.706.088
2024	2024	453.901

La agrupación de 2008–2011 con 2014–2019 no es arbitraria: ambos períodos comparten idéntico esquema de categorías y formato de escritura, de modo que sus registros son directamente comparables. Tratarlos como bloques separados reduciría la muestra de 6.661.490 a 3.926.136 observaciones sin justificación.

La variable cumple una doble función: documenta la procedencia semántica de cada valor y opera como criterio obligatorio de estratificación o filtrado en todo análisis que emplee variables afectadas por ruptura. Las variables `PESO_NAC`, `T_GES`, `TALLA_NAC`, `AREA_RES`, `SEXO`, `EDAD_MADRE`, `CODPTORE`, `CODMUNRE` y `N_HIJOSV` conservan esquema estable en los veintisiete años y admiten análisis sobre la serie completa.

Preservación del formato original

Los códigos se almacenan como cadenas de caracteres y no como enteros. La decisión es deliberada: la conversión a entero equipararía los valores `4` y `04`, eliminando la única evidencia observable del cambio de instrumento, y transformaría el código municipal `001` en `1`, impidiendo el empalme con la nomenclatura `DIVIPOLA`. La codificación por diccionario de Parquet hace que la decisión no tenga costo apreciable de almacenamiento.

Impacto de la recodificación

Sobre la capa analítica se aplica la conversión a nulo de las categorías de no informado, mediante una tabla que especifica, **para cada variable y cada régimen**, los códigos correspondientes:

Cuadro 4.11: Efecto de la recodificación de las categorías de no informado sobre las variables de interés analítico. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	Antes	Después	Convertidos
NIV_EDUP	0,00 %	12,38 %	2.229.713
NUMCONSUL	0,00 %	7,66 %	1.380.168
EDAD_PADRE	0,00 %	4,18 %	752.984
NIV_EDUM	0,00 %	3,87 %	696.055
SEG_SOCIAL	0,00 %	3,14 %	566.264
EST_CIVM	0,00 %	2,74 %	494.381

Los dos ejes socioeconómicos principales presentan tras la operación un 3,87 % y un 3,14 % de valores faltantes, proporciones lo bastante pequeñas como para que el análisis de casos completos no desplace de forma apreciable ninguna de las cantidades estimadas, según se argumenta en la Sección 4.3.4. La educación paterna, con 12,38 %, es la única variable del bloque social con ausencia por ítem sustancial, y por esa razón se describe y se somete al cribado pero no interviene en los modelos explicativos.




Figura 4.6: Nivel educativo materno. Composición de la población (izquierda) y prevalencia de bajo peso al nacer (derecha) por código original del certificado, 1998–2024. El significado de cada código figura en el Cuadro 4.12. Elaboración propia.

Cuadro 4.12: Significado de los códigos de NIV_EDUM antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Código	1998–2007	2008–2024
1	Preescolar	Preescolar
2	Primaria completa	Básica primaria
3	Primaria incompleta	Básica secundaria
4	Secundaria completa	Media académica o clásica
5	Secundaria incompleta	Media técnica
6	Universitaria completa	Normalista
7	Universitaria incompleta	Técnica profesional
8	Ninguno	Tecnológica
9	Sin información	Profesional
10	—	Especialización
11	—	Maestría
12	—	Doctorado
13	—	Ninguno
99	—	Sin información

El código 9 concentra el caso más peligroso de toda la serie: designa *sin información* hasta 2007 y *profesional* desde 2008. Una regla de limpieza uniforme que tratase el nueve como valor faltante (que es la convención habitual y la que aplica por defecto cualquier rutina de lectura) eliminaría del análisis a las madres con formación universitaria completa de todo el período posterior a 2008, esto es, al extremo superior del gradiente educativo que constituye el objeto mismo de esta investigación. El código 8 invierte el problema: pasa de *ninguno* a *tecnológica*, de manera que los dos extremos de la escala quedan intercambiados.

Cuadro 4.13: Significado de los códigos de SEG_SOCIAL antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Código	1998–2007	2008–2024
1	Contributivo	Contributivo
2	Subsidiado	Subsidiado
3	Vinculado	Excepción
4	Particular	Especial
5	Otro	No asegurado
6	Ignorado	—
9	Sin información	Sin información

Los códigos 1 y 2 se conservan, pero del 3 al 5 designan categorías distintas en cada versión. La consecuencia sustantiva es que el grupo *no asegurado* (el de mayor interés para




Figura 4.7: Régimen de afiliación de la madre. Composición de la población (izquierda) y prevalencia de bajo peso al nacer (derecha) por código original del certificado, 1998–2024. El significado de cada código figura en el Cuadro 4.13. Elaboración propia.

el análisis de desigualdad, por ser el extremo desfavorecido de la escala) solo existe como tal desde 2008. Antes de esa fecha, la población sin aseguramiento efectivo se repartía entre los códigos *vinculado* y *particular*, que no son equivalentes entre sí.




Figura 4.8: Estado conyugal de la madre. Composición de la población (izquierda) y prevalencia de bajo peso al nacer (derecha) por código original del certificado, 1998–2024. El significado de cada código figura en el Cuadro 4.14. Elaboración propia.

Este es el caso de reenumeración completa: ningún código conserva su referente. El efecto sobre el panel de composición es el más visible de las cuatro figuras, y cuantifica lo anticipado más arriba: el código 1 pasa del 15,1 % de los registros en 2005 al 50,8 % en 2019 sin que haya cambiado el comportamiento de la población, únicamente porque el

Cuadro 4.14: Significado de los códigos de EST_CIVM antes y después de 2008. Fuente: diccionarios de datos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Código	1998–2007	2008–2024
1	Soltera	No está casada y lleva dos o más años viviendo con su pareja
2	Casada	No está casada y lleva menos de dos años viviendo con su pareja
3	Viuda	Está separada o divorciada
4	En unión libre	Está viuda
5	Separada o divorciada	Está soltera
6	—	Está casada
9	Sin información	Sin información

número dejó de designar *soltera* para designar unión libre estable.




Figura 4.9: Área de residencia de la madre. Composición de la población (izquierda) y prevalencia de bajo peso al nacer (derecha) por código original del certificado, 1998–2024. Esta variable conserva la misma codificación en las dos versiones del instrumento. Elaboración propia.

Qué aportan estas cuatro figuras. La ruptura documentada en el Cuadro 4.9 podría parecer un detalle de manejo de archivos. Estas figuras muestran que no lo es: cuantifican cuánta población quedaría mal clasificada si la serie se tratase como continua, y por esa vía sostienen la decisión de construir escalas armonizadas en lugar de emplear los códigos originales. Sin ellas, esa decisión, que condiciona todos los resultados del Capítulo 5, se apoyaría únicamente en la lectura de los diccionarios del DANE; con ellas se apoya en el

comportamiento observado de los datos.

Su aporte va más allá del control de calidad. Las tres primeras identifican, para cada determinante social del trabajo, qué códigos concretos cambian de referente y qué volumen de registros arrastra cada cambio, lo que permite acotar el efecto de la ruptura en lugar de declararla en términos generales. Esa cuantificación es la que respalda la prueba de frontera de la Sección 4.3.2 y la que delimita, en el Capítulo 5, qué comparaciones entre 1998 y 2024 son legítimas y cuáles no.

En cuanto a su estructura, cada figura consta de dos paneles: el izquierdo muestra la composición de la población (qué porcentaje de los nacimientos de cada año corresponde a cada código) y el derecho, la prevalencia del desenlace dentro de cada código. El eje es el **código numérico original** del certificado y no la categoría armonizada, porque es precisamente esa elección la que hace visible el problema: un código que conserva su número pero cambia de significado produce un corte abrupto en las bandas sin que nada en el archivo lo advierta.

La Figura 4.9 se incluye como contraste. El área de residencia mantiene los mismos tres códigos (cabecera municipal, centro poblado y rural disperso) en las dos versiones del certificado, y sus bandas de composición no presentan discontinuidad alguna en 2008. La comparación con las tres figuras anteriores muestra que el corte que aparece en ellas es un artefacto del instrumento y no un rasgo general de la serie: si se tratase de un cambio real en la población colombiana, afectaría también a esta variable.

4.3.7. Trazabilidad y reproducibilidad del procesamiento

El procesamiento se organiza en cuatro rutinas ejecutables en secuencia, cada una con su producto documentado: la construcción de la capa base en Parquet particionado, junto con la tabla de disponibilidad y los reportes de valores faltantes; la creación de la base analítica con sus vistas de consulta; la recodificación de las categorías de no informado y su reporte de impacto; y la carga en memoria con tipos optimizados.

Las reglas de recodificación se versionan en formato legible, de modo que la especificación de códigos de no informado por variable y régimen sea auditable con independencia del código que la aplica. Los metadatos de construcción —registros por año, variables por archivo, correspondencias aplicadas y esquema canónico resultante— se registran igualmente en formato estructurado. La rutina de construcción es reanudable: cada partición anual se marca como completa al finalizar su escritura, de modo que una interrupción no obliga a reprocesar la serie.

4.4. Análisis estadístico

La estrategia analítica se organiza en siete fases. La Fase 1 responde a la primera pregunta específica y sirve a la vez de exploración; la Fase 2 es preparatoria; las Fases 3 a 5 responden a las preguntas segunda, cuarta y tercera, y la Fase 4 aborda además la quinta y la sexta; la Fase 6 somete el resultado principal a análisis de sensibilidad; y la Fase 7 responde a la séptima pregunta, la del componente predictivo. Las preguntas se formulan en la Sección 1.1 y los objetivos correspondientes en el Capítulo 2.

4.4.1. Fase 1. Análisis descriptivo y de tendencia

Las variables categóricas se describen mediante frecuencias absolutas y relativas; las continuas, mediante media y desviación estándar o mediana y rango intercuartílico, según su distribución. La prevalencia de bajo peso al nacer se calcula por cada cien nacidos vivos, con intervalos de confianza del 95 % por el método de Wilson. La tendencia temporal se modela mediante regresión de Poisson con varianza robusta, estimando el cambio porcentual anual; cuando la serie sugiere puntos de inflexión, se recurre a regresión de puntos de unión. La distribución territorial se representa mediante mapas de coropletas por departamento y municipio.

4.4.2. Fase 2. Cribado de variables por información mutua

Concluido el análisis exploratorio, y antes de especificar cualquier modelo, se evalúa la información que cada determinante candidato aporta sobre el indicador de bajo peso al nacer. El propósito es doble: obtener una ordenación de los determinantes que no dependa de supuestos de forma funcional, y reducir la dimensionalidad del componente predictivo descartando las variables cuya aportación no se distinga del azar.

El procedimiento emplea las tres formas de la información mutua descritas en la Sección 3.4.2: la marginal de la Ecuación (3.5), la condicional de la Ecuación (3.7) y la información de interacción de la Ecuación (3.8).

Por qué no basta la información mutua marginal. Un cribado que evaluara cada determinante en aislamiento descartaría aquellos cuyo aporte es exclusivamente interactivo, y lo haría de manera silenciosa. Dado que el componente predictivo de este trabajo tiene por objeto precisamente detectar no linealidades e interacciones, un filtro previo ciego a las interacciones sería contradictorio con el propósito del análisis. Por esa razón

el criterio de retención admite dos vías, y la selección se conduce de forma secuencial y condicional.

Procedimiento

El cribado se ejecuta en seis pasos, sobre la partición de entrenamiento.

1. **Estimación marginal.** Para los determinantes categóricos, la información mutua se estima por conteo de frecuencias sobre la tabla de contingencia conjunta. Para los de soporte continuo o de recuento amplio, edad materna, número de consultas prenatales, número de embarazos y número de hijos nacidos vivos, se emplea el estimador por vecinos más próximos de Kraskov et al. (2004) en la adaptación de Ross (2014) para el caso mixto, con $k = 3$ vecinos.
2. **Normalización.** Los valores se expresan como incertidumbre simétrica, Ecuación (3.6), para hacerlos comparables entre variables de cardinalidad distinta, y como proporción de la entropía del desenlace $H(Y)$ (3.4), que fija el techo de lo que cualquier determinante puede aportar.
3. **Distribución nula por permutación.** Para cada determinante se generan réplicas en las que el vector del desenlace se permuta aleatoriamente, preservando su prevalencia, la distribución marginal del determinante y el tamaño de muestra, pero destruyendo toda asociación entre ambos. De esas réplicas se obtiene el percentil 95 de la información mutua atribuible al azar dada la cardinalidad de la variable. Se descarta el criterio alternativo de un umbral absoluto común porque, por el sesgo descrito en la Sección 3.4.2, un mismo umbral resulta exigente para una variable dicotómica y laxo para una de mil niveles.
4. **Selección secuencial por información mutua condicional.** Entra en primer lugar el determinante de mayor información mutua marginal. En cada paso posterior, las candidatas restantes se evalúan por su información mutua condicional al conjunto ya seleccionado, estratificando por las combinaciones de sus valores y promediando según el tamaño de los estratos. Se descartan los estratos con menos de trescientas observaciones, en los que la estimación estaría dominada por el sesgo, y se renormalizan los pesos. La distribución nula se recalcula en cada paso bajo las mismas condiciones de condicionamiento.
5. **Información de interacción.** Se calcula la Ecuación (3.8) para todos los pares de determinantes. Los pares con valor positivo señalan sinergia, y son aquellos cuya

contribución una descomposición aditiva atribuiría de manera incorrecta a los efectos principales. Los pares con valor negativo señalan redundancia.

6. **Criterio de retención por dos vías.** Se retiene todo determinante que supere el percentil 95 de su distribución nula *en la evaluación marginal o en la condicional*. La disyunción es deliberada: una única vía dejaría fuera los determinantes cuyo aporte es exclusivamente interactivo.

Límite de la estimación condicional. El número de estratos crece de forma multiplicativa con el tamaño del conjunto condicionante, de modo que a partir de un número reducido de variables seleccionadas los estratos se vacían, la estimación se degrada y la distribución nula alcanza a la señal. El procedimiento se detiene entonces por agotamiento de la estimación, no porque las variables restantes carezcan de información. La distinción es relevante para la lectura de los resultados y se declara aquí de forma explícita, en lugar de presentar el punto de parada como un hallazgo sustantivo.

Ámbito de aplicación del cribado

Esta distinción es la decisión metodológica central de la fase y se declara de forma explícita para evitar una lectura errónea de los resultados.

- **En el componente predictivo, Fase 7, el cribado sí elimina variables.** El objetivo allí es el desempeño fuera de muestra, y descartar predictores no informativos reduce la varianza del estimador sin comprometer ninguna interpretación causal.
- **En los modelos multinivel, Fases 4 y 5, el cribado no elimina ninguna variable.** Su especificación permanece determinada por el marco de determinantes sociales y por la distinción entre confusor y mediador expuesta en la Sección 3.10. La razón es que un confusor puede presentar información mutua marginal baja con el desenlace y ser, aun así, indispensable para estimar sin sesgo el efecto de otro determinante. Seleccionar covariables mediante criterios guiados por los datos introduce sesgo en las estimaciones puntuales e invalida la cobertura nominal de los intervalos de confianza, porque la incertidumbre del propio proceso de selección no se incorpora a la varianza (Heinze et al., 2018).

En los modelos multinivel, por tanto, la información mutua se reporta como evidencia descriptiva junto al coeficiente V de Cramér (3.3), y no como filtro. El coeficiente se calcula con la corrección de sesgo de Bergsma (2013), necesaria porque el valor sin corregir crece de

forma espuria con el número de categorías, y varias de las variables examinadas presentan más de mil niveles: el municipio de residencia, sin ir más lejos.

Control de la fuga de información en el cribado

El cribado se ajusta exclusivamente sobre la partición de entrenamiento. Calcular la información mutua sobre la base completa y después particionar constituiría fuga de información, porque la selección de predictores habría visto los desenlaces del conjunto de prueba. Dentro de la validación cruzada, el cribado se recalcula en cada pliegue de entrenamiento como una etapa más de la tubería de procesamiento, en coherencia con el procedimiento descrito en la Sección 4.4.7.

Reporte

Se reporta un cuadro con, para cada determinante, la información mutua bruta en bits, la incertidumbre simétrica, la media y el percentil 95 de la distribución nula, y la decisión de retención. La ordenación resultante se compara con la ordenación por importancia de permutación obtenida en la Fase 7; la coincidencia o discrepancia entre ambas es material de discusión, ya que la información mutua mide asociación marginal y la importancia de permutación mide contribución condicional al desempeño de un modelo ajustado.

[NO OLVIDAR. Numerar el cuadro de resultados de esta fase cuando ejecute el análisis. Y reescribir con mis palabras los párrafos de justificación de esta subsección, sobre todo el bloque de ámbito de aplicación: es el que voy a tener que defender de viva voz.]

4.4.3. Fase 3. Medición de la desigualdad socioeconómica

La desigualdad se cuantifica mediante el índice de concentración definido en la Ecuación (3.9). La variable de ordenamiento principal es el nivel educativo materno y, de manera alternativa, el régimen de afiliación. Dado que el desenlace es binario y acotado, el índice se corrige mediante la normalización de Erreygers (3.10). Se acompaña de la curva de concentración y de dos medidas complementarias basadas en regresión: el índice de desigualdad de la pendiente y el índice relativo de desigualdad. Los intervalos de confianza se estiman por remuestreo bootstrap con mil réplicas. El procedimiento se repite por año, lo que permite examinar si la desigualdad se ha ampliado o reducido a lo largo del período.

4.4.4. Fase 4. Modelos de regresión logística multinivel

Para estimar el efecto independiente de cada determinante social se ajustan modelos de regresión logística multinivel de tres niveles, con nacimientos anidados en municipios y municipios anidados en departamentos. La estimación se realiza por máxima verosimilitud con aproximación de Laplace.

Una sola especificación ajustada en cinco pasos. Conviene precisar, para evitar una lectura equivocada, que los cinco modelos que siguen **no son cinco técnicas distintas**. Son la misma regresión logística multinivel de interceptos aleatorios, ajustada cinco veces sobre los mismos datos y con la misma estructura jerárquica. Lo único que cambia entre uno y otro es qué bloque de variables entra en la parte fija. El resultado relevante no reside únicamente en cada ajuste por separado, sino en **la diferencia entre un modelo y el siguiente**: es esa diferencia la que permite separar confusión de mediación. La estrategia corresponde a lo expuesto en la Sección 3.10.

Estos cinco ajustes no deben confundirse con los siete modelos de clasificación de la Fase 7, que sí son siete técnicas distintas y persiguen un objetivo predictivo. El trabajo comprende, por tanto, *una* especificación multinivel ajustada en cinco pasos anidados y *siete* algoritmos de clasificación comparados entre sí.

Estructura común a los cinco ajustes. El desenlace es la variable binaria definida en la Ecuación (4.1). La jerarquía es la misma en los cinco: cada nacimiento se anida en su municipio de residencia y cada municipio en su departamento de residencia, con 1.157 municipios y 33 departamentos. Cada municipio pertenece a exactamente un departamento, de modo que el anidamiento es estricto. Los efectos aleatorios son un intercepto por municipio, $v_{jk} \sim N(0, \sigma_v^2)$, y un intercepto por departamento, $u_k \sim N(0, \sigma_u^2)$. El territorio empleado es el de *residencia* de la madre y no el de ocurrencia del parto.

- **Modelo 0.** Modelo vacío, sin covariables. Permite estimar la varianza atribuible a cada nivel territorial, el coeficiente de correlación intraclase (3.12) y la razón de momios mediana (3.13). Constituye la referencia contra la cual se calcula el cambio proporcional en la varianza de los modelos siguientes.
- **Modelo 1.** Incorpora el bloque de posición socioeconómica y adscripción social de la madre: nivel educativo, estado conyugal, régimen de afiliación y área de residencia. Estima el **efecto total** de la posición social, entendiendo por total que incluye cuanto ocurre por consecuencia de ella, incluidas las vías que pasan por la atención prenatal.

- **Modelo 2.** Añade las tres covariables biológicas de ajuste (edad materna, paridad y multiplicidad del embarazo), con lo que estima el **efecto independiente** de cada determinante social. Es el ajuste que responde al objetivo específico 3 y del que proceden los coeficientes reportados como resultado principal.
- **Modelo 3.** Incorpora la pertenencia étnica, con lo que estima el efecto social descontada la composición étnica del territorio.
- **Modelo 4.** Añade el número de consultas prenatales, con lo que estima el **efecto directo**: aquello que queda del efecto social una vez descontado lo que transcurre por la atención prenatal.

El ajuste comparativo entre modelos se evalúa mediante el criterio de información de Akaike, el criterio bayesiano de Schwarz y el cambio proporcional en la varianza (3.14). Los resultados se presentan como razones de momios (3.1) con intervalos de confianza del 95 % contruidos por el método de Woolf (3.2).

Comparabilidad entre ajustes sucesivos. Cada bloque de variables presenta un patrón de valores faltantes propio, de manera que comparar un modelo contra otro estimado sobre un número distinto de registros confundiría el efecto de incorporar variables con el de cambiar de población. Por ello cada comparación se realiza sobre la misma submuestra: antes de contrastar, el modelo previo se reajusta sobre las filas comunes a ambos. Esta consideración motiva además el orden de entrada de los bloques. La pertenencia étnica no se registra con anterioridad a 2008 y su incorporación reduce la muestra en torno al 43 %; situarla después del ajuste obstétrico permite que el Modelo 2, que responde al objetivo específico 3, se estime sobre el 91,8 % de los registros.

Advertencia sobre la interpretación de los modelos anidados. El número de consultas prenatales se sitúa en la vía causal entre la posición socioeconómica y el bajo peso al nacer: es un mediador, no un factor de confusión. Su incorporación en el Modelo 4 atenúa deliberadamente el coeficiente social, y esa atenuación se interpreta como evidencia sobre el mecanismo y no como corrección de un sesgo. Por esta razón el Modelo 2 se reporta como estimación principal del efecto social y el Modelo 4 como estimación del efecto directo. Presentar el coeficiente atenuado del Modelo 4 como «el efecto de la educación ya controlado por todo» subestimaría el efecto total e induciría a concluir que la posición social pesa menos de lo que pesa.

El caso de la multiplicidad del embarazo. Entre las tres covariables de ajuste, la multiplicidad requiere una justificación propia porque su condición no es evidente. No se comporta como mediador ni como factor de confusión, sino como **covariable de precisión**: presenta un coeficiente V de Cramér de 0,2419 con el desenlace (el segundo más alto de las quince variables examinadas) y de apenas 0,0106 con el nivel educativo materno. Al no existir una vía apreciable desde la posición social hacia la multiplicidad, ajustar por ella no elimina confusión sino que reduce la varianza residual, con la consiguiente ganancia de precisión en los coeficientes sociales. Esta distinción es la que explica que la multiplicidad se incorpore en el Modelo 2 y las consultas prenatales en el Modelo 4 pese a tratarse, ambas, de variables del embarazo: lo que las separa no es la materia sino la estructura causal, y se resuelve con los datos y no por convención.

Referencias de las variables categóricas. Cada variable categórica se representa mediante indicadoras con omisión de una categoría, que actúa como referencia. En los determinantes sociales se omite la primera categoría, de modo que las razones de momios de educación se leen contra la ausencia de educación formal y las de estado conyugal contra la condición de casada. Conviene advertir que ello implica direcciones de lectura opuestas: en educación una razón inferior a la unidad indica menor riesgo, mientras que en estado conyugal es una razón superior a la unidad la que lo indica. En las tres covariables de ajuste la referencia se fija explícitamente en el grupo de menor riesgo obstétrico (de 20 a 34 años, un hijo previo y embarazo simple), conforme a la práctica habitual en la literatura perinatal.

Limitación en la estimación del efecto étnico. Los interceptos aleatorios municipales absorben buena parte de la variación étnica antes de que el coeficiente fijo la recoja, dado que la pertenencia étnica presenta un V de Cramér de 0,473 con el municipio y de 0,378 con el departamento. En consecuencia, el coeficiente del Modelo 3 no mide el efecto de la pertenencia étnica en términos absolutos sino aquello que aporta *por encima del lugar de residencia*. Con estos datos no resulta posible separar la condición étnica de la residencia en los territorios donde esa población se concentra, y así se declara entre las limitaciones del trabajo.

Implementación del estimador. La estimación no se realizó con las bibliotecas habituales de Python. La única implementación disponible para desenlaces binarios exige materializar en memoria una matriz de diseño con una columna por conglomerado y deja de converger a partir de quinientos conglomerados, cuando este análisis requiere 1.157. Se

programó por ello una implementación propia del mismo modelo (interceptos aleatorios con aproximación de Laplace, que es el procedimiento que aplica por defecto la implementación de referencia `lme4`, Breslow and Clayton, 1993), apoyada en la agregación binomial de los perfiles de covariables y en la resolución en forma cerrada del sistema lineal que permite la estructura de anidamiento estricto. El método no es original; lo es únicamente la implementación. El Apéndice B documenta su validación mediante simulación y recoge las comprobaciones de exactitud correspondientes.

Supuesto de constancia temporal, y cómo se acota. Los cinco ajustes estiman un único coeficiente por determinante para todo el período, lo que supone que la asociación entre cada determinante y el desenlace se mantiene constante entre 1998 y 2024. Ese supuesto no se cumple: la descomposición por subperíodos de la Sección 5.5.3 muestra que la contribución del nivel educativo se multiplica por más de cuatro a lo largo de la serie.

Los coeficientes de esta fase deben interpretarse, en consecuencia, como **promedios ponderados del período** y no como el efecto vigente en un año concreto. La evolución temporal de la asociación se aborda en la Fase 5, que es donde el trabajo la estima, y no aquí.

Declararlo importa porque las dos fases podrían parecer contradictorias: una reporta un coeficiente estable y la otra una contribución que cambia. No se contradicen, estiman cantidades distintas.

Medida de asociación. Dado que la prevalencia del desenlace no es baja, la razón de momios sobrestima la razón de prevalencias (Barros and Hirakata, 2003). Como análisis complementario se estiman razones de prevalencia mediante regresión de Poisson multinivel con varianza robusta, y se contrastan ambas estimaciones.

4.4.5. Fase 5. Descomposición de la desigualdad

La cuarta pregunta se responde mediante la descomposición del índice de concentración (3.11) propuesta por Wagstaff, van Doorslaer y Watanabe (Wagstaff et al., 2003). Las contribuciones de cada determinante se expresan en términos absolutos y como porcentaje del índice total, y sus intervalos de confianza se obtienen por bootstrap.

4.4.6. Fase 6. Análisis de sensibilidad

Se ejecutan cinco análisis de sensibilidad para evaluar la robustez de los hallazgos:

- **Cotas por ausencia.** Recálculo del índice bajo los dos escenarios extremos posibles para los registros sin dato, sin supuesto alguno sobre el mecanismo que los produce, con el fin de acotar hasta dónde podría desplazarse el resultado si esa ausencia no fuera inocua.
- **Restricción temporal.** Análisis limitado a 2008–2024, período con el instrumento de captura homogéneo, contrastado con la serie completa.
- **Especificación alternativa.** Ordenamiento socioeconómico basado en el régimen de afiliación en lugar del nivel educativo, y viceversa, para evaluar la estabilidad del índice de concentración.
- **Definición del desenlace.** Comparación de los resultados con el desenlace restringido a nacimientos a término frente al conjunto de nacidos vivos.
- **Estructura jerárquica.** Comparación del modelo de tres niveles frente a uno de dos niveles con errores estándar agrupados por departamento.

Cotas por ausencia de información. El tratamiento de los valores faltantes descansa sobre el supuesto de que los datos faltan al azar condicionalmente, supuesto que no resulta contrastable con la información disponible. Para no hacer depender las conclusiones de él, se acompaña el análisis principal de una evaluación de cotas en la tradición de Manski (1990) y Horowitz and Manski (2000): se recalcula el indicador de desigualdad asignando a la totalidad de los registros incompletos, primero, el valor que *minimiza* la desigualdad estimada y, después, el que la *maximiza*. El intervalo así obtenido no exige supuesto alguno sobre el mecanismo de ausencia, y contiene necesariamente el valor verdadero. Cuando ambos extremos conservan el mismo signo, la conclusión se sostiene con independencia de qué haya ocurrido con los registros faltantes; cuando no lo conservan, así se declara.

4.4.7. Fase 7. Comparación de modelos de clasificación

Las fases anteriores responden a un objetivo explicativo. Esta séptima fase aborda el componente predictivo: establecer con qué capacidad puede identificarse un nacimiento en riesgo a partir de la información disponible en el certificado de nacido vivo, y determinar si la complejidad algorítmica añade información sobre la regresión logística.

Qué información entra, y por qué no solo la social. Esta fase emplea todas las variables que retuvo el cribado de la Sección 4.4.2, incluidas las de naturaleza clínica y

asistencial. La razón es la ya expuesta: el objetivo aquí es predictivo y un mediador es un predictor legítimo. Restringir el modelo a los determinantes sociales daría una capacidad de clasificación menor sin que ello significase que la posición social importa poco.

Ahora bien, la pregunta de interés sustantivo no es cuánto predice el conjunto completo, sino **cuánto añaden los determinantes sociales sobre la información clínica**. Por ello se ajustan *dos* especificaciones de cada modelo: una con todas las variables retenidas y otra restringida al bloque social. La diferencia de desempeño entre ambas es la medida del aporte predictivo propio de la posición social, y es la cifra que responde a la pregunta. Se comparan los siete modelos descritos en la Sección 3.8: regresión logística, regresión logística con penalización lasso, regresión logística con penalización ridge, árbol de decisión (3.19), bosque aleatorio, *gradient boosting* (3.25) y perceptrón multicapa (3.27).

Criterio de partición de los árboles. Los tres modelos basados en árboles (árbol de decisión, bosque aleatorio y *gradient boosting*) dividen cada nodo buscando la partición que más reduce la impureza. Con un desenlace binario esa impureza se mide por la entropía del nodo (3.21); la versión para desenlace continuo (3.22) no se emplea aquí y se incluye en el marco teórico únicamente para situar el procedimiento. La unidad de cómputo de las tres familias es, en último término, la neurona o el nodo elemental descritos en las Ecuaciones (3.26) y (3.19).

Un contraste de especificación sobre el *gradient boosting*. Los árboles buscan el corte que separa un nodo tomando el valor de la variable como una magnitud ordenada. Sobre una variable nominal codificada con números esa operación carece de sentido: un corte en el código 3 de EST_CIVM agrupa categorías que no guardan relación entre sí y separa las que sí la guardan. El propio trabajo ofrece la mejor ilustración del problema, pues el código 9 de NIV_EDUM significa *sin información* hasta 2007 y *profesional* desde 2008: un algoritmo que tratase ese número como una cantidad estaría midiendo la numeración del formulario.

Por esa razón, el *gradient boosting* se ajusta **dos veces** sobre el mismo pliegue, con los mismos hiperparámetros y la misma semilla, y la única diferencia entre los dos ajustes es que en el segundo las variables se declaran categóricas, de modo que el algoritmo busca una partición del conjunto de categorías en lugar de un punto de corte. La diferencia de desempeño entre ambos es por construcción atribuible a esa única decisión.

Este contraste **no añade un octavo modelo**: es una corrección de especificación del séptimo, y se reporta como tal en la Sección 5.6. Los modelos comparados siguen

siendo siete. Se declara aquí porque la elección de tratar las covariables como nominales o como ordinales es una decisión metodológica con consecuencias sobre el resultado, y las decisiones de esa clase se someten a prueba en lugar de adoptarse en silencio.

Naturaleza predictiva de esta fase. A diferencia de las Fases 3 y 4, orientadas a la estimación de efectos, la Fase 7 tiene un objetivo estrictamente predictivo. En consecuencia, no hereda la restricción de excluir mediadores que impone el marco causal de la Sección 3.10: variables como el número de consultas prenatales se incorporan aquí como predictores legítimos, porque el propósito es maximizar la capacidad de clasificación y no estimar un efecto causal. Esta diferencia de objetivo explica que una misma variable reciba tratamientos distintos en fases distintas, sin que ello constituya una inconsistencia interna del trabajo.

Estrategia de partición

El estudio emplea dos esquemas de partición que responden a preguntas distintas y se reportan por separado.

El **esquema principal** es una partición aleatoria estratificada por la clase del desenlace, con 70 % de entrenamiento y 30 % de prueba. La estratificación preserva la prevalencia del bajo peso al nacer en ambos subconjuntos, condición necesaria dado que la clase positiva es minoritaria. Este esquema mide la capacidad de discriminación de cada modelo y es el que sustenta la comparación entre los siete algoritmos.

El **esquema complementario** es una partición temporal: los modelos se entrenan con los nacimientos de 1998 a 2018 y se evalúan sobre los de 2019 a 2024, que el modelo no vio durante el entrenamiento. Este segundo esquema no compite con el primero, sino que responde a una pregunta diferente: si el modelo generaliza hacia el futuro. La pregunta es pertinente porque la prevalencia del desenlace no es estable en el período, sino que asciende del 7,67 % en 1998 al 11,24 % en 2024, lo que indica una deriva temporal real del fenómeno. Un modelo que discrimine bien sobre una mezcla aleatoria de años puede degradarse al aplicarse a un período posterior.

Ambos resultados se reportan en el Capítulo 5, indicando de forma explícita qué partición corresponde a cada cifra. La partición temporal se interpreta como análisis de robustez y no sustituye al esquema principal.

Procedimiento

1. **Partición.** Según los dos esquemas descritos, con semilla fija.
2. **Preprocesamiento.** Codificación disyuntiva completa de las variables categóricas y estandarización de las continuas. La estandarización es indispensable para las penalizaciones L_1 y L_2 de las Ecuaciones (3.17) y (3.18), cuya magnitud depende de la escala de los coeficientes, y para el perceptrón multicapa.
3. **Tratamiento de la ausencia.** Los valores faltantes no se imputan: cada variable recibe una categoría propia, *sin informar*, que entra al modelo como un nivel más. La razón es la misma que sostiene la Sección 4.3.4: en esta fuente la ausencia no ocurre al azar sino que depende del año y de la versión del instrumento, de modo que informa por sí misma. Sustituirla por un valor estimado reemplazaría esa información por una construida bajo el supuesto que el Capítulo 3 declara dudoso para este registro. La restricción que sí se aplica es sobre el codificador, no sobre ningún imputador: se ajusta exclusivamente sobre el conjunto de entrenamiento y después se aplica al de prueba, de manera que ninguna información de este último interviene en la construcción del modelo.
4. **Hiperparámetros.** Se fijan *a priori* en valores convencionales, y no mediante búsqueda: profundidad máxima de ocho y quinientas observaciones mínimas por hoja en el árbol; trescientos árboles, profundidad catorce y raíz cuadrada del número de variables por división en el bosque aleatorio; tasa de aprendizaje de 0,1 con detención temprana en el *gradient boosting*; dos capas ocultas de 64 y 32 unidades en el perceptrón multicapa; y $C = 0,1$ y $C = 1$ en lasso y ridge respectivamente. Los valores exactos se declaran en el repositorio.

La decisión es de viabilidad computacional: una búsqueda exhaustiva sobre siete modelos y dos esquemas de partición multiplicaría el tiempo de cómputo por un factor de veinte sobre una muestra de millones de registros.

Implicación para la lectura de los resultados, y conviene declararla. Con hiperparámetros no optimizados, el desempeño de cada modelo es una cota inferior de lo que esa familia podría alcanzar. Esa limitación afecta sobre todo a los modelos de ensamble y a la red neuronal, que son los más sensibles a su configuración, y **juega en contra de la hipótesis de que la complejidad algorítmica no aporta**: si aun así los ensambles no superan a la regresión logística, la conclusión se sostiene con mayor holgura de la que tendría con una búsqueda completa. La comparación debe leerse, por

tanto, como un contraste entre configuraciones convencionales y no como el máximo alcanzable de cada familia.

5. **Manejo del desbalance.** Ponderación de clases con pesos inversamente proporcionales a su frecuencia en los seis modelos que la admiten. El perceptrón multicapa no implementa esa ponderación, de modo que en él el desbalance se compensa desplazando el umbral de decisión. Por esa razón el umbral óptimo del perceptrón no es comparable con el de los demás modelos y cada uno se reporta con el suyo.
6. **Evaluación.** Cálculo de la puntuación F_1 (3.30), la precisión y la sensibilidad (3.29), la especificidad, el área bajo la curva ROC y el área bajo la curva de precisión-sensibilidad. Todas las métricas se calculan sobre el conjunto de entrenamiento y sobre el de prueba, de modo que la brecha entre ambos documente la ausencia de sobreajuste. Los intervalos de confianza se obtienen por bootstrap no paramétrico sobre el conjunto de prueba, y la comparación entre modelos se resuelve por solapamiento de intervalos. POR QUÉ NO PARAMÉTRICO AQUÍ Y SÍ EN LAS FASES 3 y 5: allí se remuestrea un conteo binomial sobre celdas, porque remuestrear los registros individuales no es viable; aquí el conjunto de prueba tiene un tamaño manejable y el remuestreo directo no exige ningún supuesto distribucional.

Control de la fuga de información

La validez del componente predictivo depende de que ninguna información del conjunto de prueba intervenga en el ajuste. Se adoptan cuatro medidas.

Codificador ajustado solo sobre entrenamiento. La codificación de las variables categóricas se aprende únicamente con los datos de entrenamiento y se aplica al conjunto de prueba mediante la transformación ya aprendida, sin reajustarla. Dentro de la validación cruzada se ajusta de forma independiente en cada pliegue. Hacerlo sobre la base completa antes de particionar permitiría que el codificador conociera categorías presentes solo en el conjunto de prueba e inflaría artificialmente el desempeño reportado. Se aplica el mismo criterio a la estandarización de variables.

Predictores sin vínculo mecánico con el desenlace. El conjunto de predictores se restringe a los determinantes sociales y a las variables asistenciales de la madre. Se excluyen deliberadamente las variables clínicas del recién nacido ligadas por construcción

al desenlace, como la talla al nacer y la puntuación APGAR, cuya inclusión constituiría una fuga directa de la etiqueta hacia los predictores.

Corte temporal de la historia obstétrica. Las variables de historia obstétrica previa (fecha de nacimiento del hijo anterior, número de hijos nacidos vivos y número de embarazos) se construyen utilizando exclusivamente información anterior al parto índice, por lo que no introducen fuga temporal.

Limitación no resoluble. El certificado de nacido vivo no incluye un identificador único de la madre, de modo que no es posible agrupar los registros correspondientes a una misma mujer ni aplicar estrategias de partición agrupada. Sus implicaciones se declaran en la Sección 6.9.

Regularización del perceptrón multicapa

El perceptrón multicapa es, de los siete modelos, el más propenso a memorizar patrones del conjunto de entrenamiento. Se aplican tres mecanismos de control: detención temprana (*early stopping*) sobre un conjunto interno de validación equivalente al 10 % del entrenamiento, con paciencia de diez épocas sin mejora; decaimiento de pesos (*weight decay*) con el coeficiente por defecto de la implementación; y un número máximo de épocas fijado de antemano. Los valores empleados se declaran en el repositorio.

Importancia de variables

La importancia se reporta mediante los coeficientes estandarizados en los tres modelos lineales, la reducción media de impureza de Gini (3.20) en el árbol, el bosque y el *gradient boosting*, y la importancia por permutación en todos los modelos, que es el único procedimiento comparable entre familias.

Relación con el componente explicativo. Esta fase no sustituye a los modelos multinivel ni a la descomposición de la desigualdad. Un modelo con alta capacidad predictiva no identifica causas, y un determinante socialmente decisivo puede aportar poco al desempeño predictivo si su distribución es homogénea. Ambos componentes responden a preguntas distintas y se reportan por separado, salvo en el contraste jerárquico descrito en la Sección 3.8.9, que los pone deliberadamente en relación.

4.5. Software y reproducibilidad

El procesamiento y el análisis se realizan en Python, versión 3.9, sobre un entorno virtual aislado que fija las versiones de todas las dependencias. La manipulación de los microdatos se apoya en `pandas` y `numpy`; la lectura de los archivos originales en formato SPSS, en `pyreadstat`. Los modelos de clasificación descritos en la Sección 3.8 se implementan con `scikit-learn` (Pedregosa et al., 2011), que provee la regresión logística con penalización L_1 y L_2 , los árboles de decisión, el bosque aleatorio y el perceptrón multicapa, además de las rutinas de partición estratificada, validación cruzada y cálculo de métricas. El desbalance del desenlace se compensa mediante la ponderación de clases que la propia biblioteca ofrece y, en el perceptrón multicapa, que no la implementa, mediante el desplazamiento del umbral de decisión. Los modelos multinivel *no* se ajustan con `statsmodels`: su implementación de modelos mixtos construye una columna por conglomerado y no soporta los 1.157 municipios de este análisis, de modo que se programó un estimador propio que el Apéndice B documenta y valida contra soluciones conocidas. La cartografía se resuelve con `matplotlib` para las figuras estáticas y `plotly` para los mapas navegables. El índice de concentración, su descomposición y los intervalos por remuestreo se implementan mediante rutinas propias documentadas, verificadas sobre un subconjunto de prueba contra los resultados del comando `conindex` de Stata.

Todo el flujo de trabajo se organiza en un proyecto con control de versiones y semilla aleatoria fija, de modo que los resultados sean íntegramente reproducibles. El archivo `requirements.txt` registra las versiones exactas de cada biblioteca. Los scripts de depuración, análisis y generación de figuras, junto con la tabla de correspondencias `crosswalk.yaml` descrita en la Sección 4.3.1, se publican en el repositorio del proyecto, <https://github.com/GREGORYMELENDEZ/TESIS-GRADO-UNINORTE->, cuyo contenido se detalla en el Apéndice A.

4.6. Consideraciones éticas

El estudio utiliza datos secundarios, anonimizados y de acceso público, provenientes de un registro estadístico oficial. De acuerdo con la Resolución 8430 de 1993 del Ministerio de Salud, que establece las normas científicas, técnicas y administrativas para la investigación en salud en Colombia, una investigación documental retrospectiva que no interviene sobre variables biológicas, fisiológicas, psicológicas o sociales de los participantes se clasifica como investigación sin riesgo. No obstante, el protocolo se somete a la revisión y aval del comité de ética institucional antes de su ejecución.

El tratamiento de la información observa lo dispuesto en la Ley 1581 de 2012 sobre protección de datos personales. Los microdatos publicados por el DANE no contienen variables de identificación directa. Los resultados se presentan únicamente en forma agregada, y se aplica supresión de celdas con frecuencias reducidas para impedir la reidentificación de casos en municipios de baja población.

Capítulo 5

Resultados

[ESTADO DEL CAPÍTULO, al 18 de septiembre. Están escritas las secciones 5.1 a 5.5, la 5.7 y la 5.8. Falta una sola cosa que dependa de mí: la 5.6 entera, que espera a que corra la Fase 7, y son nueve apartados. Falta además la última fila de los cuadros de ajuste, la que compara el Modelo 3b con el Modelo 4 y mide qué aporta la atención prenatal: espera a que corra el bloque de M3b del notebook 04 y a volver a pasar `corregir_aic.py`. Todo lo demás de este capítulo está redactado.]

5.1. Análisis descriptivo

Esta sección responde a la pregunta específica 1, relativa a la magnitud y la evolución del bajo peso al nacer en el período.

5.1.1. Conformación de la muestra y completitud

La conformación de la muestra se presenta en el Cuadro 4.1: de los 18.008.809 nacidos vivos registrados entre 1998 y 2024, la muestra analítica retiene 17.376.860, esto es, el 96,49 %.

La completitud de las variables no es uniforme a lo largo de la serie, y el patrón tiene consecuencias para lo que puede compararse entre años.

Tres rasgos del cuadro condicionan el diseño del análisis.

El primero es que la completitud mejora de forma sostenida: las variables que en 1998 se situaban por debajo del 95 % superan el 97 % desde 2008. Los registros incompletos no se reparten por igual a lo largo del período, sino que se concentran en su primer tramo, de

Cuadro 5.1: Completitud de las variables del análisis en años seleccionados, en porcentaje de registros informados. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Variable	1998	2007	2008	2018	2024	Mínimo
Nivel educativo materno	93,1	97,0	97,6	95,7	95,8	93,1
Estado conyugal	95,1	97,4	97,9	97,0	96,3	95,1
Régimen de afiliación	87,4	96,8	97,9	100,0	98,1	87,4
Área de residencia	97,4	98,3	98,2	99,4	97,6	96,7
Pertenencia étnica	0,0	0,0	81,5	100,0	98,2	0,0
Controles prenatales	73,4	94,4	97,1	99,4	98,1	69,6
Hijos nacidos vivos	94,8	98,8	99,1	100,0	98,1	94,8
Multiplicidad del parto	95,0	99,1	98,6	100,0	98,1	95,0
Peso al nacer	94,0	98,9	99,0	99,2	97,8	94,0
Edad gestacional	93,8	98,0	98,3	99,2	97,8	93,8

modo que un análisis de casos completos sobre la serie entera descarta proporcionalmente más observaciones antiguas que recientes.

El segundo es la pertenencia étnica, que no existe como variable antes de 2008. No se trata de un dato faltante sino de una *ausencia estructural*: el formulario no la recogía. Por esa razón el Modelo 3 se ajusta sobre la submuestra posterior a esa fecha y no sobre la serie completa.

El tercero es el mínimo del 69,6 % en los controles prenatales, correspondiente a los primeros años de la serie. Es la variable peor informada del conjunto, y es también la que opera como mediador en el Modelo 4, lo que restringe la submuestra sobre la que ese modelo puede estimarse.

5.1.2. Distribución de la variable respuesta

De los 17,376,860 nacimientos de la muestra analítica, 1,525,772 presentan bajo peso al nacer. La prevalencia global del período es del **8,78 %**, con un intervalo de confianza del 95 % de [8,77; 8,79] construido por el procedimiento de Wilson. Se emplea este procedimiento y no el de aproximación normal porque el segundo se comporta mal con proporciones alejadas de 0,5; con un tamaño de muestra de esta magnitud la diferencia entre ambos es despreciable, pero se mantiene por coherencia con los intervalos estimados sobre subgrupos pequeños, donde sí importa.

La amplitud del intervalo, dos centésimas de punto porcentual, es consecuencia del tamaño de la muestra, y conviene interpretarla con cautela: expresa la precisión con que

se estima la prevalencia *registrada*, no la incertidumbre sobre la prevalencia poblacional, que depende además de la cobertura del registro y se discute en la Sección 5.1.4.

5.1.3. Caracterización sociodemográfica de las madres

Cuadro 5.2: Distribución de la población y prevalencia de bajo peso al nacer según los determinantes sociales, 1998–2024. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Categoría	Nacimientos	% de la población	Prevalencia
<i>Nivel educativo materno</i>			
Ninguno o preescolar	288,941	1,66	9,40 %
Primaria	3,510,961	20,20	8,16 %
Secundaria	9,840,986	56,63	8,80 %
Superior	3,179,210	18,30	9,20 %
<i>Régimen de afiliación, ordenado</i>			
No asegurado	2,525,812	14,54	8,36 %
Subsidiado	7,637,958	43,95	8,52 %
Contributivo, especial o excepción	6,758,590	38,89	9,27 %

El cuadro contiene el resultado que organiza todo el capítulo, y conviene detenerse en él antes de introducir cualquier índice.

La prevalencia no desciende al ascender por la escala educativa. El valor más bajo no corresponde a las madres con educación superior sino a las de primaria (8,16 %), y las de educación superior presentan una prevalencia (9,20 %) muy próxima a la de quienes no tienen educación formal (9,40 %). La relación descriptiva entre educación y bajo peso al nacer no es, por tanto, monótona descendente, que es la forma que adopta el gradiente social en la mayor parte de los desenlaces de salud.

El patrón se repite, en sentido inverso y de forma monótona, con el régimen de afiliación: la prevalencia asciende del 8,36 % entre las no aseguradas al 9,27 % entre las afiliadas al régimen contributivo.

Estos dos hechos anticipan tres resultados posteriores. Explican que el índice de concentración del período sea *positivo* (el desenlace se concentra hacia el extremo más favorecido) tanto con el ordenamiento educativo como con el de aseguramiento. Explican que el gradiente educativo del Modelo 1 aparezca plano y desordenado, puesto que el Modelo 1 no hace sino estimar esta misma relación con ajuste territorial. Y hacen previsible que el ajuste por covariables obstétricas modifique el patrón, dado que la composición por edad

y paridad difiere marcadamente entre niveles educativos.

Ninguno de esos tres resultados es, en consecuencia, un artefacto del modelo: están ya presentes en la descripción.

5.1.4. Tendencia temporal de la prevalencia, 1998–2024

La prevalencia de bajo peso al nacer en el conjunto de la muestra analítica es del 8,78 % (1.525.772 casos sobre 17.376.860 nacimientos). Lejos de mantenerse estable, la serie muestra un ascenso sostenido a lo largo de todo el período, que la Figura 5.1 resume.




Figura 5.1: Prevalencia anual de bajo peso al nacer en Colombia, 1998–2024, con intervalos de confianza del 95 % contruidos por el método de Wilson. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

La prevalencia pasa del 7,64 % en 1998 al 11,15 % en 2024, un incremento relativo del 45,9 %. El ascenso no es uniforme: entre 1998 y 2011 la serie sube de forma gradual hasta estabilizarse en torno al 9 % durante la década siguiente, y a partir de 2021 se acelera de nuevo hasta los valores más altos de todo el registro.

La regresión de Poisson con varianza robusta estima un cambio porcentual anual del +1,170 % (IC 95 %: +0,960 a +1,380). El valor p asociado es inferior a 10^{-15} y no se interpreta: con veintisiete observaciones y más de diecisiete millones de registros, cualquier pendiente distinta de cero alcanza significación estadística. Lo interpretable es la magnitud.

Cobertura del registro como amenaza a la validez. El volumen anual de nacimientos registrados cae de 649.493 en 2017 a 439.899 en 2024, y correlaciona de forma negativa y fuerte con la prevalencia observada ($r = -0,853$). Ese hecho impide atribuir el ascenso íntegramente a un deterioro del riesgo perinatal: si los nacimientos que dejaron de registrarse difieren sistemáticamente de los que sí se registran, parte del incremento es artefacto de la cobertura. La magnitud de esa fracción no es identificable con la información disponible, de modo que el hallazgo se enuncia como prevalencia *registrada* y no como incidencia poblacional. El análisis de sensibilidad de la Sección 5.7.1 restringe la serie a los años de cobertura estable para acotar el efecto.




Figura 5.2: Volumen anual de nacimientos registrados y prevalencia observada de bajo peso al nacer, 1998–2024. La asociación negativa entre ambas series ($r = -0,853$) impide atribuir el ascenso de la prevalencia únicamente a un deterioro del riesgo perinatal. Elaboración propia.

Localización formal de las inflexiones

La descripción anterior identifica los cambios de tendencia por inspección. Para situarlos con precisión se ajustó una regresión segmentada log-lineal sobre la serie anual (el procedimiento conocido como regresión de puntos de unión), ponderando cada año por el inverso de la varianza de su logaritmo y seleccionando el número de segmentos por el criterio de información bayesiano.

La serie sostiene **tres puntos de unión**, situados en 2010, 2014 y 2020. El cambio porcentual anual del período completo es del +1,180 %, con un intervalo del 95 % de $[+0,98; +1,38]$, coherente con el estimado sin segmentar.

El rasgo más destacado del cuadro es el último tramo: desde 2020 la prevalencia crece




Figura 5.3: Prevalencia anual de bajo peso al nacer y regresión segmentada log-lineal. Las líneas verticales señalan los puntos de unión seleccionados. Elaboración propia.

Cuadro 5.3: Cambio porcentual anual por tramo y estabilidad de cada punto de unión en 500 réplicas. Elaboración propia.

Tramo	Cambio porcentual anual	Estabilidad del corte
1998–2010	+1,724 %	—
2010–2014	−0,915 %	67,8 %
2014–2020	+1,060 %	53,0 %
2020–2024	+4,972 %	67,8 %
Período completo	+1,180 %	

a un ritmo del +4,97 % anual, más de cuatro veces el promedio del período. El segundo es que 2010–2014 es el único tramo de descenso.

Tres precisiones sobre la lectura de estos resultados, en orden de importancia.

La posición exacta de los cortes es menos firme que su existencia. La selección de tres puntos de unión se repite en el 86,6 % de las réplicas, pero cada año concreto se selecciona entre el 53 % y el 68 % de las veces, y sus vecinos inmediatos recogen buena parte del resto (2009 aparece en el 22,4 % de las réplicas y 2015 en el 21,2 %). Lo que puede afirmarse es que hay tres cambios de tendencia y en qué entorno se sitúan, con una incertidumbre del orden de un año; no que ocurran exactamente en esos años.

La variación anual excede con mucho a la que explicaría el muestreo. El parámetro de dispersión estimado es de 11,7, esto es, la desviación típica de la serie es unas tres veces y media la binomial. Las prevalencias anuales no son extracciones aleatorias

de una población fija: cambian la cobertura del registro, la composición de la población y las condiciones del período. Los intervalos aquí reportados incorporan esa corrección; sin ella resultarían unas tres veces más estrechos. La corrección afecta también a la estabilidad reportada más arriba: bajo el supuesto de variación puramente binomial, los tres cortes se seleccionaban en el 100 % de las réplicas, cifra que habría descrito la firmeza del supuesto y no la de los datos.

El método localiza cambios en la serie registrada, no en el fenómeno. Un punto de unión en 2020 coincide con el inicio de la pandemia, y también con el tramo en que el volumen de nacimientos registrados desciende con mayor rapidez. La aceleración del último tramo es, por tanto, la magnitud sobre la que la advertencia de cobertura de esta misma sección pesa con más fuerza, y no debe leerse sin ella.

5.1.5. Distribución territorial

La prevalencia no se distribuye de manera homogénea sobre el territorio. Las Figuras 5.4 y 5.5 contrastan el primero y el último año de la serie en los dos niveles de agregación que emplea el modelo multinivel.




Figura 5.4: Prevalencia de bajo peso al nacer por municipio de residencia de la madre, 1998 y 2024. Los municipios en gris no registran nacimientos en el año correspondiente. Elaboración propia a partir de los microdatos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025) y del marco geoestadístico nacional del DANE.

La lectura conjunta de las cuatro figuras admite tres observaciones.




Figura 5.5: Prevalencia de bajo peso al nacer por departamento de residencia de la madre, 1998 y 2024. Elaboración propia a partir de los microdatos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025) y del marco geoestadístico nacional del DANE.

La primera es el **desplazamiento general hacia los tonos oscuros** entre los dos años, que traduce sobre el territorio el ascenso de la prevalencia ya descrito en la Sección 5.1.4. En el nivel departamental, el rango pasa de 4,10–11,48 % en 1998 a 5,18–16,89 % en 2024: no solo sube el valor máximo, sino también el mínimo, de modo que el incremento no procede de unos pocos departamentos sino del conjunto.

La segunda es que los territorios con valores altos **no son los mismos en ambos años**. Bogotá encabeza la distribución en 1998 y en 2024, pero el resto del grupo se renueva: Chocó, que ocupaba la segunda posición en 1998 con 10,19 %, desciende a la octava; Guainía, Guaviare y Vichada, que completaban las cinco primeras posiciones, salen de ellas. En su lugar entran Cundinamarca, que asciende siete posiciones hasta la segunda con 14,51 %; Nariño, que asciende once hasta la tercera; y Caldas, que asciende diecinueve hasta la cuarta. El patrón territorial del bajo peso al nacer en Colombia, por tanto, se reordena a lo largo del período en lugar de mantenerse estable.

La tercera es que **la dispersión municipal supera con holgura a la departamental**. En 1998 la desviación típica de la prevalencia entre municipios es de 5,16 puntos porcentuales frente a 1,57 entre departamentos; en 2024, de 13,97 frente a 2,59. Dicho de otro modo: la heterogeneidad territorial del bajo peso al nacer se manifiesta sobre todo *dentro* de los departamentos y no entre ellos. Esta observación justifica haber incluido los dos niveles en la estructura jerárquica en lugar de uno solo, y anticipa el resultado del

Modelo 0 de la Sección 5.4.

Advertencia sobre la lectura de los mapas municipales. Los valores extremos del mapa municipal no deben interpretarse como riesgo. En 2024, el 82,4 % de los municipios con registro (766 de 930) notifican menos de cien nacimientos en el año, y entre todos reúnen apenas el 2,84 % de los nacimientos del país. Con denominadores tan pequeños la prevalencia es inestable por construcción: el rango municipal de ese año va del 0 al 100 %, y los 383 municipios que registran prevalencia nula tienen *todos* menos de cien nacimientos. Un mapa de coropletas otorga a esos municipios la misma superficie visual que a los de mayor volumen, de modo que la vista queda dominada por las unidades donde la estimación es menos fiable.

Los modelos multinivel del presente capítulo corrigen ese efecto por contracción: el intercepto aleatorio de un municipio con pocos nacimientos se aproxima a la media de su departamento, precisamente porque los datos propios aportan poca información. Un mapa de coropletas no incorpora esa corrección. Las dos representaciones responden, en consecuencia, a propósitos distintos, y el patrón territorial que este trabajo sostiene es el que estiman los modelos y no el que dibujan los mapas.

El ordenamiento completo de los treinta y tres departamentos, con su posición en 1998 y en 2024 y el cambio entre ambas, se reproduce en el Cuadro C.9 del Apéndice C. Se remite allí porque el detalle territorial exhaustivo interrumpe la lectura de esta sección sin añadir a su argumento, que se refiere al patrón de reordenamiento y no a la posición de cada departamento en particular.

5.2. Cribado de variables por información mutua

Qué aporta esta matriz al trabajo. La Figura 5.6 cumple aquí una función de diagnóstico y no de selección. El objetivo específico 3 exige estimar el efecto *independiente* de cada determinante social, y esa estimación solo es interpretable si los determinantes no se solapan hasta el punto de que el modelo no pueda distinguirlos. La matriz permite comprobarlo antes de especificar los modelos, en lugar de descubrirlo después en forma de errores estándar inflados.

Dos resultados de esta matriz condicionan decisiones posteriores del trabajo. El primero es que los cuatro determinantes sociales presentan asociaciones bajas entre sí, lo que sostiene la decisión de conservarlos todos en el Modelo 1 en lugar de sustituirlos por un índice compuesto: no son medidas redundantes de una misma cosa, sino dimensiones distintas




Figura 5.6: Coeficiente V de Cramér entre las variables candidatas, con la corrección de sesgo de Bergsma (2013). Elaboración propia.

de la posición social. El segundo es la asociación elevada entre la pertenencia étnica y el territorio, que anticipa la limitación declarada en la Sección 4.4.4 y explica por qué el coeficiente étnico del Modelo 3 debe interpretarse como efecto neto del lugar de residencia.

Qué aporta esta matriz al trabajo. La Figura 5.7 mide algo que ninguna otra salida de este capítulo recoge: cuánta información sobre el desenlace procede de la *combinación* de dos variables y no de cada una por separado. Su relevancia es directa para el objetivo específico 4, que descompone la desigualdad en contribuciones atribuibles a cada determinante. Una descomposición es por construcción aditiva, de modo que toda la información que reside en la interacción entre dos variables queda repartida entre los efectos principales, atribuida a cada determinante por separado cuando en realidad procede de su concurrencia.

El resultado sustantivo es que los determinantes sociales presentan sinergia positiva con la atención prenatal, mientras que entre ellos son prácticamente independientes. Eso significa que la desventaja social y el acceso deficiente a servicios no se suman: se refuerzan. La descomposición del objetivo 4 no puede captar ese refuerzo, y esta figura es la que permite declarar su magnitud en lugar de dejarla implícita.




Figura 5.7: Información de interacción entre pares de variables respecto del bajo peso al nacer. Los valores positivos indican sinergia: el par conjunto informa más que la suma de sus partes. Elaboración propia.

5.2.1. Cribado por información mutua

El cribado de la Fase 2 evalúa cada determinante candidato por la información que aporta sobre el desenlace, medida en bits, y contrasta ese valor contra la distribución nula que se obtiene permutando la variable. El procedimiento responde a una pregunta concreta: si una variable guarda una asociación con el bajo peso al nacer mayor que la que produciría el azar dado su número de categorías y su completitud.

Catorce de las quince variables candidatas superan su propia distribución nula y se retienen. La excepción es la **pertenencia étnica**, cuya información mutua con el desenlace queda por debajo del percentil 95 de su nulo: la razón es de 0,3, esto es, el valor observado es inferior al que produce la permutación. Contribuyen a ello sus dos características más desfavorables para esta prueba: una completitud del 59,8 % (la menor del conjunto, por ser ausencia estructural antes de 2008) y una distribución muy concentrada en una sola categoría.

Dos precisiones sobre el alcance de este resultado, ambas necesarias para no leerlo de más.

La primera es que el descarte **se aplica únicamente al componente predictivo de**

Cuadro 5.4: Cribado por información mutua. La incertidumbre simétrica normaliza la información mutua por las entropías marginales; la razón frente al nulo compara el valor observado con el percentil 95 de la distribución obtenida por permutación. Elaboración propia.

Variable	Bloque	Compl.	IM (bits)	% de $H(Y)$	Razón nulo	Retenida
Edad gestacional	obstétrico	100,0	0,110425	25,665	6,585,2	sí
Multiplicidad	obstétrico	99,3	0,022246	5,170	1,568,2	sí
Tipo de parto	obstétrico	99,8	0,007176	1,668	507,4	sí
Controles prenatales	obstétrico	93,9	0,006344	1,475	57,5	sí
Edad materna	obstétrico	99,8	0,000767	0,178	27,8	sí
Estado conyugal	social	97,8	0,000608	0,141	26,4	sí
Sexo	obstétrico	100,0	0,000539	0,125	49,1	sí
Número de embarazos	obstétrico	99,3	0,000510	0,118	8,5	sí
Educación del padre	social	88,4	0,000500	0,116	6,9	sí
Educación de la madre	social	96,8	0,000434	0,101	6,7	sí
Hijos nacidos vivos	obstétrico	99,3	0,000346	0,080	7,2	sí
Régimen de afiliación	social	97,7	0,000303	0,070	16,7	sí
Área de residencia	social	99,2	0,000154	0,036	12,6	sí
Situación del parto	obstétrico	100,0	0,000095	0,022	10,5	sí
Pertenencia étnica	social	59,8	0,000011	0,003	0,3	no

la **Fase 7**. La pertenencia étnica permanece en el análisis explicativo, donde se incorpora al Modelo 3, porque el criterio que gobierna esa fase no es la capacidad predictiva sino la pertinencia teórica: el objetivo específico 6 pregunta por la desigualdad étnica con independencia de que esta mejore o no una predicción.

La segunda es la distancia entre magnitud e importancia. La edad gestacional concentra el 25,7 % de la entropía del desenlace, mientras que los cuatro determinantes sociales suman menos del 0,4 %. De ahí no se sigue que la posición social sea irrelevante, sino que la información mutua mide asociación bruta y no efecto ajustado: la edad gestacional se sitúa en la vía causal inmediata del bajo peso al nacer, y de hecho queda excluida de los modelos por esa misma razón. Un criterio que ordenara los determinantes por esta columna seleccionaría, sistemáticamente, las variables más próximas al desenlace y menos útiles para explicarlo.

5.3. Desigualdad socioeconómica

Esta sección responde a la pregunta específica 2, relativa a la magnitud de la desigualdad socioeconómica en el bajo peso al nacer.

5.3.1. Prevalencia según posición socioeconómica

Las prevalencias por nivel educativo y por régimen de afiliación, con sus tamaños de muestra, se presentaron en el Cuadro 5.2. Interesa aquí retomar la implicación que de allí se desprende para la medición de la desigualdad.

El ordenamiento de la población según el nivel educativo no reproduce el ordenamiento según la prevalencia del desenlace. Con la escala educativa, la prevalencia describe una forma aproximadamente de U: desciende de 9,40 % a 8,16 % entre el nivel más bajo y el siguiente, y vuelve a ascender hasta 9,20 % en el más alto. Con la escala de aseguramiento, en cambio, asciende de forma monótona, del 8,36 % al 9,27 %.

Ambos patrones conducen a un índice de concentración positivo, esto es, a una concentración del bajo peso al nacer hacia el extremo más favorecido de la escala, pero por vías distintas: en el caso del aseguramiento se trata de un gradiente sostenido, y en el educativo de una relación no monótona en la que el extremo superior pesa más que el inferior. La distinción no es menor, porque el índice de concentración resume ambas situaciones en una misma cifra. Es la razón por la que se reporta además la curva de concentración, que las distingue.

5.3.2. Índice y curva de concentración

Qué aporta esta figura al trabajo. El índice de concentración resume la desigualdad en una sola cifra, y esa economía tiene un costo: dos distribuciones distintas pueden producir el mismo índice. La Figura 5.8 muestra la distribución completa de la que ese índice es resumen, y permite verificar que la cifra reportada para el objetivo específico 2 no procede de un comportamiento irregular en un tramo concreto de la escala educativa sino de un gradiente sostenido a lo largo de toda ella.

La distinción importa para lo que el trabajo puede afirmar. Un índice sustentado en un gradiente continuo autoriza a hablar de desigualdad socioeconómica en sentido estricto; un índice del mismo valor producido por un único grupo atípico autorizaría únicamente a señalar ese grupo. La curva es lo que permite distinguir un caso del otro, y por tanto lo que respalda la interpretación que se da al índice en el resto del capítulo.

El índice de concentración del período es de +0,0174, y su corrección de Erreygers, que es la que se reporta como resultado del objetivo específico 2, de +0,0061. Ninguno de los dos intervalos contiene el cero.

El signo positivo indica que el bajo peso al nacer se concentra hacia el extremo *más* educado de la distribución, y no hacia el menos educado como cabría esperar de un gradiente




Figura 5.8: Curva de concentración del bajo peso al nacer según el nivel educativo materno. La desviación respecto de la diagonal de igualdad indica concentración del desenlace en un extremo de la distribución educativa. Elaboración propia.

Cuadro 5.5: Índices de desigualdad según el nivel educativo materno, con intervalos bootstrap del 95 %. Elaboración propia.

Medida	Estimación	IC inferior	IC superior
Índice de concentración	+0,01740	+0,01660	+0,01826
Corrección de Erreygers	+0,00610	+0,00581	+0,00639
Corrección de Wagstaff	+0,01909	+0,01819	+0,02001

social clásico. Es la lectura que anticipaba el Cuadro 5.2.

La corrección es necesaria porque con un desenlace binario los límites que el índice puede alcanzar dependen de la prevalencia: con una prevalencia del 8,78 % el máximo alcanzable queda muy por debajo de la unidad, de modo que comparar índices sin corregir entre años de prevalencia distinta compara escalas distintas. Se reportan las dos correcciones habituales (la de Erreygers, que devuelve el índice al rango $[-1, 1]$, y la de Wagstaff, que lo divide por el complemento de la media) y ambas coinciden en signo y en orden de magnitud, lo que permite descartar que el resultado sea producto de la normalización elegida.

5.3.3. Índice de desigualdad de la pendiente e índice relativo




Figura 5.9: Prevalencia de bajo peso al nacer frente al rango fraccional de la distribución educativa materna. La pendiente de la recta ajustada es el índice de desigualdad de la pendiente. Elaboración propia.

Qué aportan estos dos índices al trabajo. El objetivo específico 2 pide cuantificar la desigualdad, y el índice de concentración lo hace en una escala que carece de unidades interpretables: su valor no dice cuántos niños están de más. El índice de desigualdad de la pendiente sí, porque se expresa en puntos porcentuales de prevalencia entre los extremos de la escala social, y admite por tanto traducirse a número de nacimientos. Esa traducción es la que convierte un resultado estadístico en una magnitud con consecuencias de política pública, que es lo que el objetivo general del trabajo se propone establecer.

La Figura 5.9 aporta además una corrección que el índice de concentración no incorpora con la misma transparencia: al situar cada nivel educativo según la proporción de población que acumula, y no según su etiqueta, impide que una categoría marginal pese lo mismo que una que agrupa a la mitad de las madres. En una serie de veintisiete años durante los cuales la composición educativa del país cambió de forma sustancial, esa ponderación no es un tecnicismo: determina si lo que se compara entre 1998 y 2024 son grupos comparables. El índice de desigualdad de la pendiente es de +1,166 puntos porcentuales, con un intervalo bootstrap del 95 % de [1,112; 1,223]; el índice relativo de desigualdad, de 1,143, con intervalo [1,136; 1,150].

La interpretación del primero es directa: entre los extremos hipotéticos de la escala educativa media una diferencia de 1,17 puntos porcentuales en la prevalencia de bajo peso al nacer, a favor del extremo menos educado. Sobre los 17,4 millones de nacimientos de la serie, esa diferencia equivale a unos 203,000 casos, cifra que no debe leerse como *exceso evitable* sino como la magnitud que el gradiente representa a escala poblacional. Conviene precisar que esa cifra resulta de aplicar la diferencia de prevalencia al total de la muestra, y supone por tanto que el contraste entre extremos se mantendría constante en toda la población, lo que es un supuesto de cálculo y no un resultado.

El índice relativo complementa al anterior porque dos poblaciones pueden presentar la misma diferencia absoluta y magnitudes relativas distintas si sus prevalencias de base difieren. Un valor de 1,143 indica que la prevalencia en un extremo de la escala supera en un 14,3 % a la del otro.

Conviene señalar que ambos índices, calculados sobre el rango fraccional, ponderan cada nivel educativo por la proporción de población que acumula. En una serie de veintisiete años durante la cual la composición educativa del país se transformó de manera sustancial (el nivel superior pasa de ser marginal a agrupar al 18,30 % de las madres), esa ponderación es lo que permite que la comparación entre el inicio y el final del período se establezca entre posiciones sociales equivalentes y no entre etiquetas de igual nombre.

5.3.4. Evolución de la desigualdad en el período

Los índices presentados hasta aquí resumen los veintisiete años en una sola cifra. Repetir el cálculo año a año permite examinar algo distinto: si la brecha se ha ampliado o reducido a lo largo del período. La Figura 5.10 recoge ese resultado.

Qué aporta esta figura al trabajo. Los índices reportados hasta aquí resumen veintisiete años en una cifra única, y esa agregación oculta precisamente lo que el objetivo específico 1 pide establecer: la *tendencia*. La Figura 5.10 recupera esa dimensión, y al hacerlo modifica lo que el trabajo puede sostener sobre la desigualdad educativa en Colombia.

El panel superior recoge el índice de concentración de cada año y el inferior la prevalencia global, de modo que ambas trayectorias puedan contrastarse. La contraposición no es accesorio: permite distinguir si la desigualdad se mueve con el nivel general de riesgo o con independencia de él, que son dos escenarios con implicaciones de política pública opuestas. Si la brecha se estrechara porque el riesgo aumenta en todos los grupos por igual, eso sería un empeoramiento y no una mejora, y solo la lectura conjunta de los dos paneles permite




Figura 5.10: Índice de concentración con corrección de Erreygers según nivel educativo materno (panel superior) y prevalencia global de bajo peso al nacer (panel inferior), por año, 1998–2024. Elaboración propia.

advertirlo.

La clave de lectura reside en el **signo** del índice superior. Un valor positivo (en naranja) indica que el bajo peso al nacer se concentra en los hijos de las madres con *mayor* nivel educativo; uno negativo (en azul) que se concentra en los hijos de las madres con *menor* nivel educativo, que es la dirección esperable según la literatura de determinantes sociales. El cero no señala ausencia de diferencias entre grupos, sino ausencia de *gradiente*: que el desenlace deja de ordenarse de manera sistemática a lo largo de la escala educativa.

La serie describe una trayectoria en dos tramos. Entre 1998 y 2009 el índice *asciende*, de +0,00123 a +0,00726: durante esa década el bajo peso al nacer se concentra de forma creciente en los hijos de las madres con mayor nivel educativo. A partir de 2009 desciende de manera sostenida, cruza el cero en 2019 y continúa en terreno negativo hasta alcanzar -0,00651 en 2024. El índice de desigualdad de la pendiente recorre el mismo camino, de +1,40 puntos porcentuales en 2009 a -1,26 en 2024, y el índice relativo pasa de 1,169 a 0,893.

El hallazgo, por tanto, no es que la brecha educativa se haya reducido. Es que ha **cambiado de dirección**: el desenlace, que durante la primera mitad del período se con-

centraba en el extremo más favorecido de la escala educativa, se concentra desde 2019 en el más desfavorecido, que es la dirección que la literatura de determinantes sociales conduce a esperar. El cruce no es un episodio aislado de un año: los seis últimos años de la serie, de 2019 a 2024, presentan índice negativo, y la magnitud crece de forma monótona a partir de 2021.

La comparación con el panel inferior añade una precisión necesaria. El cambio de signo ocurre mientras la prevalencia global asciende del 7,64 al 11,15 %, de modo que las dos series no se mueven juntas: la desigualdad se invierte al tiempo que el riesgo aumenta en el conjunto de la población. Conviene excluir explícitamente la lectura benévola, porque es la que el lector hará por defecto: lo observado no es que el grupo desfavorecido haya mejorado hasta alcanzar al favorecido, sino que el riesgo ha aumentado en ambos y lo ha hecho más deprisa en el desfavorecido.

Alcance de este resultado. Es el hallazgo más llamativo del capítulo y también el que exige mayor cautela al enunciarse. La Sección 5.7.1 muestra que la inversión *no* aparece cuando la población se ordena por régimen de afiliación en lugar de por nivel educativo. En consecuencia, el resultado se enuncia aquí como una propiedad del gradiente **educativo** y no de la desigualdad socioeconómica en general.

[DECISIÓN PARA HABLAR CON LIHKI, y de las importantes. ¿Presento esto como EL hallazgo del trabajo o como uno entre varios? A favor de lo primero: ningún trabajo previo sobre bajo peso al nacer en Colombia lo ha documentado, y desde la Fase 5 ya tengo el mecanismo (la contribución de la educación se cuadruplica mientras el contrapeso de la paridad se debilita) en lugar de solo la observación. A favor de lo segundo: sigue dependiendo de la variable con que ordeno la población. Lo que ya NO vale como argumento en contra es la dilución de la escala educativa: la contrasté en la Sección 5.7.1 y los datos la descartan. Debo cerrar esta decisión antes de redactar el resumen y las conclusiones, porque cambia el tono de las dos.]

5.4. Modelos multinivel

Esta sección responde a las preguntas específicas 3 y 5. Conviene precisar de entrada que los cinco ajustes que siguen no son cinco técnicas distintas sino **una sola especificación multinivel estimada en pasos anidados**, en la que cada paso incorpora un bloque de variables al anterior. La estrategia se detalla en la Sección 4.4.4. La razón de proceder por pasos es que cada uno estima una cantidad distinta: el efecto total de la posición

social, su efecto independiente de las características obstétricas, y su efecto directo una vez descontada la vía de la atención prenatal. Un único modelo con todas las variables estimaría solo el último, que no es el que interesa para la política pública.

5.4.1. Modelo 0. Variación municipal y departamental

El modelo vacío estima cuánta variación del bajo peso al nacer es territorial antes de ajustar por nada, y establece la referencia contra la cual se calcula el cambio proporcional en la varianza de los modelos siguientes.

Cuadro 5.6: Componentes de varianza del modelo vacío. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Cantidad	Valor	Interpretación
σ municipal	0,1772	desviación típica de los interceptos municipales
σ departamental	0,1693	desviación típica de los interceptos departamentales
Varianza individual	3,2899	$\pi^2/3$, fijada por la variable latente
CCI municipal	1,79 %	dos nacimientos del mismo municipio
CCI departamental	0,86 %	municipios distintos del mismo departamento
MOR municipal	1,184	cambio mediano del momio al mudar de municipio
MOR departamental	1,175	cambio mediano al mudar de departamento
Municipios	1,157	conglomerados de nivel 2
Departamentos	33	conglomerados de nivel 3
Nacimientos	17,376,860	

El Modelo 0 no incluye covariables: estima únicamente cuánta variación del riesgo de bajo peso al nacer ocurre entre territorios. Como el desenlace es binario, la varianza del nivel individual no está identificada por los datos, de modo que se emplea la formulación de variable latente, que la fija en $\pi^2/3 = 3,2899$, la varianza de la distribución logística estándar.

Sobre esa escala, la desviación típica de los interceptos municipales es de 0,1772 y la de los departamentales de 0,1693. El coeficiente de correlación intraclase resultante es del 1,79 % en el nivel municipal y del 0,86 % en el departamental: en conjunto, algo menos del 2 % de la variación total del riesgo latente corresponde al territorio, y aproximadamente dos tercios de esa fracción se sitúan entre municipios de un mismo departamento.

Conviene precisar cómo debe leerse esa magnitud. Un coeficiente del 1,79 % es un valor habitual en estudios de epidemiología social sobre desenlaces perinatales, y su interpretación directa es limitada, porque una proporción de varianza no dispone de una escala

de referencia con la que contrastarse. La cantidad comparable con el resto de los resultados del capítulo es la razón de momios mediana, que traduce la varianza de los efectos aleatorios a la misma escala en la que se expresan los coeficientes de los determinantes.

La razón de momios mediana admite una lectura directa: es el cambio mediano del momio de bajo peso al nacer que se obtendría al comparar dos nacimientos idénticos en todo salvo en el municipio de residencia. Su valor en el Modelo 0 es de 1,184. La Sección 5.4.7 lo contrasta con las razones de momios de los determinantes individuales (empleando para ello el valor que corresponde al Modelo 2), que es la comparación que permite valorar el peso relativo del territorio.

La prevalencia implicada por el intercepto del Modelo 0 es del 7,26 %, inferior a la prevalencia observada del 8,78 %. La diferencia no indica un error de ajuste: en un modelo logístico con interceptos aleatorios el intercepto corresponde al conglomerado *mediano* y no al promedio poblacional, y ambas cantidades difieren porque la función de enlace no es lineal. Es la misma distinción que separa los efectos condicionales de los marginales en los modelos no lineales, y su presencia es esperable en una especificación correctamente ajustada.

5.4.2. Modelo 1. Efecto total de la posición social

El Modelo 1 incorpora los cuatro determinantes sociales sin covariables de ajuste, de modo que sus coeficientes recogen el efecto *total* de la posición social, incluida la parte que discurre a través de las características obstétricas.

Las razones de momios del nivel educativo materno son de 0,857 para primaria, 0,858 para secundaria y 0,874 para educación superior, todas frente a la ausencia de educación. El gradiente resulta, por tanto, casi plano, y además no es monótono: la categoría superior presenta una razón de momios mayor que la de secundaria, lo que carece de lectura sustantiva. El estado conyugal y el área de residencia sí se comportan en el sentido esperado: soltera frente a casada arroja 1,288 y rural disperso frente a cabecera 1,098.

Este resultado no se presenta como conclusión, sino como punto de partida. La Sección 5.4.3 muestra que el patrón se ordena al introducir las covariables obstétricas, y que el sentido de ese cambio es informativo sobre la estructura del problema.

5.4.3. Modelo 2. Efecto independiente tras el ajuste obstétrico

El Modelo 2 incorpora las tres covariables de ajuste (edad materna, paridad y multiplicidad del embarazo) y estima con ello el efecto independiente de cada determinante social, que es lo que pide el objetivo específico 3. De este modelo proceden los coeficientes reportados como resultado principal del trabajo.

Cuadro 5.7: Razones de momios del Modelo 2, ajustadas por edad materna, paridad y multiplicidad. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Término	Coefficiente	Razón de momios
<i>Determinantes sociales</i>		
Primaria <i>vs</i> ninguno o preescolar	−0,1576	0,854
Secundaria <i>vs</i> ninguno o preescolar	−0,1811	0,834
Superior <i>vs</i> ninguno o preescolar	−0,2126	0,808
Unión libre <i>vs</i> casada	+0,1233	1,131
Soltera <i>vs</i> casada	+0,2285	1,257
Separada o divorciada <i>vs</i> casada	+0,1692	1,184
Viuda <i>vs</i> casada	+0,0902	1,094
Subsidiado <i>vs</i> contributivo	+0,0705	1,073
No asegurado <i>vs</i> contributivo	−0,0110	0,989
Rural disperso <i>vs</i> cabecera	+0,0927	1,097
<i>Covariables de ajuste</i>		
35 años o más <i>vs</i> 20 a 34	+0,3256	1,385
Menor de 20 <i>vs</i> 20 a 34	+0,0905	1,095
2 hijos <i>vs</i> 1 hijo	−0,2420	0,785
3 hijos <i>vs</i> 1 hijo	−0,2863	0,751
4 o más <i>vs</i> 1 hijo	−0,3701	0,691
Parto doble <i>vs</i> simple	+2,9937	19,960
Parto triple o más <i>vs</i> simple	+3,1383	23,066

El resultado central de esta sección no reside en el valor de los coeficientes, sino en el sentido en que estos cambian respecto del Modelo 1.

Sin ajustar, el gradiente educativo era plano y no monótono: 0,857 para primaria, 0,858 para secundaria y 0,874 para educación superior. Una vez incorporadas la edad materna, la paridad y la multiplicidad del embarazo, las razones de momios pasan a ser de 0,854, 0,834 y 0,808 respectivamente: monótonas decrecientes, que es la forma del gradiente social clásico. El cambio de mayor magnitud corresponde a la categoría superior, con un $-7,52\%$, frente a un $-0,28\%$ en primaria.

La dirección de ese cambio es informativa. El ajuste por una variable situada en la vía causal entre la exposición y el desenlace (esto es, por un mediador) atenúa el efecto

estimado de la exposición. Lo que se observa aquí es lo contrario: el gradiente no se atenúa, sino que se ordena, y lo hace intensificándose precisamente en el extremo que antes resultaba anómalo. Ese comportamiento es el que corresponde a variables que operan como confusores o como covariables de precisión, y no como mediadores.

La consecuencia es que la decisión metodológica adoptada en la Sección 4.4.4 (incorporar edad, paridad y multiplicidad en el Modelo 2 y reservar la atención prenatal para el Modelo 4) queda respaldada por el comportamiento de los datos y no únicamente por el argumento teórico que la motivó.

La edad materna describe la forma de U esperada: las madres menores de veinte años presentan una razón de momios de 1,095 y las de treinta y cinco o más de 1,385, ambas frente al tramo de veinte a treinta y cuatro años. Esta comprobación se fijó antes de estimar el modelo: un patrón monótono, en lugar de una U, habría indicado un error en la definición de la categoría de referencia.

El efecto de mayor magnitud de todo el modelo corresponde a la multiplicidad del embarazo: 19,960 en los partos dobles y 23,066 en los de tres o más, frente al parto simple. La cifra es coherente con la prevalencia observada, del 59,15 % en los partos dobles frente al 7,87 % en los simples.

Esa magnitud no se traslada, sin embargo, a la desigualdad. La Sección 5.5 muestra que la contribución de la multiplicidad al índice de concentración es del 4,9 %, pese a tratarse del factor de riesgo más potente estimado en este trabajo.

El régimen de afiliación no se comporta como cabría esperar de un eje de ordenamiento socioeconómico. El régimen subsidiado arroja una razón de momios de 1,073 frente al contributivo, en el sentido previsto; pero la categoría de no asegurado arroja 0,989, esto es, prácticamente la unidad. El grupo teóricamente más desfavorecido no presenta, por tanto, mayor riesgo una vez realizado el ajuste.

El resultado se explica, en buena medida, por la composición temporal de la categoría. El Modelo 2b, idéntico al Modelo 2 pero ajustado sobre la submuestra de 2008 en adelante, arroja para el grupo de no aseguradas una razón de momios de 1,109, esto es, en el sentido esperado. La anomalía corresponde al período completo y no al fenómeno.

Dos circunstancias concurren en el tramo anterior a 2008. La primera es que el 72,1 % de los registros clasificados como no asegurados procede de ese tramo: de los 2,525,812 que integran la categoría, 1,820,805 son anteriores al cambio de formulario, de modo que el coeficiente del período completo está dominado por ellos. La segunda es que en ese tramo la categoría reúne dos poblaciones que el formulario antiguo distinguía (la vinculada al sistema y la que pagaba de forma particular) y que la prevalencia registrada del conjunto

resultante (7,67 %) es *inferior* a la del régimen contributivo (8,31 %), lo que invierte el orden esperado antes de cualquier ajuste.

A ello se añade una explicación de naturaleza no biológica sobre la propia composición de la muestra. La ausencia del dato de peso al nacer no se distribuye de manera uniforme entre regímenes: entre los 18,0 millones de registros anteriores a las exclusiones, el 2,943 % de los correspondientes a mujeres no aseguradas carece de peso informado, frente al 0,214 % de los del régimen contributivo. La razón entre ambas proporciones es de 13,8, y se amplía a lo largo del período: de 7,4 en 1998–2007 a 32,0 en 2019–2024, no porque la completitud del grupo no asegurado se deteriore, sino porque la del contributivo se aproxima a la totalidad.

Si esa ausencia es informativa, el grupo de no aseguradas efectivamente observado no corresponde al grupo de no aseguradas de la población, sino al subconjunto cuyo parto quedó registrado de forma completa, y la exclusión operaría en el sentido de atenuar el efecto social estimado. Una acotación al modo de Manski (1990) delimita el alcance de esa posibilidad: asignando la totalidad de los registros sin peso a la condición de bajo peso al nacer, la razón de prevalencias crudas entre no aseguradas y afiliadas al régimen contributivo pasa de 0,904 a 1,168, de modo que el signo se invierte.

Las dos explicaciones son compatibles y apuntan al mismo tramo de la serie: el período en el que la categoría es heterogénea es también aquel en el que peor se registra el peso al nacer entre las no aseguradas.

Ninguno de los dos supuestos queda demostrado, y conviene precisar hasta dónde llega el argumento. Para que el grupo no asegurado alcanzase la prevalencia del contributivo, la prevalencia de bajo peso al nacer entre sus 79,907 registros sin peso informado habría de situarse en el 38,9 %, aproximadamente cuatro veces y media la observada en ese mismo grupo. Lo que puede sostenerse, en consecuencia, es que la anomalía resulta compatible con un mecanismo de registro y no exige uno de naturaleza biológica; no que dicho mecanismo la explique.

Una precisión sobre lo que se está comparando. Las cifras de completitud corresponden a prevalencias crudas calculadas sobre la matriz previa a las exclusiones del Cuadro 4.1, y no a la razón de momios ajustada del Modelo 2, que es una cantidad distinta. El argumento opera sobre la composición de la muestra y afecta, por tanto, a ambas.

5.4.4. Modelo 3. Efecto social descontada la composición étnica

El Modelo 3 incorpora la pertenencia étnica de la madre. La variable solo está disponible desde 2008, de modo que el ajuste se realiza sobre la submuestra de 9,951,407 nacimientos que la tienen informada, y la comparación se establece frente al Modelo 2 reajustado sobre esas mismas filas, denominado aquí Modelo 2b. Comparar contra el Modelo 2 original, estimado sobre 15,946,216 registros, confundiría el efecto de añadir la etnia con el de cambiar de muestra.

Cuadro 5.8: Razones de momios de la pertenencia étnica en el Modelo 3, referidas a la categoría indígena. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Término	Coefficiente	Razón de momios
Rom <i>vs</i> indígena	−0,1141	0,892
Palenquero <i>vs</i> indígena	−0,1833	0,833
Afrodescendiente <i>vs</i> indígena	+0,0027	1,003
Raizal <i>vs</i> indígena	+0,0570	1,059
Ninguna de las anteriores <i>vs</i> indígena	+0,0113	1,011

El resultado de esta sección es que la pertenencia étnica, una vez tenido en cuenta el municipio de residencia, no aporta información adicional sobre el riesgo de bajo peso al nacer. Tres medidas independientes lo indican.

La primera es la magnitud de los propios coeficientes. Ninguna de las cinco categorías se aparta apreciablemente de la unidad, y las dos que más lo hacen, Rom y palenquero, son las de menor tamaño de la muestra.

La segunda es el efecto de añadir la variable sobre el resto de la especificación. Los coeficientes del gradiente educativo se desplazan un −0,13 %, un −0,16 % y un −0,16 % respectivamente, y ningún otro término del modelo se mueve más de un 0,04 %. El cambio proporcional en la varianza municipal es del −0,03 %: la etnia no explica nada de la variación territorial que los interceptos municipales no explicaran ya.

La tercera son los criterios de información. Frente al Modelo 2b, y sobre la misma submuestra, el Modelo 3 *empeora* el AIC en 1,7 unidades y el BIC en 72,3: los cinco parámetros adicionales no compran ajuste.

La interpretación de este resultado requiere precisión, porque admite dos lecturas y solo una es sostenible. Lo que los datos permiten afirmar es que la pertenencia étnica no añade capacidad explicativa *por encima del municipio de residencia*. Lo que no permiten afirmar es que no existan desigualdades étnicas en el bajo peso al nacer. La razón es de diseño:

la pertenencia étnica y el municipio están fuertemente asociados (V de Cramér de 0,473, según la Figura 5.6), de modo que los interceptos municipales absorben la mayor parte del contraste étnico antes de que el coeficiente fijo pueda recogerlo. Con esta fuente no es posible separar el hecho de pertenecer a un pueblo indígena del hecho de residir donde reside la población indígena.

El coeficiente que aquí se reporta debe leerse, por tanto, como una cota inferior del efecto étnico, y la brecha étnica bruta se documenta en la Sección 5.3 mediante índices de concentración, que no compiten con los interceptos territoriales.

5.4.5. Modelo 4. Efecto directo tras el ajuste por atención prenatal

El Modelo 4 incorpora el número de controles prenatales, agrupado en cuatro categorías. A diferencia de las covariables del Modelo 2, la atención prenatal se postula como *mediador* del efecto social y no como confusor: la posición socioeconómica condiciona el acceso a los controles, y estos a su vez condicionan el desenlace. El contraste entre ambos modelos estima, en consecuencia, qué parte del efecto de la educación discurre por esa vía.

Cuadro 5.9: Gradiente educativo antes y después del ajuste por atención prenatal. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Nivel educativo	Modelo 3	Modelo 4	Atenuación
Primaria <i>vs</i> ninguno	0,877	0,969	76,2 %
Secundaria <i>vs</i> ninguno	0,822	0,970	84,6 %
Superior <i>vs</i> ninguno	0,764	0,974	90,2 %

El gradiente educativo prácticamente desaparece al condicionar por la atención prenatal: las tres razones de momios se aproximan a la unidad y el ordenamiento entre niveles deja de ser monótono. La atenuación del coeficiente correspondiente a la educación superior alcanza el 90,2 %. El propio efecto de los controles es de gran magnitud: siete o más consultas frente a ninguna arroja una razón de momios de 0,256.

Esa atenuación no admite, sin embargo, lectura como proporción del efecto social mediada por la atención prenatal, y conviene exponer las razones antes de que la cifra se interprete en ese sentido.

La primera es de medición. El número de controles prenatales depende mecánicamente de la duración de la gestación: un parto pretérmino registra menos consultas porque el

embarazo terminó antes, y no porque la madre accediera menos al sistema. Puesto que la prematuridad es una de las dos vías por las que se produce el bajo peso al nacer, condicionar por el número de consultas equivale, en parte, a condicionar por una consecuencia del propio desenlace.

La segunda es el comportamiento del resto de los coeficientes. Seis términos del modelo cambian de signo al incorporar el mediador. El más ilustrativo es el régimen de afiliación: la categoría de no asegurada pasa de 1,109 en el Modelo 3 a 0,761 en el Modelo 4, es decir, aparece como protectora. Esa comparación responde a la pregunta de qué ocurriría si una mujer no asegurada recibiera el mismo número de controles que una afiliada al régimen contributivo, y ese contrafactual no está representado en los datos.

La tercera es la varianza territorial. El cambio proporcional en la varianza departamental es del -101% , esto es, se duplica al añadir el mediador, lo que apunta en la misma dirección que los dos indicios anteriores.

Lo que el Modelo 4 sostiene, en consecuencia, es que el gradiente educativo se atenúa de forma sustancial al condicionar por la atención prenatal, y que esa atenuación es compatible con un papel mediador de los controles. Cuantificar esa mediación exigiría una medida del acceso a la atención prenatal que no dependiera de la duración de la gestación (por ejemplo, la edad gestacional del primer control) de la que esta fuente no dispone.

5.4.6. Comparación de ajuste y cambio proporcional en la varianza

Las comparaciones de esta sección se establecen siempre entre modelos ajustados sobre la misma submuestra. Añadir una covariable descarta los registros que la tienen sin informar, de modo que un modelo con más variables se estima, salvo excepción, sobre menos filas; comparar sus criterios de información con los de un modelo ajustado sobre más registros confundiría el efecto de la especificación con el del tamaño de la muestra. Por esa razón se ajustaron los modelos auxiliares 1c, 2b y 3b, idénticos a los modelos 1, 2 y 3 salvo en que emplean las filas del modelo con el que se comparan.

Sobre las mismas 15,946,216 filas, el ajuste obstétrico reduce el AIC en 514,700 unidades respecto del Modelo 1c: las tres covariables mejoran el ajuste de forma sustancial, en coherencia con el reordenamiento del gradiente educativo descrito en la Sección 5.4.3.

Sobre las 9,951,407 filas del Modelo 3, en cambio, la incorporación de la pertenencia étnica *empeora* el AIC en 1,7 unidades y el BIC en 72,3. Los cinco parámetros añadidos no compran ajuste, lo que concuerda con las otras dos medidas presentadas en la Sección 5.4.4.

Cuadro 5.10: Criterios de información de los cinco ajustes y de los tres modelos auxiliares. Elaboración propia.

Modelo	n	k	AIC	BIC
			millones	
Modelo 0	17,376,860	3	10,240	10,240
Modelo 1	16,141,664	15	9,490	9,490
Modelo 1c	15,946,216	15	9,374	9,375
Modelo 2	15,946,216	22	8,860	8,860
Modelo 2b	9,951,407	22	5,742	5,742
Modelo 3	9,951,407	27	5,742	5,743
Modelo 4	9,873,473	30	5,580	5,580

Los criterios de información se calculan sobre la log-verosimilitud de los datos sin agregar. La estimación opera sobre celdas binomiales, y la log-verosimilitud de la muestra agregada incorpora una constante combinatoria que depende de cómo estén formadas las celdas; puesto que añadir una covariable las subdivide, esa constante cambia con cada especificación y haría incomparables los criterios entre modelos. La constante no interviene en la estimación, de modo que descontarla no altera ningún coeficiente ni ninguna varianza.

Cuadro 5.11: Cambio proporcional en la varianza entre modelos ajustados sobre la misma submuestra. Elaboración propia.

Comparación	CPV municipal	CPV departamental
Modelo 1c → Modelo 2	−6,66 %	−6,18 %
Modelo 2b → Modelo 3	−0,03 %	+1,04 %

Los valores negativos del cambio proporcional en la varianza no indican un error de estimación. Un cambio negativo significa que la varianza territorial *aumenta* al incorporar el bloque de variables, lo que ocurre cuando estas enmascaraban parte de la heterogeneidad entre territorios: al mantenerlas constantes, la variación que corresponde al lugar se hace más visible. Es el mismo fenómeno que explica que la razón de momios mediana municipal pase de 1,184 en el Modelo 0 a 1,197 en el Modelo 2.

[ME FALTA LA ÚLTIMA FILA de las dos tablas: la comparación del Modelo 3b con el Modelo 4, que es la que mide qué aporta la atención prenatal. El bloque de M3b ya está escrito en el notebook 04; falta correrlo y volver a guardar el pickle. Después, correr `corregir_aic.py` otra vez y la tabla sale completa.]

5.4.7. Contraste con la desigualdad territorial observada

La razón de momios mediana entre municipios que se desprende del Modelo 2 es de 1,197. La razón de momios de ser soltera frente a casada, estimada en ese mismo modelo, es de 1,257. Ambas cantidades proceden de la misma especificación y están expresadas en la misma escala, la del momio de bajo peso al nacer, de modo que son directamente comparables. El contraste se establece con la razón de momios mediana del Modelo 2 y no con la del Modelo 0 (1,184), para que las dos cantidades comparadas procedan de una misma especificación. La diferencia entre ambas es menor, y su sentido es el esperable: al incorporar los determinantes individuales la varianza entre municipios aumenta ligeramente, puesto que parte de la heterogeneidad territorial quedaba enmascarada por la composición social de los municipios.

La lectura es que un único atributo individual se asocia con un cambio del momio superior al que corresponde a la mediana de la heterogeneidad existente entre los 1,157 municipios del país. Ello proporciona una respuesta cuantitativa a la pregunta de qué aporta la especificación multinivel: no aporta un determinante de mayor magnitud que los individuales, sino la posibilidad de situar la magnitud del territorio en la misma escala que ellos y comprobar que es menor.

Conviene delimitar lo que la comparación establece. En primer lugar, la razón de momios mediana es una mediana sobre pares de municipios, de manera que existen contrastes territoriales que superan holgadamente ese valor; el resultado no implica que ningún municipio importe, sino que el municipio típico pesa menos que este atributo individual. En segundo lugar, y como se detalla en el Capítulo 6, la ausencia de covariables municipales impide establecer a qué se debe la variación territorial que el modelo mide.

5.5. Descomposición de la desigualdad

Esta sección responde a la pregunta específica 4. El índice de concentración de la Sección 5.3 cuantifica cuánta desigualdad hay; la descomposición establece de dónde procede.

Conviene recordar antes la lógica del procedimiento, porque de ella depende la lectura de todo lo que sigue. La contribución de un determinante es el **producto** de dos cantidades: su elasticidad, que recoge cuánto se asocia con el desenlace, y su propio índice de concentración, que recoge cómo de desigualmente está repartido en la población. Un determinante contribuye a la desigualdad solo si cumple las dos condiciones a la vez. Un factor de riesgo intenso pero repartido por igual entre estratos no genera desigualdad, y

un factor muy desigualmente repartido que no afecte al desenlace tampoco.

5.5.1. Contribución de cada determinante

Descomposición de la desigualdad educativa en el bajo peso al nacer




Figura 5.11: Contribución de cada determinante al índice de concentración de la desigualdad educativa en el bajo peso al nacer, 1998–2024, con intervalos bootstrap del 95 %. El panel (a) recoge el reparto completo; el (b) lo repite sin la variable que define el eje socioeconómico. Elaboración propia.

Antes de leer el reparto conviene fijar la base sobre la que está calculado. El índice que se descompone en esta sección es de +0,018182, y difiere del reportado en la Sección 5.3, de +0,017404. La diferencia no procede del procedimiento sino de la muestra sobre la que cada uno se calcula: el de la Fase 3 exige únicamente que el nivel educativo esté informado, y se estima sobre 16,820,098 registros; la descomposición exige dato completo en los siete determinantes de forma simultánea, y se estima sobre 15,946,216, esto es, 873,882 registros menos. Todos los porcentajes de esta sección están calculados sobre el segundo valor.

El reparto no se ajusta a lo que cabría anticipar. Si el índice mide la desigualdad educativa en el bajo peso al nacer, lo esperable sería que el propio nivel educativo fuese su principal componente. No lo es.

El mayor contribuyente es la **paridad**, con +0,01529, equivalente al 84,1 % del índice del período; le siguen el régimen de afiliación, con +0,00696 (38,3 %), y el área de residencia, con +0,00410 (22,5 %). El nivel educativo materno aporta −0,00343, esto es, −18,8 %: contribuye en sentido contrario al del índice total. Ninguno de los intervalos bootstrap del 95 % cruza el cero.

Los porcentajes se calculan sobre el índice del período y hay contribuciones de uno y otro signo, de modo que la suma de sus valores absolutos excede el 100 %. No se trata de

un error aritmético: los componentes de signo negativo cancelan parte de los positivos.

El signo de la contribución de la paridad exige explicación, porque procede del producto de dos cantidades negativas. Por un lado, tener cuatro o más hijos se asocia con *menos* bajo peso al nacer ($\beta = -0,0285$). Por otro, la paridad alta se concentra en las madres menos educadas ($CI_k = -0,409$). La combinación de ambas implica que la paridad alta protege precisamente al grupo situado en la parte baja del gradiente educativo, y por esa vía desplaza el índice de concentración hacia el extremo más educado.

El resultado es coherente con la evidencia clínica. Una revisión sistemática con meta-análisis de la asociación entre paridad y peso al nacer estima que la nuliparidad se asocia con una razón de momios de 1,41 (IC del 95 %: 1,26–1,58) para el bajo peso al nacer y de 1,89 (1,82–1,96) para el pequeño para la edad gestacional, con una diferencia media de peso de -282 g (Shah, 2010). El mecanismo propuesto remite a la inmadurez materna: crecimiento incompleto, menor tamaño uterino y competencia del feto por nutrientes. No es, por tanto, que la multiparidad proteja, sino que el primer embarazo transcurre en un organismo que todavía no ha atravesado ninguno.

Conviene declarar una imprecisión del instrumento. La variable disponible, `N_HIJOSV`, registra el número de hijos nacidos vivos y no la paridad en sentido estricto, que incluiría las pérdidas gestacionales y los mortinatos. La diferencia es menor en magnitud, pero afecta a la interpretación del término: lo que el modelo compara es a las madres sin hijos vivos previos con las que ya los tienen, y no exactamente a las primigestas con las multíparas.

Es necesaria una advertencia metodológica antes de leer la figura. El residuo de esta descomposición es **cero por construcción** y no como consecuencia de la calidad del ajuste. La razón es algebraica: el rango fraccional es constante dentro de cada nivel educativo, de modo que constituye una combinación lineal de las variables indicadoras de esos niveles; y los residuos de mínimos cuadrados son ortogonales a los regresores del modelo. En consecuencia, cuando la variable que define el ordenamiento figura entre los regresores, la parte no explicada del índice se anula necesariamente.

La comprobación numérica lo confirma: incluyendo el nivel educativo entre los regresores el residuo es del orden de 10^{-16} , mientras que excluyéndolo asciende al $-12,1$ % del índice. Por esta razón el panel (b) de la Figura 5.11 omite la educación: su barra no es comparable con las de los demás determinantes, puesto que no procede de la misma clase de estimación.

5.5.2. Elasticidades y distribución de los determinantes

Cada contribución es el producto de dos factores: la elasticidad del desenlace respecto del determinante y el índice de concentración del propio determinante. Separarlos permite distinguir un problema de riesgo de un problema de distribución, que son cuestiones distintas y admiten intervenciones distintas.

La multiplicidad del embarazo ilustra la diferencia con particular claridad. Su elasticidad es la mayor del conjunto (la prevalencia de bajo peso al nacer es del 59,15 % en los partos dobles frente al 7,87 % en los simples) y, sin embargo, su contribución al índice es de apenas el 4,9 %. La explicación está en el segundo factor: el índice de concentración de la exposición es de 0,0073, esto es, prácticamente nulo. La multiplicidad se distribuye de forma casi idéntica a lo largo del gradiente educativo.

La paridad presenta el caso inverso. Sin ser el factor de riesgo de mayor magnitud, es el mayor contribuyente a la desigualdad, porque su distribución social sí es marcadamente desigual. Ambos casos, tomados conjuntamente, delimitan el alcance de lo que este índice mide: un factor de riesgo que no está socialmente distribuido genera morbilidad, pero no genera desigualdad.

5.5.3. Reparto por subperíodo

La Sección 5.1.4 dejó abierta una pregunta: el índice de concentración educativa cambia de signo hacia el final del período, y la serie anual muestra ese cruce pero no explica a qué se debe. Repetir la descomposición dentro de cada tramo permite responderla, porque muestra qué determinantes se reordenan entre un tramo y el siguiente.

Los índices de los tres tramos son de +0,016824, +0,010518 y $-0,003848$, esto es, positivo y decreciente en los dos primeros y negativo en el tercero. El Cuadro 5.12 recoge la contribución de cada determinante en cada uno de ellos, en valor absoluto.

El reparto por subperíodos permite responder a la pregunta que quedaba abierta en la Sección 5.1.4. La inversión del gradiente educativo no procede de un cambio en la composición de la población, sino de la evolución divergente de dos contribuciones de signo opuesto.

La contribución propia del nivel educativo se cuadruplica en la dirección clásica, al pasar de $-0,0072$ en 1998–2009 a $-0,0299$ en 2019–2024. En el mismo intervalo, el contrapeso que ejerce la paridad se debilita, de +0,0166 a +0,0110. Una fuerza se intensifica mientras la que la compensaba pierde magnitud, y el índice total cruza el cero. Solo dos determinantes cambian de signo a lo largo de los tres tramos (la multiplicidad del embarazo y la edad




Figura 5.12: Contribución de cada determinante al índice de concentración en tres tramos de la serie: 1998–2009, cuando el índice asciende; 2010–2018, cuando desciende; y 2019–2024, cuando es negativo. Se omite la variable que define el eje socioeconómico. Elaboración propia.

Cuadro 5.12: Contribución de cada determinante al índice de concentración, por subperíodo. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Determinante	1998–2009	2010–2018	2019–2024
Nivel educativo materno	–0,00721	–0,01504	–0,02992
Paridad	+0,01660	+0,01293	+0,01096
Régimen de afiliación	+0,00609	+0,00951	+0,00988
Área de residencia	+0,00764	+0,00402	+0,00306
Multiplicidad	–0,00087	+0,00356	+0,00564
Estado conyugal	–0,00294	–0,00307	–0,00419
Edad materna	–0,00250	–0,00138	+0,00071
Índice del tramo	+0,01682	+0,01052	–0,00385

materna) y ambos lo hacen con magnitudes menores que las anteriores.

El enunciado que estos resultados sostienen es, en consecuencia, restringido y conviene formularlo con precisión: el gradiente *educativo* se invirtió entre 2018 y 2019, mientras que el gradiente por régimen de afiliación se mantuvo positivo a lo largo de los veintisiete años, entre +0,0032 y +0,0089. Lo que se invierte es el ordenamiento por educación, no la desigualdad socioeconómica considerada en su conjunto.

Este resultado es además el que permite descartar la explicación alternativa más inmediata, que la inversión proceda de una dilución de la escala educativa al expandirse la educación superior, cuya refutación se desarrolla en la Sección 5.7.1. Si la escala se hubiera degradado como instrumento de ordenamiento, la contribución propia de la educación se habría debilitado; se cuadruplicó.

Esta comparación está sujeta a una limitación que conviene declarar antes de extraer conclusiones de ella. Los tramos son tramos de tiempo, de modo que cuanto varíe a lo largo del período queda confundido con ellos: el fenómeno mismo, la cobertura del registro y la versión del instrumento de captura. La sección establece, por tanto, *qué* se reordena entre subperíodos, pero no *por qué* se reordena.

Las contribuciones se reportan en valor absoluto y no como porcentaje del índice de cada tramo. La razón es que el índice del tramo 2019–2024 se sitúa muy próximo a cero, de modo que expresar las contribuciones como proporción de esa cantidad produce porcentajes de magnitud arbitrariamente grande y sin contenido interpretable. Los porcentajes solo resultan comparables dentro de un mismo tramo.

5.6. Comparación de modelos de clasificación

Esta sección desarrolla el componente predictivo del trabajo, descrito en la Sección 4.4.7, y responde al objetivo específico 7. Conviene precisar qué pregunta contesta y cuál no. Contesta hasta dónde llega la información del certificado de nacido vivo para señalar un nacimiento en riesgo, y cuánto añade a ese señalamiento el bloque de determinantes sociales por encima del obstétrico. No contesta por qué un nacimiento está en riesgo: un modelo de clasificación ordena observaciones según su probabilidad estimada, y de esa ordenación no se sigue ninguna afirmación causal ni ningún efecto atribuible a una variable. Esa pregunta la responden los modelos multinivel de la Sección 5.4, y las dos mitades del trabajo se reconcilian en la Sección 5.6.10.

5.6.1. Desempeño en validación cruzada

[ME FALTA. Las métricas promedio de los cinco pliegues para los siete modelos.]

5.6.2. Desempeño en el conjunto de prueba

[ME FALTA. F_1 , precisión, sensibilidad, especificidad y AUC de los siete modelos, con intervalos bootstrap.]

5.6.3. Brecha entre entrenamiento y prueba

[ME FALTA. Un cuadro con una fila por modelo y columnas separadas para entrenamiento y prueba (F_1 , sensibilidad, especificidad y AUC), con el formato del Cuadro 5.13. Interpretarlo modelo por modelo: brecha amplia es sobreajuste, brecha estrecha es buena generalización. VIGILAR el perceptrón multicapa y el bosque aleatorio, que son los que más fácilmente separan casi perfecto el entrenamiento y luego fallan.]

Cuadro 5.13: Desempeño en entrenamiento y en prueba de los siete modelos de clasificación. Una brecha reducida entre ambas columnas indica ausencia de sobreajuste. Elaboración propia a partir de los microdatos de nacimientos de las Estadísticas Vitales (Departamento Administrativo Nacional de Estadística, 2025).

Modelo	F_1		Sensibilidad		Especificidad		AUC	
	Entr.	Prueba	Entr.	Prueba	Entr.	Prueba	Entr.	Prueba
Regresión logística								
Lasso								
Ridge								
Árbol de decisión								
Random Forest								
Gradient boosting								
Perceptrón multicapa								

5.6.4. Desempeño bajo partición temporal

[ME FALTA. El esquema complementario: entrenar con 1998–2018 y probar con 2019–2024. Contrastarlo con la partición aleatoria y discutir si el modelo generaliza hacia el futuro. Ojo aquí, porque la prevalencia sube a lo largo del período: es probable que el desempeño caiga, y si cae tengo que explicar por qué en lugar de esconderlo.]

5.6.5. Curvas ROC y precisión-sensibilidad

[ME FALTA. Las curvas del modelo seleccionado y el umbral óptimo.]

5.6.6. Importancia de variables por modelo

[ME FALTA. Coeficientes estandarizados, impureza de Gini e importancia por permutación.]

5.6.7. Matrices de confusión

[ME FALTA. Las siete matrices de confusión sobre el conjunto de prueba.]

5.6.8. Contraste de la especificación categórica

[ME FALTA. El cuadro que compara el *gradient boosting* con las covariables declaradas como categóricas frente al mismo modelo sin declararlas, descrito en la Sección 4.4.7. Cuatro columnas: AUC-PR, AUC-ROC, Brier y brecha entre entrenamiento y prueba. Sale de `clasificacion_especificacion_categorica`. NO es un octavo modelo y hay que decirlo en el texto: son dos especificaciones del séptimo.]

5.6.9. Intervalos bootstrap y modelo seleccionado

[ME FALTA. El solapamiento de intervalos y la justificación del modelo que elija.]

5.6.10. Contraste jerárquico entre el ensamble y el modelo multinivel

[ME FALTA, y es la sección que reconcilia las dos mitades de mi trabajo. Comparar la CCI y la MOR del *gradient boosting* con el departamento codificado frente a las del logístico multinivel. Reportar también la diferencia entre las estimaciones departamentales de los dos enfoques, mirando sobre todo los departamentos pequeños: ahí es donde la contracción jerárquica debe notarse más.]

5.7. Análisis de sensibilidad

5.7.1. Especificación alternativa de la variable de ordenamiento

La medición de la desigualdad socioeconómica exige ordenar a la población a lo largo de una escala. Este trabajo emplea el nivel educativo materno, pero esa elección no es la

única posible, y conviene comprobar si el resultado depende de ella. La Figura 5.13 repite el cálculo anual del índice de concentración empleando el régimen de afiliación como variable de ordenamiento y superpone ambas series.




Figura 5.13: Índice de concentración con corrección de Erreygers estimado con el nivel educativo materno y con el régimen de afiliación como variable de ordenamiento socioeconómico, por año, 1998–2024. Elaboración propia.

Qué aporta esta figura al trabajo. El objetivo específico 2 establece dos ejes de ordenamiento social (el nivel educativo materno y el régimen de afiliación) y esta figura somete a prueba si el resultado principal depende de cuál de los dos se emplee. La pregunta no es metodológica en sentido accesorio: de su respuesta depende el alcance de lo que el trabajo puede afirmar.

El criterio es explícito. Si ambas series siguieran trayectorias semejantes, la inversión del gradiente sería atribuible al fenómeno, y el trabajo podría enunciarla como un cambio en la desigualdad socioeconómica del bajo peso al nacer en Colombia. Si divergen, la inversión es atribuible en parte al instrumento con que se mide la posición social, y el enunciado debe restringirse en consecuencia. Esta figura es, por tanto, la que fija los términos en que puede formularse el hallazgo más llamativo del capítulo.

Las dos series **no coinciden**. El índice basado en el nivel educativo desciende de forma sostenida y cruza el cero entre 2018 y 2019, mientras que el basado en el régimen de

afiliación permanece positivo durante los veintisiete años, en una banda de $+0,0032$ a $+0,0089$, sin aproximarse al cero en ningún momento.

Conviene enunciar la consecuencia sin atenuarla, porque delimita el alcance del hallazgo principal: la inversión del gradiente es una propiedad del ordenamiento **educativo** y no una propiedad general de la desigualdad socioeconómica en el bajo peso al nacer. Un enunciado de la forma «la desigualdad socioeconómica se invirtió en Colombia» no se sostiene con esta evidencia; sí se sostiene uno de la forma «el gradiente educativo se invirtió, mientras el gradiente por aseguramiento se mantuvo».

Una explicación que los datos descartan. La divergencia entre los dos ordenamientos admite una explicación inmediata y plausible, que conviene examinar explícitamente porque es la primera que se le ocurre al lector. La expansión educativa del período ha reducido el tamaño del grupo sin educación formal y ha modificado su composición, de manera que la escala educativa de 2024 no ordena a la población del mismo modo que la de 1998. Si así fuera, parte de la inversión sería un artefacto del cambio en la distribución de la variable de ordenamiento y no un cambio en el riesgo relativo, y el régimen de afiliación, que no sufre esa dilución en la misma medida, no la mostraría.

La descomposición por subperíodos de la Sección 5.5.3 permite contrastar esa explicación, y el resultado la contradice. Bajo la hipótesis de dilución, la contribución propia del nivel educativo debería *debilitarse* a lo largo del período: si la escala ordena cada vez peor, su asociación con el desenlace tendría que diluirse con ella. Lo que se observa es lo contrario. Esa contribución pasa de $-0,00721$ en 1998–2009 a $-0,02992$ en 2019–2024, es decir, se multiplica por más de cuatro, y lo hace en la dirección del gradiente social clásico.

La explicación por dilución del instrumento queda, por tanto, descartada, y la divergencia entre los dos ordenamientos debe atribuirse a que miden dimensiones distintas de la posición social y no a que uno de ellos se haya degradado como instrumento de medida.

El resultado central del capítulo, que el índice de concentración educativa cambia de signo hacia el final del período, admite varias explicaciones alternativas que no son del fenómeno sino del procedimiento. Esta sección las somete a prueba una por una. El criterio de lectura es el mismo en todas: interesa menos que la magnitud del índice se mantenga que el hecho de que su *signo* y su *dirección temporal* lo hagan.

La restricción por cobertura del registro. La objeción más seria a la serie es que el volumen de nacimientos registrados desciende de forma pronunciada en el último tramo, de modo que parte de la tendencia podría ser artefacto. Restringido a los veinticuatro años

Cuadro 5.14: Análisis de sensibilidad del índice de concentración educativa. La columna de cambio expresa la variación de la corrección de Erreygers respecto del análisis base. Elaboración propia.

Escenario	<i>n</i>	Erreygers	Cambio	Signo
Análisis base, 1998–2024	16,820,098	+0,00609	—	+
Casos completos con cotas	17,376,860	+0,00462 a +0,00670	—	+
Solo 2008–2024	10,266,550	+0,00336	–44,9 %	+
Solo 1998–2007	6,553,548	+0,00370	–39,3 %	+
Cobertura estable, 24 años	15,350,918	+0,00565	–7,2 %	+
Partos institucionales	16,618,695	+0,00576	–5,5 %	+
Quintil de tamaño fijo	16,820,098	+0,00296	–51,4 %	+

en que el volumen se mantiene por encima del 85 % de su máximo, el índice se reduce en un 7,2 %, que es la menor alteración de todos los escenarios examinados. La cobertura, por tanto, no produce el resultado.

La restricción por régimen de codificación. Separar la serie en sus dos regímenes de formulario reduce el índice en un 44,9 % y un 39,3 % respectivamente, lo cual es esperable: cada tramo cubre menos años y por tanto menos recorrido de la tendencia. El signo se mantiene positivo en ambos.

La especificación alternativa del ordenamiento. Sustituir la escala educativa nominal por un quintil de tamaño fijo (definido de modo que el grupo superior sea siempre el 20 % más educado de cada año, con independencia de cómo se llame esa categoría) reduce el índice a la mitad. Es la alteración de mayor magnitud, y era previsible: al fijar el tamaño de los grupos se elimina por construcción el efecto de la expansión educativa sobre la composición de la escala. El signo, de nuevo, se conserva.

La definición de la muestra. Restringir el análisis a los partos institucionales, que son el 98,8 % del total, altera el índice en un 5,5 %.

La prueba que más importa

Ninguno de los escenarios anteriores examina lo que constituye la objeción de fondo: que la inversión sea un artefacto del cambio de formulario, esto es, que proceda de comparar poblaciones clasificadas con instrumentos distintos. La prueba pertinente consiste en calcular el índice *dentro* de cada régimen de codificación, donde el instrumento es constante

por construcción.

Cuadro 5.15: Índice de concentración estimado dentro de cada régimen de codificación del formulario. Elaboración propia.

Régimen	n	Erreygers	Signo
1998–2007	6,553,548	+0,003696	+
2008–2011 y 2014–2019	6,346,266	+0,003861	+
2012–2013	1,277,994	+0,004909	+
2020	590,026	–0,000167	–
2021–2023	1,622,155	–0,002489	–
2024	430,109	–0,006507	–

El resultado es el que sostiene la interpretación del capítulo. Los tres regímenes anteriores a 2020 arrojan índices positivos y de magnitud similar; los tres posteriores, negativos y de magnitud creciente. **El cambio de signo ocurre dentro de la serie y no en la frontera entre regímenes de codificación.** Si la inversión procediera del instrumento, el signo debería cambiar al pasar de un régimen a otro y permanecer constante dentro de cada uno; lo que se observa es lo contrario.

Síntesis

De los doce escenarios examinados, los nueve anteriores a 2020 conservan el signo positivo del índice y los tres posteriores lo invierten, en coherencia con la cronología del fenómeno y no con la de los instrumentos de medida. La magnitud sí varía apreciablemente, entre un 5 % y un 51 % respecto del análisis base, lo que aconseja tratar el valor puntual del índice con la prudencia que corresponde a una cantidad sensible a la especificación, y concentrar la interpretación en su signo y en su evolución, que es lo que ningún escenario altera.

Queda fuera de este contraste la estructura jerárquica, cuyo efecto sobre las estimaciones se examina por separado en la Sección 5.4, y la definición del desenlace, que no admite especificación alternativa porque PESO_NAC se registra en bandas de 500 gramos y no permite desplazar el umbral de los 2,500.

Capítulo 6

Conclusiones

Este capítulo recoge las conclusiones del trabajo en el orden en que se plantearon las preguntas específicas del Capítulo 2, y reserva los apartados finales para las contribuciones, las limitaciones y el alcance de lo que puede afirmarse.

Cada apartado sigue la misma estructura: qué se encontró, qué significa y qué no permite concluir. El tercer movimiento no es una concesión retórica. En un trabajo que emplea registros administrativos para medir desigualdad, la distancia entre lo observado y lo que puede afirmarse es en sí misma un resultado, y delimitarla forma parte de la respuesta.

6.1. Magnitud y evolución del bajo peso al nacer

La prevalencia de bajo peso al nacer en Colombia entre 1998 y 2024, estimada sobre los 17,376,860 nacimientos de la muestra analítica, es del 8,78 % (IC 95 %: 8,77–8,79). La serie asciende del 7,64 % en 1998 al 11,15 % en 2024, con un cambio porcentual anual del +1,18 % (IC 95 %: +0,98 a +1,38).

Ese ascenso no es uniforme. La regresión segmentada identifica tres puntos de unión (en 2010, 2014 y 2020) que delimitan cuatro tramos de comportamiento distinto: un ascenso sostenido del +1,72 % anual hasta 2010, un descenso del $-0,92$ % entre 2010 y 2014, una recuperación del +1,06 % hasta 2020 y una aceleración final del +4,97 % anual, más de cuatro veces el promedio del período.

Dos precisiones acompañan necesariamente a estas cifras, y conviene enunciarlas aquí y no diferirlas al apartado de limitaciones.

La primera es que la posición de los puntos de unión es menos firme que su existencia. El número de cortes se reproduce en el 86,6 % de las réplicas del procedimiento de remuestreo,

pero cada año concreto se selecciona entre el 53 % y el 68 % de las veces, y los años contiguos recogen buena parte del resto. La conclusión defendible es que la serie presenta tres cambios de tendencia y en qué entorno se sitúan, con una incertidumbre del orden de un año.

La segunda es que el tramo de mayor crecimiento coincide con el de mayor deterioro del registro. El volumen anual de nacimientos notificados desciende de 649,493 en 2017 a 439,899 en 2024, y correlaciona negativamente con la prevalencia estimada. El análisis restringido a los años de cobertura estable modifica el índice de desigualdad en apenas un 7,2 %, de modo que la conclusión sobre la desigualdad no depende de la cobertura; pero la magnitud de la aceleración final sí queda afectada por ella.

Por esa razón, el trabajo concluye sobre la evolución de la prevalencia *registrada* y no sobre la incidencia poblacional. La distinción no es una cautela formal: separar ambas exigiría una fuente externa de denominadores de la que este trabajo no dispone.

6.2. Magnitud de la desigualdad socioeconómica

Existe desigualdad socioeconómica medible en el bajo peso al nacer, y su dirección no es la que la teoría de los determinantes sociales anticipa.

El índice de concentración según el nivel educativo materno es de +0,0174 para el período, con corrección de Erreygers de +0,0061; el índice de desigualdad de la pendiente, de +1,17 puntos porcentuales, y el índice relativo, de 1,143. Ninguno de los intervalos bootstrap contiene el cero, y las cotas calculadas sin supuesto alguno sobre el mecanismo de ausencia sitúan el índice entre +0,0132 y +0,0191, ambos positivos.

El signo positivo indica que el desenlace se concentra hacia el extremo *más* favorecido de la escala educativa. Este resultado no procede de la especificación de ningún modelo: está contenido en la descripción. La prevalencia por nivel educativo materno es del 9,40 % entre las madres sin educación formal, del 8,16 % en primaria, del 8,80 % en secundaria y del 9,20 % en educación superior. La relación no es monótona descendente, y el valor mínimo no corresponde al extremo superior de la escala sino a su segundo nivel.

Con el régimen de afiliación como variable de ordenamiento el patrón es monótono y también ascendente: 8,36 % entre las no aseguradas, 8,52 % en el régimen subsidiado y 9,27 % en el contributivo.

La interpretación de estos índices tiene un límite que conviene fijar. Miden concentración ordenada del desenlace a lo largo de una escala socioeconómica, no efecto causal de la

posición social sobre el riesgo. Que el bajo peso al nacer se concentre hacia el extremo más educado no autoriza a concluir que la educación proteja o perjudique, sino que la distribución del desenlace y la de la educación están ordenadamente asociadas en ese sentido.

6.3. Efectos independientes de los determinantes sociales

El gradiente social existe, y solo resulta visible bajo la especificación adecuada.

El Modelo 2, ajustado por edad materna, paridad y multiplicidad del embarazo, estima razones de momios de 0,854, 0,834 y 0,808 para primaria, secundaria y educación superior frente a la ausencia de educación formal; de 1,257 para la soltería materna frente al matrimonio; y de 1,097 para la residencia rural dispersa frente a la cabecera municipal.

El hallazgo de este apartado no reside en esos valores sino en el sentido en que cambian respecto del modelo sin ajustar. En el Modelo 1 el gradiente educativo es plano y no monótono (0,857, 0,858 y 0,874), de manera que la categoría superior aparenta mayor riesgo que la secundaria. Al incorporar las tres covariables obstétricas el gradiente se *ordena*, y lo hace intensificándose precisamente en el extremo que resultaba anómalo, con una variación del $-7,52\%$ en la categoría superior frente al $-0,28\%$ en primaria. Los criterios de información concuerdan: sobre la misma submuestra, el ajuste obstétrico reduce el AIC en 514,700 unidades.

El ajuste por un mediador atenúa el efecto estimado de la exposición. Lo observado es lo contrario, y ese comportamiento corresponde a variables que operan como confusores o como covariables de precisión. La decisión metodológica de incorporarlas al Modelo 2 y de reservar la atención prenatal para el Modelo 4 queda así respaldada por el comportamiento de los datos y no únicamente por el argumento teórico que la motivó.

Conviene sin embargo no confundir respaldo con demostración. Que un ajuste ordene un gradiente es compatible con que las covariables sean confusores, pero también con fenómenos de supresión o con condicionamiento en un colisionador. El argumento que sostiene la especificación sigue siendo el expuesto en la Sección 4.4.4 (la multiplicidad del embarazo no depende de la posición social, con un V de Cramér de 0,0106 frente al nivel educativo), y el resultado empírico lo refuerza sin sustituirlo.

6.4. Reparto de la desigualdad entre determinantes

La descomposición del índice de concentración muestra que efecto y desigualdad son cantidades distintas, y el trabajo lo establece con un caso límite.

El mayor contribuyente a la desigualdad educativa no es la educación sino la **paridad**, con +0,01529, equivalente al 84,1 % del índice; le siguen el régimen de afiliación, con +0,00696, y el área de residencia, con +0,00410. La contribución del propio nivel educativo es de -0,00343, es decir, de signo contrario al del índice total.

El caso que mejor ilustra la distinción es la multiplicidad del embarazo. Su razón de momios es de 19,96 en los partos dobles (el efecto de mayor magnitud estimado en todo el trabajo) y su contribución a la desigualdad es del 4,9 %. La explicación está en el segundo factor del producto: el índice de concentración de la exposición es de 0,0073, prácticamente nulo. La multiplicidad se distribuye de manera casi idéntica a lo largo del gradiente educativo.

De ahí se sigue una conclusión con consecuencias directas para la acción pública: un factor de riesgo que no está socialmente distribuido genera morbilidad, pero no genera desigualdad. Reducir el bajo peso al nacer y reducir la desigualdad en bajo peso al nacer son objetivos distintos, y una política que priorice las intervenciones por la magnitud del riesgo que atacan no reducirá necesariamente la brecha. La paridad ilustra el caso inverso: sin ser el factor de riesgo de mayor magnitud, es el mayor contribuyente a la desigualdad, porque su distribución social sí es marcadamente desigual.

La descomposición es un procedimiento contable. Reparte una cantidad observada según asociaciones estimadas, y no autoriza a concluir que la paridad *cause* el 84,1 % de la desigualdad observada.

6.5. La dimensión territorial

El territorio explica una fracción modesta de la variación del riesgo, y establecerlo con precisión es en sí mismo un resultado del trabajo.

El coeficiente de correlación intraclase municipal es del 1,79 % y el departamental del 0,86 %. La razón de momios mediana entre municipios es de 1,184 en el modelo vacío y de 1,197 en el Modelo 2. Esta última cantidad admite comparación directa con las razones de momios de los determinantes individuales, puesto que procede de la misma especificación y se expresa en la misma escala.

La comparación arroja que un único atributo individual (la soltería materna, con una

razón de momios de 1,257) se asocia con un cambio del momio superior al que corresponde a la mediana de la heterogeneidad existente entre los 1,157 municipios del país. Ello proporciona una respuesta cuantitativa a la pregunta de qué aporta la especificación multinivel: no un determinante de mayor magnitud que los individuales, sino la posibilidad de situar la magnitud del territorio en la misma escala que ellos y comprobar que es menor.

Dos límites acotan esta conclusión. El primero es que la razón de momios mediana es una mediana sobre pares de municipios, de modo que existen contrastes territoriales que la superan holgadamente: el resultado no implica que ningún municipio importe, sino que el municipio típico pesa menos que ese atributo individual. El segundo es que, al no incorporarse covariables municipales de privación, el trabajo establece *cuánta* variación es territorial pero no *a qué* se debe.

6.6. La dimensión étnica

La pertenencia étnica de la madre no aporta información sobre el riesgo de bajo peso al nacer por encima del municipio de residencia. Cuatro procedimientos independientes conducen a esa misma conclusión.

Las razones de momios del Modelo 3 se sitúan entre 0,833 y 1,059, y las dos que más se apartan de la unidad corresponden a las categorías de menor tamaño muestral. Añadir la variable desplaza los coeficientes del gradiente educativo en un 0,16 % o menos, y ningún otro término del modelo se mueve más de un 0,04 %. El cambio proporcional en la varianza municipal es del $-0,03$ %. Y los criterios de información empeoran: sobre la misma submuestra, el AIC aumenta en 1,7 unidades y el BIC en 72,3. A ello se suma que, en el cribado por información mutua de la Fase 2, fue la única de quince variables candidatas que no superó su propia distribución nula.

La lectura de este resultado admite dos versiones y solo una es sostenible. Lo que los datos permiten afirmar es que la pertenencia étnica no añade capacidad explicativa una vez tenido en cuenta el lugar de residencia. Lo que no permiten afirmar es que no existan desigualdades étnicas en el bajo peso al nacer.

La razón de esa distinción es de diseño y no de resultado. La pertenencia étnica y el municipio presentan un V de Cramér de 0,473, de manera que los interceptos municipales absorben la mayor parte del contraste étnico antes de que el coeficiente fijo pueda recogerlo. Con esta fuente no es posible separar el hecho de pertenecer a un pueblo indígena del hecho de residir donde reside la población indígena. El coeficiente estimado debe leerse, en consecuencia, como una cota inferior del efecto étnico.

Enunciado en positivo, el resultado es que **la desigualdad que suele atribuirse a la pertenencia étnica es, con estos datos, desigualdad de lugar**. Es una conclusión sustantiva, y no la ausencia de una.

6.7. Capacidad predictiva

[ME FALTA ESTE APARTADO, y espera a que corra la Fase 7. Lo que tengo que reportar: el AUC-PR del mejor modelo frente a la línea base de 0,0878 que es la prevalencia; si los ensambles superan o no a la regresión logística; qué aporta el bloque social por encima del clínico; y la caída del desempeño en la partición temporal y en la partición por municipio. NO OLVIDAR declarar que de esta fase no se sigue nada causal.]

6.8. Contribuciones del trabajo

Tres aportes se desprenden de lo anterior. Los tres son al método y a la explotación de la fuente, y conviene enunciarlos con la precisión que permita defenderlos palabra por palabra.

La inversión del gradiente educativo, con su mecanismo. El índice de concentración educativa cambia de signo entre 2018 y 2019, pasando de +0,00123 en 1998 a −0,00651 en 2024. Ningún trabajo previo sobre bajo peso al nacer en Colombia había documentado ese cambio.

La descomposición por subperíodos establece además el mecanismo. La contribución propia del nivel educativo se cuadruplica en la dirección del gradiente social clásico (de −0,0072 a −0,0299) mientras el contrapeso que ejerce la paridad se debilita (de +0,0166 a +0,0110). Una fuerza se intensifica mientras la que la compensaba pierde magnitud, y el índice total cruza el cero.

La objeción natural a este hallazgo es que proceda del instrumento y no del fenómeno, dado que el certificado de nacido vivo cambió de formulario durante el período. El análisis de sensibilidad la descarta: estimado *dentro* de cada régimen de codificación, el índice resulta positivo en los tres regímenes anteriores a 2020 y negativo en los tres posteriores. El cambio de signo ocurre dentro de la serie y no en la frontera entre instrumentos, que es lo contrario de lo que se observaría si fuese un artefacto de la medición.

El enunciado que estos resultados sostienen es restringido, y conviene formularlo así: el

gradiente *educativo* se invirtió, mientras el gradiente por régimen de afiliación se mantuvo positivo a lo largo de los veintisiete años, entre +0,0032 y +0,0089. Lo que se invierte es el ordenamiento por educación, no la desigualdad socioeconómica considerada en su conjunto.

La documentación de la ruptura de codificación de 2008. El código 9 de la variable de nivel educativo materno significa «sin información» hasta 2007 y «profesional» desde 2008, y el código 8 pasa de «ninguno» a «tecnológica»: los dos extremos de la escala quedan intercambiados. La variable de estado conyugal experimenta una reenumeración completa, cuyo efecto se aprecia en que el código 1 representa el 15,1 % de los registros en 2005 y el 50,8 % en 2019 sin que nada cambiara en la población.

La consecuencia práctica es lo que convierte esta observación en contribución. Una regla de limpieza uniforme (tratar el código 9 como dato faltante, que es la convención habitual y lo que hace por defecto cualquier rutina de lectura) eliminaría del análisis a todas las madres con formación universitaria completa desde 2008, es decir, al extremo superior del gradiente educativo, que es el objeto mismo de la investigación. Cualquier trabajo que compare la serie de las Estadísticas Vitales a uno y otro lado de 2008 sin armonizar está produciendo resultados sin sentido interpretable.

Una implementación multinivel viable a escala nacional. El método empleado no es original: es un modelo logístico de interceptos aleatorios estimado por máxima verosimilitud con aproximación de Laplace. Lo que no existía era una implementación en Python capaz de operar con 1,157 conglomerados, dado que la alternativa disponible deja de converger a partir de unos quinientos. La validación por simulación, recogida en el Apéndice B, estima un sesgo de +0,00036 en el coeficiente y de +0,00020 en la desviación típica municipal, con una correlación de 0,975 entre los efectos estimados y los verdaderos.

6.9. Limitaciones del estudio

Nueve limitaciones deben declararse de forma explícita.

Discontinuidad instrumental de la serie. El certificado de nacido vivo se actualizó hacia 2008, de modo que la pertenencia étnica y el régimen de afiliación no están disponibles antes de esa fecha. El análisis de esos dos ejes se restringe a 2008–2024, mientras que la serie completa se reserva para los ejes presentes en todo el período.

Ausencia de medidas directas de posición socioeconómica. El certificado no capta estrato, ingreso del hogar ni ocupación materna. La posición social se aproxima mediante el nivel educativo y el régimen de afiliación, que son indicadores parciales del constructo descrito en la Sección 3.1.

Subregistro de nacimientos. El registro es plausiblemente menos completo en zonas rurales dispersas y en territorios de baja densidad institucional. Si el subregistro se concentra en la población más desfavorecida, la desigualdad estimada constituye una cota inferior de la real.

Esta limitación admite ahora una cuantificación parcial. La ausencia del dato de peso al nacer alcanza el 2,94 % entre las mujeres no aseguradas frente al 0,21 % entre las afiliadas al régimen contributivo (una razón de 13,8) y esa brecha se amplía a lo largo del período, de 7,4 veces en 1998–2007 a 32,0 en 2019–2024. La ausencia es, por tanto, diferencial por posición socioeconómica, y opera en el sentido de atenuar el efecto social estimado.

Variación territorial sin covariables contextuales observadas. La heterogeneidad entre municipios se modela mediante interceptos aleatorios y no mediante indicadores agregados de privación material, por las razones de comparabilidad temporal expuestas en la Sección 4.3. El trabajo establece, en consecuencia, *cuánta* variación es territorial y si persiste tras ajustar por la composición individual, pero no *a qué* se debe: no permite distinguir si un municipio de mayor riesgo lo es por privación material, por menor oferta de servicios o por su composición demográfica. Atribuir la variación territorial a una de esas causas exigiría datos municipales anuales de los que no se dispone.

Precisión desigual de las dos componentes de varianza. La varianza departamental se estima sobre 33 unidades frente a las 1.157 del nivel municipal. Las simulaciones del Apéndice B muestran que su sesgo es aproximadamente veinte veces mayor. Las conclusiones relativas a la variación municipal descansan por ello sobre una estimación sustancialmente más firme que las referidas a la variación departamental, y así deben leerse.

Imposibilidad de separar los dos mecanismos del bajo peso al nacer. El peso inferior a 2.500 gramos procede de dos vías distintas, la restricción del crecimiento intrauterino y el nacimiento pretérmino, y la literatura sostiene que los determinantes sociales no pesan igual sobre una y otra. Distinguir las exige clasificar cada nacimiento según haya ocurrido antes o después de las 37 semanas, y el certificado consigna el tiempo de gestación

en cinco bandas de las cuales una, la de *28 a 37 semanas*, contiene precisamente ese corte. El único límite disponible es el de las 38 semanas, que no corresponde a la definición y agruparía como pretérmino a los nacimientos de la semana 37. El trabajo se refiere en consecuencia al bajo peso al nacer como desenlace único, sin pronunciarse sobre por cuál de las dos vías se produce, y las conclusiones sobre mecanismo del Capítulo 3 quedan como marco interpretativo y no como resultado propio.

Ausencia de variables clínicas del embarazo. No se registran el estado nutricional materno, la anemia, la enfermedad hipertensiva ni las infecciones, lo que impide verificar directamente los mecanismos biológicos discutidos en la Sección 3.2.

Conviene precisar la **dirección** en que esa ausencia afecta a los resultados, en lugar de dejarla enunciada en términos generales. Las cuatro condiciones se distribuyen de forma desfavorable para la población de menor posición socioeconómica: peor estado nutricional, mayor exposición a riesgos laborales y menor probabilidad de control efectivo de la hipertensión. Si ese patrón se cumple, las variables omitidas actúan en el mismo sentido que los determinantes sociales estimados, de modo que su ausencia **atenúa** el efecto social observado en lugar de inflarlo.

Los coeficientes reportados constituyen, por tanto, una **cota inferior** del efecto real. El sesgo por variable omitida juega en contra de la hipótesis del trabajo y no a su favor, lo que refuerza las conclusiones en lugar de debilitarlas.

Imposibilidad de agrupar por madre. Los certificados de nacido vivo no incluyen un identificador materno único, de modo que no fue posible identificar partos sucesivos de una misma mujer ni aplicar estrategias de partición agrupada en el componente predictivo. En consecuencia, registros correspondientes a una misma madre pueden haber quedado distribuidos entre los conjuntos de entrenamiento y prueba, lo que podría implicar una leve sobreestimación del desempeño predictivo reportado en la Sección 4.4.7. La limitación no es resoluble con los datos disponibles y afecta únicamente al componente predictivo, no a las estimaciones de efecto ni a los índices de desigualdad.

Diseño observacional y transversal. La naturaleza de los datos impide establecer relaciones causales. Las asociaciones estimadas se interpretan bajo los supuestos declarados en la Sección 3.10, que no son verificables con la información disponible.

6.10. Alcance de las conclusiones

Conviene cerrar delimitando lo que este trabajo no establece, porque es lo que separa sus conclusiones de las que una lectura apresurada podría extraer de ellas.

No establece relaciones causales. Los índices de concentración miden asociación ordenada; la descomposición reparte una cantidad observada; y los modelos multinivel estiman asociaciones ajustadas sobre datos observacionales.

No establece que el patrón territorial observado en la cartografía sea riesgo. En 2024, 766 de los 930 municipios con nacimientos notificados registran menos de cien, y las prevalencias municipales recorren todo el rango entre el 0 y el 100 %. Los modelos corrigen esa inestabilidad por contracción; los mapas, no.

No establece que los efectos estimados sean constantes a lo largo del período. Los coeficientes de los modelos multinivel son promedios de veintisiete años, y la propia descomposición por subperíodos muestra que algunas contribuciones se multiplican por cuatro dentro de ese lapso.

Y no establece nada sobre los nacimientos que nunca llegaron a registrarse. Ninguna fuente construida a partir del registro puede hacerlo.

Capítulo 7

Recomendaciones

Las recomendaciones que siguen se organizan por destinatario, y cada una se enuncia junto al resultado del que se deriva. Ese encadenamiento no es un recurso expositivo: una recomendación que no pueda rastrearse hasta un hallazgo concreto es una opinión, y este trabajo no las formula.

7.1. Recomendaciones metodológicas para los sistemas de información

Las recomendaciones dirigidas al productor del dato son las que se desprenden de manera más directa de los hallazgos, porque varios de ellos son hallazgos sobre la fuente misma.

Publicar una tabla oficial de equivalencias entre regímenes de codificación. Se deriva de la ruptura documentada en 2008, que afecta al menos a cuatro variables del certificado de nacido vivo y que no está recogida en los diccionarios publicados. Una tabla de equivalencias evitaría que cada equipo de investigación la reconstruya por su cuenta (con el riesgo de reconstruirla de manera distinta) y haría comparables entre sí los trabajos que emplean la serie completa.

Registrar el peso al nacer en gramos y no en bandas de quinientos. Se deriva de una limitación del análisis de sensibilidad de este trabajo: la definición del desenlace no admite especificación alternativa, porque la variable disponible no permite desplazar el umbral de los 2,500 gramos. La agregación en bandas impide además estimar la distri-

bución del peso dentro de la categoría de bajo peso, que es donde se concentra el riesgo perinatal.

Auditar la completitud diferencial del peso al nacer por régimen de afiliación.

Es la recomendación con más consecuencias de este capítulo. La ausencia del dato de peso alcanza el 2,94 % entre las mujeres no aseguradas frente al 0,21 % entre las afiliadas al régimen contributivo (una razón de 13,8) y la brecha se amplía a lo largo del período, de 7,4 veces en 1998–2007 a 32,0 en 2019–2024. La ampliación no procede de un deterioro del grupo peor registrado sino de que el mejor registrado se aproxima a la completitud total.

Una ausencia diferencial de esa magnitud compromete la comparabilidad de cualquier estudio de equidad que emplee la fuente, y opera además en una dirección determinada: excluye preferentemente a la población menos favorecida y atenúa por tanto la desigualdad estimada.

Documentar en los metadatos la naturaleza de la ausencia. La pertenencia étnica presenta un 40,1 % de valores nulos de los cuales ninguno corresponde a no respuesta: son ausencia estructural, porque el instrumento no recogía la pregunta antes de 2008. Distinguir ambos tipos de ausencia en los metadatos evitaría que las rutinas automáticas de tratamiento de datos faltantes los procesen de idéntica manera, lo que en este caso equivaldría a imputar información que nunca se recogió.

7.2. Recomendaciones para autoridades sanitarias e instituciones

Distinguir las intervenciones que reducen el bajo peso al nacer de las que reducen su desigualdad. Se deriva del contraste entre la multiplicidad del embarazo (razón de momios de 19,96 y contribución del 4,9 % a la desigualdad) y la paridad (mayor contribuyente con el 84,1 % sin ser el factor de riesgo de mayor magnitud). Una priorización que ordene las intervenciones por el tamaño del riesgo que atacan puede reducir la prevalencia sin reducir la brecha, y una que las ordene por su contribución a la desigualdad puede reducir la brecha sin reducir apreciablemente la prevalencia. Son objetivos distintos y conviene que los instrumentos de política los traten como tales.

Considerar que el tamizaje por atributos individuales tiene más recorrido que la focalización territorial. Se deriva de que la razón de momios de la soltería materna

(1,257) supera a la razón de momios mediana entre municipios (1,197). La recomendación no sostiene que no existan municipios con riesgo muy superior al promedio (los hay), sino que una estrategia basada exclusivamente en la selección de territorios rinde menos que una que incorpore atributos de la gestante.

Tratar la inversión del gradiente educativo como un fenómeno que exige explicación. Que el bajo peso al nacer haya pasado a concentrarse en los hijos de las madres menos educadas reproduce el patrón clásico de la desigualdad en salud, pero su aparición reciente en Colombia sugiere un cambio en las condiciones de las poblaciones desfavorecidas que esta fuente no puede identificar. Se recomienda no leer el cambio de signo como una normalización sino como una señal que requiere investigación específica.

7.3. Líneas de investigación futura

Las líneas que siguen se derivan de las limitaciones declaradas en la Sección 6.9, y cada una está formulada para resolver una de ellas.

Incorporar covariables municipales de privación. Permitiría establecer a qué se debe la variación territorial que este trabajo cuantifica pero no explica. La restricción que lo impidió aquí es de comparabilidad temporal: los indicadores disponibles (índice de pobreza multidimensional y necesidades básicas insatisfechas) existen únicamente para años censales, lo que no permite construir una serie de veintisiete años.

Medir el acceso a la atención prenatal con la edad gestacional del primer control. Resolvería la limitación que impide interpretar causalmente la atenuación observada en el Modelo 4. El número de controles depende mecánicamente de la duración de la gestación, de modo que condicionar por él equivale en parte a condicionar por una consecuencia del propio desenlace. La edad gestacional del primer control no presenta esa dependencia.

Examinar el gradiente de severidad y no solo el umbral. Las ocho bandas de PESO_NAC admiten un tratamiento ordinal que este trabajo no desarrolla. Un modelo de momios proporcionales sobre esas bandas respondería a una pregunta que el umbral único no alcanza: si la desigualdad socioeconómica se concentra en el bajo peso moderado o si se intensifica hacia el muy bajo peso, que es donde está el riesgo de mortalidad neonatal.

La inversión del gradiente educativo documentada aquí hace la pregunta especialmente pertinente, porque un cambio de signo en la ocurrencia no implica un cambio de signo en la intensidad.

Enlazar el registro de nacimientos con el de mortalidad infantil. Permitiría estimar las consecuencias del bajo peso al nacer y no solo su distribución, que es el límite de lo que una fuente de nacimientos puede ofrecer.

Diseñar una estrategia que separe pertenencia étnica de territorio. Un muestreo estratificado, o una comparación restringida a municipios de composición étnica mixta, permitiría estimar el componente que esta fuente no puede aislar.

Incorporar la estructura territorial a la fase predictiva. Los modelos de clasificación de este trabajo emplean únicamente información individual, mientras que el componente explicativo dedica un capítulo a la variación territorial. Los métodos que combinan potenciación con efectos aleatorios permitirían mantener esa estructura sin introducir el municipio como variable de más de mil categorías.

Separar el efecto de la pandemia del deterioro del registro. El tramo 2020–2024 crece al +4,97 % anual y coincide con dos fenómenos simultáneos cuyos efectos esta fuente no distingue. Hacerlo exigiría denominadores externos (proyecciones de población o registros de afiliación) que permitan estimar la cobertura del registro con independencia de él mismo.

Apéndice A

Código fuente y reproducibilidad

Todo el procesamiento y el análisis de este trabajo se desarrollaron en Python 3.9 sobre un entorno virtual aislado. Con el fin de garantizar la reproducibilidad íntegra de los resultados, el código no se reproduce en este documento sino que se publica en un repositorio de acceso abierto.

A.1. Repositorio

Repositorio del proyecto

<https://github.com/GREGORYMELENDEZ/TESIS-GRADO-UNINORTE->
Repositorio de acceso público.

El repositorio se publica bajo licencia abierta y queda archivado con un identificador persistente en el momento de la entrega, de modo que la versión consultada corresponda exactamente a la empleada para producir los resultados reportados en el Capítulo 5.

A.2. Contenido del repositorio

datos/ Instrucciones de descarga de los microdatos desde el portal del DANE. Los archivos originales no se incluyen por su tamaño; el repositorio documenta el catálogo y la versión de cada uno. Incluye `crosswalk.yaml`, la tabla de

correspondencias versionada descrita en la Sección 4.3.1, con los 44 conceptos del esquema canónico y el estado de cada uno en cada versión del instrumento.

scripts/	Rutinas de lectura, armonización de la serie 1998–2024, depuración, recodificación de valores de no informado y construcción de las variables analíticas.
analisis/	Cálculo del índice de concentración y su descomposición, ajuste de los modelos multinivel, entrenamiento y evaluación de los siete modelos de clasificación, y procedimientos de remuestreo.
figuras/	Código de generación de todas las figuras y mapas del documento.
mapas/	Atlas interactivo en formato HTML y sus tres vistas por separado, descritos en la Sección A.3.
salidas/	Cuadros y resultados en formato reproducible.
requirements.txt	Versiones exactas de todas las bibliotecas empleadas.
README.md	Instrucciones de instalación y orden de ejecución de los scripts.

A.3. Atlas interactivo del bajo peso al nacer

Los mapas de las Figuras 5.4 y 5.5 reproducen dos años de la serie, que es cuanto admite un documento impreso. El trabajo publica además un **atlas interactivo** que recorre los veintisiete años y permite consultar el valor de cada unidad territorial. Se abre directamente en el navegador, sin descarga ni instalación:

gregorymelendez.github.io/TESIS-GRADO-UNINORTE-

El atlas reúne tres vistas en una sola página:

Mapa municipal

Coropletas por municipio de residencia, con control deslizante de año. Al situar el cursor sobre un municipio se muestran su nombre, el número de nacimientos registrados y la prevalencia.

Mapa departamental

Equivalente en el nivel departamental, que es el segundo nivel de agrupamiento de los modelos multinivel.

Ordenamiento departamental

Departamentos ordenados por prevalencia año a año, lo que permite seguir los cambios de posición a lo largo del período.



Acceso directo

El atlas incorpora la advertencia que los mapas impresos no pueden llevar: la prevalencia de los municipios con pocos nacimientos anuales es inestable, de modo que los valores extremos pueden reflejar el tamaño de la muestra y no el riesgo. Los modelos multinivel del Capítulo 5 corrigen ese efecto por contracción; un mapa de coropletas no lo hace.

El archivo es autocontenido y funciona también sin conexión una vez descargado desde el repositorio, donde se encuentra en `salidas/mapas/`. Se incluye como material complementario y no como parte del cuerpo del documento: **ningún resultado defendido en el Capítulo 5 depende de su consulta.**

[ANTES DE ENTREGAR, imprescindible: publicar el atlas y comprobar que la dirección abre. Un QR impreso que no lleva a ninguna parte es peor que no poner QR. Pasos: (1) subo `atlas_bpn.html` a la raíz del repositorio con el nombre `index.html`; (2) en el repositorio, *Settings* → *Pages* → *Source: Deploy from a branch*, rama `main`, carpeta `/ (root)`; (3) espero unos minutos y abro la dirección. El QR ya apunta a esa raíz, así que no tengo que regenerarlo. Si prefiero no activar Pages, la alternativa es Zenodo, que da un DOI permanente, pero entonces cambio la dirección y el QR.]

A.4. Condiciones de reproducibilidad

La semilla aleatoria se fija en todos los procedimientos que involucran aleatoriedad: la partición estratificada, la validación cruzada, el remuestreo bootstrap y el entrenamiento de los modelos de ensamble y de la red neuronal. El archivo `requirements.txt` registra las versiones de cada biblioteca, dado que los resultados de algunos algoritmos pueden variar entre versiones. Con esos dos elementos, la ejecución del repositorio sobre los mismos archivos de entrada reproduce los resultados reportados.

Apéndice B

Validación del estimador multinivel

Los modelos de la Sección 4.4.4 se estimaron con una implementación propia del modelo logístico de interceptos aleatorios, incluida en el módulo `src/multinivel.py` del repositorio. Este apéndice justifica esa decisión y documenta la validación del procedimiento.

Conviene precisar el alcance de lo que se afirma. **El método no es original**: se trata de un modelo lineal generalizado mixto de interceptos aleatorios estimado por máxima verosimilitud con aproximación de Laplace, que es el procedimiento que la implementación de referencia `lme4` aplica por defecto (Breslow and Clayton, 1993). Lo que no existía era una implementación en Python capaz de operar con 1.157 conglomerados de segundo nivel sobre diecisiete millones de registros. La contribución es, por tanto, de implementación y no de método.

Todas las comprobaciones que siguen se realizaron sobre datos *simulados* con parámetros conocidos. Esa elección no es accesorio: con datos reales resulta imposible medir el sesgo de un estimador, porque el valor verdadero de los parámetros es justamente lo que se desconoce. El cuaderno `A1_validacion_estimador.ipynb` reproduce íntegramente este apéndice y puede ejecutarse sin acceso a los microdatos del DANE.

B.1. Limitaciones de las implementaciones disponibles

La única implementación de modelos mixtos generalizados disponible en `statsmodels` para desenlaces binarios, `BinomialBayesMixedGLM`, requiere una matriz de diseño explícita para los efectos aleatorios, con una columna por conglomerado. La restricción no proviene del algoritmo sino de la interfaz, que obliga a materializar esa matriz en memoria.

El Cuadro B.1 recoge el comportamiento de esa implementación al aumentar el número de conglomerados, bajo las condiciones *más favorables* posibles: dos niveles en lugar de tres y observaciones individuales sin agregar.

Cuadro B.1: Escalamiento de `BinomialBayesMixedGLM` con el número de conglomerados. Elaboración propia a partir de datos simulados.

Conglomerados	Observaciones	Matriz de efectos	Memoria	Resultado
50	10.000	$10,000 \times 50$	4 MB	converge
200	40.000	$40,000 \times 200$	61 MB	converge
500	100.000	$100,000 \times 500$	381 MB	no converge

Dos observaciones. La primera es que el procedimiento deja de converger a partir de quinientos conglomerados, cuando el análisis de este trabajo requiere **1.157**. Un resultado que no converge resulta más problemático que un fallo explícito, puesto que devuelve estimaciones de apariencia razonable sin haber alcanzado el óptimo. La segunda es que el escalamiento es aproximadamente cuadrático: entre cincuenta y quinientos conglomerados el tiempo de cómputo se multiplica por cincuenta.

Extrapolando al tamaño real del análisis, la matriz que la interfaz exigiría materializar alcanzaría **1,2 GB** en el Modelo 1 y **5,8 GB** en el Modelo 2, sin considerar las copias que el optimizador genera en cada iteración.

Las alternativas consolidadas para este tipo de modelos (`lme4` en R, GLLAMM en Stata) habrían exigido incorporar un segundo lenguaje al flujo de trabajo, comprometiendo la reproducibilidad de un entorno único que el Apéndice A documenta.

B.2. Estrategia de estimación

La implementación descansa en tres elementos. Los dos primeros no introducen error alguno; el tercero es una aproximación y se verifica en la Sección B.5.

Agregación binomial

Dado que la totalidad de las covariables del modelo son categóricas, un número elevado de nacimientos comparte exactamente el mismo perfil de covariables dentro de un mismo municipio. Los registros individuales se agregan por tanto en celdas binomiales definidas por las combinaciones distintas de agrupamiento y covariables.

La operación **no constituye una aproximación**. La verosimilitud binomial de una celda equivale a la suma de las verosimilitudes de Bernoulli de los individuos que la componen, salvo el coeficiente combinatorio, que es una constante independiente de los parámetros. La función objetivo que se maximiza es, en consecuencia, la misma.

Aproximación de Laplace

La integral sobre los efectos aleatorios carece de solución cerrada. Se aproxima mediante una distribución gaussiana centrada en el modo del integrando, procedimiento estándar en este tipo de modelos (Breslow and Clayton, 1993). Su exactitud depende de la cantidad de información que aporta cada conglomerado, razón por la cual se verifica empíricamente en la Sección B.5 en lugar de asumirse.

Resolución del Hessiano en forma cerrada

Puesto que cada municipio pertenece a exactamente un departamento (anidamiento estricto), la matriz de segundas derivadas respecto de los efectos aleatorios adopta una estructura de flecha:

$$H = \begin{pmatrix} A & B \\ B^\top & D \end{pmatrix} \quad (\text{B.1})$$

En la Ecuación (B.1), A es diagonal en los departamentos, D es diagonal en los municipios y B presenta un único elemento no nulo por columna, dado que ningún municipio aparece en más de un departamento. Bajo esa estructura, el complemento de Schur $A - BD^{-1}B^\top$ resulta asimismo diagonal, de modo que cada paso de Newton se resuelve mediante divisiones escalares y el determinante se obtiene como producto de escalares.

Sin esa propiedad sería necesario factorizar una matriz de $1,190 \times 1,190$ en cada iteración del método de Newton, dentro de cada evaluación de la verosimilitud, dentro de cada iteración del optimizador.

B.3. Verificación de la agregación binomial

Para comprobar empíricamente que la agregación no altera las estimaciones, se ajustó el mismo modelo dos veces sobre datos simulados: una sobre 120.000 observaciones individuales y otra sobre las 900 celdas binomiales equivalentes, con una reducción de 133 a

1.

Cuadro B.2: Coeficientes estimados sobre datos individuales y sobre celdas binomiales. Elaboración propia a partir de datos simulados.

Término	Individual	Agregado	Diferencia
Intercepto	-2,2968126	-2,2968134	$-8,1 \times 10^{-7}$
$x = 1$	0,2591545	0,2591545	$2,5 \times 10^{-8}$
$x = 2$	-0,1917823	-0,1917821	$2,6 \times 10^{-7}$
σ_{mun}	0,3877194	0,3877186	$-8,0 \times 10^{-7}$

Las diferencias son del orden de 10^{-7} , atribuibles a la tolerancia del optimizador y no a discrepancia sustantiva. La agregación reproduce, por tanto, la misma función de verosimilitud.

B.4. Validación mediante simulación

Se generaron cinco réplicas con la misma estructura del análisis (33 departamentos y 1.157 municipios) y componentes de varianza conocidas, y se compararon las estimaciones con los valores que generaron cada conjunto de datos.

La comparación se establece contra la desviación típica *realizada* en cada réplica y no contra el parámetro poblacional. Es la referencia correcta: un estimador insesgado debe recuperar la variabilidad presente en la muestra analizada, que en una réplica concreta no coincide exactamente con el parámetro que la generó.

Cuadro B.3: Sesgo medio del estimador sobre cinco réplicas simuladas. Elaboración propia a partir de datos simulados.

Parámetro	Valor realizado	Media estimada	Sesgo
β_0	-2,3500	-2,3689	-0,0189
β_1	0,2500	0,2504	+0,00036
σ_{mun}	0,4026	0,4028	+0,00020
σ_{dpto}	0,3118	0,3010	-0,0108

El coeficiente de la covariable se recupera con un sesgo de 0,00036 y la desviación típica municipal con uno de 0,0002, magnitudes del orden del error de simulación asociado a cinco réplicas. La correlación entre los efectos aleatorios estimados y los verdaderos asciende a 0,975 en ambos niveles.

Una limitación que conviene declarar. El sesgo de la desviación típica departamental, $-0,0108$, resulta aproximadamente veinte veces superior al de la componente municipal. La razón es estructural: dicha componente se estima a partir de **33 departamentos**, frente a los 1.157 municipios de la componente inferior. Una componente de varianza estimada sobre tan pocas unidades presenta escasa precisión por construcción, lo que constituye una limitación del diseño y no del procedimiento de estimación.

De ello se sigue una consecuencia que atraviesa la interpretación de los resultados: las conclusiones relativas a la variación *municipal* descansan sobre una estimación sustancialmente más firme que aquellas referidas a la variación *departamental*.

Prueba de coherencia. Cuando la simulación no incorpora variación departamental alguna, el estimador la sitúa en 0,030, valor prácticamente nulo en la escala del problema (las varianzas observadas en el análisis rondan 0,17) y coherente con la imposibilidad de distinguir una varianza diminuta de cero con treinta y tres unidades. Un estimador que identificara variación sustancial donde no la hay generaría heterogeneidad territorial espuria, precisamente la cantidad que este trabajo mide.

B.5. Contraste de la aproximación de Laplace

De los tres elementos del procedimiento, la agregación es exacta y la resolución del Hessiano es álgebra; la aproximación de Laplace constituye la única fuente potencial de error y es, por tanto, lo único que requiere verificación.

La cuadratura adaptativa de Gauss–Hermite converge al valor exacto de la integral conforme aumenta el número de nodos, y la aproximación de Laplace equivale a emplear un único nodo. Comparar ambas permite cuantificar el error.

Cuadro B.4: Estimaciones según el número de nodos de cuadratura. Elaboración propia a partir de datos simulados.

Nodos	Celdas con muchos nacimientos		Celdas de un nacimiento	
	β_1	σ	β_1	σ
1 (Laplace)	0,25293	0,34799	0,26900	0,33517
3	0,25293	0,34799	0,26901	0,33539
7	0,25293	0,34800	0,26901	0,33614
15	0,25293	0,34800	0,26901	0,33614

Las estimaciones permanecen estables al aumentar el número de nodos. La diferencia

entre la aproximación de Laplace y la cuadratura de quince nodos alcanza $1,2 \times 10^{-8}$ en el coeficiente para celdas con numerosos nacimientos (el escenario que corresponde al análisis, con una mediana de 3.871 nacimientos por municipio) y $9,7 \times 10^{-4}$ en la desviación típica bajo el escenario más desfavorable, celdas con un único nacimiento.

Sobre el carácter adaptativo de la cuadratura. Los nodos deben centrarse y escalarse según el modo y la curvatura del integrando de cada conglomerado. Una versión preliminar de esta verificación, construida con cuadratura *no* adaptativa, subestimaba σ en torno a un treinta por ciento y no convergía al incrementar el número de nodos, puesto que los nodos fijos no muestreaban la región donde la distribución concentra su masa. La estabilidad de las estimaciones desde un único nodo constituye, en este sentido, la evidencia de que la adaptación opera correctamente.

B.6. Síntesis

El procedimiento de estimación empleado en la Sección 4.4.4 queda respaldado por cuatro comprobaciones, todas ellas reproducibles mediante el cuaderno `A1_validacion_estimador.ipynb`:

1. Las implementaciones disponibles en Python dejan de converger a partir de quinientos conglomerados, mientras que este análisis requiere 1.157.
2. La agregación binomial reproduce las estimaciones obtenidas sobre datos individuales con diferencias del orden de 10^{-7} .
3. El estimador recupera los parámetros conocidos con sesgos de 0,00036 en el coeficiente y 0,0002 en la desviación típica municipal, y con correlaciones de 0,975 entre los efectos aleatorios estimados y los verdaderos.
4. La aproximación de Laplace coincide con la cuadratura adaptativa de quince nodos hasta el octavo decimal en el escenario correspondiente al análisis.

La única limitación identificada afecta a la componente de varianza departamental, estimada sobre treinta y tres unidades, y se declara explícitamente en la interpretación de los resultados del Capítulo 5.

Apéndice C

Resultados completos generados por el código

Los cuadros del Capítulo 5 se componen para la lectura: traducen los nombres de las variables, agrupan las filas por bloque y omiten las columnas auxiliares. Esa edición mejora la comprensión, pero introduce un riesgo: una cifra transcrita puede quedar desactualizada si el análisis se vuelve a ejecutar.

Este apéndice elimina ese riesgo. Los cuadros que siguen **no están escritos a mano**: se insertan directamente desde los archivos que producen los notebooks del repositorio, de manera que reproducen exactamente la salida del código. Cualquier lector puede contrastar una cifra del cuerpo del documento con la que aparece aquí.

Se reproducen con todos sus decimales y con los nombres de variable tal como los emplea el código, que es precisamente lo que los hace verificables.

C.1. Modelos multinivel

Cuadro C.1: Componentes de varianza del modelo vacío. Salida íntegra de 04_multinivel.ipynb.

cantidad	valor	significado
sigma municipio	0.1772	desviacion tipica de los interceptos municipales
varianza municipio	0.0314	sigma al cuadrado, nivel municipal
sigma departamento	0.1693	desviacion tipica de los interceptos departamentales
varianza departamento	0.0287	sigma al cuadrado, nivel departamental
varianza individual	3.2899	$\pi^2/3$, fijada por la formulacion de variable latente
CCI municipal (%)	1.7928	correlacion entre dos nacimientos del mismo municipio
CCI departamental (%)	0.8555	dos nacimientos de municipios distintos del mismo departamento
MOR municipal	1.1841	cambio mediano del momio al mudarse a otro municipio
MOR departamental	1.1752	cambio mediano del momio al mudarse a otro departamento
prevalencia del municipio mediano (%)	7.2554	el intercepto de un logistico mixto es la mediana, no la media
prevalencia observada (%)	8.7805	prevalencia global de la muestra sobre la que se ajusto M0
municipios	1157.0000	conglomerados de nivel 2
departamentos	33.0000	conglomerados de nivel 3
nacimientos	17376860.0000	tamano de la muestra de M0
log-verosimilitud	-6354.0927	en el optimo
AIC	12714.1853	criterio de informacion de Akaike
BIC	12758.1973	criterio bayesiano de Schwarz

Cuadro C.2: Efectos fijos del Modelo 1. Salida íntegra de 04_multinivel.ipynb.

termino	coeficiente	razon_momios
intercepto	-2.5658	0.0769
EDUC4_MADRE: Primaria vs Ninguno o preescolar	-0.1572	0.8545
EDUC4_MADRE: Secundaria vs Ninguno o preescolar	-0.1566	0.8550
EDUC4_MADRE: Superior vs Ninguno o preescolar	-0.1377	0.8714
ESTCIV5: Union libre vs Casada	0.0935	1.0980
ESTCIV5: Soltera vs Casada	0.2526	1.2873
ESTCIV5: Separada o divorciada vs Casada	0.1368	1.1466
ESTCIV5: Viuda vs Casada	0.0756	1.0786
SEG4: Especial o de excepcion vs Contributivo	0.0305	1.0310
SEG4: Subsidiado vs Contributivo	0.0451	1.0461
SEG4: No asegurado vs Contributivo	-0.0336	0.9669
AREA_RES: Centro poblado vs Cabecera	-0.0310	0.9695
AREA_RES: Rural disperso vs Cabecera	0.0934	1.0979

Cuadro C.3: Efectos fijos del Modelo 2, ajustado por edad materna, paridad y multiplicidad. Salida íntegra de 04_multinivel.ipynb.

termino	coeficiente	razon_momios
intercepto	-2.6104	0.0735
EDUC4_MADRE: Primaria vs Ninguno o preescolar	-0.1576	0.8542
EDUC4_MADRE: Secundaria vs Ninguno o preescolar	-0.1811	0.8343
EDUC4_MADRE: Superior vs Ninguno o preescolar	-0.2126	0.8084
ESTCIV5: Union libre vs Casada	0.1233	1.1312
ESTCIV5: Soltera vs Casada	0.2285	1.2568
ESTCIV5: Separada o divorciada vs Casada	0.1692	1.1844
ESTCIV5: Viuda vs Casada	0.0902	1.0944
SEG4: Especial o de excepcion vs Contributivo	0.0353	1.0359
SEG4: Subsidiado vs Contributivo	0.0705	1.0730
SEG4: No asegurado vs Contributivo	-0.0110	0.9890
AREA_RES: Centro poblado vs Cabecera	-0.0317	0.9688
AREA_RES: Rural disperso vs Cabecera	0.0927	1.0971
EDAD3: 35 o mas vs 20 a 34	0.3256	1.3849
EDAD3: menor de 20 vs 20 a 34	0.0905	1.0947
PARIDAD4: 2 hijos vs 1 hijo	-0.2420	0.7851
PARIDAD4: 3 hijos vs 1 hijo	-0.2863	0.7511
PARIDAD4: 4 o mas vs 1 hijo	-0.3701	0.6906
MULTIPLE3: doble vs simple	2.9937	19.9599
MULTIPLE3: triple o mas vs simple	3.1383	23.0657

Cuadro C.4: Cambio de cada razón de momios entre el Modelo 1 y el Modelo 2. Salida íntegra de 04_multinivel.ipynb.

termino	rm_sin_ajuste	rm_ajustado	cambio_pct
EDUC4_MADRE: Primaria vs Ninguno o preescolar	0.8565	0.8542	-0.2800
EDUC4_MADRE: Secundaria vs Ninguno o preescolar	0.8577	0.8343	-2.7300
EDUC4_MADRE: Superior vs Ninguno o preescolar	0.8742	0.8084	-7.5200
ESTCIV5: Union libre vs Casada	1.0978	1.1312	3.0400
ESTCIV5: Soltera vs Casada	1.2880	1.2568	-2.4200
ESTCIV5: Separada o divorciada vs Casada	1.1445	1.1844	3.4900
ESTCIV5: Viuda vs Casada	1.0750	1.0944	1.8100
SEG4: Especial o de excepcion vs Contributivo	1.0310	1.0359	0.4700
SEG4: Subsidiado vs Contributivo	1.0463	1.0730	2.5500
SEG4: No asegurado vs Contributivo	0.9666	0.9890	2.3200
AREA_RES: Centro poblado vs Cabecera	0.9694	0.9688	-0.0700
AREA_RES: Rural disperso vs Cabecera	1.0983	1.0971	-0.1100

C.2. Descomposición de la desigualdad

Cuadro C.5: Contribución de cada determinante al índice de concentración. Salida íntegra de 05_descomposicion.ipynb.

variable	categoria	prevalencia_exposicion	beta	elasticidad	ci_determinante	contribucion	pct_del_total
PARIDAD4	TOTAL de la variable					0.015289	84.089974
SEG4	TOTAL de la variable					0.006955	38.253252
ESTCIV5	TOTAL de la variable					-0.004473	-24.600604
AREA_RES	TOTAL de la variable					0.004096	22.526674
EDUC4_MADRE	TOTAL de la variable					-0.003425	-18.837276
EDAD3	TOTAL de la variable					-0.001143	-6.285388
MULTIPLE3	TOTAL de la variable					0.000882	4.853367

Cuadro C.6: Los dos componentes de cada contribución, por categoría. Salida íntegra de 05_descomposicion.ipynb.

variable	categoria	expuestos	beta	elasticidad	ci_del_determinante	contribucion	pct_del_total
EDUC4_MADRE	3	0.192951	-0.012607	-0.027748	0.807049	-0.022394	-123.168310
EDUC4_MADRE	1	0.202961	-0.011780	-0.027272	-0.764973	0.020862	114.741682
PARIDAD4	4 o mas	0.104965	-0.028503	-0.034128	-0.408721	0.013949	76.717322
SEG4	3	0.448211	-0.005184	-0.026504	-0.167737	0.004446	24.450909
PARIDAD4	3 hijos	0.142702	-0.021141	-0.034414	-0.127331	0.004382	24.100614
ESTCIV5	2	0.654728	0.008624	0.064405	-0.050759	-0.003269	-17.980253
PARIDAD4	2 hijos	0.310092	-0.017790	-0.062928	0.048333	-0.003041	-16.727962
SEG4	4	0.144474	-0.007172	-0.011819	-0.240183	0.002839	15.613083
AREA_RES	2	0.075249	-0.011899	-0.010214	-0.244756	0.002500	13.748923
EDUC4_MADRE	2	0.588056	-0.010835	-0.072682	0.026043	-0.001893	-10.410648
EDAD3	menor de 20	0.211687	0.005237	0.012646	-0.146737	-0.001856	-10.205996
AREA_RES	3	0.133283	-0.003205	-0.004873	-0.327490	0.001596	8.777751
ESTCIV5	3	0.146768	0.021504	0.036002	-0.030512	-0.001098	-6.041664
MULTIPLE3	doble	0.017224	0.525712	0.103290	0.007323	0.000756	4.160007
EDAD3	35 o mas	0.105850	0.026672	0.032205	0.022135	0.000713	3.920608
SEG4	2	0.014410	-0.005109	-0.000840	0.392014	-0.000329	-1.810739
MULTIPLE3	triple o mas	0.000421	0.559576	0.002690	0.046859	0.000126	0.693359
ESTCIV5	4	0.004660	0.012561	0.000668	-0.120285	-0.000080	-0.441727
ESTCIV5	5	0.001993	0.005569	0.000127	-0.196669	-0.000025	-0.136960

Cuadro C.7: Índice de concentración en cada uno de los tres tramos. Salida íntegra de 05_descomposicion.ipynb.

tramo	n	prevalencia_pct	ci	erreygers
1998-2009 (ascenso)	7108037	8.079812	0.016824	0.005437
2010-2018 (descenso)	5618393	8.926894	0.010518	0.003756
2019-2024 (negativo)	3219786	10.002932	-0.003848	-0.001540

[NO OLVIDAR al cerrar el trabajo: añadir aquí los cuadros de la Fase 7 cuando termine de correr, y los de M3 y M4. El procedimiento es copiar el .tex de salidas/tablas/ a tablas/ y añadir el bloque con input. Si algún cuadro del Capítulo 5 dejara de coincidir con el de aquí, manda el de aquí: es el que sale del código.]

Cuadro C.8: Contribución de cada determinante en cada tramo. Salida íntegra de 05_descomposicion.ipynb.

variable	1998-2009 (ascenso)	2010-2018 (descenso)	2019-2024 (negativo)
EDUC4_MADRE	-0.007206	-0.015042	-0.029918
PARIDAD4	0.016605	0.012925	0.010962
SEG4	0.006091	0.009505	0.009877
AREA_RES	0.007636	0.004019	0.003063
MULTIPLE3	-0.000865	0.003556	0.005640
ESTCIV5	-0.002936	-0.003072	-0.004185
EDAD3	-0.002501	-0.001375	0.000713

C.3. Desigualdad territorial

Cuadro C.9: Ordenamiento de los treinta y tres departamentos según la prevalencia de bajo peso al nacer en 1998 y en 2024, con el cambio de posición entre ambos años. Salida íntegra de 03_desigualdad.ipynb.

codigo	territorio	posicion_1998	posicion_2024	cambio_posicion	valor_1998	valor_2024	cambio_valor
11	Santafe De Bogota D.C	1	1	0	11.25	16.45	5.20
25	Cundinamarca	9	2	7	7.32	14.51	7.19
52	Nariño	14	3	11	6.85	13.14	6.29
17	Caldas	23	4	19	6.15	11.97	5.82
44	La Guajira	8	5	3	7.47	11.87	4.40
15	Boyaca	7	6	1	7.53	11.68	4.15
05	Antioquia	6	7	-1	7.96	11.27	3.31
27	Choco	2	8	-6	10.19	11.21	1.03
66	Risaralda	21	9	12	6.19	10.90	4.71
76	Valle Del Cauca	13	10	3	6.93	10.72	3.79
08	Atlantico	15	11	4	6.79	10.52	3.73
70	Sucre	10	12	-2	7.27	10.35	3.08
23	Cordoba	11	13	-2	7.14	10.18	3.04
19	Cauca	17	14	3	6.50	9.93	3.44
47	Magdalena	19	15	4	6.26	9.79	3.53
13	Bolivar	12	16	-4	7.00	9.79	2.78
88	Archipiélago De San Andres Providencia Y Santa Catalina	16	17	-1	6.62	9.52	2.90
91	Amazonas	30	18	12	4.77	9.42	4.65
68	Santander	20	19	1	6.22	9.41	3.20
63	Quindio	18	20	-2	6.40	9.40	3.00
20	Cesar	29	21	8	5.18	9.18	4.01
99	Vichada	5	22	-17	8.01	8.95	0.94
73	Tolima	24	23	1	5.90	8.53	2.63
86	Putumayo	27	24	3	5.39	8.40	3.01
94	Guainia	3	25	-22	9.70	7.96	-1.74
41	Huila	31	26	5	4.75	7.92	3.17
95	Guaviare	4	27	-23	8.66	7.82	-0.84
50	Meta	33	28	5	4.18	7.56	3.39
54	Norte De Santander	25	29	-4	5.78	7.56	1.77
81	Arauca	26	30	-4	5.56	7.40	1.85
85	Casanare	28	31	-3	5.20	7.07	1.87
97	Vaupes	22	32	-10	6.16	6.70	0.54
18	Caqueta	32	33	-1	4.69	5.60	0.91

Apéndice D

Diccionario consolidado de variables, 1998–2024

Este apéndice consolida los nombres que recibe cada concepto del certificado de nacido vivo en los distintos diccionarios de datos publicados por el DANE entre 1998 y 2024. No modifica los diccionarios originales: los reorganiza en una sola vista para que cada fila permita seguir un mismo concepto a lo largo de toda la serie. La celda con guion indica que el concepto no está presente en ese período. Es la tabla de equivalencias que sostiene la rutina de armonización descrita en la Sección 4.3.1.

Cuadro D.1: Equivalencia de nombres de variable por período, archivos de nacimientos de las Estadísticas Vitales del DANE.

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Departamento de ocurrencia del nacimiento	de cod_dpto	COD_DPTO	COD_DPTO	COD_DPTO	COD_DPTO	COD_DPTO	Sin cambios de fondo
Municipio de ocurrencia del nacimiento	cod_munic	COD_MUNIC	COD_MUNIC	COD_MUNIC	COD_MUNIC	COD_MUNIC	Sin cambios de fondo
Área del nacimiento (urbana/rural)	areanac	AREANAC	AREANAC	AREANAC	AREANAC	AREANAC	Sin cambios
Sitio del parto	sit_parto	SIT_PARTO	SIT_PARTO	SIT_PARTO	SIT_PARTO	SIT_PARTO	Sin cambios
Otro sitio del parto, – ¿cuál?		OTRO_SIT	OTRO_SIT	OTRO_SIT	OTRO_SIT	OTRO_SIT	NUEVA desde 2008; no existía en 1998–2007
Nombre de la institución de salud	nom_inst	–	NOM_INST	–	–	–	Solo en 1998–2007 y 2012–2013
Código de la institución de salud	cod_inst	–	COD_INST	–	–	–	Solo en 1998–2007 y 2012–2013
Sexo del nacido vivo	sexo	SEXO	SEXO	SEXO	SEXO	SEXO	Sin cambios
Peso al nacer	peso_nac	PESO_NAC	PESO_NAC	PESO_NAC	PESO_NAC	PESO_NAC	Sin cambios
Talla al nacer	talla_nac	TALLA_NAC	TALLA_NAC	TALLA_NAC	TALLA_NAC	TALLA_NAC	Sin cambios
Año de ocurrencia	ano	ANO	ANO	ANO	ANO	ANO	Sin cambios
Mes de ocurrencia	mes	MES	MES	MES	MES	MES	Sin cambios
Quién atendió el parto	aten_par	ATEN_PAR	ATEN_PAR	ATEN_PAR	ATEN_PAR	ATEN_PAR	Sin cambios

continúa en la página siguiente

Cuadro D.1 (continuación)

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Atendido por otra – persona, ¿cuál?	–	–	OTRPARATX	–	–	–	NUEVA y EXCLUSI- VA de 2012-2013
Tiempo de gestación t_ges	T_GES	T_GES	T_GES	T_GES	T_GES	T_GES	Sin cambios
Tiempo de gestación – agrupado (CIE)	T_GES_AGRU_CIE	–	–	–	T_GES_AGRU_CIE	T_GES_AGRU_CIE	NUEVA desde 2008; ausente en 2012-2013 y en 2020
Nº de consultas pre- natales	numconsul	NUMCONSUL	NUMCONSUL	NUMCONSUL	NUMCONSUL	NUMCONSUL	Sin cambios
Tipo de parto tipo_parto	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	TIPO_PARTO	Sin cambios
Multiplicidad del embarazo	mul_parto	MUL_PARTO	MUL_PARTO	MUL_PARTO	MUL_PARTO	MUL_PARTO	Sin cambios
APGAR al minuto apgar1	APGAR1	APGAR1	APGAR1	APGAR1	APGAR1	APGAR1	Sin cambios
APGAR a los 5 mi- nutos apgar2	APGAR2	APGAR2	APGAR2	APGAR2	APGAR2	APGAR2	Sin cambios
Grupo sanguíneo del nacido vivo gru_san	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	IDHEMOCLAS	1998-2007 unía gru- po+factor en 1 varia- ble; desde 2008 se se- paró en 2
Factor RH del naci- do vivo (incluido en gru_san)	IDFACTORRH	IDFACTORRH	IDFACTORRH	IDFACTORRH	IDFACTORRH	IDFACTORRH	NUEVA como varia- ble independiente des- de 2008 (antes iba dentro de gru_san)
Reconocimiento ét- nico del nacido vivo	IDPERTET	IDPUEBLOIN	IDPERTET	IDPERTET	IDPERTET	IDPERTET	NUEVA desde 2008; renombrada en 2012- 2013 (IDPUEBLOIN)
País de nacimiento – de la madre	–	–	–	–	–	CODPAISNACMAD	NUEVA y EXCLUSI- VA de 2024
Edad de la madre edad_madre	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	EDAD_MADRE	Sin cambios
Estado civil/conyu- gal de la madre est_civm	EST_CIVM	EST_CIVM	EST_CIVM	EST_CIVM	EST_CIVM	EST_CIVM	Categorías ampliadas desde 2008 (ver hoja Categorías)
Nivel educativo de la madre niv_edum	NIV_EDUM	NIV_EDUM	NIV_EDUM	NIV_EDUM	NIV_EDUM	NIV_EDUM	Categorías ampliadas de 9 a 14 desde 2008 (ver hoja Categorías)
Último año/grado – aprobado por la madre	ULTCURMAD	ULTCURMAD	ULTCURMAD	ULTCURMAD	ULTCURMAD	ULTCURMAD	NUEVA desde 2008; no existía en 1998- 2007
País de residencia de la madre (extranje- ro) codpres	CODPRES	CODPRES	CODPRES	CODPRES	CODPRES	CODPRES	Sin cambios
Departamento de re- sidencia de la madre codptore	CODPTORE	CODPTORE	CODPTORE	CODPTORE	CODPTORE	CODPTORE	Sin cambios
Municipio de resi- dencia de la madre codmunre	CODMUNRE	CODMUNRE	CODMUNRE	CODMUNRE	CODMUNRE	CODMUNRE	Sin cambios
Área de residencia area_res	AREA_RES	AREA_RES	AREA_RES	AREA_RES	AREA_RES	AREA_RES	Sin cambios
Nº de hijos nacidos vivos n_hijosv	N_HIJOSV	N_HIJOSV	N_HIJOSV	N_HIJOSV	N_HIJOSV	N_HIJOSV	Sin cambios
Fecha de nacimiento del hijo anterior fecha_nacm	FECHA_NACM	FECHA_NACM	FECHA_NACM	FECHA_NACM	FECHA_NACM	FECHA_NACM	Sin cambios
Nº de embarazos n_emb	N_EMB	N_EMB	N_EMB	N_EMB	N_EMB	N_EMB	Sin cambios
Régimen de seguri- dad social de la ma- dre seg_social	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	SEG_SOCIAL	Categorías cambiaron con la Ley 100/refor- mas de salud (ver hoja Categorías)
Entidad administra- dora en salud de la madre	IDCLASADMI	IDCLASADMI	IDCLASADMI	IDCLASADMI	IDCLASADMI	IDCLASADMI	NUEVA desde 2008; no existía en 1998- 2007
Nombre de la enti- dad administradora	–	NOMCLASAD	–	–	–	–	NUEVA y EXCLUSI- VA de 2012-2013
Edad del padre edad_padre	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	EDAD_PADRE	Sin cambios
Nivel educativo del padre niv_edup	NIV_EDUP	NIV_EDUP	NIV_EDUP	NIV_EDUP	NIV_EDUP	NIV_EDUP	Mismo patrón de ampliación que NIV_EDUM

continúa en la página siguiente

Cuadro D.1 (continuación)

Concepto	1998–2007	2008–2011 2014–2019	2012–2013	2020	2021–2023	2024	Notas
Último año/grado – aprobado por el padre		ULTCURPAD	ULTCURPAD	ULTCURPAD	ULTCURPAD	ULTCURPAD	NUEVA desde 2008; no existía en 1998- 2007
Profesión de quien profesion certifica el nacimien- to		PROFESION	PROFESION	PROFESION	PROFESION	PROFESION	Sin cambios
Fuente del certifica- – do (tipo de formula- rio)		–	–	–	TIPOFORMULARIO	TIPOFORMULARIO	NUEVA desde 2021

Bibliografía

- Alam, M. J., Islam, M. M., Maniruzzaman, M., Ahmed, N. A. M. F., Tawabunnahar, M., Rahman, M. J., et al. (2022). Socioeconomic inequality in the prevalence of low birth weight and its associated determinants in Bangladesh. *PLoS ONE*, 17(10):e0276718.
- Amjad, S., MacDonald, I., Chambers, T., Osornio-Vargas, A., Chandra, S., Voaklander, D., et al. (2019). Social determinants of health and adverse maternal and birth outcomes in adolescent pregnancies: a systematic review and meta-analysis. *Paediatric and Perinatal Epidemiology*, 33(1):88–99.
- Barros, A. J. D. and Hiraakata, V. N. (2003). Alternatives for logistic regression in cross-sectional studies: an empirical comparison of models that directly estimate the prevalence ratio. *BMC Medical Research Methodology*, 3:21.
- Battiti, R. (1994). Using mutual information for selecting features in supervised neural net learning. *IEEE Transactions on Neural Networks*, 5(4):537–550.
- Bergsma, W. (2013). A bias-correction for Cramér’s V and Tschuprow’s T . *Journal of the Korean Statistical Society*, 42(3):323–328.
- Blencowe, H., Krasevec, J., de Onis, M., Black, R. E., An, X., Stevens, G. A., et al. (2019). National, regional, and worldwide estimates of low birthweight in 2015, with trends from 2000: a systematic analysis. *The Lancet Global Health*, 7(7):e849–e860.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32.
- Breiman, L., Friedman, J. H., Olshen, R. A., and Stone, C. J. (1984). *Classification and Regression Trees*. Wadsworth & Brooks/Cole, Monterey, CA.
- Breslow, N. E. and Clayton, D. G. (1993). Approximate inference in generalized linear mixed models. *Journal of the American Statistical Association*, 88(421):9–25.
- Castro-Delgado, Ó. E., Salas-Delgado, Í., Acosta-Argoty, F. A., Delgado-Noguera, M., and Calvache, J. A. (2016). Muy bajo y extremo bajo peso al nacer. *Pediatría*, 49(1):23–30.

- Chawla, N. V., Bowyer, K. W., Hall, L. O., and Kegelmeyer, W. P. (2002). SMOTE: synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357.
- Chen, T. and Guestrin, C. (2016). XGBoost: a scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794.
- Comisión sobre Determinantes Sociales de la Salud (2008). Subsanan las desigualdades en una generación: alcanzar la equidad sanitaria actuando sobre los determinantes sociales de la salud. Technical report, Organización Mundial de la Salud, Ginebra.
- Cover, T. M. and Thomas, J. A. (2006). *Elements of Information Theory*. Wiley, Hoboken, NJ, 2 edition.
- Cozzani, M. (2023). Inequalities at birth: stable socioeconomic differences in birth outcomes in three British cohorts. *Genus*, 79:18.
- Departamento Administrativo Nacional de Estadística (2023). Índice de Pobreza Multidimensional municipal. Technical report, DANE, Bogotá.
- Departamento Administrativo Nacional de Estadística (2025). Estadísticas Vitales — EEVV: microdatos de nacimientos, 1998–2024. Base de datos en internet. Bogotá: DANE.
- Efron, B. (1979). Bootstrap methods: another look at the jackknife. *The Annals of Statistics*, 7(1):1–26.
- Engdaw, G. T., Tesfaye, A. H., Feleke, M., Negash, A., Yeshiwas, A., Addis, W., et al. (2023). Effect of antenatal care on low birth weight: a systematic review and meta-analysis in africa, 2022. *Frontiers in Public Health*, 11:1158809.
- Erreygers, G. (2009). Correcting the concentration index. *Journal of Health Economics*, 28(2):504–515.
- Godah, M. W., Beydoun, Z., Abdul-Khalek, R. A., Safieddine, B., Khamis, A. M., and Abdulrahim, S. (2021). Maternal education and low birth weight in low- and middle-income countries: systematic review and meta-analysis. *Maternal and Child Health Journal*, 25(8):1305–1315.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge, MA.

- Guarnizo-Herreño, C. C., Torres, G., and Buitrago, G. (2021). Socioeconomic inequalities in birth outcomes: an 11-year analysis in Colombia. *PLoS ONE*, 16(7):e0255150.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, New York, 2 edition.
- Heinze, G., Wallisch, C., and Dunkler, D. (2018). Variable selection: a review and recommendations for the practicing statistician. *Biometrical Journal*, 60(3):431–449.
- Heredia-Olivera, K. and Munares-García, O. (2016). Factores maternos asociados al bajo peso al nacer. *Revista Médica del Instituto Mexicano del Seguro Social*, 54(5):562–567.
- Hernán, M. A. and Robins, J. M. (2020). *Causal Inference: What If*. Chapman & Hall/CRC, Boca Raton, FL.
- Hoerl, A. E. and Kennard, R. W. (1970). Ridge regression: biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.
- Horowitz, J. L. and Manski, C. F. (2000). Nonparametric analysis of randomized experiments with missing covariate and outcome data. *Journal of the American Statistical Association*, 95(449):77–84.
- Hosmer, D. W., Lemeshow, S., and Sturdivant, R. X. (2013). *Applied Logistic Regression*. John Wiley & Sons, Hoboken, NJ, 3 edition.
- Hripcsak, G., Duke, J. D., Shah, N. H., Reich, C. G., Huser, V., Schuemie, M. J., Suchard, M. A., Park, R. W., Wong, I. C. K., Rijnbeek, P. R., van der Lei, J., Pratt, N., Norén, G. N., Li, Y.-C., Stang, P. E., Madigan, D., and Ryan, P. B. (2015). Observational health data sciences and informatics (OHDSI): opportunities for observational researchers. *Studies in Health Technology and Informatics*, 216:574–578.
- Huang, X., Liu, J., Qi, L., Adachi, J. D., Wu, J., Li, Z., Meng, Q., Li, G., and Lip, G. Y. H. (2022). Birth weight and the risk of cardiovascular outcomes: a report from the large population-based UK Biobank cohort study. *Frontiers in Cardiovascular Medicine*, 9:827491.
- Jiménez García, R., Alfonso Novo, L., Peñalver, R., and Santana Porbén, S. (2017). El bajo peso al nacer y la programación temprana de la vida, un problema de actualidad y del futuro. *Revista Cubana de Pediatría*, 89(2):241–251.

- Kakwani, N., Wagstaff, A., and van Doorslaer, E. (1997). Socioeconomic inequalities in health: measurement, computation, and statistical inference. *Journal of Econometrics*, 77(1):87–103.
- Kassie, G. A., Gebrekidan, A. Y., Adella, G. A., Woldegeorgis, B. Z., Haile, K. E., Workneh, A., and Asgedom, Y. S. (2025). Socioeconomic inequality and determinants of low birth weight in Kenya: a multilevel analysis using 2022 demographic and health survey. *Italian Journal of Pediatrics*, 51(1):222.
- Knop, M. R., Geng, T.-T., Gorny, A. W., Ding, R., Li, C., Ley, S. H., and Huang, T. (2018). Birth weight and risk of type 2 diabetes mellitus, cardiovascular disease, and hypertension in adults: a meta-analysis of 7 646 267 participants from 135 studies. *Journal of the American Heart Association*, 7(23):e008870.
- Kraskov, A., Stögbauer, H., and Grassberger, P. (2004). Estimating mutual information. *Physical Review E*, 69(6):066138.
- Manski, C. F. (1990). Nonparametric bounds on treatment effects. *American Economic Review, Papers and Proceedings*, 80(2):319–323.
- Merlo, J., Chaix, B., Ohlsson, H., Beckman, A., Johnell, K., Hjerpe, P., et al. (2006). A brief conceptual tutorial of multilevel analysis in social epidemiology: using measures of clustering in multilevel logistic regression to investigate contextual phenomena. *Journal of Epidemiology and Community Health*, 60(4):290–297.
- Núñez Rivas, H. P. and Morice Trejos, A. C. (1999). Bajo peso al nacer: un indicador de riesgo biológico y social. Technical Report Serie de documentos técnicos del Inciensa 3, Instituto Costarricense de Investigación y Enseñanza en Nutrición y Salud, Tres Ríos, Costa Rica.
- Okwaraji, Y. B., Krasevec, J., Bradley, E., Conkle, J., Stevens, G. A., Gatica-Domínguez, G., et al. (2024). National, regional, and global estimates of low birthweight in 2020, with trends from 2000: a systematic analysis. *The Lancet*, 403(10431):1071–1080.
- Organización Mundial de la Salud (2014). Metas mundiales de nutrición 2025: documento normativo sobre bajo peso al nacer. Technical Report WHO/NMH/NHD/14.5, Organización Mundial de la Salud, Ginebra.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., et al. (2011). Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.

- Peng, H., Long, F., and Ding, C. (2005). Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 27(8):1226–1238.
- Pérez Martínez, M., Basain Valdés, J. M., and Calderón Chappotin, G. C. (2018). Factores de riesgo del bajo peso al nacer. *Acta Médica del Centro*, 12(3):369–382.
- Rodríguez López, S., Tumas, N., Ortigoza, A., de Lima Friche, A. A., and Diez-Roux, A. V. (2021). Urban social environment and low birth weight in 360 Latin American cities. *BMC Public Health*, 21(1):795.
- Ross, B. C. (2014). Mutual information between discrete and continuous data sets. *PLoS ONE*, 9(2):e87357.
- Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3):581–592.
- Ruggles, S., King, M. L., Levison, D., McCaa, R., and Sobek, M. (2003). IPUMS-International. *Historical Methods: A Journal of Quantitative and Interdisciplinary History*, 36(2):60–65.
- Santos-Antonio, G., Alvis-Chirinos, K., Aguilar-Esenarro, L., Bautista-Olórtegui, W., Velarde-Delgado, P., and Aramburu, A. (2020). Ganancia de peso gestacional como predictor de macrosomía y bajo peso al nacer: revisión sistemática. *Revista Peruana de Medicina Experimental y Salud Pública*, 37(3):403–411.
- Sathi, N. J., Ahammed, B., Alam, K., Hashmi, R., Lee, K.-Y., and Keramat, S. A. (2022). Socioeconomic inequalities in low birth weight in South Asia: a comparative analysis using Demographic and Health Surveys. *SSM — Population Health*, 20:101248.
- Shah, P. S. (2010). Parity and low birth weight and preterm birth: A systematic review and meta-analyses. *Acta Obstetricia et Gynecologica Scandinavica*, 89(7):862–875. Knowledge Synthesis Group on Determinants of LBW/PT births.
- Shannon, C. E. (1948). A mathematical theory of communication. *Bell System Technical Journal*, 27(3):379–423.
- Solar, O. and Irwin, A. (2010). A conceptual framework for action on the social determinants of health. Technical Report Social Determinants of Health Discussion Paper 2, Organización Mundial de la Salud, Ginebra.

- Steuer, R., Kurths, J., Daub, C. O., Weise, J., and Selbig, J. (2002). The mutual information: detecting and evaluating dependencies between variables. *Bioinformatics*, 18(suppl 2):S231–S240.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, 58(1):267–288.
- Ticona Rendón, M., Huanco Apaza, D., and Ticona Vildoso, M. (2012). Incidencia y factores de riesgo de bajo peso al nacer en población atendida en hospitales del Ministerio de Salud del Perú. *Ginecología y Obstetricia de México*, 80(2):51–60.
- Urdaneta Machado, J. R., Lozada Reyes, M., Cepeda de Villalobos, M., García, J., Villalobos, N., Contreras Benítez, A., et al. (2015). Anemia materna y peso al nacer en productos de embarazo a término. *Revista Chilena de Obstetricia y Ginecología*, 80(4):297–305.
- van Buuren, S. and Groothuis-Oudshoorn, K. (2011). mice: multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3):1–67.
- VanderWeele, T. J. (2015). *Explanation in Causal Inference: Methods for Mediation and Interaction*. Oxford University Press, New York.
- Velásquez, N., Masud, J., and Ávila, R. (2004). Recién nacidos con bajo peso; causas, problemas y perspectivas a futuro. *Boletín Médico del Hospital Infantil de México*, 61(1):73–86.
- Vergara, J. R. and Estévez, P. A. (2013). A review of feature selection methods based on mutual information. *Neural Computing and Applications*, 24(1):175–186.
- Wagstaff, A. (2005). The bounds of the concentration index when the variable of interest is binary, with an application to immunization inequality. *Health Economics*, 14(4):429–432.
- Wagstaff, A., van Doorslaer, E., and Watanabe, N. (2003). On decomposing the causes of health sector inequalities with an application to malnutrition inequalities in Vietnam. *Journal of Econometrics*, 112(1):207–223.
- Zhang, X., Shah, A. A., and Han, L. (2025). Exploring socio-economic inequalities in low birth weight: a statistical decomposition approach. *American Journal of Human Biology*, 37(12):e70173.

Zhou, Y., Mendonça, M., Tsalacopoulos, N., Bartmann, P., Darlow, B. A., Harris, S. L., et al. (2025). Socioeconomic outcomes in very preterm/very low birth weight adults: individual participant data meta-analysis. *Pediatric Research*, 98:2401–2413.

Mis pendientes

Esta lista se genera sola a partir de mis notas en rojo. **Ninguna puede sobrevivir a la entrega:** cuando esta página quede vacía, el manuscrito está listo.

- p. 68** NO OLVIDAR. Numerar el cuadro de resultados de esta fase cuando ejecute el análisis. Y reescribir con mis palabras los párrafos de justificación de esta subsección, sobre todo el bloque de ámbito de aplicación: es el que voy a tener que defender de viva voz.
- p. 81** ESTADO DEL CAPÍTULO, al 18 de septiembre. Están escritas las secciones 5.1 a 5.5, la 5.7 y la 5.8. Falta una sola cosa que dependa de mí: la 5.6 entera, que espera a que corra la Fase 7, y son nueve apartados. Falta además la última fila de los cuadros de ajuste, la que compara el Modelo 3b con el Modelo 4 y mide qué aporta la atención prenatal: espera a que corra el bloque de M3b del notebook 04 y a volver a pasar `corregir_aic.py`. Todo lo demás de este capítulo está redactado.
- p. 98** DECISIÓN PARA HABLAR CON LIHKI, y de las importantes. ¿Presento esto como EL hallazgo del trabajo o como uno entre varios? A favor de lo primero: ningún trabajo previo sobre bajo peso al nacer en Colombia lo ha documentado, y desde la Fase 5 ya tengo el mecanismo (la contribución de la educación se cuadruplica mientras el contrapeso de la paridad se debilita) en lugar de solo la observación. A favor de lo segundo: sigue dependiendo de la variable con que ordeno la población. Lo que ya NO vale como argumento en contra es la dilución de la escala educativa: la contrasté en la Sección 5.7.1 y los datos la descartan. Debo cerrar esta decisión antes de redactar el resumen y las conclusiones, porque cambia el tono de las dos.
- p. 107** ME FALTA LA ÚLTIMA FILA de las dos tablas: la comparación del Modelo 3b con el Modelo 4, que es la que mide qué aporta la atención prenatal. El bloque de M3b ya está escrito en el notebook 04; falta correrlo y volver a guardar el pickle. Después, correr `corregir_aic.py` otra vez y la tabla sale completa.
- p. 113** ME FALTA. Las métricas promedio de los cinco pliegues para los siete modelos.
- p. 114** ME FALTA. F_1 , precisión, sensibilidad, especificidad y AUC de los siete modelos, con intervalos bootstrap.

- p. 114**ME FALTA. Un cuadro con una fila por modelo y columnas separadas para entrenamiento y prueba (F_1 , sensibilidad, especificidad y AUC), con el formato del Cuadro 5.13. Interpretarlo modelo por modelo: brecha amplia es sobreajuste, brecha estrecha es buena generalización. VIGILAR el perceptrón multicapa y el bosque aleatorio, que son los que más fácilmente separan casi perfecto el entrenamiento y luego fallan.
- p. 114**ME FALTA. El esquema complementario: entrenar con 1998–2018 y probar con 2019–2024. Contrastarlo con la partición aleatoria y discutir si el modelo generaliza hacia el futuro. Ojo aquí, porque la prevalencia sube a lo largo del período: es probable que el desempeño caiga, y si cae tengo que explicar por qué en lugar de esconderlo.
- p. 114**ME FALTA. Las curvas del modelo seleccionado y el umbral óptimo.
- p. 115**ME FALTA. Coeficientes estandarizados, impureza de Gini e importancia por permutación.
- p. 115**ME FALTA. Las siete matrices de confusión sobre el conjunto de prueba.
- p. 115**ME FALTA. El cuadro que compara el *gradient boosting* con las covariables declaradas como categóricas frente al mismo modelo sin declararlas, descrito en la Sección 4.4.7. Cuatro columnas: AUC-PR, AUC-ROC, Brier y brecha entre entrenamiento y prueba. Sale de `clasificacion_especificacion_categorica`. NO es un octavo modelo y hay que decirlo en el texto: son dos especificaciones del séptimo.
- p. 115**ME FALTA. El solapamiento de intervalos y la justificación del modelo que elija.
- p. 115**ME FALTA, y es la sección que reconcilia las dos mitades de mi trabajo. Comparar la CCI y la MOR del *gradient boosting* con el departamento codificado frente a las del logístico multinivel. Reportar también la diferencia entre las estimaciones departamentales de los dos enfoques, mirando sobre todo los departamentos pequeños: ahí es donde la contracción jerárquica debe notarse más.
- p. 125**ME FALTA ESTE APARTADO, y espera a que corra la Fase 7. Lo que tengo que reportar: el AUC-PR del mejor modelo frente a la línea base de 0,0878 que es la prevalencia; si los ensambles superan o no a la regresión logística; qué aporta el bloque social por encima del clínico; y la caída del desempeño en la partición temporal y en la partición por municipio. NO OLVIDAR declarar que de esta fase no se sigue nada causal.
- p. 136**ANTES DE ENTREGAR, imprescindible: publicar el atlas y comprobar que la dirección abre. Un QR impreso que no lleva a ninguna parte es peor que no poner QR. Pasos: (1) subo `atlas_bpn.html` a la raíz del repositorio con el nombre `index.html`; (2) en el repositorio, *Settings* → *Pages* → *Source: Deploy from a branch*, rama `main`, carpeta / (`root`); (3) espero unos minutos y abro la dirección. El QR ya apunta a esa raíz, así que no tengo que regenerarlo. Si prefiero no activar Pages, la alternativa es Zenodo, que da un DOI permanente, pero entonces cambio la dirección y el QR.

- p. 147** **NO OLVIDAR** al cerrar el trabajo: añadir aquí los cuadros de la Fase 7 cuando termine de correr, y los de M3 y M4. El procedimiento es copiar el .tex de **salidas/tablas/** a **tablas/** y añadir el bloque con **input**. Si algún cuadro del Capítulo 5 dejara de coincidir con el de aquí, manda el de aquí: es el que sale del código.